

UNIVERSIDADE TUIUTI DO PARANÁ

GABRIEL AST DOS SANTOS

**DESENVOLVIMENTO DE UM SOFTWARE COM INTELIGÊNCIA
ARTIFICIAL EXPLICÁVEL (XAI) PARA APOIO AO DIAGNÓSTICO
PREDITIVO DE CÂNCER DE MAMA UTILIZANDO SHAP E UMAP**

**CURITIBA
2026**

GABRIEL AST DOS SANTOS

**DESENVOLVIMENTO DE UM SOFTWARE COM INTELIGÊNCIA
ARTIFICIAL EXPLICÁVEL (XAI) PARA APOIO AO DIAGNÓSTICO
PREDITIVO DE CÂNCER DE MAMA UTILIZANDO SHAP E UMAP**

Trabalho de Conclusão de Curso apresentado ao curso de Bacharelado em Ciência da Computação da Faculdade de Ciências Exatas e de Tecnologia da Universidade Tuiuti do Paraná, como requisito à obtenção do grau de Bacharel.

Orientador: Prof. Rodrigo Ramos Alves

**CURITIBA
2026**

RESUMO

Este trabalho propõe o desenvolvimento de um software integrado a um modelo preditivo para a classificação de tumores mamários como benignos ou malignos, utilizando a base de dados pública Breast Cancer Wisconsin. O objetivo central é mitigar a opacidade característica dos modelos de caixa preta, fornecendo diagnósticos que unam alta precisão analítica a justificativas clínicas interpretáveis por profissionais de saúde. A metodologia contempla o treinamento e a comparação de algoritmos clássicos de aprendizado de máquina supervisionado, avaliados por métricas estatísticas. A explicabilidade das decisões é garantida pela integração da biblioteca SHAP, enquanto o algoritmo UMAP é aplicado para a análise visual da separabilidade entre tumores benignos e malignos. O sistema disponibiliza uma interface capaz de receber dados em lote via upload de planilhas e gerar relatórios estruturados com os diagnósticos e suas respectivas fundamentações visuais. Os resultados esperados indicam que a combinação de modelos preditivos de alto desempenho com técnicas de inteligência artificial explicável constitui uma solução viável e eticamente fundamentada para o apoio ao diagnóstico oncológico assistido por computador.

Palavras-chave: Aprendizado de máquina; Base de dados Wisconsin; Inteligência Artificial Explicável; SHAP; UMAP.

LISTA DE FIGURAS

FIGURA 1 – CONTRASTE MORFOLÓGICO ENTRE CÉLULAS NORMAIS E NEOPLÁSICAS.	15
FIGURA 2 – HIERARQUIA E RELAÇÃO DE INCLUSÃO ENTRE IA, ML E DL.	17
FIGURA 3 – EXEMPLO ILUSTRATIVO DE UMA MATRIZ DE CONFUSÃO	20
FIGURA 4 – COMPARAÇÃO ENTRE CURVAS ROC E PRECISÃO-REVOCAÇÃO EM DADOS DESBALANCEADOS	22
FIGURA 5 – GRÁFICO ILUSTRATIVO DAS TAREFAS DE CLASSIFICAÇÃO E REGRESSÃO	23
FIGURA 6 – REPRESENTAÇÃO GEOMÉTRICA DO HIPERPLANO E MARGENS DE SEPARAÇÃO DO SVM	25
FIGURA 7 – PROJEÇÃO UMAP E FORMAÇÃO DE CLUSTERS EM DADOS DE CÂNCER DE MAMA	35
FIGURA 8 – DIAGRAMA DE BLOCOS DO FLUXO DE DADOS E COMUNICAÇÃO DA ARQUITETURA	44

LISTA DE QUADROS

QUADRO 1 – PRINCIPAIS HIPERPARÂMETROS DO ALGORITMO UMAP . .	34
QUADRO 2 – COMPARAÇÃO ENTRE TRABALHOS RELACIONADOS E O PRESENTE PROJETO.	41
QUADRO 3 – BIBLIOTECAS UTILIZADAS NO MÓDULO CIENTÍFICO. . . .	45

LISTA DE CÓDIGOS

CÓDIGO 1 – IMPLEMENTAÇÃO DA REDUÇÃO DIMENSIONAL UTILIZANDO O ALGORITMO UMAP EM PYTHON.	34
CÓDIGO 2 – LIMPEZA E CODIFICAÇÃO DA VARIÁVEL ALVO.	46
CÓDIGO 3 – DIVISÃO ESTRATIFICADA DA BASE EM CONJUNTOS DE TREINO E TESTE.	47
CÓDIGO 4 – AJUSTE E APLICAÇÃO DO PADRONIZADOR Z-SCORE.	48
CÓDIGO 5 – DIVISÃO LEGADA UTILIZADA PELA ÁRVORE DE DECISÃO.	48

LISTA DE SIGLAS E ACRÔNIMOS

AUC	<i>Area Under the Curve</i> (Área Sob a Curva)
CART	<i>Classification and Regression Trees</i> (Árvores de Classificação e Regressão)
DNA	Ácido Desoxirribonucleico
DL	<i>Deep Learning</i> (Aprendizado Profundo)
FN	Falso Negativo
FP	Falso Positivo
GLM	<i>Generalized Linear Model</i> (Modelo Linear Generalizado)
IA	Inteligência Artificial
ID3	<i>Iterative Dichotomiser 3</i> (Dicotomizador Iterativo 3)
INCA	Instituto Nacional de Câncer
KNN	<i>K-Nearest Neighbors</i> (K-Vizinhos Mais Próximos)
LIME	<i>Local Interpretable Model-agnostic Explanations</i>
MDA	<i>Mean Decrease in Accuracy</i> (Importância por Permutação)
MDI	<i>Mean Decrease in Impurity</i> (Diminuição Média da Impureza)
ML	<i>Machine Learning</i> (Aprendizado de Máquina)
MLE	<i>Maximum Likelihood Estimation</i> (Estimativa de Máxima Verossimilhança)
OOB	<i>Out-of-Bag</i>
PAAF	Punção Aspirativa por Agulha Fina
PAHO	<i>Pan American Health Organization</i> (Organização Pan-Americana da Saúde)
PR	<i>Precision-Recall</i> (Precisão-Revocação)
RBF	<i>Radial Basis Function</i> (Função de Base Radial)
ROC	<i>Receiver Operating Characteristic</i> (Característica de Operação do Receptor)

SHAP	<i>SHapley Additive exPlanations</i>
SVM	<i>Support Vector Machine</i> (Máquina de Vetores de Suporte)
UMAP	<i>Uniform Manifold Approximation and Projection</i>
VN	Verdadeiro Negativo
VP	Verdadeiro Positivo
WDBC	<i>Wisconsin Diagnostic Breast Cancer</i>
XAI	<i>eXplainable Artificial Intelligence</i> (Inteligência Artificial Explicável)
XGBoost	<i>Extreme Gradient Boosting</i>

LISTA DE SÍMBOLOS

$p(x)$	Probabilidade de malignidade estimada pela função sigmoide
β_0	Intercepto (termo independente) do modelo logístico
β_1	Coeficiente da variável preditora no modelo logístico
x_1	Vetor de características de entrada do modelo
$L(\beta_0, \beta_1)$	Função de verossimilhança a ser maximizada
y_i	Rótulo real da amostra i (0 para benigno, 1 para maligno)
w	Vetor de pesos que define a inclinação do hiperplano separador
b	Termo de viés que determina a posição do hiperplano no espaço
x	Vetor de características de entrada
γ	Margem de separação entre as classes no SVM
ξ	Variável de folga utilizada na margem flexível do SVM
C	Hiperparâmetro de regularização do SVM (controle da margem flexível)
$d_E(x, y)$	Distância Euclidiana entre os vetores de características x e y
$d_M(x, y)$	Distância de Manhattan entre os vetores de características x e y
n	Número total de atributos (dimensões) do vetor de características
k	Número de vizinhos mais próximos considerados pelo KNN
$H(S)$	Entropia do conjunto de dados S
$p(c)$	Proporção de amostras pertencentes à classe c no conjunto S
c	Classe de saída do problema de classificação
$IG(S, a)$	Ganho de informação do atributo a sobre o conjunto S
a	Atributo celular avaliado como critério de divisão na árvore de decisão
S_v	Subconjunto de amostras de S nas quais o atributo a assume o valor v
v	Valor específico assumido pelo atributo a em uma divisão

ϕ_i	Valor de Shapley para a característica isolada i
Σ	Somatório
N	Conjunto total de características celulares disponíveis
S	Subconjunto específico de características
i	Característica celular isolada em análise
$\subseteq$	Subconjunto de
$\setminus$	Diferença de conjuntos (exclusão)
$ \cdot $	Cardinalidade (quantidade de elementos de um conjunto)
$!$	Operador fatorial
$\cup$	União de conjuntos
$v(\cdot)$	Função de valor (predição de risco do modelo para um determinado subconjunto)

SUMÁRIO

1	INTRODUÇÃO	12
2	FUNDAMENTAÇÃO TEÓRICA	14
2.1	O CÂNCER DE MAMA E A ANÁLISE MORFOLÓGICA	14
2.2	INTELIGÊNCIA ARTIFICIAL E MACHINE LEARNING: DEFINIÇÕES E HIERARQUIA	16
2.3	MACHINE LEARNING: CONCEITOS E PARADIGMAS	17
2.3.1	O Paradigma do Aprendizado Supervisionado e a Classificação Binária	18
2.3.2	O Dilema da Generalização e o Ciclo de Vida do Modelo	19
2.3.3	Métricas de Avaliação de Desempenho	20
2.3.4	Principais Algoritmos Classificadores	22
2.4	O DILEMA DA CAIXA PRETA E A INTELIGÊNCIA ARTIFICIAL EXPLICÁVEL	29
2.5	SHAPLEY ADDITIVE EXPLANATIONS (SHAP)	30
2.5.1	Fundamentação Matemática: A Equação de Shapley	31
2.6	REDUÇÃO DE DIMENSIONALIDADE E UMAP	32
3	TRABALHOS RELACIONADOS	36
3.1	EXTRAÇÃO DE CARACTERÍSTICAS NUCLEARES PARA O DIAGNÓSTICO DE TUMORES MAMÁRIOS (STREET <i>ET AL.</i> , 1993)	36
3.2	APLICAÇÕES DE MACHINE LEARNING NA PREDIÇÃO E PROGNÓSTICO DO CÂNCER (CRUZ E WISHART, 2006)	36
3.3	SEGMENTAÇÃO E CONTAGEM DE CÉLULAS EM IMAGENS (SILVA JÚNIOR, 2018)	37
3.4	DIAGNÓSTICO DE CÂNCER DE PULMÃO E CÓLON VIA DEEP LEARNING (MASUD <i>ET AL.</i> , 2021)	38
3.5	PREDIÇÃO DE CÂNCER DE PULMÃO COM SELEÇÃO DE CORRELAÇÃO (ABDULLAH <i>ET AL.</i> , 2021)	38
3.6	ABORDAGENS DE MACHINE LEARNING NA PREDIÇÃO DO CÂNCER DE MAMA (RABIEI <i>ET AL.</i> , 2022)	39
3.7	PREDIÇÃO BASEADA EM APRENDIZADO DE MÁQUINA (CHEN <i>ET AL.</i> , 2023)	39
3.8	ESTUDO COMPARATIVO COM SELEÇÃO LASSO E SHAP (SHAON <i>ET AL.</i> , 2024)	40
3.9	SÍNTESE E LACUNA DE PESQUISA	40
4	METODOLOGIA	42
4.1	CLASSIFICAÇÃO DA PESQUISA	42
4.2	VISÃO GERAL DA ARQUITETURA DA SOLUÇÃO	43
4.3	BASE DE DADOS E AMBIENTE DE DESENVOLVIMENTO	44

4.4	PRÉ-PROCESSAMENTO DOS DADOS	45
4.4.1	Codificação da Variável Alvo	46
4.4.2	Divisão Treino e Teste	46
4.4.3	Padronização Z-score	47
4.4.4	Divisão Legada para a Árvore de Decisão	47
4.5	ANÁLISE EXPLORATÓRIA DOS DADOS	48
4.5.1	Estatísticas Descritivas	48
4.5.2	Distribuição das Classes	49
4.5.3	Histogramas dos Atributos	49
4.5.4	Boxplots dos Atributos	50
	REFERÊNCIAS	51

1 INTRODUÇÃO

De acordo com a Organização Pan-Americana da Saúde (PAHO, 2026), as patologias oncológicas impõem uma enorme carga de adoecimento nas Américas, sendo superadas unicamente pelas doenças cardiovasculares. A instituição aponta que, em 2022, a região contabilizou mais de 4,2 milhões de novos casos, com a expectativa de que esse índice sofra um acréscimo de 60% até 2045, chegando à marca de 6,7 milhões. Como uma das causas primárias de mortalidade no continente, a doença resultou em 1,4 milhão de óbitos em 2022, afetando pessoas com 69 anos ou menos em 45% das ocorrências. Contudo, o órgão ressalta que muitos desses quadros possuem elevadas taxas de cura quando há o rastreio precoce somado ao tratamento clínico assertivo.

No cenário nacional, as projeções apontam para um panorama de alerta, com a estimativa de 781 mil novos casos de câncer por ano no Brasil ao longo do triênio de 2026 a 2028. Dentro dessa estatística, o câncer de mama consolida-se de forma alarmante como a neoplasia mais incidente entre o público feminino, representando 30% de todos os novos diagnósticos nas mulheres. Esses números expressivos refletem não apenas o envelhecimento populacional, mas também evidenciam as profundas desigualdades regionais e os desafios persistentes que as pacientes enfrentam no acesso à prevenção, ao rastreamento, ao diagnóstico precoce e ao tratamento oportuno no sistema de saúde (INCA, 2026).

O uso de tecnologias computacionais para enfrentar essa carga de adoecimento está em plena expansão, impulsionado pela chamada revolução do *Big Data* na saúde. Instituições de referência, como o próprio Instituto Nacional de Câncer (INCA, 2022a), destacam que a bioinformática e a biologia computacional são cruciais para analisar dados em larga escala e identificar assinaturas do câncer. Ao processar grandes volumes de dados morfológicos e genéticos, abrem-se caminhos para uma medicina cada vez mais direcionada e personalizada. Nesse contexto, o uso de algoritmos de *Machine Learning* para o reconhecimento de padrões e classificação de tumores já se consolida como uma linha de pesquisa fundamental para a oncologia moderna, capaz de extrair marcadores de interesse clínico de forma automatizada.

Apesar do notável desempenho preditivo, a adoção clínica dessas tecnologias esbarra no chamado "problema da caixa preta". Algoritmos avançados fornecem previsões altamente acuradas, mas não revelam o raciocínio matemático interno que levou àquela conclusão. Na prática médica, entregar um diagnóstico de malignidade automatizado sem uma fundamentação biológica rastreável é insuficiente e eticamente questionável. O profissional de saúde necessita compreender quais fatores morfológicos e celulares pesaram na decisão para validar a previsão, confiar no modelo e transmitir o diagnóstico com segurança ao paciente.

É nesse cenário que a Inteligência Artificial Explicável (XAI - *eXplainable AI*) se faz estritamente necessária. A aplicação de técnicas de interpretabilidade, como o *SHapley Additive exPlanations* (SHAP), permite "abrir" essa caixa preta ao quantificar o impacto exato e a contribuição de cada variável clínica no risco de malignidade. Em paralelo, a utilização de algoritmos de redução de dimensionalidade, como o *Uniform Manifold Approximation and Projection for Dimension Reduction* (UMAP), facilita a análise visual da separabilidade natural dos dados, identificando agrupamentos (*clusters*) e anomalias de forma gráfica. Dessa forma, o sistema computacional deixa de ser apenas um classificador opaco e passa a atuar como uma ferramenta de apoio transparente, unindo a precisão analítica à explicabilidade exigida pelo campo oncológico.

Diante da necessidade de conciliar desempenho preditivo e interpretabilidade clínica, formula-se o seguinte problema de pesquisa: como integrar técnicas de explicabilidade e redução de dimensionalidade em um modelo preditivo de câncer de mama, de modo a fornecer diagnósticos que sejam, simultaneamente, acurados e interpretáveis por profissionais de saúde?

O objetivo deste trabalho é desenvolver um software integrado a um modelo preditivo para a classificação de tumores mamários (benignos ou malignos), utilizando algoritmos de Machine Learning e a base de dados pública Breast Cancer Wisconsin. O intuito principal é mitigar a opacidade característica dos modelos de "caixa preta", fornecendo aos profissionais de saúde diagnósticos preditivos que unam alta precisão analítica a justificativas clínicas transparentes.

Para alcançar esse propósito, o projeto engloba o treinamento e a seleção de classificadores, bem como a aplicação do UMAP para a análise visual da separabilidade natural dos dados, facilitando a identificação de agrupamentos (*clusters*) e anomalias (*outliers*) biológicas. Em paralelo, o sistema integrará a biblioteca SHAP para garantir a explicabilidade das decisões, quantificando o impacto de cada variável celular no risco de malignidade apontado pelo modelo. Por fim, visando a viabilidade de uso no cotidiano médico, o trabalho contempla a criação de uma interface capaz de receber dados em lote via upload de planilhas, automatizando a geração de relatórios de saída estruturados (como PDF, Excel ou CSV) com os resumos dos diagnósticos e suas respectivas fundamentações visuais.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo destina-se à fundamentação teórica que sustenta a pesquisa, conectando conceitos fundamentais ao problema proposto. O objetivo é estabelecer uma base sólida, com base na literatura científica consolidada, que conduza e valide o estudo. Nas seções a seguir, serão explorados os aspectos clínicos da doença, a evolução tecnológica na análise de dados em saúde e as abordagens computacionais escolhidas para o desenvolvimento do modelo preditivo.

2.1 O CÂNCER DE MAMA E A ANÁLISE MORFOLÓGICA


O termo câncer abrange um complexo conjunto de mais de cem doenças malignas que têm como denominador comum o crescimento desordenado e incontrolável das células. A base biológica dessa patologia reside na perda estrutural e funcional dos mecanismos de regulação celular. Esse processo de formação tumoral, cientificamente denominado carcinogênese ou oncogênese, é engatilhado quando o ácido desoxirribonucleico (DNA), a "memória química" que guarda as instruções das atividades celulares, sofre alterações críticas. Em condições normais, genes reguladores específicos chamados proto-oncogenes permanecem inativos; contudo, sob a ação de fatores cancerígenos cumulativos, eles sofrem mutações e são ativados, convertendo-se em oncogenes. Essa ativação desencadeia um processo lento e progressivo composto por três estágios: a iniciação, onde a célula sofre a alteração genética primária de forma silenciosa, a promoção, fase em que agentes externos ou internos transformam gradual e lentamente essa célula iniciada em uma estrutura maligna, e por fim, a progressão, caracterizada pela multiplicação descontrolada e irreversível das células alteradas, culminando na consolidação clínica do tumor e em seu potencial de invasão (INCA, 2022b).

O tipo mais comum desta doença é classificado como carcinoma, uma nomeação atribuída aos tumores malignos que se originam nas células epiteliais, que são os tecidos responsáveis por revestir as superfícies internas e externas do corpo humano. Dependendo do tipo específico de célula epitelial afetada, o carcinoma recebe denominações distintas. No contexto anatômico do câncer de mama, a manifestação predominante é o adenocarcinoma, um subtipo que se desenvolve especificamente nas células epiteliais dos tecidos glandulares, cuja função biológica é produzir fluidos e muco (NCI, 2021).

No entanto, o desenvolvimento desse adenocarcinoma não ocorre de maneira instantânea, estruturando-se por meio de uma progressão morfológica gradual e microscopicamente rastreável. Inicialmente, o tecido mamário pode apresentar uma hiperplasia, caracterizada por um acúmulo de células que se multiplicam em um ritmo

acelerado, mas que ainda preservam rigorosamente sua aparência e arquitetura originais. Se a anomalia celular progredir para o estágio de displasia, além do acúmulo excessivo, as células perdem sua organização e começam a apresentar deformidades morfológicas evidentes. O ápice dessa fase pré-invasiva é denominado carcinoma *in situ* (frequentemente referido na literatura clínica como estágio 0). Neste limiar, as células já exibem características visualmente malignas em seus núcleos, mas ainda se encontram confinadas, pois não romperam as barreiras do tecido glandular original para invadir as áreas vizinhas (NCI, 2021). A diferença fundamental entre a biologia de um tecido saudável e o desenvolvimento anômalo gerado por essa cascata de mutações pode ser observada na Figura 1.

FIGURA 1 – CONTRASTE MORFOLÓGICO ENTRE CÉLULAS NORMAIS E NEOPLÁSICAS.



FONTE: INCA, 2022c, Disponível em: <https://www.gov.br/inca/pt-br/assuntos/cancer/o-que-e-cancer>

Na ciência da computação aplicada à saúde, o dado mais valioso desta anomalia não é apenas a mutação genética em si, mas sim a profunda alteração morfológica que ela desencadeia. A pressão para sustentar uma replicação em massa e desordenada leva à deformação severa do núcleo de uma célula maligna. Como resultado, quando analisadas ao microscópio, estas células apresentam variações perceptíveis e quantificáveis na área, no raio, na textura e na concavidade, em comparação com uma célula saudável. São justamente essas assimetrias físicas que se tornam o insumo fundamental para alimentar e treinar algoritmos de aprendizagem de máquina. Estes algoritmos apoiam o diagnóstico preditivo (Street *et al.*, 1993).

Um dos marcos pioneiros na convergência entre a oncologia clínica e a ciência da computação, voltado especificamente para a quantificação dessas assimetrias celulares, é a base de dados *Breast Cancer Wisconsin (Diagnostic)*. No início dos anos 90, pesquisadores da Universidade de Wisconsin desenvolveram esta base com o objetivo de mitigar a subjetividade e a fadiga associadas à análise microscópica realizada por especialistas (Street *et al.*, 1993). O principal diferencial metodológico deste trabalho residiu na opção por não construir um repositório de imagens biomédicas de alta dimensionalidade, pois demandaria elevada capacidade computacional de armazenamento e

processamento, mas sim uma base estruturada de atributos numéricos extraídos das imagens, de processamento eficiente.

Para alcançar esse resultado, os pesquisadores utilizaram amostras coletadas via Punção Aspirativa por Agulha Fina (PAAF) e aplicaram algoritmos de processamento de imagem, conhecidos como contornos ativos (*snakes*), para delinear digitalmente as fronteiras dos núcleos celulares. A partir deste tratamento computacional, foram extraídas matematicamente dez características morfológicas essenciais de cada célula, incluindo o raio, a textura, o perímetro, a área e a suavidade. Ao calcular a média, o erro padrão e o valor máximo para cada uma dessas dez medidas, o sistema gerou as 30 variáveis numéricas que compõem o conjunto de dados. Esta otimização consolidou a base de Wisconsin como um recurso de referência na literatura, permitindo que os algoritmos preditivos processem informações oncológicas complexas de forma rápida e eficiente (Street *et al.*, 1993).

2.2 INTELIGÊNCIA ARTIFICIAL E MACHINE LEARNING: DEFINIÇÕES E HIERARQUIA

A Inteligência Artificial (IA) é uma área da ciência da computação que teve um marco histórico em 1956, durante a Conferência de Dartmouth, quando o termo foi formalmente cunhado (Russel; Norvig, 2010). Desde então, a área evoluiu e ramificou-se em diversas vertentes de pesquisa. Segundo Russell e Norvig (2010), as definições históricas e contemporâneas de IA podem ser organizadas em quatro categorias principais, divididas entre abordagens que buscam simular o comportamento ou o pensamento humano, e abordagens focadas puramente no conceito de racionalidade. No contexto computacional moderno, a abordagem mais adotada e cientificamente rigorosa é a dos "agentes racionais", que são sistemas que operam de forma autônoma e agem para alcançar o melhor resultado possível diante de um problema, dado o conhecimento e as percepções que possuem do ambiente.


Para que um sistema alcance essa racionalidade em ambientes complexos, a programação de regras lógicas estáticas (*if-then*) torna-se inviável. É para solucionar esta limitação que surge o *Machine Learning* (ML), o principal subcampo da Inteligência Artificial. Em vez de serem explicitamente programados para executar uma tarefa passo a passo, os algoritmos de ML utilizam métodos estatísticos para extrair padrões diretamente dos dados. A definição formal mais consolidada na literatura é proposta por Mitchell (1997), que estabelece que um programa de computador aprende a partir da experiência E , em relação a uma classe de tarefas T e uma medida de desempenho P , se o seu desempenho em T , quantificado por P , melhora com a experiência E .

Para compreender essa definição de forma mais prática, pode-se estabelecer um paralelo com o aprendizado humano em jogos. A tarefa T representa o objetivo,

como identificar tumores; a experiência E consiste nos dados históricos e exemplos fornecidos ao sistema (como a base de dados Wisconsin), e o desempenho P atua como a métrica de sucesso, indicando quantos diagnósticos a máquina acertou. O algoritmo é considerado capaz de "aprender" quando, ao ser exposto a mais dados (maior E), ele aumenta sua taxa de acertos (maior P) ao realizar o diagnóstico (tarefa T).

A hierarquia da inteligência computacional estende-se ainda a camadas mais especializadas, como o *Deep Learning* (DL), ou Aprendizado Profundo. Esta vertente do machine learning usa redes neurais artificiais para processar grandes volumes de dados (Richardson, 2022). Essa relação hierárquica e de pertencimento entre os campos pode ser visualizada por meio de um diagrama de conjuntos, conforme ilustrado na Figura 2.

FIGURA 2 – HIERARQUIA E RELAÇÃO DE INCLUSÃO ENTRE IA, ML E DL.



FONTE: Richardson, 2022, Disponível em: <https://www.redhat.com/pt-br/blog/what-aiml-and-why-does-it-matter-your-business>

Essa estrutura demonstra que todo Aprendizado Profundo é uma forma de Aprendizado de Máquina, e todo Aprendizado de Máquina é uma aplicação de Inteligência Artificial. Para o escopo do diagnóstico preditivo oncológico proposto neste estudo, a construção do agente racional será fundamentada especificamente nas técnicas clássicas de *Machine Learning*, cujos paradigmas e mecânicas de avaliação serão detalhados a seguir.

2.3 MACHINE LEARNING: CONCEITOS E PARADIGMAS

O desenvolvimento de um modelo de IA não segue uma receita universal, a abordagem escolhida depende fundamentalmente da natureza dos dados disponíveis e do objetivo do problema. Na literatura clássica de *Machine Learning*, os algoritmos são categorizados em três grandes paradigmas de aprendizado: Não Supervisionado,

Aprendizado por Reforço e Aprendizado Supervisionado. Como o escopo deste trabalho visa prever um diagnóstico clínico a partir de dados históricos previamente validados por médicos patologistas, o referencial teórico e metodológico desta pesquisa concentra-se exclusivamente no paradigma do Aprendizado Supervisionado (Cruz e Wishart, 2006).

2.3.1 O Paradigma do Aprendizado Supervisionado e a Classificação Binária

O Aprendizado Supervisionado, que a literatura classifica como uma tarefa preditiva de aprendizagem indutiva, caracteriza-se sobretudo pela presença de um "gabarito" nos dados de treinamento. Neste paradigma, o algoritmo é alimentado com um conjunto de dados históricos contendo tanto as variáveis independentes de entrada, conhecidas como *features* ou atributos, quanto as suas respectivas variáveis dependentes de saída, os rótulos ou *labels*. O objetivo deste método é fazer com que o modelo descubra e mapeie a relação matemática entre as entradas e a saída. Dessa forma, ao aprender as regras ocultas que conectam as características observadas ao resultado final, o sistema torna-se capaz de generalizar esse conhecimento para realizar previsões automáticas quando exposto a novos dados não rotulados no futuro (Faceli *et al.*, 2011).

Nesse paradigma, o modelo aprende a partir de exemplos previamente rotulados, ajustando seus parâmetros internos de forma iterativa para generalizar padrões a novos dados. O algoritmo analisa casos em que tanto o problema quanto a resposta correta são fornecidos simultaneamente. Após essa fase de treinamento, o modelo deve ser capaz de generalizar o conhecimento adquirido para prever a resposta correta quando apresentado a novos dados inéditos, que não possuem o rótulo (Faceli *et al.*, 2011).

Dentro do Aprendizado Supervisionado, Bishop (2006) divide os problemas de acordo com o tipo de resultado que se deseja alcançar. Quando o objetivo do modelo é organizar as informações recebidas em grupos bem definidos, a tarefa é chamada de problema de classificação. Por outro lado, se o sistema tenta prever um valor numérico contínuo, como estimar a expectativa de vida de um paciente ou calcular o rendimento de um processo químico, a tarefa recebe o nome de problema de regressão.

No contexto da oncologia e da base de dados *Breast Cancer Wisconsin*, a tarefa computacional se enquadra como um problema de Classificação Binária. Isso significa que a variável de saída que o modelo deve prever possui apenas dois estados: o tumor é Benigno ou Maligno (Street *et al.*, 1993). Todo o esforço de treinamento e otimização dos algoritmos neste trabalho visa buscar a melhor fronteira de decisão matemática capaz de separar essas duas classes, minimizando ao máximo os erros de categorização, dada a criticidade de um falso diagnóstico médico.

2.3.2 O Dilema da Generalização e o Ciclo de Vida do Modelo

A construção de um classificador médico eficiente vai muito além do simples processamento numérico de dados históricos. O objetivo central de um modelo de aprendizado de máquina não é apenas memorizar os exemplos exatos que foram apresentados durante o treinamento, mas sim desenvolver a capacidade de generalização. Ou seja, o sistema precisa aprender a regra geral para conseguir prever com precisão o diagnóstico de novos pacientes que nunca processou antes. Nesse processo de aprendizado, o algoritmo pode cometer dois erros estatísticos extremos: o *underfitting* e o *overfitting* (Faceli *et al.*, 2011).

O *underfitting* ocorre quando o modelo matemático é estruturalmente simples demais e não consegue capturar nem mesmo os padrões morfológicos básicos dos tumores. Nesse cenário, o algoritmo falha em extrair o conhecimento necessário e erra classificações fundamentais. No extremo oposto, encontra-se o *overfitting*, que é um risco estatístico muito mais comum e perigoso na área da saúde. Nesse caso, o modelo se torna tão complexo que passa a "decorar" não apenas as características reais do câncer, mas também as falhas, as exceções e os pequenos ruídos específicos daquela base de dados de treinamento. Consequentemente, o modelo atinge uma precisão artificialmente alta durante seu desenvolvimento, mas fracassa ao avaliar novos pacientes, pois apenas memorizou os dados antigos em vez de assimilar a lógica subjacente à doença (Faceli *et al.*, 2011).

Na estatística, essa linha tênue entre memorizar e generalizar é explicada pelo dilema viés e variância (*bias-variance tradeoff*). O viés representa a limitação estrutural do modelo em enxergar a complexidade dos dados reais, o que causa o *underfitting*. Já a variância mede o quanto o modelo altera sua fronteira de decisão de forma exagerada diante de pequenas mudanças nos dados, o que resulta no *overfitting*. Para garantir que o classificador encontre o equilíbrio estatístico perfeito e seja seguro para uso clínico, é obrigatório adotar um ciclo de vida rigoroso no qual a base de dados original nunca é entregue inteira de uma só vez ao algoritmo. Ela precisa ser metodologicamente dividida em subconjuntos separados (Bishop, 2006).

Essa metodologia de divisão geralmente particiona os dados em três grupos: Treinamento, Validação e Teste. O conjunto de treinamento é o ambiente computacional primário, onde o algoritmo ajusta seus pesos e constrói suas regras de classificação. O conjunto de validação atua como um ambiente de aferição intermediária, permitindo que o desenvolvedor calibre os detalhes matemáticos do modelo e perceba rapidamente se o *overfitting* está ocorrendo. Por fim, o conjunto de teste representa o cenário do mundo real. Ele permanece totalmente isolado e oculto do computador durante todo o processo de desenvolvimento, sendo acionado apenas uma única vez na etapa final. O desempenho alcançado neste conjunto de teste isolado é o indicador soberano que


comprova a verdadeira eficácia do sistema em acertar diagnósticos na prática médica (Faceli *et al.*, 2011).

2.3.3 Métricas de Avaliação de Desempenho

Após submeter o conjunto de teste ao algoritmo, é fundamental quantificar o seu desempenho clínico. Na classificação binária, a base para qualquer avaliação é a construção de uma Matriz de Confusão. Essa ferramenta organiza os resultados das previsões em quatro categorias possíveis. Os Verdadeiros Positivos (VP) representam os tumores malignos corretamente identificados, enquanto os Verdadeiros Negativos (VN) são os tumores benignos confirmados. Por outro lado, os erros são divididos em Falsos Positivos (FP), que ocorrem quando um tumor benigno gera um alarme falso de malignidade, e Falsos Negativos (FN), que acontecem quando o sistema ignora um tumor maligno e o classifica como inofensivo. Em um cenário oncológico, o falso negativo representa a falha mais crítica do modelo, pois resulta em um paciente doente que é liberado sem receber o tratamento adequado (James *et al.*, 2023).

A Figura 3 ilustra um exemplo dessa estrutura, onde os acertos do modelo concentram-se na diagonal principal (430 VN e 61 VP), enquanto os erros aparecem nos quadrantes secundários (6 FP e 3 FN).

FIGURA 3 – EXEMPLO ILUSTRATIVO DE UMA MATRIZ DE CONFUSÃO



FONTE: O Autor

A métrica mais intuitiva extraída dessa matriz é a acurácia (*accuracy*), que representa a taxa geral de acertos do modelo. Contudo, confiar exclusivamente na acurácia é um erro metodológico perigoso na área da saúde devido ao problema matemático das classes desbalanceadas. Considere uma situação onde a base de dados possui noventa e nove pacientes saudáveis para cada paciente com câncer. Se um algoritmo quebrado simplesmente classificar todas as pessoas do mundo como saudáveis, ele obterá uma acurácia de 99%. Apesar de parecer um sucesso estatístico absoluto, o modelo seria clinicamente inútil e letal para a pequena parcela de pacientes

doentes (Faceli *et al.*, 2011). Matematicamente, a acurácia é calculada pela razão entre as predições corretas e o total de predições, conforme a Equação 1. Seu resultado é expresso em uma escala de 0 a 1, onde valores próximos a 1 indicam maior acerto global.

$$Acurácia = \frac{VP + VN}{VP + VN + FP + FN} \quad (1)$$

Para contornar essa ilusão estatística, o desempenho do modelo deve ser avaliado por métricas que observam os acertos e erros de cada classe de forma isolada. A sensibilidade, também conhecida na literatura como revocação (*recall*), mede a capacidade do algoritmo de identificar corretamente os pacientes que realmente possuem a doença, sendo expressa pela Equação 2 (Davis e Goadrich, 2006). Em outras palavras, essa métrica quantifica a proporção de casos positivos que são efetivamente recuperados pelo modelo, sendo particularmente relevante em contextos clínicos onde a omissão de diagnósticos pode acarretar consequências graves.

$$Sensibilidade = \frac{VP}{VP + FN} \quad (2)$$

Em paralelo, a precisão (*precision*) avalia a confiabilidade técnica do alerta, ou seja, de todos os tumores que o sistema afirmou serem malignos, qual proporção realmente era, expressada pela Equação 3 (Davis e Goadrich, 2006). Essa métrica está diretamente relacionada à taxa de alarmes falsos do sistema, refletindo o quanto as predições positivas podem ser consideradas confiáveis na prática. Assim, modelos com alta precisão tendem a evitar intervenções desnecessárias em pacientes saudáveis.

$$Precisão = \frac{VP}{VP + FP} \quad (3)$$

Como frequentemente existe uma balança entre essas duas métricas, onde o aumento de uma pode diminuir a outra, utiliza-se a métrica *F1-score*. Esse indicador calcula a média harmônica entre a precisão e a sensibilidade, fornecendo um único número que atesta o equilíbrio e a segurança geral do classificador (Manning *et al.*, 2006). O *F1-score* consolida esses valores através da Equação 4.


$$F1-Score = 2 \times \frac{Precisão \times Sensibilidade}{Precisão + Sensibilidade} \quad (4)$$

A avaliação final do modelo é frequentemente consolidada visualmente pela Curva de Característica de Operação do Receptor (ROC). Essa curva ilustra a relação entre a taxa de verdadeiros positivos (sensibilidade) e a taxa de falsos positivos. Para resumir essa análise em um único valor, utiliza-se a área sob a curva (AUC), cujo valor varia de 0 a 1, sendo que valores próximos de 1 indicam maior capacidade discriminativa do modelo (Faceli *et al.*, 2011).

Entretanto, conforme discutido por Davis e Goadrich (2006), a Curva ROC pode apresentar uma visão excessivamente otimista do desempenho em cenários com forte

desbalanceamento de classes, como é comum em aplicações médicas. A Figura 4 ilustra esse fenômeno: embora dois algoritmos apresentem desempenhos semelhantes no espaço ROC, diferenças significativas tornam-se evidentes quando analisados no espaço de Precisão-Revocação.

FIGURA 4 – COMPARAÇÃO ENTRE CURVAS ROC E PRECISÃO-REVOCAÇÃO EM DADOS DESBALANCEADOS



FONTE: Adaptado de (DAVIS; GOADRICH, 2006)

Essa discrepância ocorre porque a taxa de falsos positivos utilizada na Curva ROC é normalizada pelo número total de exemplos negativos, que tende a ser muito elevado em bases desbalanceadas, reduzindo o impacto visual dos erros. Em contraste, a Curva de Precisão-Revocação (PR) considera diretamente a proporção entre verdadeiros e falsos positivos, tornando-se mais sensível a variações no desempenho do modelo na classe minoritária (Davis e Goadrich, 2006).

Dessa forma, em cenários oncológicos, onde o interesse principal está na correta identificação de casos positivos (tumores malignos), a Curva PR e sua respectiva área sob a curva (PR-AUC) fornecem uma avaliação mais fiel do desempenho do classificador. Uma alta PR-AUC indica que o modelo consegue manter elevada precisão mesmo com altos níveis de sensibilidade, sendo, portanto, uma métrica mais adequada para validação em problemas com classes desbalanceadas (Saito e Rehmsmeier, 2015).


2.3.4 Principais Algoritmos Classificadores

Com a base de dados metodologicamente preparada e as métricas de avaliação estabelecidas, o desenvolvimento do sistema avança para o seu núcleo computacional: a escolha do algoritmo de classificação. O campo do aprendizado supervisionado dispõe de um vasto leque de modelos matemáticos, variando desde equações probabilísticas mais tradicionais até arquiteturas estruturalmente complexas. Embora todos esses algoritmos compartilhem o mesmo propósito central de traçar uma fronteira

capaz de separar as células benignas das malignas, cada um deles interpreta os dados e resolve esse problema geométrico utilizando lógicas completamente distintas (Faceli *et al.*, 2011).

A Figura 5 ilustra de forma clara essa mecânica geométrica. Na representação da classificação (a), observa-se o traçado de uma fronteira de decisão dividindo o espaço de características, representado por dois exames, entre a classe saudável e a doente, o que é característico da tarefa abordada neste trabalho. Em contraste, na representação da regressão (b), não se traçam limites separadores, mas sim busca-se uma função que se aproxime continuamente da distribuição dos dados (Faceli *et al.*, 2011).

FIGURA 5 – GRÁFICO ILUSTRATIVO DAS TAREFAS DE CLASSIFICAÇÃO E REGRESSÃO



FONTE: Adaptado de (FACELI *et al.*, 2011)

O modelo de base mais clássico na modelagem estatística em saúde é a Regressão Logística. Apesar do nome referenciar problemas contínuos, trata-se de um classificador probabilístico. Ele atua calculando uma combinação linear das características da célula, como o seu raio e a sua textura, e aplica esse resultado numérico em uma função matemática chamada sigmoide. Essa função comprime qualquer valor para um intervalo estrito entre zero e um, fornecendo diretamente a probabilidade de o tumor ser maligno. Se essa probabilidade exceder um limiar de corte, o sistema consolida o diagnóstico positivo. A sua adoção contínua na prática clínica decorre da transparência da equação, permitindo que o médico entenda o peso exato de cada variável na decisão final (Bishop, 2006).

Estruturalmente, a regressão logística integra a família dos modelos lineares generalizados (GLMs). Em vez de modelar probabilidades diretamente com uma função linear, o algoritmo trabalha com a chance logarítmica (*log-odds*), também conhecida como função *logit*, para mapear a relação entre variáveis (Lee, 2026).

Matematicamente, a função sigmoide comprime valores reais ilimitados para o intervalo $[0, 1]$ ao calcular a razão entre a base exponencial da entrada e essa mesma base acrescida de uma unidade (Lee, 2026). Como o denominador é sempre

estritamente superior ao numerador, a fração resultante converge para uma escala de probabilidade válida, conforme demonstrado na Equação 5.

$$p(x) = \frac{e^{\beta_0 + \beta_1 x_1}}{1 + e^{\beta_0 + \beta_1 x_1}} \quad (5)$$

Para estimar os coeficientes (β_0 e β_1), utiliza-se a Estimativa de Máxima Verossimilhança (MLE), um processo otimizado iterativamente por gradiente descendente que busca os parâmetros capazes de tornar os dados observados mais prováveis (Lee, 2026). A função de verossimilhança a ser maximizada neste processo é representada pela Equação 6.

$$L(\beta_0, \beta_1) = \prod_{i=1}^n p(x_i)^{y_i} \cdot (1 - p(x_i))^{1-y_i} \quad (6)$$

Quando a dispersão entre as características de células benignas e malignas apresenta uma distribuição complexa que não pode ser separada por uma linha reta simples, a computação recorre às Máquinas de Vetores de Suporte, frequentemente referenciadas pela sigla SVM. O objetivo primário deste algoritmo é encontrar uma fronteira de decisão geométrica, denominada hiperplano, que consiga separar as duas classes de tumores garantindo a maior margem de segurança possível entre elas. Os vetores de suporte, que dão nome ao modelo, são justamente os dados dos pacientes que estão posicionados de forma mais arriscada, ou seja, mais próximos a essa fronteira crítica. Eles atuam como os pilares estruturais que sustentam e definem o formato da decisão final do algoritmo (Bishop, 2006).


Entretanto, nos problemas oncológicos reais, é muito comum que os dados das células estejam sobrepostos, configurando um cenário não linear. Para solucionar essa limitação e viabilizar a classificação, o SVM utiliza uma operação matemática sofisticada conhecida como truque de *kernel*. Conforme detalhado por AI Online Course (2023), o *kernel* atua como uma função de mapeamento que eleva os dados originais de um espaço de baixa dimensão para um espaço de dimensão superior. Nessa nova perspectiva matemática ampliada, as células malignas e benignas que antes pareciam misturadas passam a se afastar, tornando-se linearmente separáveis por um hiperplano. Existem diversas funções capazes de realizar essa transformação geométrica, sendo o *kernel* Polinomial e o *kernel* Gaussiano RBF os mais utilizados na prática para garantir que o algoritmo se adapte perfeitamente à complexidade biológica do câncer.

Desenvolvidas na década de 1990 por Vladimir N. Vapnik, as SVMs tornaram-se aliadas robustas na pesquisa médica devido à sua capacidade de detectar tendências sutis em bases de dados complexas (Kavlakoglu, 2026a). O fundamento geométrico do algoritmo baseia-se na criação de uma fronteira de separação cuja natureza dimensional depende diretamente da quantidade de atributos dos dados de entrada: em um

espaço 2D, essa fronteira é uma linha simples, enquanto em espaços de dimensões superiores ela se projeta como um hiperplano n-dimensional (Kavlakoglu, 2026a).

A Figura 6 ilustra visualmente o funcionamento do truque de *kernel* aplicado pelo SVM. No espaço bidimensional à esquerda, os dados das duas classes encontram-se sobrepostos e misturados, tornando impossível a separação por qualquer fronteira linear. Por meio da função de mapeamento $\varphi(x_1, x_2) = (x_1, x_2, z)$, os pontos são projetados para um espaço tridimensional enriquecido com uma nova dimensão z , onde as classes passam a ocupar regiões distintas e geometricamente afastadas. Nesse espaço ampliado, o SVM é capaz de posicionar um hiperplano que separa com clareza os dois grupos, demonstrando como a elevação dimensional transforma um problema inicialmente insolúvel em uma tarefa de classificação linear viável (Kavlakoglu, 2026a).

FIGURA 6 – REPRESENTAÇÃO GEOMÉTRICA DO HIPERPLANO E MARGENS DE SEPARAÇÃO DO SVM



FONTE: AI Online Course, 2023, Disponível em: <https://www.coursera.org/learn/machine-learning/lecture/2s9nP/support-vector-machines>

O propósito central do algoritmo é encontrar a orientação ideal dessa fronteira para que ela maximize a distância ou a margem entre os pontos mais próximos de classes distintas, conhecidos como vetores de suporte (Kavlakoglu, 2026a). Essa lógica é frequentemente comparada ao ajuste da "rua mais larga possível" entre os dados, garantindo que o modelo não apenas separe os grupos, mas o faça com uma folga que favoreça a generalização para novos diagnósticos clínicos (Kavlakoglu, 2026a). Matematicamente, o hiperplano separador é descrito formalmente pela Equação 7, onde w é o vetor de peso que dita a inclinação da fronteira, x é o vetor de entrada e b representa o termo de viés que define a posição do plano no espaço (Kavlakoglu, 2026a).

$$wx + b = 0 \quad (7)$$

O modelo pode adotar uma configuração de margem rígida, exigindo que todos os dados sejam perfeitamente isolados fora da zona definida pelos vetores de suporte. Sob este regime, a maximização da margem projetada entre as classes é calculada pela Equação 8 (Kavlakoglu, 2026a).

$$\max \gamma = \frac{2}{\|w\|} \quad (8)$$

Para lidar com a complexidade e os ruídos inerentes aos dados oncológicos reais, utiliza-se alternativamente a classificação de margem flexível. Essa técnica permite estrategicamente a ocorrência de pequenos erros de classificação através do uso de variáveis de folga (ξ) e do hiperparâmetro de regularização C . Um valor de C elevado estreita a margem para minimizar classificações incorretas, enquanto um valor menor amplia a margem, permitindo uma maior tolerância a ruídos para evitar o sobreajuste e melhorar o desempenho preditivo (Kavlakoglu, 2026a).

Outra abordagem geométrica muito intuitiva para a classificação é o algoritmo KNN (*K-Nearest Neighbors*). Diferente dos modelos que processam os dados para construir uma equação fixa durante o treinamento, o KNN adota um método de aprendizado baseado em instâncias. Na prática, ele memoriza todo o conjunto de dados históricos de tumores. Quando os dados de um novo paciente são inseridos no sistema, o algoritmo calcula a distância matemática espacial, como a distância Euclidiana, entre as características dessa nova célula e todas as células antigas já armazenadas. O sistema então identifica os "K" vizinhos mais próximos, ou seja, os exames históricos que possuem as medidas anatômicas mais idênticas ao caso atual. O diagnóstico preditivo é determinado por uma votação simples nessa vizinhança. Se a maioria dos tumores vizinhos for maligna, o novo caso será classificado como maligno. A sua aplicação em sistemas médicos destaca-se pela facilidade de interpretação espacial por parte do profissional de saúde, embora o esforço computacional para calcular essas distâncias aumente consideravelmente em bases de dados muito volumosas (Faceli *et al.*, 2011).

Os conceitos iniciais que fundamentam o KNN foram propostos em 1951, sendo o modelo categorizado como de "aprendizado preguiçoso" ou baseado em memória. Isso significa que não há fase formal de treinamento prévio, pois o algoritmo apenas armazena os dados, exigindo que toda a computação ocorra no exato momento da previsão. Para determinar os vizinhos, o modelo fundamenta-se em métricas de distância, como a euclidiana ou a distância de Manhattan. Recomenda-se que o número de vizinhos (k) seja definido de forma ímpar para evitar empates decisórios. Apesar da simplicidade, o KNN sofre com a "maldição da dimensionalidade" e torna-se ineficiente em termos de memória à medida que a base cresce (Kavlakoglu, 2026b).

Entre as métricas disponíveis para mensurar essa proximidade, a Distância Euclidiana é a mais utilizada na prática. Ela representa o comprimento da linha reta que liga dois pontos no espaço de características, de forma análoga à distância física entre dois exames plotados em um gráfico. Sendo x e y dois vetores de características de pacientes distintos e n o número total de atributos considerados, essa distância é calculada conforme a Equação 9 (Kavlakoglu, 2026b):

$$d_E(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (9)$$

Outra métrica relevante é a Distância de Manhattan, que em vez de traçar um caminho diagonal entre os pontos, percorre as diferenças atributo a atributo de forma ortogonal, somando apenas os deslocamentos absolutos em cada dimensão. Essa abordagem torna o cálculo menos sensível a valores extremos isolados, o que pode ser vantajoso em conjuntos de dados clínicos com medidas discrepantes. Sua formulação é apresentada na Equação 10 (Kavlakoglu, 2026b):

$$d_M(x, y) = \sum_{i=1}^n |x_i - y_i| \quad (10)$$

Ambas as métricas são casos particulares da Distância de Minkowski, que as unifica por meio de um parâmetro p : atribuindo $p = 2$ recupera-se a fórmula euclidiana, enquanto $p = 1$ corresponde à distância de Manhattan (Kavlakoglu, 2026b). A escolha entre elas influencia diretamente a sensibilidade do algoritmo a variações nos dados clínicos, tornando essa decisão um passo relevante na configuração do modelo para cada contexto oncológico.

Explorando uma abordagem fundamentada em regras lógicas sucessivas, surgem os algoritmos baseados em Árvores de Decisão. Uma árvore individual funciona como um fluxograma hierárquico que parte de um nó raiz, se ramifica por nós internos de decisão e chega às folhas, onde a classificação final é atribuída. A cada etapa desse percurso, o algoritmo testa uma condição sobre uma característica celular, como o raio ou a textura do tumor, e encaminha cada amostra para o ramo correspondente até que ela alcance um nó terminal com um rótulo de classe definido (Kavlakoglu, 2026c).

A lógica que determina qual característica deve ser testada primeiro é guiada pelo conceito de entropia, oriundo da teoria da informação, que quantifica o grau de desordem ou impureza presente em um conjunto de dados. Em um nó que contenha apenas tumores malignos, por exemplo, não há nenhuma incerteza sobre a classe e a entropia é nula. Já em um nó com metade dos casos benignos e metade malignos, a incerteza é máxima e a entropia atinge seu valor mais alto. Sendo S o conjunto de dados de um nó, c cada uma das classes possíveis e $p(c)$ a proporção de amostras pertencentes à classe c , a entropia é calculada conforme a Equação 11 (Kavlakoglu, 2026c):

$$H(S) = - \sum_{c=1}^C p(c) \log_2 p(c) \quad (11)$$

A partir da entropia, o algoritmo calcula o ganho de informação de cada atributo disponível, que representa a redução de incerteza obtida ao dividir os dados segundo aquela característica. O atributo que produzir a maior redução de entropia é escolhido

como critério de divisão naquele nó, e o processo se repete recursivamente em cada subárvore resultante. O ganho de informação de um atributo a sobre o conjunto S é definido pela Equação 12, onde S_v representa o subconjunto de amostras em que o atributo a assume o valor v (Kavlakoglu, 2026c):

$$IG(S, a) = H(S) - \sum_v \frac{|S_v|}{|S|} H(S_v) \quad (12)$$

Esse critério é a base do algoritmo ID3, desenvolvido por Ross Quinlan em 1986, e de sua evolução, o C4.5, que introduziu melhorias na forma de lidar com atributos contínuos e dados faltantes. Estruturalmente, o aprendizado das árvores adota uma estratégia de dividir para conquistar, realizando buscas recursivas e descendentes até que os nós folha contenham amostras suficientemente homogêneas (Kavlakoglu, 2026c). Contudo, quando crescem sem restrições, as árvores individuais tornam-se extremamente suscetíveis ao *overfitting*, memorizando os dados de treinamento em vez de aprender padrões generalizáveis (Faceli *et al.*, 2011). Para conter esse problema, aplica-se a técnica de poda, que remove ramificações formadas sobre atributos de baixa relevância preditiva, em consonância com o princípio da parcimônia preconizado pela Navalha de Occam (Kavlakoglu, 2026c).

Para sanar essa vulnerabilidade da árvore única, a estatística computacional recorre à técnica *Random Forest*, ou Floresta Aleatória. Este modelo opera sob o paradigma de comitês de máquinas, criando grandes quantidades de árvores de decisão simultâneas de forma paralela. Para garantir que as árvores não tomem decisões idênticas, o algoritmo força uma diversidade matemática ao treinar cada uma delas com um subconjunto aleatório de pacientes e características. Ao submeter os dados de um novo exame ao modelo, o diagnóstico final não é imposto por uma única regra, mas determinado por uma votação majoritária entre todas as árvores que compõem a floresta. Essa dinâmica de sabedoria coletiva dilui os erros de árvores individuais e gera um sistema preditivo altamente estável e protegido contra anomalias (Faceli *et al.*, 2011).

A essência da floresta aleatória consiste em atuar como uma expansão avançada do método *bagging* (agregação *bootstrap*), incorporando também a aleatoriedade de características (método do subespaço aleatório) para forçar uma correlação extremamente baixa entre as árvores (IBM, 2026). Durante as amostragens no conjunto original, um terço dos dados é estrategicamente blindado sob a nomenclatura de amostra *out-of-bag* (oob), servindo primariamente para validações cruzadas (IBM, 2026). Um grande benefício clínico do *Random Forest* é a sua clareza na atribuição de importância preditiva das variáveis, mensurada com ferramentas como a diminuição média da impureza (MDI) e a importância por permutação (MDA) (IBM, 2026).

Ainda dentro do paradigma de comitês de máquinas, destaca-se o *Extreme*

Gradient Boosting, amplamente conhecido no mercado como *XGBoost*. Ao contrário da floresta aleatória que constrói todas as suas árvores de forma simultânea e independente, este algoritmo adota uma arquitetura sequencial focada no aprendizado com os próprios erros. A primeira árvore tenta classificar os tumores e inevitavelmente comete equívocos. A segunda árvore é construída com o propósito exclusivo de corrigir os erros da primeira, a terceira foca nos erros da segunda, e assim sucessivamente. Essa otimização contínua baseada na descida do gradiente cria um modelo preditivo de alto desempenho (Faceli *et al.*, 2011).

No ápice da complexidade arquitetônica encontram-se as Redes Neurais Artificiais, algoritmos inspirados no funcionamento biológico do cérebro humano. Elas são compostas por múltiplas camadas de neurônios matemáticos interconectados, capazes de extrair relacionamentos profundos ocultos nos dados oncológicos (Bishop, 2006). Entretanto, essa evolução tecnológica impõe um grave dilema clínico. À medida que a ciência avança da transparente Regressão Logística para as poderosas redes neurais e algoritmos sequenciais como o *XGBoost*, o modelo ganha acurácia estatística, mas perde drasticamente a sua interpretabilidade, transformando-se em uma caixa preta inescrutável. Na prática médica, entregar uma predição isolada não é eticamente aceitável, pois o oncologista necessita compreender as justificativas celulares do sistema. É exatamente para romper essa barreira analítica e resgatar a transparência das decisões que a Inteligência Artificial Explicável se torna indispensável.

2.4 O DILEMA DA CAIXA PRETA E A INTELIGÊNCIA ARTIFICIAL EXPLICÁVEL

A evolução dos sistemas computacionais na oncologia transitou de ferramentas visuais puramente assistenciais para algoritmos preditivos autônomos de alta complexidade. Modelos baseados em comitês de árvores e redes neurais profundas alcançam taxas de acerto notáveis na classificação de tumores. Contudo, essa elevada acurácia estatística impôs um custo severo à prática clínica, consolidando o que a literatura científica denomina como o dilema da caixa preta. Em um cenário de alto risco como o diagnóstico de câncer de mama, a previsão matemática isolada é insuficiente. O médico patologista não pode basear uma decisão terapêutica drástica, como uma intervenção cirúrgica, em um sistema que emite um alerta de malignidade sem fornecer o raciocínio biológico e morfológico que motivou tal conclusão (Holzinger *et al.*, 2019).

Para preencher essa lacuna entre a precisão matemática e a confiança médica, consolidou-se o campo da Inteligência Artificial Explicável, amplamente referenciado pela sigla em inglês XAI. O propósito primordial da XAI não é focar na criação de novos classificadores, mas sim no desenvolvimento de métodos e ferramentas que tornem o processo de decisão das máquinas transparente e compreensível para os seres humanos. Em aplicações médicas, a explicabilidade atua como uma camada de

auditoria e segurança. Ela permite que o especialista de saúde verifique se o algoritmo está baseando sua decisão em características celulares clinicamente válidas, como a concavidade e a textura do núcleo, em vez de aprender padrões espúrios ou artefatos irrelevantes presentes na base de dados (Adadi e Berrada, 2018).

Do ponto de vista arquitetônico, Rudin (2019) destaca que a explicabilidade se divide em duas abordagens fundamentais. A primeira consiste na utilização de modelos intrinsecamente interpretáveis, como a Regressão Logística ou uma única Árvore de Decisão, cujas equações matemáticas são naturalmente transparentes, embora frequentemente apresentem limitações de desempenho em dados biológicos complexos. A segunda abordagem engloba as técnicas de explicabilidade *post-hoc*. Estas técnicas são acopladas externamente a modelos de caixa preta após a fase de treinamento, extraindo interpretações sem alterar a estrutura interna do algoritmo original. No escopo deste estudo, opta-se pela segunda via. Ao aplicar métodos *post-hoc* sobre classificadores robustos, busca-se entregar ao oncologista uma ferramenta que alie o máximo desempenho preditivo da computação moderna à transparência analítica exigida pela ética médica.

2.5 SHAPLEY ADDITIVE EXPLANATIONS (SHAP)

A técnica *SHapley Additive exPlanations* (SHAP) representa o atual estado da arte em explicabilidade algorítmica. A sua base teórica não nasceu na ciência da computação, mas sim na teoria dos jogos cooperativos, formulada pelo matemático Lloyd Shapley. Na teoria original, o valor de Shapley calcula a contribuição exata e justa de cada jogador para o prêmio final obtido por uma equipe. Quando esse conceito é transportado para o aprendizado de máquina, o modelo preditivo assume o papel do jogo, as características celulares atuam como os jogadores e o prêmio a ser dividido é a predição final do algoritmo. De acordo com a documentação oficial da ferramenta, o SHAP atua como uma abordagem unificada, consolidando diversas metodologias anteriores sob a classe de métodos de atribuição de características aditivas para revelar os bastidores matemáticos da caixa preta (Lundberg e Lee, 2017).

Um dos grandes trunfos arquitetônicos da biblioteca SHAP, conforme detalhado em seu manual técnico, é a disponibilidade de otimizadores algorítmicos específicos denominados *explainers*. Como o cálculo de todas as combinações possíveis de variáveis possui um custo computacional altíssimo, a ferramenta oferece soluções otimizadas para diferentes modelos. Para algoritmos baseados em árvores, como o *Random Forest* e o *XGBoost*, a biblioteca disponibiliza o *TreeExplainer*, um algoritmo capaz de calcular os valores exatos de Shapley de forma extremamente rápida aproveitando a estrutura de roteamento interna das árvores. Para arquiteturas matemáticas distintas ou caixas pretas absolutas, o sistema recorre a algoritmos agnósticos, como o *KernelExplainer*,

garantindo que qualquer modelo oncológico possa ser dissecado independentemente de sua complexidade teórica (Lundberg, 2026).

O resultado desse robusto processamento matemático é traduzido em visualizações gráficas projetadas especificamente para a prática clínica e auditoria de dados. No escopo da interpretabilidade local, voltada para o diagnóstico de um único paciente, o SHAP fornece gráficos de cascata (*waterfall plots*) (Dutta, 2024). Essas representações ilustram milimetricamente como cada característica, como a textura ou a área do núcleo celular, empurrou a probabilidade do diagnóstico para cima ou para baixo a partir do valor base da população. No escopo global, o algoritmo compila todas as previsões em gráficos de enxame (*beeswarm plots* ou *summary plots*). Esse panorama permite que o médico observe não apenas quais variáveis são globalmente mais importantes para o classificador, mas também a direção biomédica desse impacto, revelando se os valores altos de uma determinada característica estão sistematicamente associados a tumores malignos (Adadi e Berrada, 2018).

Em comparação com outras ferramentas de explicabilidade disponíveis na literatura, como o modelo LIME, o método SHAP destaca-se por sua extrema robustez teórica. Enquanto outras técnicas tentam adivinhar o comportamento do algoritmo criando aproximações em torno dos dados locais, o SHAP garante propriedades matemáticas vitais de consistência e precisão local. Na prática, isso significa que a soma de todos os valores e pesos atribuídos a cada característica celular pelo SHAP resultará exatamente na previsão percentual final emitida pelo sistema principal. Essa garantia de exatidão torna o método estatisticamente seguro e incontestável para auditar diagnósticos críticos na área da saúde (Lundberg e Lee, 2017).

2.5.1 Fundamentação Matemática: A Equação de Shapley

Para compreender como a biblioteca computacional distribui os pesos das características oncológicas, é estritamente necessário analisar a equação matemática original proposta para o Valor de Shapley. O cálculo baseia-se na análise de todas as permutações e subconjuntos possíveis de jogadores em um cenário cooperativo. Seja N o conjunto total de características celulares disponíveis em um exame e S um subconjunto específico dessas características, o valor de Shapley para uma característica isolada i , denotado por ϕ_i , é definido pela Equação 13 (Lundberg e Lee, 2017):

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [v(S \cup \{i\}) - v(S)] \quad (13)$$

A interpretação desta equação revela a essência do método explicativo. O termo $v(S \cup \{i\}) - v(S)$ representa a contribuição marginal da característica i . Na prática médica, ele calcula a diferença entre a previsão de risco do modelo quando a característica i (como a simetria celular) está presente no exame e a previsão quando

ela é omitida daquela combinação específica. O algoritmo calcula essa diferença não apenas uma vez, mas para todos os subconjuntos S possíveis formados pelas outras variáveis do modelo (Lundberg e Lee, 2017).

A fração que antecede a contribuição marginal atua como um sistema de pesos baseado em probabilidade combinatória. Os termos fatoriais, representados pelo símbolo de exclamação, calculam o peso exato daquela coalizão específica se formar, garantindo que o valor final seja distribuído de maneira perfeitamente justa. Por fim, o somatório agrega todas essas contribuições marginais ponderadas. O resultado é um único valor ϕ_i que quantifica, com exatidão matemática, o impacto líquido que aquela característica anatômica exerceu para elevar ou reduzir a probabilidade de o tumor ser classificado como maligno (Lundberg e Lee, 2017).

2.6 REDUÇÃO DE DIMENSIONALIDADE E UMAP

A análise preditiva de tumores lida com um volume massivo de informações simultâneas. No caso do câncer de mama, o algoritmo avalia dezenas de características anatômicas em um único exame, como o raio, a textura e a simetria de cada núcleo celular (Street *et al.*, 1993). Embora os modelos matemáticos consigam processar e cruzar esses dados em um espaço de trinta dimensões com extrema facilidade, essa estrutura de alta dimensionalidade não possui uma representação física direta que possa ser desenhada ou interpretada visualmente. Essa assimetria estrutural cria um obstáculo analítico significativo na prática médica, pois inviabiliza a observação direta do comportamento de toda a base de pacientes utilizando os eixos convencionais de um gráfico bi ou tridimensional.

Para solucionar essa limitação biomédica, a ciência de dados recorre a técnicas de redução de dimensionalidade. O propósito primário dessas ferramentas não é simplesmente descartar variáveis anatômicas aleatoriamente, mas sim aplicar transformações matemáticas capazes de comprimir um grande volume de dimensões em apenas dois eixos principais (James *et al.*, 2023). O desafio central desse processo de compressão é preservar ao máximo a essência da informação original. Uma técnica metodologicamente eficiente deve garantir que a estrutura dos dados apresentada no gráfico bidimensional seja um reflexo direto e fiel das relações biológicas que existiam no espaço multidimensional complexo (Bollon *et al.*, 2022).

Entre as metodologias disponíveis na literatura estatística contemporânea, o algoritmo UMAP, que consiste na Aproximação e Projeção de Variedade Uniforme, consolidou-se como uma ferramenta de altíssimo desempenho para a redução de dimensionalidade. O seu funcionamento interno diverge de abordagens matemáticas puramente lineares ao fundamentar-se em princípios de topologia algébrica. Na primeira etapa de seu processamento computacional, o algoritmo constrói uma re-

apresentação teórica do conjunto de dados em seu espaço original de alta dimensão. Para isso, o modelo calcula as distâncias entre todos os pontos do sistema e mapeia rigorosamente os vizinhos mais próximos de cada elemento, formando um complexo grafo matemático que modela a estrutura exata de conectividade da informação original (McInnes *et al.*, 2018).

Uma vez que essa rede de vizinhanças é estabelecida, a segunda fase do algoritmo consiste em projetar essa estrutura em um espaço de dimensão reduzida, como um plano bidimensional. Para realizar essa transição geométrica sem descaracterizar os dados, o UMAP inicializa um posicionamento espacial e aplica um rigoroso processo de otimização. O sistema utiliza vetores de atração matemática para aproximar as coordenadas dos pontos que foram mapeados como vizinhos fortes no espaço original, ao mesmo tempo em que aplica métricas de repulsão para afastar os pontos que não possuíam conexões de similaridade. O algoritmo ajusta iterativamente essas posições até que o gráfico plano atinja a aproximação topológica mais fiel possível da complexa rede inicial (Bollon *et al.*, 2022).

O grande diferencial técnico desta arquitetura algorítmica reside na sua capacidade matemática de preservar simultaneamente a estrutura local e a estrutura global do conjunto de dados originais. Ao contrário de técnicas anteriores que frequentemente sacrificam a disposição geral em prol do ajuste de vizinhanças imediatas, o UMAP assegura que as proporções de distância sejam mantidas na projeção visual. Como resultado geométrico direto desse processamento topológico, elementos de dados com propriedades numéricas semelhantes convergem naturalmente para regiões isoladas do gráfico, formando densos agrupamentos visuais conhecidos na estatística descritiva como *clusters*. Essa capacidade inerente de revelar a separabilidade natural de bases complexas consolida o método como um recurso indispensável na análise exploratória avançada (Bollon *et al.*, 2022).

Apesar de sua complexidade matemática interna, a aplicação prática do UMAP exige a calibração de hiperparâmetros fundamentais que governam o resultado da projeção geométrica. De acordo com Bollon *et al.* (2022), o principal deles é o número de vizinhos mais próximos (*nearest neighbors* ou NN), que dita como o algoritmo constrói o grafo inicial, balanceando a atenção entre a estrutura local e global dos dados. Outro parâmetro crucial é a distância mínima (*minimum distance* ou MD), que controla o quão próximos os pontos podem ficar no espaço de baixa dimensão. Por fim, deve-se definir a métrica de saída, que determina a topologia do espaço latente, como a Euclidiana ou a Esférica. Nesse cenário, a sintonia exata desses valores é vital para aplicações oncológicas. Estudos voltados à estratificação de tumores de mama evidenciam, por exemplo, que a adoção de uma distância mínima nula maximiza a coesão biológica da separação espacial. Além disso, para assegurar a reprodutibilidade científica e contornar a natureza estocástica inerente à otimização do algoritmo, faz-se

necessária a adoção de estratégias de estabilização em sua execução (Bollon *et al.*, 2022). As características destes parâmetros estão sumarizadas no Quadro 1.

QUADRO 1 – PRINCIPAIS HIPERPARÂMETROS DO ALGORITMO UMAP

Hiperparâmetro	Descrição
Número de Vizinhos (NN)	Controla a construção do grafo inicial, ditando o equilíbrio entre a preservação da estrutura local e global dos dados.
Distância Mínima (MD)	Define o quão próximos os pontos podem ficar no espaço reduzido, afetando diretamente a compactação visual dos <i>clusters</i> .
Métrica de Saída	Determina o espaço geométrico (como Euclidiano ou Esférico) no qual as distâncias finais serão projetadas.

FONTE: Adaptado de (BOLLON *et al.*, 2022)

No ambiente de desenvolvimento, a implementação desta técnica é frequentemente realizada por meio da biblioteca *umap-learn* em Python. O Código 1 ilustra a instanciação do algoritmo com a definição de seus respectivos hiperparâmetros para a posterior redução de dimensionalidade de um conjunto de dados clínicos.

CÓDIGO 1 – IMPLEMENTAÇÃO DA REDUÇÃO DIMENSIONAL UTILIZANDO O ALGORITMO UMAP EM PYTHON.

```

1  import umap
2
3  # Configuracao e instanciacao do redutor topologico
4  redutor = umap.UMAP(
5      n_neighbors=65,
6      min_dist=0.0,
7      metric='euclidean',
8      random_state=42
9  )
10
11 # Aplicacao da reducao dimensional na base de dados
12 dados_reduzidos = redutor.fit_transform(dados_pacientes)


```

FONTE: O autor

A eficácia dessa convergência topológica pode ser observada na Figura 7. A imagem ilustra a projeção geométrica gerada pelo UMAP a partir de uma base de dados de pacientes com câncer de mama. É possível notar nitidamente como a redução de dimensionalidade preserva a estrutura biológica original: os diferentes subtipos tumorais agrupam-se em *clusters* densos e isolados no novo espaço reduzido. Essa representação comprova a capacidade visual do algoritmo em evidenciar a

separabilidade natural e as relações de similaridade em bases oncológicas de alta dimensionalidade (Bollon *et al.*, 2022).

FIGURA 7 – PROJEÇÃO UMAP E FORMAÇÃO DE CLUSTERS EM DADOS DE CÂNCER DE MAMA



FONTE: Adaptado de (BOLLON *et al.*, 2022)

3 TRABALHOS RELACIONADOS

Este capítulo apresenta uma análise detalhada da literatura científica que fundamenta o estado da arte no uso de aprendizado de máquina para o diagnóstico oncológico. A seleção abrange desde os estudos seminais que deram origem às bases de dados modernas até pesquisas recentes focadas em inteligência artificial explicável, estabelecendo o contexto necessário para a identificação da lacuna de pesquisa preenchida por este projeto.

3.1 EXTRAÇÃO DE CARACTERÍSTICAS NUCLEARES PARA O DIAGNÓSTICO DE TUMORES MAMÁRIOS (STREET *ET AL.*, 1993)

O trabalho conduzido por Street *et al.* (1993) é considerado a pedra angular para o desenvolvimento de sistemas de diagnóstico assistido por computador aplicados ao câncer de mama. O objetivo primordial da pesquisa foi desenvolver um sistema que pudesse processar imagens digitais de aspirados por agulha fina para fornecer um diagnóstico maligno ou benigno de forma automatizada e precisa.

A metodologia baseou-se na criação de um sistema de análise de imagens que permitia ao usuário delimitar grosseiramente as bordas dos núcleos celulares. A partir dessa interação inicial, o software calculava automaticamente dez características geométricas distintas para cada núcleo, incluindo o raio, o perímetro, a textura e a simetria. Esse processo gerou a base de dados conhecida como *Wisconsin Diagnostic Breast Cancer* (WDBC), que é utilizada como padrão ouro na literatura acadêmica até os dias atuais.

Os resultados obtidos na época demonstraram uma acurácia de classificação de noventa e sete por cento utilizando um classificador baseado em programação linear. O trabalho provou que as medidas nucleares, quando extraídas de forma sistemática, continham informações estatísticas suficientes para diferenciar tumores sem a necessidade de intervenções invasivas imediatas.

Para este projeto de graduação, este estudo é fundamental pois define a origem e o significado biológico de cada uma das variáveis que serão processadas pelos modelos de SHAP e UMAP. Compreender a gênese dos dados permite uma interpretação mais rica das explicações fornecidas pela inteligência artificial explicável.

3.2 APLICAÇÕES DE MACHINE LEARNING NA PREDIÇÃO E PROGNÓSTICO DO CÂNCER (CRUZ E WISHART, 2006)

A revisão sistemática elaborada por Cruz e Wishart (2006) ofereceu um panorama crítico sobre como as técnicas de aprendizado de máquina estavam migrando de laboratórios de pesquisa para aplicações práticas no prognóstico oncológico. O foco

do estudo foi avaliar a viabilidade de substituir métodos estatísticos convencionais por modelos preditivos mais robustos.

Os autores analisaram diversas arquiteturas, como as Máquinas de Vetores de Suporte (SVM) e Redes Neurais Artificiais, destacando que a complexidade biológica do câncer exigia ferramentas capazes de lidar com relacionamentos não lineares. A pesquisa ressaltou que, embora o câncer de mama fosse o mais estudado, a metodologia poderia ser estendida para outros tipos de neoplasias, como as de próstata e pulmão.

Uma das conclusões mais relevantes deste trabalho foi a identificação de que a acurácia isolada não era o único fator de sucesso. Os pesquisadores apontaram que a qualidade dos dados de entrada e a seleção cuidadosa de variáveis eram determinantes para a utilidade clínica do modelo.

Este estudo corrobora a necessidade de superar as limitações da estatística básica na oncologia. No entanto, a busca por capturar as nuances da malignidade celular não deve resultar em modelos de complexidade interpretativa inacessível. A abordagem deste trabalho enfatiza que, no contexto médico, modelos preditivos que priorizam a simplicidade e a explicabilidade trazem vantagens substanciais, permitindo que a equipe de saúde compreenda e confie nos critérios lógicos que fundamentam o diagnóstico.

3.3 SEGMENTAÇÃO E CONTAGEM DE CÉLULAS EM IMAGENS (SILVA JÚNIOR, 2018)

Desenvolvido no contexto acadêmico de Curitiba, o trabalho de Silva Silva Júnior (2018) focou no desenvolvimento de um *pipeline* detalhado para o processamento digital de imagens microscópicas de câncer de mama. O objetivo era automatizar a tarefa exaustiva de contagem e segmentação de núcleos celulares realizada por patologistas.

A abordagem metodológica utilizou técnicas de processamento de imagens para isolar componentes celulares e reduzir o ruído visual das lâminas. O autor detalhou cada etapa do fluxo de trabalho, desde a captura da imagem até a extração final de dados quantitativos, enfatizando os desafios técnicos de lidar com células sobrepostas ou imagens de baixa qualidade.

Embora o foco principal fosse a segmentação e não a classificação preditiva, o trabalho demonstrou a importância de transformar evidências visuais em dados tabulares estruturados. O autor concluiu que a automação dessas etapas iniciais reduz significativamente a fadiga do profissional de saúde e aumenta a reprodutibilidade dos diagnósticos.

A relevância deste estudo para o presente projeto reside na compreensão da

infraestrutura necessária para gerar os dados de entrada. Enquanto este TCC foca na inteligência preditiva e explicável sobre dados já estruturados, o trabalho de Silva Júnior fornece a base sobre como esses dados são extraídos do mundo físico.

3.4 DIAGNÓSTICO DE CÂNCER DE PULMÃO E CÓLON VIA DEEP LEARNING (MASUD *ET AL.*, 2021)

A pesquisa de Masud *et al.* (2021) explorou o uso de Redes Neurais Profundas para o diagnóstico de câncer em tecidos pulmonares e colorretais. O diferencial do trabalho foi o uso de uma estrutura de classificação baseada em imagens de histopatologia para identificar padrões malignos de forma automática.

O modelo desenvolvido utilizou técnicas de aprendizado profundo para extrair características de alto nível que muitas vezes são imperceptíveis ao olho humano. Os autores conseguiram alcançar métricas de desempenho superiores a noventa e seis por cento de acurácia, demonstrando o poder das arquiteturas modernas de inteligência artificial na oncologia.

Contudo, os pesquisadores notaram que modelos de rede neural profunda, apesar de precisos, operam como sistemas de difícil interpretação. O estudo concluiu que a integração de sistemas computacionais na medicina requer um equilíbrio entre a capacidade de processamento e a facilidade de uso pelo corpo clínico.

Este trabalho é citado para contrastar com a abordagem tabular deste TCC. Ele exemplifica o estado da arte em processamento de imagens, servindo de base para discutir por que a explicabilidade se torna ainda mais necessária quando lidamos com modelos de alta complexidade como os de *Deep Learning*.

3.5 PREDIÇÃO DE CÂNCER DE PULMÃO COM SELEÇÃO DE CORRELAÇÃO (ABDULLAH *ET AL.*, 2021)

Focando na eficiência computacional, Abdullah *et al.* (2021) investigaram como a seleção inteligente de variáveis pode melhorar a precisão do diagnóstico de câncer de pulmão. O objetivo era identificar quais características clínicas e genéticas eram mais correlacionadas com a presença da doença.

A metodologia utilizou a ferramenta WEKA para testar diversos classificadores, com destaque para as Máquinas de Vetores de Suporte (SVM). Os autores aplicaram um método de seleção baseado em correlação para remover variáveis irrelevantes ou redundantes, buscando um modelo mais enxuto e rápido.

Os resultados mostraram que modelos com menos variáveis, porém mais significativas, apresentavam desempenho equivalente ou superior a modelos que utilizavam todos os dados disponíveis. Isso demonstrou que o excesso de informação pode, por vezes, prejudicar o aprendizado da máquina.

Este estudo corrobora a utilidade do UMAP no presente projeto. Ao discutir a redução de dimensionalidade, o trabalho de Abdullah et al. fornece o embasamento sobre como a simplificação de dados complexos pode levar a diagnósticos mais precisos e interpretáveis.

3.6 ABORDAGENS DE MACHINE LEARNING NA PREDIÇÃO DO CÂNCER DE MAMA (RABIEI *ET AL.*, 2022)

O estudo de Rabiei *et al.* (2022) avaliou diferentes algoritmos de aprendizado de máquina aplicados a dados hospitalares reais de câncer de mama. O foco principal foi lidar com o problema de bases de dados desbalanceadas, onde o número de casos benignos costuma ser muito superior aos malignos.

Os pesquisadores testaram modelos como Regressão Logística, *Random Forest* e Redes Neurais. Para corrigir o desbalanceamento, utilizaram técnicas de sobreamostragem, permitindo que os algoritmos aprendessem com a mesma eficácia sobre ambas as classes de tumores.

As conclusões apontaram que o algoritmo *Random Forest* obteve o melhor equilíbrio entre sensibilidade e especificidade. O trabalho enfatizou que o ajuste de hiperparâmetros e o pré-processamento rigoroso são as chaves para a obtenção de modelos confiáveis em ambientes médicos.

Para este TCC, a pesquisa de Rabiei et al. serve como uma referência metodológica para a fase de treinamento dos modelos. Ela valida a inclusão de comitês de árvores no conjunto de classificadores a serem testados e explicados via SHAP.

3.7 PREDIÇÃO BASEADA EM APRENDIZADO DE MÁQUINA (CHEN *ET AL.*, 2023)

A pesquisa de Chen *et al.* (2023) revisitou o desafio da classificação do câncer de mama focando na robustez das métricas de avaliação. O objetivo era determinar quais algoritmos eram mais seguros para a adoção clínica, priorizando a redução de falsos negativos.

O estudo utilizou a base de dados de Wisconsin para treinar modelos e compará-los através de curvas ROC e métricas de precisão. Os autores destacaram que a inteligência artificial não deve ser vista como um substituto para o médico, mas como uma ferramenta de segunda opinião capaz de filtrar casos suspeitos com alta velocidade.

Os resultados confirmaram a eficácia dos modelos de *Boosting* para este tipo de dado tabular. A pesquisa concluiu que a integração desses modelos em sistemas de apoio à decisão poderia acelerar significativamente o início do tratamento de pacientes oncológicos.

Este trabalho é relevante por ser uma das publicações mais recentes sobre a mesma base de dados utilizada neste projeto. Ele estabelece o patamar de acurácia que este TCC deve buscar atingir ou superar antes de aplicar as camadas de explicabilidade.

3.8 ESTUDO COMPARATIVO COM SELEÇÃO LASSO E SHAP (SHAON *ET AL.*, 2024)

Considerado o trabalho mais próximo da proposta deste TCC, Shaon *et al.* (2024) realizaram uma comparação de modelos preditivos utilizando técnicas modernas de seleção de atributos e explicabilidade. O objetivo era não apenas prever o câncer, mas entender quais variáveis eram determinantes para o modelo.

A metodologia integrou o uso de LASSO para a regularização dos dados e o SHAP para a interpretabilidade local e global. Os autores alcançaram uma acurácia de noventa e nove por cento, demonstrando que é possível unir alto desempenho com transparência analítica.

O estudo concluiu que o uso de valores de Shapley oferece uma justificativa robusta para cada diagnóstico, permitindo que médicos confiem nos resultados apresentados. No entanto, o trabalho limitou-se à análise técnica dos dados, sem propor uma ferramenta de interface para o usuário final.

Este artigo representa o "estado da arte" atual e serve como o principal ponto de comparação. O diferencial deste TCC em relação ao trabalho de Shaon *et al.* é a inclusão do UMAP para visualização topológica e o desenvolvimento de um software completo com interface gráfica, indo além da análise estatística pura.

3.9 SÍNTESE E LACUNA DE PESQUISA

A análise dos trabalhos relacionados permite concluir que, embora existam pesquisas robustas focadas na acurácia preditiva e estudos recentes explorando a técnica SHAP, ainda há uma carência de soluções que integrem esses elementos em uma ferramenta de software coesa e utilizável pelo profissional de saúde.

Muitos dos modelos propostos na literatura permanecem restritos a ambientes de programação ou relatórios estáticos. O Quadro 2 sintetiza a comparação entre as obras citadas e a proposta deste projeto. A contribuição acadêmica deste trabalho reside na integração de quatro elementos que, isoladamente, já foram explorados na literatura, mas que não foram reunidos em uma única solução: o treinamento e a comparação sistemática de algoritmos clássicos de aprendizado de máquina supervisionado sobre a base Wisconsin, a aplicação do SHAP para explicabilidade local e global das decisões, a utilização do UMAP para visualização topológica da separabilidade dos dados, e o desenvolvimento de uma interface funcional capaz de processar dados em lote e gerar relatórios estruturados com as fundamentações visuais dos diagnósticos.

QUADRO 2 – COMPARAÇÃO ENTRE TRABALHOS RELACIONADOS E O PRESENTE PROJETO.

Trabalho	ML	Base Pública	Tabular	Câncer de mama	Interface	XAI
Street <i>et al.</i> (1993)	Sim	—	Não	Sim	Sim	Não
Cruz & Wishart (2006)	Sim	Sim	Sim	Não	Não	Não
Silva Júnior (2018)	Não	Sim	Não	Sim	Não	Não
Masud <i>et al.</i> (2021)	Sim	Sim	Não	Não	Não	Não
Abdullah <i>et al.</i> (2021)	Sim	Sim	Sim	Não	Não	Não
Rabiei <i>et al.</i> (2022)	Sim	Não	Sim	Sim	Não	Não
Chen <i>et al.</i> (2023)	Sim	Sim	Sim	Sim	Não	Não
Shaon <i>et al.</i> (2024)	Sim	Sim	Sim	Sim	Não	Sim
Este Projeto	Sim	Sim	Sim	Sim	Sim	Sim

FONTE: O autor

4 METODOLOGIA

Este capítulo descreve o processo técnico de desenvolvimento da solução proposta, abrangendo desde a preparação dos dados até a serialização dos artefatos que alimentam o software. A construção é dividida em dois componentes principais, detalhados nas seções seguintes: o módulo científico, responsável pelo treinamento e avaliação dos modelos, e o módulo de software, responsável pela interface de uso pelo profissional de saúde.

4.1 CLASSIFICAÇÃO DA PESQUISA

A correta caracterização do tipo de pesquisa é um requisito metodológico fundamental, pois delimita o escopo do trabalho e orienta as decisões relacionadas à coleta de dados, à escolha dos instrumentos de análise e à forma de apresentação dos resultados. Neste contexto, o presente trabalho pode ser classificado segundo quatro dimensões complementares.

Quanto à sua natureza, a pesquisa é classificada como aplicada, pois seu objetivo central não é a geração de conhecimento teórico abstrato, mas sim o desenvolvimento de uma solução computacional concreta voltada a um problema real da área da saúde: a opacidade dos modelos preditivos utilizados no diagnóstico oncológico (Gil, 2002).

Quanto à abordagem, a pesquisa é quantitativa, uma vez que todo o processo de modelagem, avaliação e comparação entre os algoritmos fundamenta-se no tratamento numérico de dados morfológicos celulares e na mensuração objetiva do desempenho dos modelos por meio de métricas estatísticas formalmente definidas (Faceli *et al.*, 2011).

Quanto ao objetivo, o trabalho possui caráter simultaneamente preditivo e exploratório. O componente preditivo manifesta-se no treinamento de classificadores supervisionados capazes de estimar a probabilidade de malignidade de um tumor a partir de seus atributos morfológicos. O componente exploratório está presente na investigação visual da estrutura dos dados por meio de técnicas de redução de dimensionalidade, permitindo identificar padrões, agrupamentos e relações de similaridade que não são diretamente observáveis no espaço original de trinta dimensões (Cruz e Wishart, 2006).

Quanto ao procedimento, a pesquisa é classificada como experimental e computacional. O desenvolvimento ocorre integralmente em ambiente de programação controlado, com experimentos reproduzíveis garantidos pela fixação de sementes de aleatoriedade, divisão padronizada dos dados e registro sistemático das métricas de cada modelo avaliado (Faceli *et al.*, 2011).

4.2 VISÃO GERAL DA ARQUITETURA DA SOLUÇÃO

A arquitetura da solução proposta foi concebida sob uma perspectiva modular, visando segregar de forma clara a etapa de experimentação e modelagem estatística do ambiente de produção e interação com o usuário. Essa estratégia de projeto garante o desacoplamento do sistema, otimiza a manutenibilidade do código e simplifica a distribuição da ferramenta, dividindo o ecossistema em dois componentes fundamentais: o módulo científico e o módulo de software.

O módulo científico é centralizado no *notebook* Wisconsin.ipynb. Este componente engloba todo o *pipeline* experimental do projeto, compreendendo as rotinas de análise exploratória dos dados (EDA), preparação dos atributos preditivos, tratamento de inconsistências, codificação de variáveis e padronização *Z-score* das características morfológicas. Além disso, é neste ambiente que ocorre o treinamento e a avaliação dos algoritmos de aprendizado de máquina supervisionado nos conjuntos de treino e teste, bem como a configuração dos modelos de Inteligência Artificial Explicável acoplados via bibliotecas shap e umap-learn.


Por outro lado, o módulo de software compreende a aplicação de interface gráfica desktop estruturada dentro do diretório app, tendo o script main.py como ponto de entrada principal do sistema. Construído sobre a biblioteca CustomTkinter, este componente gerencia a experiência do usuário final, operando as telas de consulta, dashboards de métricas e a lógica de processamento em lote. Para mitigar erros humanos e otimizar a rotina de trabalho em ambientes clínicos, a aplicação foi projetada para receber diretamente arquivos de planilhas formatadas, eliminando a necessidade de inserção manual dos trinta atributos preditivos por parte do operador.

A comunicação e a transferência de inteligência entre esses dois ambientes independentes ocorrem por meio do arquivo serializado wisconsin.pkl, gerado através da biblioteca pickle. Este artefato estático encapsula os modelos preditivos previamente treinados, os parâmetros ajustados do padronizador *Z-score* e a lista ordenada dos nomes dos atributos morfológicos. Dessa forma, o módulo de software realiza inferências em tempo real de modo puramente local, sem a necessidade de retreinar os algoritmos ou expor os dados a servidores externos, garantindo desempenho computacional e privacidade à infraestrutura de saúde.

A escolha por uma arquitetura desacoplada em dois módulos distintos também reflete uma decisão de manutenibilidade a longo prazo. Caso seja necessário retreinar os modelos com uma base de dados atualizada ou substituir o algoritmo principal, basta reexecutar o módulo científico e gerar um novo arquivo wisconsin.pkl, sem qualquer alteração no código do módulo de software. Da mesma forma, melhorias na interface gráfica ou na lógica de geração de relatórios podem ser realizadas de forma independente, sem risco de comprometer a integridade dos modelos preditivos já

validados. O fluxo completo de processamento e a respectiva transição dos dados entre as camadas lógica e operacional da arquitetura integrada encontram-se detalhados na Figura 8.

FIGURA 8 – DIAGRAMA DE BLOCOS DO FLUXO DE DADOS E COMUNICAÇÃO DA ARQUITETURA



FONTE: O Autor

4.3 BASE DE DADOS E AMBIENTE DE DESENVOLVIMENTO

A base de dados utilizada neste projeto é a *Breast Cancer Wisconsin (Diagnostic)*, disponibilizada publicamente no repositório UCI Machine Learning Repository e referenciada ao longo deste trabalho como base Wisconsin. O arquivo `data.csv` é composto por 569 amostras e 32 colunas em sua forma bruta: um identificador numérico único (`id`), a variável alvo (`diagnosis`) e trinta atributos morfológicos numéricos extraídos computacionalmente dos núcleos celulares obtidos via Punção Aspirativa por Agulha Fina, conforme descrito por Street *et al.* (1993).

Antes do início do *pipeline* de modelagem, duas colunas foram removidas da base por não agregarem valor preditivo ao sistema. A coluna `id` consiste em um identificador administrativo sem qualquer significado morfológico ou biológico e, caso mantida, introduziria ruído espúrio no processo de aprendizado. A coluna `Unnamed: 32`, por sua vez, é um artefato gerado automaticamente durante a exportação do arquivo no formato CSV, não correspondendo a nenhum atributo real da base original. Após essas remoções, o conjunto de dados utilizado para modelagem passa a conter 569 amostras e 31 colunas: a variável alvo e os trinta atributos preditivos.

O ambiente de desenvolvimento foi fixado na versão Python 3.11.15, decisão motivada pela necessidade de compatibilidade entre o módulo científico (`Wisconsin.ipynb`) e o módulo de software (`app/main.py`). A fixação da versão garante que os artefatos serializados via pickle sejam carregados corretamente pela aplicação, evitando incompatibilidades entre versões do interpretador que poderiam corromper os objetos `scikit-learn` persistidos no arquivo `wisconsin.pkl`.

Todo o desenvolvimento foi realizado em um ambiente virtual isolado, garantindo que as versões das bibliotecas listadas no arquivo `requirements.txt` permanecessem estáveis e reproduzíveis independentemente do sistema operacional utilizado. Essa prática é amplamente recomendada em projetos de ciência de dados, pois elimina

conflitos entre dependências e assegura que qualquer colaborador ou avaliador consiga reproduzir os experimentos nas mesmas condições em que foram conduzidos

O Quadro 3 apresenta as principais bibliotecas empregadas no módulo científico, com suas respectivas funções no projeto.

QUADRO 3 – BIBLIOTECAS UTILIZADAS NO MÓDULO CIENTÍFICO.

Biblioteca	Função no Projeto
pandas	Carregamento do arquivo CSV, remoção das colunas id e Unnamed: 32, codificação da variável alvo e manipulação dos subconjuntos de dados.
scikit-learn	Treinamento dos cinco classificadores, pré-processamento (StandardScaler, train_test_split), decomposição linear via PCA e cálculo das métricas de avaliação.
umap-learn	Redução de dimensionalidade não linear para visualização topológica da separabilidade natural entre tumores benignos e malignos.
shap	Cálculo dos valores de Shapley para explicabilidade global (<i>summary plot</i>) e local (<i>waterfall plot</i>) das predições do modelo selecionado.
matplotlib	Geração das visualizações estáticas: histogramas, <i>boxplots</i> e projeções UMAP e PCA.
seaborn	Geração de gráficos estatísticos: <i>countplot</i> de distribuição de classes e <i>heatmap</i> das matrizes de confusão.
yellowbrick	Visualização complementar de métricas e diagnósticos do processo de aprendizado de máquina.
pickle	Serialização dos modelos treinados, do escalonador ajustado e da lista de atributos no arquivo wisconsin.pkl.

FONTE: O autor

4.4 PRÉ-PROCESSAMENTO DOS DADOS

O pré-processamento dos dados constitui uma etapa fundamental para garantir a qualidade e a confiabilidade dos modelos preditivos desenvolvidos. Antes de qualquer

algoritmo de aprendizado ser instanciado, os dados brutos da base Wisconsin passam por uma sequência de transformações que os tornam adequados para o treinamento supervisionado. As subseções a seguir detalham cada etapa desse *pipeline*, executado na ordem em que aparece no módulo científico.

4.4.1 Codificação da Variável Alvo

A variável alvo da base Wisconsin, denominada *diagnosis*, armazena os rótulos das amostras em formato categórico: o caractere B para tumores benignos e M para tumores malignos. Como os algoritmos de aprendizado de máquina supervisionado operam exclusivamente sobre valores numéricos, essa coluna é convertida para uma representação binária antes do treinamento. O mapeamento adotado atribui o valor 0 à classe benigna e o valor 1 à classe maligna, convenção amplamente consolidada na literatura para problemas de classificação binária em oncologia (Street *et al.*, 1993). Aproveitando a mesma etapa, duas colunas são removidas da base por não agregarem valor preditivo ao sistema, conforme descrito na Seção 4.3. O Código 2 apresenta as operações de limpeza e codificação realizadas sobre o DataFrame bruto.

CÓDIGO 2 – LIMPEZA E CODIFICAÇÃO DA VARIÁVEL ALVO.

```

1  # Remocao de colunas sem valor preditivo
2  wisconsin_base = wisconsin_base.drop(
3      columns=['id', 'Unnamed: 32'], errors='ignore'
4  )
5
6  # Codificacao do rotulo: 'B' (Benigno) -> 0 / 'M' (Maligno) -> 1
7  wisconsin_base['diagnosis'] = wisconsin_base['diagnosis'].map(
8      {'B': 0, 'M': 1}
9  )
10
11 # Separacao entre atributos (X) e variavel alvo (y)
12 X = wisconsin_base.drop(columns=['diagnosis'])
13 y = wisconsin_base['diagnosis']

```

FONTE: O autor

4.4.2 Divisão Treino e Teste

Após a codificação da variável alvo, a base é particionada em dois subconjuntos mutuamente exclusivos: treino e teste. O conjunto de treino, composto por 75% das amostras (426 registros), é utilizado para o ajuste dos parâmetros internos de cada classificador. O conjunto de teste, com os 25% restantes (143 registros), permanece completamente isolado durante todo o desenvolvimento e é acionado apenas na etapa final de avaliação, simulando o comportamento do modelo diante de dados clínicos inéditos.

Um aspecto metodológico crítico desta divisão é o uso do parâmetro `stratify=y`, conforme demonstrado no Código 3. Esse parâmetro instrui a função a realizar uma amostragem estratificada, garantindo que a proporção original entre as classes, sendo 357 tumores benignos (62,7%) e 212 malignos (37,3%), seja preservada em ambos os subconjuntos. Sem essa estratificação, uma partição aleatória desfavorável poderia concentrar a maioria dos casos malignos em um único subconjunto, introduzindo viés no treinamento e comprometendo a validade estatística da avaliação final. A semente `RANDOM_STATE = 42` é fixada para garantir a reprodutibilidade dos resultados.

CÓDIGO 3 – DIVISÃO ESTRATIFICADA DA BASE EM CONJUNTOS DE TREINO E TESTE.

```

1  # Split estratificado (75% treino | 25% teste)
2  # stratify=y: mantem a proporcao original de classes em ambos os conjuntos
3  X_train, X_test, y_train, y_test = train_test_split(
4      X, y, test_size=0.25, random_state=RANDOM_STATE, stratify=y
5  )

```

FONTE: O autor

4.4.3 Padronização Z-score

Com os subconjuntos definidos, aplica-se a padronização *Z-score* sobre os atributos numéricos por meio do `StandardScaler` da biblioteca `scikit-learn`. Essa transformação recalcula cada valor subtraindo a média da coluna e dividindo pelo desvio padrão, de forma que todos os atributos passem a operar em uma escala comum com média zero e variância unitária. Essa etapa é indispensável para algoritmos sensíveis à magnitude das variáveis, como a Regressão Logística, o SVM e o KNN, nos quais diferenças de escala entre atributos, como o raio celular medido em micrômetros e a textura medida em níveis de cinza, distorceriam o cálculo das distâncias e dos gradientes.

A decisão mais importante desta etapa, ilustrada no Código 4, é que o `StandardScaler` é ajustado exclusivamente sobre o conjunto de treino. O mesmo objeto já calibrado é então aplicado tanto ao conjunto de teste quanto à base completa. Esse procedimento evita o *data leakage*: se o escalonador fosse ajustado sobre todos os dados antes da divisão, informações estatísticas do conjunto de teste contaminariam o processo de treinamento, produzindo uma estimativa artificialmente otimista do desempenho real do modelo (Faceli *et al.*, 2011).

4.4.4 Divisão Legada para a Árvore de Decisão

O módulo científico mantém uma segunda partição dos dados, independente da descrita na Subseção 4.4.2, utilizada exclusivamente pela Árvore de Decisão em

CÓDIGO 4 – AJUSTE E APLICAÇÃO DO PADRONIZADOR Z-SCORE.

```

1  # Ajuste exclusivamente sobre o treino para evitar data leakage
2  scaler          = StandardScaler().fit(X_train)
3  X_train_scaled  = scaler.transform(X_train)
4  X_test_scaled   = scaler.transform(X_test)
5  X_scaled_all    = scaler.transform(X)    # base completa - visualizacoes e
      SHAP

```

FONTE: O autor

sua função de modelo *baseline*. Essa divisão adota a proporção 80/20 e não aplica padronização *Z-score*, pois árvores de decisão são algoritmos invariantes à escala dos atributos, uma vez que suas regras de divisão baseiam-se em limiares de valor absoluto, não em distâncias ou gradientes (Faceli *et al.*, 2011). A manutenção dessa partição separada preserva os resultados obtidos nas etapas iniciais de desenvolvimento do projeto, anteriores à refatoração do *pipeline* principal, garantindo a rastreabilidade e a reprodutibilidade do histórico experimental.

CÓDIGO 5 – DIVISÃO LEGADA UTILIZADA PELA ÁRVORE DE DECISÃO.

```

1  # Divisao legada: 80% treino / 20% teste (sem padronizacao)
2  # Mantida para preservar os resultados originais da Arvore de Decisao
3  x_wisconsin_train, x_wisconsin_test, y_wisconsin_train, y_wisconsin_test
    = \
4      train_test_split(
5          X.values, y.values, test_size=0.2, random_state=RANDOM_STATE
6      )

```

FONTE: O autor

4.5 ANÁLISE EXPLORATÓRIA DOS DADOS

A análise exploratória dos dados (EDA) constitui uma etapa preliminar indispensável ao desenvolvimento de qualquer modelo preditivo. Antes de submeter os dados ao treinamento dos classificadores, é necessário compreender a estrutura, a distribuição e a qualidade das informações disponíveis. Essa inspeção permite identificar eventuais inconsistências, avaliar o balanceamento entre as classes e observar o comportamento estatístico dos atributos morfológicos, subsidiando decisões metodológicas nas etapas subsequentes do *pipeline*.

4.5.1 Estatísticas Descritivas

A primeira etapa da EDA consistiu na inspeção estrutural do *DataFrame* por meio dos métodos `info()` e `describe()` da biblioteca *pandas*. O método `info()` confirmou que a base, após a remoção das colunas não preditivas, contém 569 amostras e 31

colunas, a variável alvo e os trinta atributos morfológicos numéricos, sem a presença de valores ausentes em nenhuma das colunas, dispensando etapas de inserção de dados.

O método `describe()` forneceu as estatísticas descritivas de cada atributo, incluindo média, desvio padrão, valores mínimo e máximo e os quartis Q1, Q2 e Q3. A análise dessas estatísticas revelou amplitudes consideravelmente distintas entre os atributos: variáveis como `area_worst` operam em escalas na casa dos milhares, enquanto atributos como `symmetry_mean` assumem valores entre 0 e 1. Essa disparidade de magnitude reforça a necessidade da padronização *Z-score* aplicada na Seção 4.4, especialmente para os algoritmos sensíveis à escala, como a Regressão Logística, o SVM e o KNN.

4.5.2 Distribuição das Classes

A distribuição da variável alvo foi verificada por meio de um gráfico de barras (*countplot*), conforme apresentado na Figura ???. A contagem confirmou um leve desbalanceamento entre as classes: 357 amostras pertencem à classe benigna (62,7%) e 212 à classe maligna (37,3%). Embora essa proporção não caracterize um desbalanceamento severo, ela é suficiente para que a acurácia isolada se torne uma métrica enganosa, na qual um classificador trivial que sempre predisse benigno atingiria 62,7% de acurácia sem aprender nenhum padrão real. Por essa razão, a avaliação dos modelos prioriza métricas como Sensibilidade, F1-score e PR-AUC, que mensuram o desempenho sobre a classe minoritária de forma mais fiel (Davis e Goadrich, 2006).

4.5.3 Histogramas dos Atributos

Os trinta atributos morfológicos foram inspecionados por meio de uma grade de histogramas com 6 linhas e 5 colunas, utilizando 20 intervalos (*bins*) por variável, conforme exibido na Figura ???. A visualização evidenciou que a maioria dos atributos apresenta distribuição assimétrica à direita, com concentração de valores em magnitudes menores e caudas alongadas em direção aos valores máximos. Esse comportamento é esperado em medidas morfológicas celulares, nas quais a maioria das amostras benignas concentra valores mais baixos, enquanto os tumores malignos tendem a ocupar as regiões de maior magnitude. Em alguns atributos, como `radius_mean` e `area_mean`, é possível observar indícios de distribuição bimodal, sugerindo que os dois grupos de classes contribuem com picos distintos para o histograma global, um indicativo qualitativo da separabilidade entre as classes que será explorada formalmente nas projeções UMAP e PCA da Seção ??.

4.5.4 Boxplots dos Atributos

Complementando a análise dos histogramas, uma grade equivalente de *boxplots* foi gerada para cada um dos trinta atributos, conforme apresentado na Figura ???. Os *boxplots* permitiram identificar a presença de valores extremos (*outliers*) em praticamente todos os atributos, com maior concentração nos grupos de variáveis relacionadas à área, ao perímetro e às concavidades dos núcleos celulares. Do ponto de vista clínico, esses valores extremos não necessariamente representam erros de medição, podendo corresponder a amostras com morfologia celular atipicamente agressiva. Por essa razão, optou-se por não realizar remoção sistemática de *outliers*, preservando a integridade biológica dos dados e delegando aos algoritmos de aprendizado a tarefa de aprender a lidar com essa variabilidade natural (Faceli *et al.*, 2011).

REFERÊNCIAS

- ABDULLAH, D. M.; ABDULAZEEZ, A. M.; SALLOW, A. B. Lung cancer prediction and classification based on correlation selection method using machine learning techniques. **Qubahan Academic Journal**, v. 1, n. 2, p. 141–150, 2021.
- ADADI, A.; BERRADA, M. Peeking inside the black-box: a survey on explainable artificial intelligence (xai). **IEEE access**, IEEE, v. 6, p. 52138–52160, 2018.
- AI Online Course. **Kernel SVM for Dummies (with Python Code) | Machine Learning**. 2023. Disponível em: <https://www.aionlinecourse.com/tutorial/machine-learning/kernel-svm>. Acesso em: 21 abr. 2026.
- BISHOP, C. M. **Pattern Recognition and Machine Learning**. [S.l.]: Springer, 2006.
- BOLLON, J. *et al.* Investigating how reproducibility and geometrical representation in umap dimensionality reduction impact the stratification of breast cancer tumors. **Applied Sciences**, MDPI, v. 12, n. 9, p. 4247, 2022.
- CHEN, H. *et al.* Classification prediction of breast cancer based on machine learning. **Computational Intelligence and Neuroscience**, v. 2023, p. 1–9, 2023.
- CRUZ, J. A.; WISHART, D. S. Applications of machine learning in cancer prediction and prognosis. **Cancer Informatics**, v. 2, p. 59–77, 2006.
- DAVIS, J.; GOADRICH, M. The relationship between precision-recall and roc curves. In: **Proceedings of the 23rd International Conference on Machine Learning**. [S.l.]: ACM, 2006. p. 233–240.
- DUTTA, M. An interpretable machine learning-based breast cancer classification using xgboost. **Bulletin of Electrical Engineering and Informatics**, Institute of Advanced Engineering and Science, v. 13, n. 6, p. 4306–4315, 2024.
- FACELI, K. *et al.* **Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina**. 2nd. ed. [S.l.]: LTC, 2011.
- GIL, A. C. **Como Elaborar Projetos de Pesquisa**. 4. ed. São Paulo: Atlas, 2002.
- HOLZINGER, A. *et al.* Causability and explainability of artificial intelligence in medicine. **Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery**, Wiley Online Library, v. 9, n. 4, p. e1312, 2019.
- IBM. **O que é random forest?** 2026. Disponível em: <https://www.ibm.com/br-pt/think/to-pics/random-forest>.
- INCA. **Bioinformática e biologia computacional**. Instituto Nacional de Câncer, 2022a. Disponível em: <https://www.gov.br/inca/pt-br/assuntos/pesquisa/pesquisa-basica-e-experimental/bioinformatica-e-biologia-computacional/bioinformatica-e-biologia-computacional-1>. Acesso em: 19 mar. 2026.
- INCA. **Como surge o câncer?** Instituto Nacional de Câncer, 2022b. Disponível em: <https://www.gov.br/inca/pt-br/assuntos/cancer/como-surge-o-cancer>. Acesso em: 07 abr. 2026.

INCA. **O que é câncer?** Instituto Nacional de Câncer, 2022c. Disponível em: <https://www.gov.br/inca/pt-br/assuntos/cancer/o-que-e-cancer>. Acesso em: 07 abr. 2026.

INCA. **Câncer de Mama.** Instituto Nacional de Câncer, 2026. Disponível em: <https://www.gov.br/inca/pt-br/assuntos/noticias/2026/inca-estima-781-mil-novos-casos-de-cancer-por-ano-no-brasil-entre-2026-e-2028>. Acesso em: 19 mar. 2026.

JAMES, G. *et al.* **An Introduction to Statistical Learning: with Applications in Python.** 1. ed. New York: Springer, 2023.

KAVLAKOGLU, E. **O que é a Máquina de Vetores de Suporte?** 2026a. Disponível em: <https://www.ibm.com/br-pt/think/topics/support-vector-machine>. Acesso em: 31 mai. 2026.

KAVLAKOGLU, E. **O que é o algoritmo dos k vizinhos mais próximos?** 2026b. Disponível em: <https://www.ibm.com/br-pt/think/topics/knn>. Acesso em: 31 mai. 2026.

KAVLAKOGLU, E. **O que é uma Decision Tree?** 2026c. Disponível em: <https://www.ibm.com/br-pt/think/topics/decision-trees>. Acesso em: 31 mai. 2026.

LEE, F. **O que é regressão logística?** 2026. Disponível em: <https://www.ibm.com/br-pt/think/topics/logistic-regression>. Acesso em: 31 mai. 2026.

LUNDBERG, S. M. **SHAP: SHapley Additive exPlanations Documentation.** 2026. Disponível em: <https://shap.readthedocs.io/en/latest/>. Acesso em: 21 abr. 2026.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: GUYON, I. *et al.* (Ed.). **Advances in Neural Information Processing Systems 30.** [S.l.]: Curran Associates, Inc., 2017. p. 4765–4774.

MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. **Introduction to Information Retrieval.** New York: Cambridge University Press, 2006.

MASUD, M. *et al.* A machine learning approach to diagnosing lung and colon cancer using a deep learning-based classification framework. **Sensors**, v. 21, n. 3, p. 1–20, 2021.

MCINNES, L. *et al.* **UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction Documentation.** 2018. Disponível em: <https://umap-learn.readthedocs.io/en/latest/>. Acesso em: 21 abr. 2026.

MITCHELL, T. M. **Machine Learning.** [S.l.]: McGraw-Hill, 1997.

NCI. **What is Cancer?** NATIONAL CANCER INSTITUTE, 2021. Disponível em: <https://www.cancer.gov/about-cancer/understanding/what-is-cancer>. Acesso em: 08 abr. 2026.

PAHO. **Câncer.** Organização Pan-Americana da Saúde, 2026. Disponível em: <https://www.paho.org/pt/topicos/cancer>. Acesso em: 18 mar. 2026.

RABIEI, R. *et al.* Prediction of breast cancer using machine learning approaches. **Journal of Biomedical Physics and Engineering**, v. 12, n. 3, p. 297–308, 2022.

RICHARDSON, D. **O que é IA/ML e por que é importante para seus negócios?** Red Hat, 2022. Disponível em: <https://www.redhat.com/pt-br/blog/what-aiml-and-why-does-it-matter-your-business>. Acesso em: 11 abr. 2026.

RUDIN, C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. **Nature Machine Intelligence**, Nature Publishing Group, v. 1, n. 5, p. 206–215, 2019.

RUSSELL, S.; NORVIG, P. **Artificial Intelligence: A Modern Approach**. 3rd. ed. [S.l.]: Prentice Hall, 2010.

SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the roc plot when evaluating binary classifiers on imbalanced datasets. **PLoS ONE**, Public Library of Science, v. 10, n. 3, p. e0118432, 2015.

SHAON, M. S. H. *et al.* A comparative study of machine learning models with lasso and shap feature selection for breast cancer prediction. **Healthcare Analytics**, v. 6, p. 100353, 2024.

SILVA JÚNIOR, O. J. d. **Segmentação e contagem de células em imagens de câncer de mama: um estudo detalhado do desenvolvimento do pipeline**. Monografia (Trabalho de Conclusão de Curso) — Universidade Federal do Paraná, Curitiba, 2018.

STREET, W. N.; WOLBERG, W. H.; MANGASARIAN, O. L. Nuclear feature extraction for breast tumor diagnosis. *SPIE*, p. 861–870, 1993.