UNIVERSIDADE TUIUTI DO PARANÁ

GABRIEL AST DOS SANTOS

DESENVOLVIMENTO DE UM SOFTWARE COM INTELIGÊNCIA ARTIFICIAL EXPLICÁVEL (XAI) PARA APOIO AO DIAGNÓSTICO PREDITIVO DE CÂNCER DE MAMA UTILIZANDO SHAP E UMAP

CURITIBA
2026

GABRIEL AST DOS SANTOS

DESENVOLVIMENTO DE UM SOFTWARE COM INTELIGÊNCIA ARTIFICIAL EXPLICÁVEL (XAI) PARA APOIO AO DIAGNÓSTICO PREDITIVO DE CÂNCER DE MAMA UTILIZANDO SHAP E UMAP

Trabalho de Conclusão de Curso apresentado ao curso de Bacharelado em Ciência da Computação da Faculdade de Ciências Exatas e de Tecnologia da Universidade Tuiuti do Paraná, como requisito à obtenção do grau de Bacharel.

Orientador: Prof. Rodrigo Ramos Alves

CURITIBA

2026

RESUMO

Este trabalho desenvolveu um software integrado a um modelo preditivo para a classificação de tumores mamários como benignos ou malignos, utilizando a base de dados pública Breast Cancer Wisconsin. O objetivo central é mitigar a opacidade característica dos modelos de caixa preta, fornecendo diagnósticos que unam alta precisão analítica a justificativas clínicas interpretáveis por profissionais de saúde. A metodologia contempla o treinamento e a comparação de algoritmos clássicos de aprendizado de máquina supervisionado, avaliados por métricas estatísticas. A explicabilidade é oferecida por valores de Shapley, que decompõem cada diagnóstico nas contribuições dos atributos, e o algoritmo UMAP é aplicado para a análise visual da separabilidade entre tumores benignos e malignos. O sistema disponibiliza uma interface capaz de receber dados em lote via upload de planilhas e gerar relatórios estruturados com os diagnósticos e suas respectivas fundamentações visuais. Os resultados quanto à explicabilidade indicam que o software acompanha cada diagnóstico de uma justificativa que decompõe a certeza exibida nos atributos que mais pesaram na decisão, em valores de Shapley, e cujo conteúdo é coerente com alterações morfológicas associadas à malignidade. Contudo, essa interpretabilidade ainda não foi avaliada por profissionais de saúde.

Palavras-chave: Aprendizado de máquina; Base de dados Wisconsin; Inteligência Artificial Explicável; SHAP; UMAP.

LISTA DE CÓDIGOS

CÓDIGO 1 – IMPLEMENTAÇÃO DA REDUÇÃO DIMENSIONAL UTILIZANDO O ALGORITMO UMAP EM PYTHON. 42
CÓDIGO 2 – LIMPEZA E CODIFICAÇÃO DA VARIÁVEL ALVO. 58
CÓDIGO 3 – DIVISÃO ESTRATIFICADA DA BASE EM CONJUNTOS DE TREINO E TESTE. 59
CÓDIGO 4 – AJUSTE E APLICAÇÃO DO PADRONIZADOR Z-SCORE. 60
CÓDIGO 5 – CONFIGURAÇÃO E TREINAMENTO DA ÁRVORE DE DECISÃO. 65
CÓDIGO 6 – CONFIGURAÇÃO, TREINAMENTO E INFERÊNCIA DO KNN. . . 67
CÓDIGO 7 – CONFIGURAÇÃO E TREINAMENTO DA REGRESSÃO LOGÍSTICA. 69
CÓDIGO 8 – CONFIGURAÇÃO E TREINAMENTO DO RANDOM FOREST. . . 71
CÓDIGO 9 – CONFIGURAÇÃO E TREINAMENTO DO SVM. 74

LISTA DE FIGURAS

FIGURA 1 – CONTRASTE MORFOLÓGICO ENTRE CÉLULAS NORMAIS E NEOPLÁSICAS. 20
FIGURA 2 – HIERARQUIA E RELAÇÃO DE INCLUSÃO ENTRE IA, ML E DL. 23
FIGURA 3 – EXEMPLO ILUSTRATIVO DE UMA MATRIZ DE CONFUSÃO . . . 26
FIGURA 4 – COMPARAÇÃO ENTRE CURVAS ROC E PRECISÃO-REVOCAÇÃO EM DADOS DESBALANCEADOS . . 28
FIGURA 5 – GRÁFICO ILUSTRATIVO DAS TAREFAS DE CLASSIFICAÇÃO E REGRESSÃO 29
FIGURA 6 – REPRESENTAÇÃO GEOMÉTRICA DO HIPERPLANO E MARGENS DE SEPARAÇÃO DO SVM 32
FIGURA 7 – PROJEÇÃO UMAP E FORMAÇÃO DE CLUSTERS EM DADOS DE CÂNCER DE MAMA 43
FIGURA 8 – DIAGRAMA DE BLOCOS DO FLUXO DE DADOS E COMUNICAÇÃO DA ARQUITETURA 56
FIGURA 9 – HISTOGRAMAS DOS TRINTA ATRIBUTOS MORFOLÓGICOS DA BASE WISCONSIN 62
FIGURA 10 – BOXPLOTS DOS ATRIBUTOS DO GRUPO MEAN DA BASE WISCONSIN 63
FIGURA 11 – TELA DE DIAGNÓSTICO COM OS SEIS PASSOS DO FLUXO DE TRABALHO 86
FIGURA 12 – COLUNAS DE CONFIABILIDADE NA TABELA DE RESULTADOS 87
FIGURA 13 – RELATÓRIO DA ÁRVORE DE DECISÃO: GANHO DE INFORMAÇÃO E DETALHE DO PACIENTE 89
FIGURA 14 – RELATÓRIO DO RANDOM FOREST: CONSENSO ENTRE AS ÁRVORES DA FLORESTA 90
FIGURA 15 – RELATÓRIO DO SVM: MAPA COLORIDO PELO ESCORE DE DECISÃO E PAINEL DA MARGEM 91
FIGURA 16 – RELATÓRIO SHAP: IMPORTÂNCIA GLOBAL E CONTRIBUIÇÃO POR PACIENTE 92

FIGURA 17 – MAPA POPULACIONAL: PROJEÇÃO UMAP DO LOTE SOBRE O CONJUNTO DE TREINO 93
FIGURA 18 – RELATÓRIO DO COMITÊ: CONCORDÂNCIA DOS MEMBROS E FATORES QUE MAIS PESARAM 94
FIGURA 19 – AUDITORIA ACADÊMICA: DESEMPENHO DO COMITÊ CONTRA O GABARITO 95

LISTA DE GRÁFICOS

GRÁFICO 1 – DISTRIBUIÇÃO DAS CLASSES NA BASE WISCONSIN 61
GRÁFICO 2 – CURVAS ROC E PRECISÃO-REVOCAÇÃO DA ÁRVORE DE DECISÃO 66
GRÁFICO 3 – CURVAS ROC E PRECISÃO-REVOCAÇÃO DO KNN 68
GRÁFICO 4 – CURVAS ROC E PRECISÃO-REVOCAÇÃO DA REGRESSÃO LOGÍSTICA 70
GRÁFICO 5 – CURVAS ROC E PRECISÃO-REVOCAÇÃO DO RANDOM FOREST 73
GRÁFICO 6 – CURVAS ROC E PRECISÃO-REVOCAÇÃO DO SVM 74
GRÁFICO 7 – CURVA RISCO-COBERTURA NO TREINO (*OUT-OF-FOLD*), COM O PONTO DE OPERAÇÃO DE CADA MODELO 83

LISTA DE QUADROS

QUADRO 1 – PRINCIPAIS HIPERPARÂMETROS DO ALGORITMO UMAP . . 42
QUADRO 2 – COMPARAÇÃO ENTRE TRABALHOS RELACIONADOS E O PRESENTE PROJETO. 52
QUADRO 3 – COMPARAÇÃO TÉCNICA ENTRE OS TRABALHOS RELACIONADOS E O PRESENTE PROJETO. 52
QUADRO 4 – BIBLIOTECAS UTILIZADAS NO PROJETO. 57
QUADRO 5 – MÓDULOS DE LÓGICA DA APLICAÇÃO (app/core). 85

LISTA DE SIGLAS E ACRÔNIMOS

AUC	*Area Under the Curve* (Área Sob a Curva)
CART	*Classification and Regression Trees* (Árvores de Classificação e Regressão)
DNA	Ácido Desoxirribonucleico
DL	*Deep Learning* (Aprendizado Profundo)
FN	Falso Negativo
FP	Falso Positivo
GLM	*Generalized Linear Model* (Modelo Linear Generalizado)
IA	Inteligência Artificial
ID3	*Iterative Dichotomiser* 3 (Dicotomizador Iterativo 3)
INCA	Instituto Nacional de Câncer
KNN	*K-Nearest Neighbors* (K-Vizinhos Mais Próximos)
LIME	*Local Interpretable Model-agnostic Explanations*
MDA	*Mean Decrease in Accuracy* (Importância por Permutação)
MDI	*Mean Decrease in Impurity* (Diminuição Média da Impureza)
ML	*Machine Learning* (Aprendizado de Máquina)
MLE	*Maximum Likelihood Estimation* (Estimativa de Máxima Verossimilhança)
OOB	*Out-of-Bag*
PAAF	Punção Aspirativa por Agulha Fina
PAHO	*Pan American Health Organization* (Organização Pan-Americana da Saúde)

PR	*Precision-Recall* (Precisão-Revocação)
RBF	*Radial Basis Function* (Função de Base Radial)
ROC	*Receiver Operating Characteristic* (Característica de Operação do Receptor)
SHAP	*SHapley Additive exPlanations*
SVM	*Support Vector Machine* (Máquina de Vetores de Suporte)
UMAP	*Uniform Manifold Approximation and Projection*
VN	Verdadeiro Negativo
VP	Verdadeiro Positivo
WDBC	*Wisconsin Diagnostic Breast Cancer*
XAI	*eXplainable Artificial Intelligence* (Inteligência Artificial Explicável)
XGBoost	*Extreme Gradient Boosting*

LISTA DE SÍMBOLOS

$p(x)$	Probabilidade de malignidade estimada pela função sigmoide
β_0	Intercepto (termo independente) do modelo logístico
β_1	Coeficiente da variável preditora no modelo logístico
x_1	Vetor de características de entrada do modelo
$L(\beta_0, \beta_1)$	Função de verossimilhança a ser maximizada
y_i	Rótulo real da amostra i (0 para benigno, 1 para maligno)
w	Vetor de pesos que define a inclinação do hiperplano separador
b	Termo de viés que determina a posição do hiperplano no espaço
x	Vetor de características de entrada
γ	Margem de separação entre as classes no SVM
ξ	Variável de folga utilizada na margem flexível do SVM
C	Hiperparâmetro de regularização do SVM (controle da margem flexível)
$d_E(x, y)$	Distância Euclidiana entre os vetores de características x e y
$d_M(x, y)$	Distância de Manhattan entre os vetores de características x e y
n	Número total de atributos (dimensões) do vetor de características
k	Número de vizinhos mais próximos considerados pelo KNN
$H(S)$	Entropia do conjunto de dados S
$p(c)$	Proporção de amostras pertencentes à classe c no conjunto S
c	Classe de saída do problema de classificação
$IG(S, a)$	Ganho de informação do atributo a sobre o conjunto S
a	Atributo celular avaliado como critério de divisão na árvore de decisão

S_v	Subconjunto de amostras de S nas quais o atributo a assume o valor v
v	Valor específico assumido pelo atributo a em uma divisão
ϕ_i	Valor de Shapley para a característica isolada i
Σ	Somatório
N	Conjunto total de características celulares disponíveis
S	Subconjunto específico de características
i	Característica celular isolada em análise
$\subseteq$	Subconjunto de
$\setminus$	Diferença de conjuntos (exclusão)
$\lvert \cdot \rvert$	Cardinalidade (quantidade de elementos de um conjunto)
!	Operador fatorial
$\cup$	União de conjuntos
$v(\cdot)$	Função de valor (predição de risco do modelo para um determinado subconjunto)

LISTA DE TABELAS

TABELA 1 – COMPARAÇÃO DE DESEMPENHO ENTRE OS CLASSIFICADORES 75
TABELA 2 – DESEMPENHO SOB VALIDAÇÃO CRUZADA (MÉDIA $\pm$ DESVIO-PADRÃO EM 50 DOBRAS) 77
TABELA 3 – TESTE PAREADO 5$\times$2CV DA REGRESSÃO LOGÍSTICA CONTRA CADA RIVAL 78
TABELA 4 – VALORES DE p DO PÓS-HOC DE NEMENYI ENTRE OS CINCO MODELOS 79
TABELA 5 – MÉTRICAS DE CALIBRAÇÃO DAS PROBABILIDADES NO CONJUNTO DE TESTE (MENOR É MELHOR) 80
TABELA 6 – ESCORE DE BRIER ANTES E DEPOIS DA RECALIBRAÇÃO . . 81
TABELA 7 – PONTO DE OPERAÇÃO: LIMIAR, FAIXA DE RECUSA, COBERTURA E ERRO 83

SUMÁRIO

1 INTRODUÇÃO 16
2 FUNDAMENTAÇÃO TEÓRICA 19
2.1 O CÂNCER DE MAMA E A ANÁLISE MORFOLÓGICA 19
2.2 INTELIGÊNCIA ARTIFICIAL E MACHINE LEARNING: DEFINIÇÕES E HIERARQUIA 21
2.3 MACHINE LEARNING: CONCEITOS E PARADIGMAS 23
2.3.1 O paradigma do aprendizado supervisionado e a classificação binária . 23
2.3.2 O dilema da generalização e o ciclo de vida do modelo 24
2.3.3 Métricas de avaliação de desempenho 26
2.3.4 Principais algoritmos classificadores 29
2.4 O DILEMA DA CAIXA PRETA E A INTELIGÊNCIA ARTIFICIAL EXPLICÁVEL 36
2.5 SHAPLEY ADDITIVE EXPLANATIONS (SHAP) 37
2.5.1 Fundamentação matemática: a equação de Shapley 39
2.6 REDUÇÃO DE DIMENSIONALIDADE E UMAP 40
3 TRABALHOS RELACIONADOS 44
3.1 EXTRAÇÃO DE CARACTERÍSTICAS NUCLEARES PARA O DIAGNÓSTICO DE TUMORES MAMÁRIOS (STREET *ET AL.*, 1993) 44
3.2 APLICAÇÕES DE MACHINE LEARNING NA PREDIÇÃO E PROGNÓSTICO DO CÂNCER (CRUZ E WISHART, 2006) 45
3.3 DIAGNÓSTICO DE CÂNCER DE PULMÃO E CÓLON VIA DEEP LEARNING (MASUD *ET AL.*, 2021) 45
3.4 PREDIÇÃO DE CÂNCER DE PULMÃO COM SELEÇÃO DE CORRELAÇÃO (ABDULLAH *ET AL.*, 2021) 46
3.5 ABORDAGENS DE MACHINE LEARNING NA PREDIÇÃO DO CÂNCER DE MAMA (RABIEI *ET AL.*, 2022) 47
3.6 SEGMENTAÇÃO E CONTAGEM DE CÉLULAS EM IMAGENS (SILVA JÚNIOR, 2023) 48
3.7 PREDIÇÃO BASEADA EM APRENDIZADO DE MÁQUINA (CHEN *ET AL.*, 2023) 49

3.8 ESTUDO COMPARATIVO COM SELEÇÃO LASSO E SHAP (SHAON *ET AL.*, 2024) 50
3.9 SÍNTESE E LACUNA DE PESQUISA 51
4 METODOLOGIA 53
4.1 CLASSIFICAÇÃO DA PESQUISA 53
4.2 VISÃO GERAL DA ARQUITETURA DA SOLUÇÃO 54
4.3 BASE DE DADOS E AMBIENTE DE DESENVOLVIMENTO 55
4.4 PRÉ-PROCESSAMENTO DOS DADOS 56
4.4.1 Codificação da variável alvo 58
4.4.2 Divisão treino e teste 58
4.4.3 Padronização Z-score 59
4.5 ANÁLISE EXPLORATÓRIA DOS DADOS 60
4.5.1 Estatísticas descritivas 60
4.5.2 Distribuição das classes 61
4.5.3 Histogramas dos atributos 61
4.5.4 Boxplots dos atributos 63
4.6 TREINAMENTO E AVALIAÇÃO DOS MODELOS 63
4.6.1 Árvore de Decisão 64
4.6.2 K-Nearest Neighbors 66
4.6.3 Regressão Logística 68
4.6.4 Random Forest 70
4.6.5 Support Vector Machine 72
4.6.6 Comparação entre os modelos 74
4.7 RIGOR ESTATÍSTICO: VALIDAÇÃO CRUZADA, SIGNIFICÂNCIA, CALIBRAÇÃO E PONTO DE OPERAÇÃO 76
4.7.1 Validação cruzada estratificada repetida 76
4.7.2 Testes de significância estatística 77
4.7.3 Análise de calibração das probabilidades 79
4.7.4 Ponto de operação e curva risco-cobertura 82
4.8 O SOFTWARE DESENVOLVIDO 84
4.8.1 Organização do código 84
4.8.2 Fluxo de trabalho 86

4.8.3 Sinais de confiabilidade 87
4.8.4 Relatórios de explicabilidade 88
4.8.5 Auditoria, exportação e consulta 94
4.8.6 Distribuição 95
4.8.7 Limitações do software 96
5 CONCLUSÃO 97
REFERÊNCIAS 100
APÊNDICE A – MANUAL DE INSTALAÇÃO DO DIAGNOSISXAI . . . 103
APÊNDICE B – MANUAL DE USO DO DIAGNOSISXAI 106

1 INTRODUÇÃO

De acordo com a Organização Pan-Americana da Saúde (PAHO, 2026), as patologias oncológicas impõem uma enorme carga de adoecimento nas Américas, sendo superadas unicamente pelas doenças cardiovasculares. A instituição aponta que, em 2022, a região contabilizou mais de 4,2 milhões de novos casos, com a expectativa de que esse índice sofra um acréscimo de 60% até 2045, chegando à marca de 6,7 milhões. Como uma das causas primárias de mortalidade no continente, a doença resultou em 1,4 milhão de óbitos em 2022, afetando pessoas com 69 anos ou menos em 45% das ocorrências. Contudo, o órgão ressalta que muitos desses quadros possuem elevadas taxas de cura quando há o rastreio precoce somado ao tratamento clínico assertivo.

No cenário nacional, as projeções apontam para um panorama de alerta, com a estimativa de 781 mil novos casos de câncer por ano no Brasil ao longo do triênio de 2026 a 2028. Dentro dessa estatística, o câncer de mama consolida-se de forma alarmante como a neoplasia mais incidente entre o público feminino, representando 30% de todos os novos diagnósticos nas mulheres. Esses números expressivos refletem não apenas o envelhecimento populacional, mas também evidenciam as profundas desigualdades regionais e os desafios persistentes que as pacientes enfrentam no acesso à prevenção, ao rastreamento, ao diagnóstico precoce e ao tratamento oportuno no sistema de saúde (INCA, 2026).

O uso de tecnologias computacionais para enfrentar essa carga de adoecimento está em plena expansão, impulsionado pela chamada revolução do *Big Data* na saúde. Instituições de referência, como o próprio Instituto Nacional de Câncer (INCA, 2022a), destacam que a bioinformática e a biologia computacional são cruciais para analisar dados em larga escala e identificar assinaturas do câncer. Ao processar grandes volumes de dados morfológicos e genéticos, abrem-se caminhos para uma medicina cada vez mais direcionada e personalizada. Nesse contexto, o uso de algoritmos de *Machine Learning* para o reconhecimento de padrões e classificação de tumores já se consolida como uma linha de pesquisa fundamental para a oncologia moderna, capaz de extrair marcadores de interesse clínico de forma automatizada.

Apesar do notável desempenho preditivo, a adoção clínica dessas tecnologias

esbarra no chamado "problema da caixa preta". Algoritmos avançados fornecem predições altamente acuradas, mas não revelam o raciocínio matemático interno que levou àquela conclusão. Na prática médica, entregar um diagnóstico de malignidade automatizado sem uma fundamentação biológica rastreável é insuficiente e eticamente questionável. O profissional de saúde necessita compreender quais fatores morfológicos e celulares pesaram na decisão para validar a predição, confiar no modelo e transmitir o diagnóstico com segurança ao paciente.

É nesse cenário que a Inteligência Artificial Explicável (XAI - *eXplainable AI*) se faz estritamente necessária. A aplicação de técnicas de interpretabilidade, como o *SHapley Additive exPlanations* (SHAP), permite "abrir" essa caixa preta ao quantificar o impacto exato e a contribuição de cada variável clínica no risco de malignidade. Em paralelo, a utilização de algoritmos de redução de dimensionalidade, como o *Uniform Manifold Approximation and Projection for Dimension Reduction* (UMAP), facilita a análise visual da separabilidade natural dos dados, identificando agrupamentos (*clusters*) e anomalias de forma gráfica. Dessa forma, o sistema computacional deixa de ser apenas um classificador opaco e passa a atuar como uma ferramenta de apoio transparente, unindo a precisão analítica à explicabilidade exigida pelo campo oncológico.

Diante da necessidade de conciliar desempenho preditivo e interpretabilidade clínica, formula-se o seguinte problema de pesquisa: como integrar técnicas de explicabilidade e redução de dimensionalidade em um modelo preditivo de câncer de mama, de modo a fornecer diagnósticos que sejam, simultaneamente, acurados e interpretáveis por profissionais de saúde?

O objetivo deste trabalho é desenvolver um software integrado a um modelo preditivo para a classificação de tumores mamários (benignos ou malignos), utilizando algoritmos de *Machine Learning* e a base de dados pública Breast Cancer Wisconsin. O intuito principal é mitigar a opacidade característica dos modelos de "caixa preta", fornecendo aos profissionais de saúde diagnósticos preditivos que unam alta precisão analítica a justificativas clínicas transparentes.

Para alcançar esse propósito, o trabalho compreende o treinamento e a comparação de classificadores e a explicação de cada diagnóstico pela biblioteca SHAP, que quantifica o impacto de cada variável celular no risco de malignidade apontado pelo

modelo. O UMAP foi aplicado à análise visual da separabilidade natural dos dados, facilitando a identificação de agrupamentos (*clusters*) e a localização de cada paciente na população de treino. Inicialmente, previa-se que o UMAP também identificasse anomalias (*outliers*). Essa função, porém, não se mostrou adequada à projeção bidimensional, e a sinalização de perfis atípicos passou a ser feita pela distância de Mahalanobis, medida no espaço completo dos atributos. Por fim, visando a viabilidade de uso no cotidiano médico, foi desenvolvida uma interface capaz de receber dados em lote via upload de planilhas e de gerar relatórios estruturados (em PDF ou CSV) com os resumos dos diagnósticos e suas respectivas fundamentações visuais.

Este trabalho está organizado em cinco capítulos. O Capítulo 2 apresenta a fundamentação teórica, abordando o câncer de mama e sua análise morfológica, os conceitos de aprendizado de máquina, as métricas de avaliação, os algoritmos classificadores e as técnicas de explicabilidade (SHAP) e de redução de dimensionalidade (UMAP). O Capítulo 3 analisa os trabalhos relacionados e identifica a lacuna que este projeto busca preencher. O Capítulo 4 descreve a metodologia de construção da solução, desde o pré-processamento e a análise exploratória até o treinamento, a avaliação e a calibração dos modelos, e o software desenvolvido. O Capítulo 5 retoma os resultados obtidos, suas limitações e os trabalhos futuros. Os Apêndices A e B trazem, respectivamente, os manuais de instalação e de uso do software.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo destina-se à fundamentação teórica que sustenta a pesquisa, conectando conceitos fundamentais ao problema proposto. O objetivo é estabelecer uma base sólida, com base na literatura científica consolidada, que conduza e valide o estudo. Nas seções a seguir, serão explorados os aspectos clínicos da doença, a evolução tecnológica na análise de dados em saúde e as abordagens computacionais escolhidas para o desenvolvimento do modelo preditivo.

2.1 O CÂNCER DE MAMA E A ANÁLISE MORFOLÓGICA

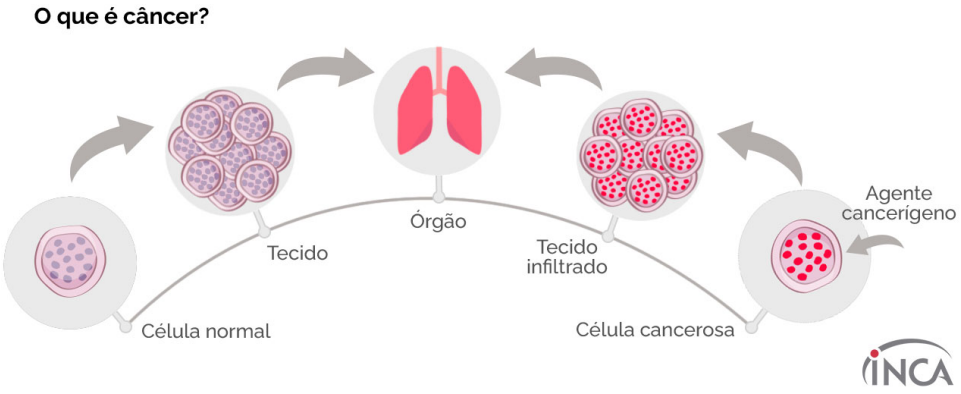
O termo câncer abrange um complexo conjunto de mais de cem doenças malignas que têm como denominador comum o crescimento desordenado e incontrolável das células. A base biológica dessa patologia reside na perda estrutural e funcional dos mecanismos de regulação celular. Esse processo de formação tumoral, cientificamente denominado carcinogênese ou oncogênese, é engatilhado quando o ácido desoxirribonucleico (DNA), a "memória química" que guarda as instruções das atividades celulares, sofre alterações críticas. Em condições normais, genes reguladores específicos chamados proto-oncogenes permanecem inativos; contudo, sob a ação de fatores cancerígenos cumulativos, eles sofrem mutações e são ativados, convertendo-se em oncogenes. Essa ativação desencadeia um processo lento e progressivo composto por três estágios: a iniciação, onde a célula sofre a alteração genética primária de forma silenciosa, a promoção, fase em que agentes externos ou internos transformam gradual e lentamente essa célula iniciada em uma estrutura maligna, e por fim, a progressão, caracterizada pela multiplicação descontrolada e irreversível das células alteradas, culminando na consolidação clínica do tumor e em seu potencial de invasão (INCA, 2022b).

O tipo mais comum desta doença é classificado como carcinoma, uma nomeação atribuída aos tumores malignos que se originam nas células epiteliais, que são os tecidos responsáveis por revestir as superfícies internas e externas do corpo humano. Dependendo do tipo específico de célula epitelial afetada, o carcinoma recebe denominações distintas. No contexto anatômico do câncer de mama, a manifestação predominante é o adenocarcinoma, um subtipo que se desenvolve especificamente

nas células epiteliais dos tecidos glandulares, cuja função biológica é produzir fluidos e muco (NCI, 2021).

No entanto, o desenvolvimento desse adenocarcinoma não ocorre de maneira instantânea, estruturando-se por meio de uma progressão morfológica gradual e microscopicamente rastreável. Inicialmente, o tecido mamário pode apresentar uma hiperplasia, caracterizada por um acúmulo de células que se multiplicam em um ritmo acelerado, mas que ainda preservam rigorosamente sua aparência e arquitetura originais. Se a anomalia celular progredir para o estágio de displasia, além do acúmulo excessivo, as células perdem sua organização e começam a apresentar deformidades morfológicas evidentes. O ápice dessa fase pré-invasiva é denominado carcinoma *in situ* (frequentemente referido na literatura clínica como estágio 0). Neste limiar, as células já exibem características visualmente malignas em seus núcleos, mas ainda se encontram confinadas, pois não romperam as barreiras do tecido glandular original para invadir as áreas vizinhas (NCI, 2021). A diferença fundamental entre a biologia de um tecido saudável e o desenvolvimento anômalo gerado por essa cascata de mutações pode ser observada na Figura 1.

FIGURA 1 – CONTRASTE MORFOLÓGICO ENTRE CÉLULAS NORMAIS E NEOPLÁSICAS.



FONTE: INCA, 2022c, Disponível em: https://www.gov.br/inca/pt-br/assuntos/cancer/o-que-e-cancer

Na ciência da computação aplicada à saúde, o dado mais valioso desta anomalia não é apenas a mutação genética em si, mas sim a profunda alteração morfológica que ela desencadeia. A pressão para sustentar uma replicação em massa e desordenada leva à deformação severa do núcleo de uma célula maligna. Como resultado, quando analisadas ao microscópio, estas células apresentam variações perceptíveis e quantificáveis na área, no raio, na textura e na concavidade, em comparação com uma

célula saudável. São justamente essas assimetrias físicas que se tornam o insumo fundamental para alimentar e treinar algoritmos de aprendizagem de máquina. Estes algoritmos apoiam o diagnóstico preditivo (Street *et al.*, 1993).

Um dos marcos pioneiros na convergência entre a oncologia clínica e a ciência da computação, voltado especificamente para a quantificação dessas assimetrias celulares, é a base de dados *Breast Cancer Wisconsin (Diagnostic)*. No início dos anos 90, pesquisadores da Universidade de Wisconsin desenvolveram esta base com o objetivo de mitigar a subjetividade e a fadiga associadas à análise microscópica realizada por especialistas (Street *et al.*, 1993). O principal diferencial metodológico deste trabalho residiu na opção por não construir um repositório de imagens biomédicas de alta dimensionalidade, pois demandaria elevada capacidade computacional de armazenamento e processamento, mas sim uma base estruturada de atributos numéricos extraídos das imagens, de processamento eficiente.

Para alcançar esse resultado, os pesquisadores utilizaram amostras coletadas via Punção Aspirativa por Agulha Fina (PAAF) e aplicaram algoritmos de processamento de imagem, conhecidos como contornos ativos (*snakes*), para delinear digitalmente as fronteiras dos núcleos celulares. A partir deste tratamento computacional, foram extraídas matematicamente dez características morfológicas essenciais de cada célula, incluindo o raio, a textura, o perímetro, a área e a suavidade. Ao calcular a média, o erro padrão e o valor máximo para cada uma dessas dez medidas, o sistema gerou as 30 variáveis numéricas que compõem o conjunto de dados. Esta otimização consolidou a base de Wisconsin como um recurso de referência na literatura, permitindo que os algoritmos preditivos processem informações oncológicas complexas de forma rápida e eficiente (Street *et al.*, 1993).

2.2 INTELIGÊNCIA ARTIFICIAL E MACHINE LEARNING: DEFINIÇÕES E HIERARQUIA

A Inteligência Artificial (IA) é uma área da ciência da computação que teve um marco histórico em 1956, durante a Conferência de Dartmouth, quando o termo foi formalmente cunhado (Russell; Norvig, 2010). Desde então, a área evoluiu e ramificou-se em diversas vertentes de pesquisa. Segundo Russell e Norvig (2010), as definições históricas e contemporâneas de IA podem ser organizadas em quatro categorias

principais, divididas entre abordagens que buscam simular o comportamento ou o pensamento humano, e abordagens focadas puramente no conceito de racionalidade. No contexto computacional moderno, a abordagem mais adotada e cientificamente rigorosa é a dos "agentes racionais", que são sistemas que operam de forma autônoma e agem para alcançar o melhor resultado possível diante de um problema, dado o conhecimento e as percepções que possuem do ambiente.

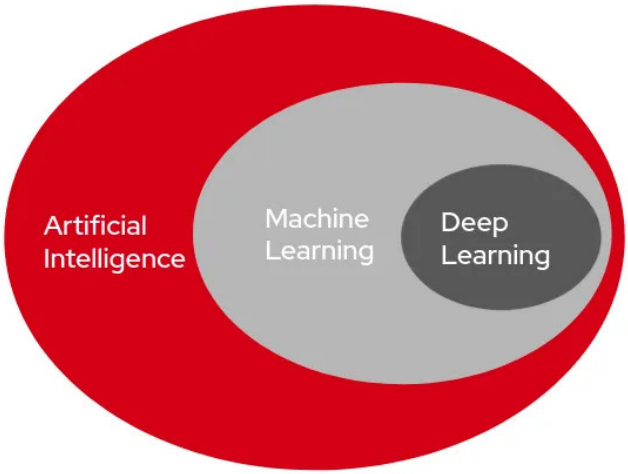
Para que um sistema alcance essa racionalidade em ambientes complexos, a programação de regras lógicas estáticas (*if-then*) torna-se inviável. É para solucionar esta limitação que surge o *Machine Learning* (ML), o principal subcampo da Inteligência Artificial. Em vez de serem explicitamente programados para executar uma tarefa passo a passo, os algoritmos de ML utilizam métodos estatísticos para extrair padrões diretamente dos dados. A definição formal mais consolidada na literatura é proposta por Mitchell (1997), que estabelece que um programa de computador aprende a partir da experiência E, em relação a uma classe de tarefas T e uma medida de desempenho P, se o seu desempenho em T, quantificado por P, melhora com a experiência E.

Para compreender essa definição de forma mais prática, pode-se estabelecer um paralelo com o aprendizado humano. A tarefa T representa o objetivo, como identificar tumores; a experiência E consiste nos dados históricos e exemplos fornecidos ao sistema (como a base de dados Wisconsin), e o desempenho P atua como a métrica de sucesso, indicando quantos diagnósticos a máquina acertou. O algoritmo é considerado capaz de "aprender" quando, ao ser exposto a mais dados (maior E), ele aumenta sua taxa de acertos (maior P) ao realizar o diagnóstico (tarefa T).

A hierarquia da inteligência computacional estende-se ainda a camadas mais especializadas, como o *Deep Learning* (DL), ou Aprendizado Profundo. Esta vertente do *Machine Learning* usa redes neurais artificiais para processar grandes volumes de dados (Richardson, 2022). Essa relação hierárquica e de pertencimento entre os campos pode ser visualizada por meio de um diagrama de conjuntos, conforme ilustrado na Figura 2.

Essa estrutura demonstra que todo Aprendizado Profundo é uma forma de Aprendizado de Máquina, e todo Aprendizado de Máquina é uma aplicação de Inteligência Artificial. Para o escopo do diagnóstico preditivo oncológico proposto neste estudo, a construção do agente racional será fundamentada especificamente nas técnicas

FIGURA 2 – HIERARQUIA E RELAÇÃO DE INCLUSÃO ENTRE IA, ML E DL.



FONTE: Richardson, 2022, Disponível em: https://www.redhat.com/pt-br/blog/what-aiml-and-why-does-it-matter-your-business

clássicas de *Machine Learning*, cujos paradigmas e mecânicas de avaliação serão detalhados a seguir.

2.3 MACHINE LEARNING: CONCEITOS E PARADIGMAS

O desenvolvimento de um modelo de IA não segue uma receita universal. A abordagem escolhida depende fundamentalmente da natureza dos dados disponíveis e do objetivo do problema. Na literatura clássica de *Machine Learning*, os algoritmos são categorizados em três grandes paradigmas de aprendizado: Não Supervisionado, Aprendizado por Reforço e Aprendizado Supervisionado. Como o escopo deste trabalho visa prever um diagnóstico clínico a partir de dados históricos previamente validados por médicos patologistas, o referencial teórico e metodológico desta pesquisa concentra-se exclusivamente no paradigma do Aprendizado Supervisionado (Cruz e Wishart, 2006).

2.3.1 O paradigma do aprendizado supervisionado e a classificação binária

O Aprendizado Supervisionado, que a literatura classifica como uma tarefa preditiva de aprendizagem indutiva, caracteriza-se sobretudo pela presença de um "gabarito" nos dados de treinamento. Neste paradigma, o algoritmo é alimentado com um conjunto de dados históricos contendo tanto as variáveis independentes de entrada, conhecidas como *features* ou atributos, quanto as suas respectivas variáveis dependentes de saída, os rótulos ou *labels*. O objetivo deste método é fazer com que o

modelo descubra e mapeie a relação matemática entre as entradas e a saída. Dessa forma, ao aprender as regras ocultas que conectam as características observadas ao resultado final, o sistema torna-se capaz de generalizar esse conhecimento para realizar predições automáticas quando exposto a novos dados não rotulados no futuro (Faceli *et al.*, 2021).

Nesse paradigma, o modelo aprende a partir de exemplos previamente rotulados, ajustando seus parâmetros internos de forma iterativa para generalizar padrões a novos dados. O algoritmo analisa casos em que tanto o problema quanto a resposta correta são fornecidos simultaneamente. Após essa fase de treinamento, o modelo deve ser capaz de generalizar o conhecimento adquirido para prever a resposta correta quando apresentado a novos dados inéditos, que não possuem o rótulo (Faceli *et al.*, 2021).

Dentro do Aprendizado Supervisionado, Bishop (2006) divide os problemas de acordo com o tipo de resultado que se deseja alcançar. Quando o objetivo do modelo é organizar as informações recebidas em grupos bem definidos, a tarefa é chamada de problema de classificação. Por outro lado, se o sistema tenta prever um valor numérico contínuo, como estimar a expectativa de vida de um paciente ou calcular o rendimento de um processo químico, a tarefa recebe o nome de problema de regressão.

No contexto da oncologia e da base de dados *Breast Cancer Wisconsin*, a tarefa computacional se enquadra como um problema de Classificação Binária. Isso significa que a variável de saída que o modelo deve prever possui apenas dois estados: o tumor é Benigno ou Maligno (Street *et al.*, 1993). Todo o esforço de treinamento e otimização dos algoritmos neste trabalho visa buscar a melhor fronteira de decisão matemática capaz de separar essas duas classes, minimizando ao máximo os erros de categorização, dada a criticidade de um falso diagnóstico médico.

2.3.2 O dilema da generalização e o ciclo de vida do modelo

A construção de um classificador médico eficiente vai muito além do simples processamento numérico de dados históricos. O objetivo central de um modelo de aprendizado de máquina não é apenas memorizar os exemplos exatos que foram apresentados durante o treinamento, mas sim desenvolver a capacidade de generalização. Ou seja, o sistema precisa aprender a regra geral para conseguir prever com precisão o diagnóstico de novos pacientes que nunca processou antes. Nesse processo de

aprendizado, o algoritmo pode cometer dois erros estatísticos extremos: o *underfitting* e o *overfitting* (Faceli *et al.*, 2021).

O *underfitting* ocorre quando o modelo matemático é estruturalmente simples demais e não consegue capturar nem mesmo os padrões morfológicos básicos dos tumores. Nesse cenário, o algoritmo falha em extrair o conhecimento necessário e erra classificações fundamentais. No extremo oposto, encontra-se o *overfitting*, que é um risco estatístico muito mais comum e perigoso na área da saúde. Nesse caso, o modelo se torna tão complexo que passa a "decorar" não apenas as características reais do câncer, mas também as falhas, as exceções e os pequenos ruídos específicos daquela base de dados de treinamento. Consequentemente, o modelo atinge uma precisão artificialmente alta durante seu desenvolvimento, mas fracassa ao avaliar novos pacientes, pois apenas memorizou os dados antigos em vez de assimilar a lógica subjacente à doença (Faceli *et al.*, 2021).

Na estatística, essa linha tênue entre memorizar e generalizar é explicada pelo dilema viés e variância (*bias-variance tradeoff*). O viés representa a limitação estrutural do modelo em enxergar a complexidade dos dados reais, o que causa o *underfitting*. Já a variância mede o quanto o modelo altera sua fronteira de decisão de forma exagerada diante de pequenas mudanças nos dados, o que resulta no *overfitting*. Para garantir que o classificador encontre o equilíbrio estatístico perfeito e seja seguro para uso clínico, é obrigatório adotar um ciclo de vida rigoroso no qual a base de dados original nunca é entregue inteira de uma só vez ao algoritmo. Ela precisa ser metodologicamente dividida em subconjuntos separados (Bishop, 2006).

Essa metodologia de divisão geralmente particiona os dados em três grupos: Treinamento, Validação e Teste. O conjunto de treinamento é o ambiente computacional primário, onde o algoritmo ajusta seus pesos e constrói suas regras de classificação. O conjunto de validação atua como um ambiente de aferição intermediária, permitindo que o desenvolvedor calibre os detalhes matemáticos do modelo e perceba rapidamente se o *overfitting* está ocorrendo. Por fim, o conjunto de teste representa o cenário do mundo real. Ele permanece totalmente isolado e oculto do computador durante todo o processo de desenvolvimento, sendo acionado apenas uma única vez na etapa final. O desempenho alcançado neste conjunto de teste isolado é o principal indicador disponível do desempenho do sistema diante de casos inéditos, embora dependa de

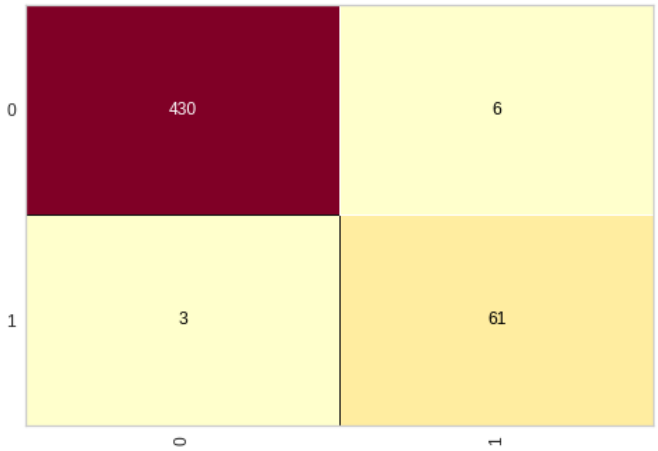
uma única partição e precise ser complementado pela validação cruzada apresentada na metodologia (Faceli *et al.*, 2021).

2.3.3 Métricas de avaliação de desempenho

Após submeter o conjunto de teste ao algoritmo, é fundamental quantificar o seu desempenho clínico. Na classificação binária, a base para qualquer avaliação é a construção de uma Matriz de Confusão. Essa ferramenta organiza os resultados das previsões em quatro categorias possíveis. Os Verdadeiros Positivos (VP) representam os tumores malignos corretamente identificados, enquanto os Verdadeiros Negativos (VN) são os tumores benignos confirmados. Por outro lado, os erros são divididos em Falsos Positivos (FP), que ocorrem quando um tumor benigno gera um alarme falso de malignidade, e Falsos Negativos (FN), que acontecem quando o sistema ignora um tumor maligno e o classifica como inofensivo. Em um cenário oncológico, o falso negativo representa a falha mais crítica do modelo, pois resulta em um paciente doente que é liberado sem receber o tratamento adequado (James *et al.*, 2023).

A Figura 3 ilustra um exemplo dessa estrutura, onde os acertos do modelo concentram-se na diagonal principal (430 VN e 61 VP), enquanto os erros aparecem nos quadrantes secundários (6 FP e 3 FN).

FIGURA 3 – EXEMPLO ILUSTRATIVO DE UMA MATRIZ DE CONFUSÃO



FONTE: O Autor

A métrica mais intuitiva extraída dessa matriz é a acurácia (*accuracy*), que representa a taxa geral de acertos do modelo. Contudo, confiar exclusivamente na acurácia é um erro metodológico perigoso na área da saúde devido ao problema matemático das classes desbalanceadas. Considere uma situação onde a base de

dados possui noventa e nove pacientes saudáveis para cada paciente com câncer. Se um algoritmo quebrado simplesmente classificar todas as pessoas do mundo como saudáveis, ele obterá uma acurácia de 99%. Apesar de parecer um sucesso estatístico absoluto, o modelo seria clinicamente inútil e letal para a pequena parcela de pacientes doentes (Faceli *et al.*, 2021). Matematicamente, a acurácia é calculada pela razão entre as predições corretas e o total de predições, conforme a Equação 1. Seu resultado é expresso em uma escala de 0 a 1, onde valores próximos a 1 indicam maior acerto global.

$$Acurácia = \frac{VP + VN}{VP + VN + FP + FN} \tag{1}$$

Para contornar essa ilusão estatística, o desempenho do modelo deve ser avaliado por métricas que observam os acertos e erros de cada classe de forma isolada. A sensibilidade, também conhecida na literatura como revocação (*recall*), mede a capacidade do algoritmo de identificar corretamente os pacientes que realmente possuem a doença, sendo expressa pela Equação 2 (Davis e Goadrich, 2006). Em outras palavras, essa métrica quantifica a proporção de casos positivos que são efetivamente recuperados pelo modelo, sendo particularmente relevante em contextos clínicos onde a omissão de diagnósticos pode acarretar consequências graves.

$$Sensibilidade = \frac{VP}{VP + FN} \tag{2}$$

Em paralelo, a precisão (*precision*) avalia a confiabilidade técnica do alerta, ou seja, de todos os tumores que o sistema afirmou serem malignos, qual proporção realmente era, expressa pela Equação 3 (Davis e Goadrich, 2006). Essa métrica está diretamente relacionada à taxa de alarmes falsos do sistema, refletindo o quanto as predições positivas podem ser consideradas confiáveis na prática. Assim, modelos com alta precisão tendem a evitar intervenções desnecessárias em pacientes saudáveis.

$$Precisão = \frac{VP}{VP + FP} \tag{3}$$

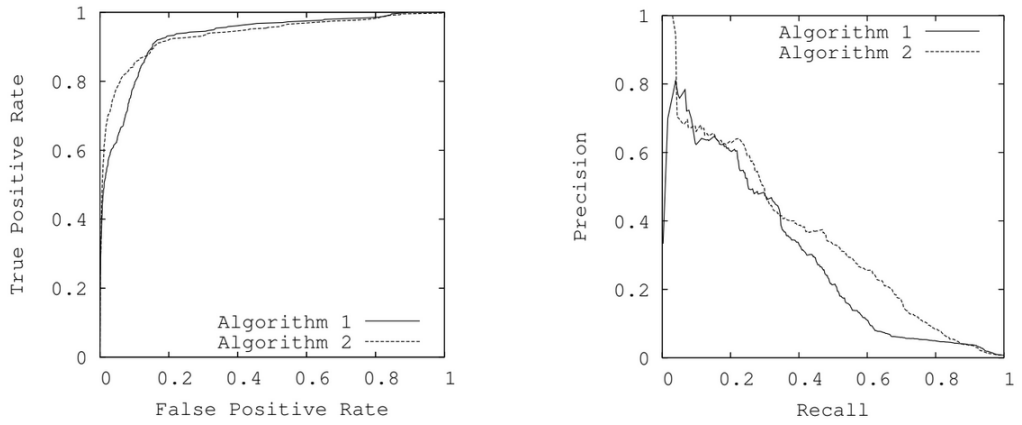
Como frequentemente existe uma balança entre essas duas métricas, onde o aumento de uma pode diminuir a outra, utiliza-se a métrica *F1-score*. Esse indicador calcula a média harmônica entre a precisão e a sensibilidade, fornecendo um único número que atesta o equilíbrio e a segurança geral do classificador (Manning *et al.*, 2008). O *F1-score* consolida esses valores através da Equação 4.

$$F1\text{-}Score = 2 \times \frac{Precisão \times Sensibilidade}{Precisão + Sensibilidade} \tag{4}$$

A avaliação final do modelo é frequentemente consolidada visualmente pela Curva de Característica de Operação do Receptor (ROC). Essa curva ilustra a relação entre a taxa de verdadeiros positivos (sensibilidade) e a taxa de falsos positivos. Para resumir essa análise em um único valor, utiliza-se a área sob a curva (AUC), cujo valor varia de 0 a 1, sendo que valores próximos de 1 indicam maior capacidade discriminativa do modelo (Faceli *et al.*, 2021).

Entretanto, conforme discutido por Davis e Goadrich (2006), a Curva ROC pode apresentar uma visão excessivamente otimista do desempenho em cenários com forte desbalanceamento de classes, como é comum em aplicações médicas. A Figura 4 ilustra esse fenômeno: embora dois algoritmos apresentem desempenhos semelhantes no espaço ROC, diferenças significativas tornam-se evidentes quando analisados no espaço de Precisão-Revocação.

FIGURA 4 – COMPARAÇÃO ENTRE CURVAS ROC E PRECISÃO-REVOCAÇÃO EM DADOS DESBALANCEADOS



FONTE: Adaptado de Davis e Goadrich, 2006

Essa discrepância ocorre porque a taxa de falsos positivos utilizada na Curva ROC é normalizada pelo número total de exemplos negativos, que tende a ser muito elevado em bases desbalanceadas, reduzindo o impacto visual dos erros. Em contraste, a Curva de Precisão-Revocação (PR) considera diretamente a proporção entre verdadeiros e falsos positivos, tornando-se mais sensível a variações no desempenho do modelo na classe minoritária (Davis e Goadrich, 2006).

Dessa forma, em cenários oncológicos, onde o interesse principal está na correta identificação de casos positivos (tumores malignos), a Curva PR e sua respectiva

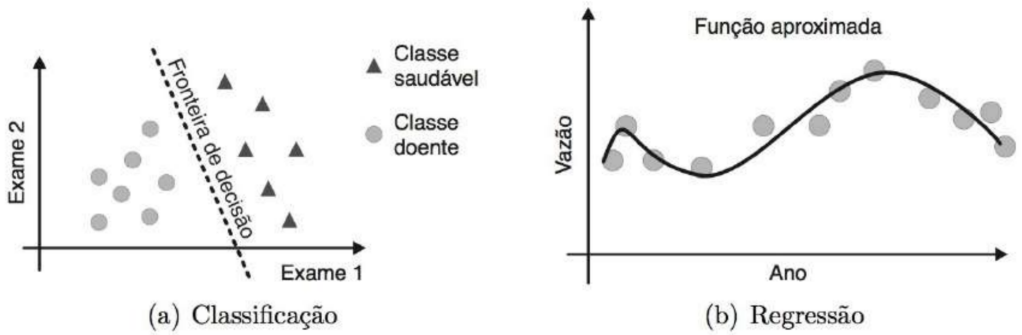
área sob a curva (PR-AUC) fornecem uma avaliação mais fiel do desempenho do classificador. Uma alta PR-AUC indica que o modelo consegue manter elevada precisão mesmo com altos níveis de sensibilidade, sendo, portanto, uma métrica mais adequada para validação em problemas com classes desbalanceadas (Saito e Rehmsmeier, 2015).

2.3.4 Principais algoritmos classificadores

Com a base de dados metodologicamente preparada e as métricas de avaliação estabelecidas, o desenvolvimento do sistema avança para o seu núcleo computacional: a escolha do algoritmo de classificação. O campo do aprendizado supervisionado dispõe de um vasto leque de modelos matemáticos, variando desde equações probabilísticas mais tradicionais até arquiteturas estruturalmente complexas. Embora todos esses algoritmos compartilhem o mesmo propósito central de traçar uma fronteira capaz de separar as células benignas das malignas, cada um deles interpreta os dados e resolve esse problema geométrico utilizando lógicas completamente distintas (Faceli *et al.*, 2021).

A Figura 5 ilustra de forma clara essa mecânica geométrica. Na representação da classificação (a), observa-se o traçado de uma fronteira de decisão dividindo o espaço de características, representado por dois exames, entre a classe saudável e a doente, o que é característico da tarefa abordada neste trabalho. Em contraste, na representação da regressão (b), não se traçam limites separadores, mas sim busca-se uma função que se aproxime continuamente da distribuição dos dados (Faceli *et al.*, 2021).

FIGURA 5 – GRÁFICO ILUSTRATIVO DAS TAREFAS DE CLASSIFICAÇÃO E REGRESSÃO



FONTE: Adaptado de Faceli *et al.*, 2021

O modelo de base mais clássico na modelagem estatística em saúde é a Regressão Logística. Apesar do nome referenciar problemas contínuos, trata-se de um classificador probabilístico. Ele atua calculando uma combinação linear das características da célula, como o seu raio e a sua textura, e aplica esse resultado numérico em uma função matemática chamada sigmoide. Essa função comprime qualquer valor para um intervalo estrito entre zero e um, fornecendo diretamente a probabilidade de o tumor ser maligno. Se essa probabilidade exceder um limiar de corte, o sistema consolida o diagnóstico positivo. A sua adoção contínua na prática clínica decorre da transparência da equação, permitindo que o médico entenda o peso exato de cada variável na decisão final (Bishop, 2006).

Estruturalmente, a regressão logística integra a família dos modelos lineares generalizados (GLMs). Em vez de modelar probabilidades diretamente com uma função linear, o algoritmo trabalha com a chance logarítmica (*log-odds*), também conhecida como função *logit*, para mapear a relação entre variáveis (Lee, 2026).

Matematicamente, a função sigmoide comprime valores reais ilimitados para o intervalo aberto $[0, 1]$ ao calcular a razão entre a base exponencial da entrada e essa mesma base acrescida de uma unidade (Lee, 2026). Como o denominador é sempre estritamente superior ao numerador, a fração resultante fica sempre entre 0 e 1 e pode ser lida como probabilidade, conforme demonstrado na Equação 5.

$$p(x) = \frac{e^{\beta_0+\beta_1 x_1}}{1 + e^{\beta_0+\beta_1 x_1}} \tag{5}$$

Para estimar os coeficientes (β_0 e β_1), utiliza-se a Estimativa de Máxima Verossimilhança (MLE), um processo otimizado iterativamente por gradiente descendente que busca os parâmetros capazes de tornar os dados observados mais prováveis (Lee, 2026). A função de verossimilhança a ser maximizada neste processo é representada pela Equação 6.

$$L(\beta_0, \beta_1) = \prod_{i=1}^{n} p(x_i)^{y_i} \cdot (1 - p(x_i))^{1-y_i} \tag{6}$$

Quando a dispersão entre as características de células benignas e malignas apresenta uma distribuição complexa que não pode ser separada por uma linha reta simples, a computação recorre às Máquinas de Vetores de Suporte, frequentemente referenciadas pela sigla SVM. O objetivo primário deste algoritmo é encontrar uma

fronteira de decisão geométrica, denominada hiperplano, que consiga separar as duas classes de tumores garantindo a maior margem de segurança possível entre elas. Os vetores de suporte, que dão nome ao modelo, são justamente os dados dos pacientes que estão posicionados de forma mais arriscada, ou seja, mais próximos a essa fronteira crítica. Eles atuam como os pilares estruturais que sustentam e definem o formato da decisão final do algoritmo (Bishop, 2006).

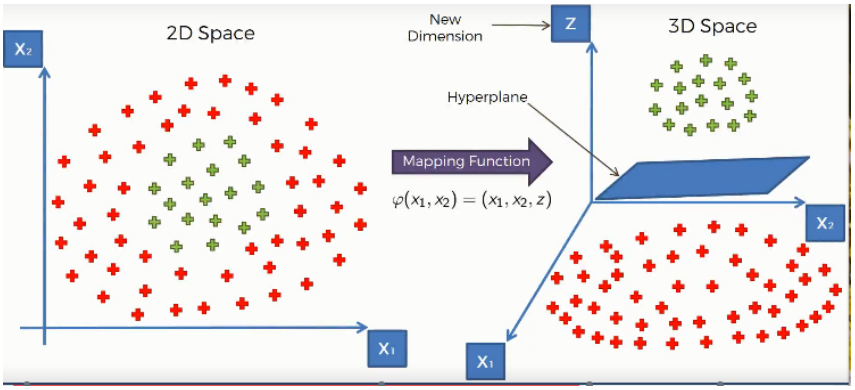
Entretanto, nos problemas oncológicos reais, é muito comum que os dados das células estejam sobrepostos, configurando um cenário não linear. Para solucionar essa limitação e viabilizar a classificação, o SVM utiliza uma operação matemática sofisticada conhecida como truque de *kernel*. Conforme detalhado por AI Online Course (2025), o *kernel* permite operar como se os dados originais fossem elevados de um espaço de baixa dimensão para um espaço de dimensão superior, calculando os produtos internos nesse novo espaço sem construí-lo explicitamente. Nessa nova perspectiva matemática ampliada, as células malignas e benignas que antes pareciam misturadas passam a se afastar, tornando-se linearmente separáveis por um hiperplano. Existem diversas funções capazes de realizar essa transformação geométrica, sendo o *kernel* Polinomial e o *kernel* Gaussiano RBF os mais utilizados na prática para garantir que o algoritmo se adapte perfeitamente à complexidade biológica do câncer.

Desenvolvidas na década de 1990 por Vladimir N. Vapnik, as SVMs tornaram-se aliadas robustas na pesquisa médica devido à sua capacidade de detectar tendências sutis em bases de dados complexas (Kavlakoglu, 2026a). O fundamento geométrico do algoritmo baseia-se na criação de uma fronteira de separação cuja natureza dimensional depende diretamente da quantidade de atributos dos dados de entrada: em um espaço 2D, essa fronteira é uma linha simples, enquanto em espaços de dimensões superiores ela se projeta como um hiperplano n-dimensional (Kavlakoglu, 2026a).

A Figura 6 ilustra visualmente o funcionamento do truque de *kernel* aplicado pelo SVM. No espaço bidimensional à esquerda, os dados das duas classes encontram-se sobrepostos e misturados, tornando impossível a separação por qualquer fronteira linear. Por meio da função de mapeamento $\varphi(x_1, x_2) = (x_1, x_2, z)$, os pontos são projetados para um espaço tridimensional enriquecido com uma nova dimensão z, onde as classes passam a ocupar regiões distintas e geometricamente afastadas. Nesse espaço ampliado, o SVM é capaz de posicionar um hiperplano que separa com clareza

os dois grupos, demonstrando como a elevação dimensional transforma um problema inicialmente insolúvel em uma tarefa de classificação linear viável (Kavlakoglu, 2026a).

FIGURA 6 – REPRESENTAÇÃO GEOMÉTRICA DO HIPERPLANO E MARGENS DE SEPARAÇÃO DO SVM



FONTE: AI Online Course, 2025, Disponível em: https://www.aionlinecourse.com/tutorial/machine-learning/kernel-svm

O propósito central do algoritmo é encontrar a orientação ideal dessa fronteira para que ela maximize a distância ou a margem entre os pontos mais próximos de classes distintas, conhecidos como vetores de suporte (Kavlakoglu, 2026a). Essa lógica é frequentemente comparada ao ajuste da "rua mais larga possível" entre os dados, garantindo que o modelo não apenas separe os grupos, mas o faça com uma folga que favoreça a generalização para novos diagnósticos clínicos (Kavlakoglu, 2026a). Matematicamente, o hiperplano separador é descrito formalmente pela Equação 7, em que w é o vetor de pesos que dita a inclinação da fronteira, x é o vetor de entrada e b representa o termo de viés que define a posição do plano no espaço (Kavlakoglu, 2026a).

$$wx + b = 0 \tag{7}$$

O modelo pode adotar uma configuração de margem rígida, exigindo que todos os dados sejam perfeitamente isolados fora da zona definida pelos vetores de suporte. Sob este regime, a maximização da margem projetada entre as classes é calculada pela Equação 8 (Kavlakoglu, 2026a).

$$\max\ \gamma = \frac{2}{\|w\|} \tag{8}$$

Para lidar com a complexidade e os ruídos inerentes aos dados oncológicos reais, utiliza-se alternativamente a classificação de margem flexível. Essa técnica

permite estrategicamente a ocorrência de pequenos erros de classificação através do uso de variáveis de folga (ξ) e do hiperparâmetro de regularização C. Um valor de C elevado estreita a margem para minimizar classificações incorretas, enquanto um valor menor amplia a margem, permitindo uma maior tolerância a ruídos para evitar o sobreajuste e melhorar o desempenho preditivo (Kavlakoglu, 2026a).

Outra abordagem geométrica muito intuitiva para a classificação é o algoritmo KNN (*K-Nearest Neighbors*). Diferente dos modelos que processam os dados para construir uma equação fixa durante o treinamento, o KNN adota um método de aprendizado baseado em instâncias. Na prática, ele memoriza todo o conjunto de dados históricos de tumores. Quando os dados de um novo paciente são inseridos no sistema, o algoritmo calcula a distância matemática espacial, como a distância Euclidiana, entre as características dessa nova célula e todas as células antigas já armazenadas. O sistema então identifica os "K"vizinhos mais próximos, ou seja, os exames históricos que possuem as medidas anatômicas mais semelhantes ao caso atual. O diagnóstico preditivo é determinado por uma votação simples nessa vizinhança. Se a maioria dos tumores vizinhos for maligna, o novo caso será classificado como maligno. A sua aplicação em sistemas médicos destaca-se pela facilidade de interpretação espacial por parte do profissional de saúde, embora o esforço computacional para calcular essas distâncias aumente consideravelmente em bases de dados muito volumosas (Faceli *et al.*, 2021).

Os conceitos iniciais que fundamentam o KNN foram propostos em 1951, sendo o modelo categorizado como de "aprendizado preguiçoso" ou baseado em memória. Isso significa que não há fase formal de treinamento prévio, pois o algoritmo apenas armazena os dados, exigindo que toda a computação ocorra no exato momento da previsão. Para determinar os vizinhos, o modelo fundamenta-se em métricas de distância, como a euclidiana ou a distância de Manhattan. Recomenda-se que o número de vizinhos (k) seja definido de forma ímpar para evitar empates decisórios. Apesar da simplicidade, o KNN sofre com a "maldição da dimensionalidade" e torna-se ineficiente em termos de memória à medida que a base cresce (Kavlakoglu, 2026b).

Entre as métricas disponíveis para mensurar essa proximidade, a Distância Euclidiana é a mais utilizada na prática. Ela representa o comprimento da linha reta que liga dois pontos no espaço de características, de forma análoga à distância física

entre dois exames plotados em um gráfico. Sendo x e y dois vetores de características de pacientes distintos e n o número total de atributos considerados, essa distância é calculada conforme a Equação 9 (Kavlakoglu, 2026b):

$$d_E(x, y) = \sqrt{\sum_{i=1}^{n}(x_i - y_i)^2} \tag{9}$$

Outra métrica relevante é a Distância de Manhattan, que em vez de traçar um caminho diagonal entre os pontos, percorre as diferenças atributo a atributo de forma ortogonal, somando apenas os deslocamentos absolutos em cada dimensão. Essa abordagem torna o cálculo menos sensível a valores extremos isolados, o que pode ser vantajoso em conjuntos de dados clínicos com medidas discrepantes. Sua formulação é apresentada na Equação 10 (Kavlakoglu, 2026b):

$$d_M(x, y) = \sum_{i=1}^{n} |x_i - y_i| \tag{10}$$

Ambas as métricas são casos particulares da Distância de Minkowski, que as unifica por meio de um parâmetro p: atribuindo $p = 2$ recupera-se a fórmula euclidiana, enquanto $p = 1$ corresponde à distância de Manhattan (Kavlakoglu, 2026b). A escolha entre elas influencia diretamente a sensibilidade do algoritmo a variações nos dados clínicos, tornando essa decisão um passo relevante na configuração do modelo para cada contexto oncológico.

Explorando uma abordagem fundamentada em regras lógicas sucessivas, surgem os algoritmos baseados em Árvores de Decisão. Uma árvore individual funciona como um fluxograma hierárquico que parte de um nó raiz, se ramifica por nós internos de decisão e chega às folhas, onde a classificação final é atribuída. A cada etapa desse percurso, o algoritmo testa uma condição sobre uma característica celular, como o raio ou a textura do tumor, e encaminha cada amostra para o ramo correspondente até que ela alcance um nó terminal com um rótulo de classe definido (Kavlakoglu, 2026c).

A lógica que determina qual característica deve ser testada primeiro é guiada pelo conceito de entropia, oriundo da teoria da informação, que quantifica o grau de desordem ou impureza presente em um conjunto de dados. Em um nó que contenha apenas tumores malignos, por exemplo, não há nenhuma incerteza sobre a classe e a entropia é nula. Já em um nó com metade dos casos benignos e metade malignos, a incerteza é máxima e a entropia atinge seu valor mais alto. Sendo S o conjunto de

dados de um nó, c cada uma das classes possíveis e $p(c)$ a proporção de amostras pertencentes à classe c, a entropia é calculada conforme a Equação 11 (Kavlakoglu, 2026c):

$$H(S) = -\sum_{c=1}^{C} p(c) \log_2 p(c) \tag{11}$$

A partir da entropia, o algoritmo calcula o ganho de informação de cada atributo disponível, que representa a redução de incerteza obtida ao dividir os dados segundo aquela característica. O atributo que produzir a maior redução de entropia é escolhido como critério de divisão naquele nó, e o processo se repete recursivamente em cada subárvore resultante. O ganho de informação de um atributo a sobre o conjunto S é definido pela Equação 12, onde S_v representa o subconjunto de amostras em que o atributo a assume o valor v (Kavlakoglu, 2026c):

$$IG(S, a) = H(S) - \sum_{v} \frac{|S_v|}{|S|} H(S_v) \tag{12}$$

Esse critério é a base do algoritmo ID3, desenvolvido por Ross Quinlan em 1986, e de sua evolução, o C4.5, que introduziu melhorias na forma de lidar com atributos contínuos e dados faltantes. Estruturalmente, o aprendizado das árvores adota uma estratégia de dividir para conquistar, realizando buscas recursivas e descendentes até que os nós folha contenham amostras suficientemente homogêneas (Kavlakoglu, 2026c). Contudo, quando crescem sem restrições, as árvores individuais tornam-se extremamente suscetíveis ao *overfitting*, memorizando os dados de treinamento em vez de aprender padrões generalizáveis (Faceli *et al.*, 2021). Para conter esse problema, aplica-se a técnica de poda, que remove ramificações formadas sobre atributos de baixa relevância preditiva, em consonância com o princípio da parcimônia preconizado pela Navalha de Occam (Kavlakoglu, 2026c).

Para sanar essa vulnerabilidade da árvore única, a estatística computacional recorre à técnica *Random Forest*, ou Floresta Aleatória. Este modelo opera sob o paradigma de comitês de máquinas, criando grandes quantidades de árvores de decisão simultâneas de forma paralela. Para garantir que as árvores não tomem decisões idênticas, o algoritmo força uma diversidade matemática ao treinar cada uma delas com um subconjunto aleatório de pacientes e características. Ao submeter os dados de um novo exame ao modelo, o diagnóstico final não é imposto por uma

única regra, mas determinado por uma votação majoritária entre todas as árvores que compõem a floresta. Essa dinâmica de sabedoria coletiva dilui os erros de árvores individuais e gera um sistema preditivo altamente estável e protegido contra anomalias (Faceli *et al*., 2021).

A essência da floresta aleatória consiste em atuar como uma expansão avançada do método *bagging* (agregação *bootstrap*), incorporando também a aleatoriedade de características (método do subespaço aleatório) para forçar uma correlação extremamente baixa entre as árvores (IBM, 2026). Em cada amostragem *bootstrap*, cerca de um terço dos dados (aproximadamente 37%) fica fora do treino da árvore; essa amostra *out-of-bag* (OOB) permite estimar o erro de generalização sem um conjunto de validação separado (IBM, 2026). Um grande benefício clínico do *Random Forest* é a sua clareza na atribuição de importância preditiva das variáveis, mensurada com ferramentas como a diminuição média da impureza (MDI) e a importância por permutação (MDA) (IBM, 2026).

Entre os algoritmos apresentados, a Regressão Logística e a Árvore de Decisão expõem diretamente sua lógica de decisão, enquanto o SVM com *kernel* e o *Random Forest* decidem por mecanismos cuja leitura direta é mais difícil para o profissional de saúde. É essa diferença de transparência, e não necessariamente de desempenho, que motiva a discussão sobre explicabilidade apresentada a seguir.

2.4 O DILEMA DA CAIXA PRETA E A INTELIGÊNCIA ARTIFICIAL EXPLICÁVEL

A evolução dos sistemas computacionais na oncologia transitou de ferramentas visuais puramente assistenciais para algoritmos preditivos autônomos de alta complexidade. Modelos como os comitês de árvores e as máquinas de vetores de suporte alcançam taxas de acerto elevadas na classificação de tumores, mas não expõem diretamente o raciocínio que leva a cada decisão, situação que a literatura científica denomina dilema da caixa preta. Em um cenário de alto risco como o diagnóstico de câncer de mama, a previsão matemática isolada é insuficiente. O médico patologista não pode basear uma decisão terapêutica drástica, como uma intervenção cirúrgica, em um sistema que emite um alerta de malignidade sem fornecer o raciocínio biológico e morfológico que motivou tal conclusão (Holzinger *et al*., 2019).

Para preencher essa lacuna entre a precisão matemática e a confiança médica,

consolidou-se o campo da Inteligência Artificial Explicável, amplamente referenciado pela sigla em inglês XAI. O propósito primordial da XAI não é focar na criação de novos classificadores, mas sim no desenvolvimento de métodos e ferramentas que tornem o processo de decisão das máquinas transparente e compreensível para os seres humanos. Em aplicações médicas, a explicabilidade atua como uma camada de auditoria e segurança. Ela permite que o especialista de saúde verifique se o algoritmo está baseando sua decisão em características celulares clinicamente válidas, como a concavidade e a textura do núcleo, em vez de aprender padrões espúrios ou artefatos irrelevantes presentes na base de dados (Adadi e Berrada, 2018).

Do ponto de vista arquitetônico, Rudin (2019) destaca que a explicabilidade se divide em duas abordagens fundamentais. A primeira consiste na utilização de modelos intrinsecamente interpretáveis, como a Regressão Logística ou uma única Árvore de Decisão, cujas equações matemáticas são naturalmente transparentes. Para a autora, em decisões de alto risco esses modelos frequentemente alcançam desempenho comparável ao dos modelos de caixa preta, possibilidade que deve ser verificada antes de se recorrer a estes. A segunda abordagem engloba as técnicas de explicabilidade *post-hoc*. Estas técnicas são acopladas externamente a modelos de caixa preta após a fase de treinamento, extraindo interpretações sem alterar a estrutura interna do algoritmo original. No escopo deste estudo, as duas vias são combinadas: modelos intrinsecamente interpretáveis são comparados a modelos de caixa preta, e métodos *post-hoc* são aplicados a todos eles, de modo a verificar se a complexidade adicional se traduz em ganho de desempenho e a acompanhar cada diagnóstico de uma explicação.

2.5 SHAPLEY ADDITIVE EXPLANATIONS (SHAP)

A técnica *SHapley Additive exPlanations* (SHAP) representa o atual estado da arte em explicabilidade algorítmica. A sua base teórica não nasceu na ciência da computação, mas sim na teoria dos jogos cooperativos, formulada pelo matemático Lloyd Shapley. Na teoria original, o valor de Shapley calcula a contribuição exata e justa de cada jogador para o prêmio final obtido por uma equipe. Quando esse conceito é transportado para o aprendizado de máquina, o modelo preditivo assume o papel do jogo, as características celulares atuam como os jogadores e o prêmio a ser dividido é a predição final do algoritmo. De acordo com a documentação oficial da ferramenta,

o SHAP atua como uma abordagem unificada, consolidando diversas metodologias anteriores sob a classe de métodos de atribuição de características aditivas para revelar os bastidores matemáticos da caixa preta (Lundberg e Lee, 2017).

Um dos grandes trunfos arquitetônicos da biblioteca SHAP, conforme detalhado em seu manual técnico, é a disponibilidade de otimizadores algorítmicos específicos denominados *explainers*. Como o cálculo de todas as combinações possíveis de variáveis possui um custo computacional altíssimo, a ferramenta oferece soluções otimizadas para diferentes modelos. Para algoritmos baseados em árvores, como a Árvore de Decisão e o *Random Forest*, a biblioteca disponibiliza o *TreeExplainer*, um algoritmo capaz de calcular os valores exatos de Shapley de forma extremamente rápida aproveitando a estrutura de roteamento interna das árvores. Para arquiteturas matemáticas distintas ou modelos de caixa preta, o sistema recorre a algoritmos agnósticos, como o *KernelExplainer*, que podem explicar modelos de qualquer natureza, ao custo de valores aproximados (Lundberg, 2026).

O resultado desse robusto processamento matemático é traduzido em visualizações gráficas projetadas especificamente para a prática clínica e auditoria de dados. No escopo da interpretabilidade local, voltada para o diagnóstico de um único paciente, o SHAP fornece gráficos de cascata (*waterfall plots*) (Dutta, 2024). Essas representações ilustram milimetricamente como cada característica, como a textura ou a área do núcleo celular, empurrou a probabilidade do diagnóstico para cima ou para baixo a partir do valor base da população. No escopo global, o algoritmo compila todas as predições em gráficos de enxame (*beeswarm plots* ou *summary plots*). Esse panorama permite que o médico observe não apenas quais variáveis são globalmente mais importantes para o classificador, mas também a direção biomédica desse impacto, revelando se os valores altos de uma determinada característica estão sistematicamente associados a tumores malignos (Adadi e Berrada, 2018).

Em comparação com outras ferramentas de explicabilidade disponíveis na literatura, como o modelo LIME, o método SHAP se destaca por sua fundamentação teórica sólida. Enquanto outras técnicas aproximam o comportamento do algoritmo a partir de vizinhanças locais dos dados, o SHAP possui propriedades matemáticas de consistência e de precisão local. Na prática, a soma dos valores atribuídos a cada característica celular pelo SHAP, acrescida do valor de base, reproduz a predição do

modelo. Os valores são exatos nos explicadores de árvores, como o TreeExplainer, e aproximados nos demais, como o KernelExplainer, o que deve ser considerado ao auditar cada diagnóstico (Lundberg e Lee, 2017).

2.5.1 Fundamentação matemática: a equação de Shapley

Para compreender como a biblioteca computacional distribui os pesos das características oncológicas, é estritamente necessário analisar a equação matemática original proposta para o Valor de Shapley. O cálculo baseia-se na análise de todas as permutações e subconjuntos possíveis de jogadores em um cenário cooperativo. Seja N o conjunto total de características celulares disponíveis em um exame e S um subconjunto específico dessas características, o valor de Shapley para uma característica isolada i, denotado por ϕ_i, é definido pela Equação 13 (Lundberg e Lee, 2017):

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [v(S \cup \{i\}) - v(S)] \tag{13}$$

A interpretação desta equação revela a essência do método explicativo. O termo $v(S \cup \{i\}) - v(S)$ representa a contribuição marginal da característica i. Na prática médica, ele calcula a diferença entre a predição de risco do modelo quando a característica i (como a simetria celular) está presente no exame e a predição quando ela é omitida daquela combinação específica. O algoritmo calcula essa diferença não apenas uma vez, mas para todos os subconjuntos S possíveis formados pelas outras variáveis do modelo (Lundberg e Lee, 2017).

A fração que antecede a contribuição marginal atua como um sistema de pesos baseado em probabilidade combinatória. Os termos fatoriais, representados pelo símbolo de exclamação, calculam o peso exato daquela coalizão específica se formar, garantindo que o valor final seja distribuído de maneira perfeitamente justa. Por fim, o somatório agrega todas essas contribuições marginais ponderadas. O resultado é um único valor ϕ_i que quantifica, com exatidão matemática, o impacto líquido que aquela característica anatômica exerceu para elevar ou reduzir a probabilidade de o tumor ser classificado como maligno (Lundberg e Lee, 2017).

2.6 REDUÇÃO DE DIMENSIONALIDADE E UMAP

A análise preditiva de tumores lida com um volume massivo de informações simultâneas. No caso do câncer de mama, o algoritmo avalia dezenas de características anatômicas em um único exame, como o raio, a textura e a simetria de cada núcleo celular (Street *et al.*, 1993). Embora os modelos matemáticos consigam processar e cruzar esses dados em um espaço de trinta dimensões com extrema facilidade, essa estrutura de alta dimensionalidade não possui uma representação física direta que possa ser desenhada ou interpretada visualmente. Essa assimetria estrutural cria um obstáculo analítico significativo na prática médica, pois inviabiliza a observação direta do comportamento de toda a base de pacientes utilizando os eixos convencionais de um gráfico bi ou tridimensional.

Para solucionar essa limitação biomédica, a ciência de dados recorre a técnicas de redução de dimensionalidade. O propósito primário dessas ferramentas não é simplesmente descartar variáveis anatômicas aleatoriamente, mas sim aplicar transformações matemáticas capazes de comprimir um grande volume de dimensões em apenas dois eixos principais (James *et al.*, 2023). O desafio central desse processo de compressão é preservar ao máximo a essência da informação original. Uma técnica metodologicamente eficiente deve garantir que a estrutura dos dados apresentada no gráfico bidimensional seja um reflexo direto e fiel das relações biológicas que existiam no espaço multidimensional complexo (Bollon *et al.*, 2022).

Entre as metodologias disponíveis na literatura estatística contemporânea, o algoritmo UMAP, que consiste na Aproximação e Projeção de Variedade Uniforme, consolidou-se como uma ferramenta de altíssimo desempenho para a redução de dimensionalidade. O seu funcionamento interno diverge de abordagens matemáticas puramente lineares ao fundamentar-se em princípios de topologia algébrica. Na primeira etapa de seu processamento computacional, o algoritmo constrói uma representação teórica do conjunto de dados em seu espaço original de alta dimensão. Para isso, o modelo calcula as distâncias entre todos os pontos do sistema e mapeia rigorosamente os vizinhos mais próximos de cada elemento, formando um complexo grafo matemático que modela a estrutura exata de conectividade da informação original (McInnes *et al.*, 2018).

Uma vez que essa rede de vizinhanças é estabelecida, a segunda fase do algo-

ritmo consiste em projetar essa estrutura em um espaço de dimensão reduzida, como um plano bidimensional. Para realizar essa transição geométrica sem descaracterizar os dados, o UMAP inicializa um posicionamento espacial e aplica um rigoroso processo de otimização. O sistema utiliza vetores de atração matemática para aproximar as coordenadas dos pontos que foram mapeados como vizinhos fortes no espaço original, ao mesmo tempo em que aplica métricas de repulsão para afastar os pontos que não possuíam conexões de similaridade. O algoritmo ajusta iterativamente essas posições até que o gráfico plano atinja a aproximação topológica mais fiel possível da complexa rede inicial (Bollon *et al.*, 2022).

O grande diferencial técnico desta arquitetura algorítmica reside na sua capacidade matemática de preservar simultaneamente a estrutura local e a estrutura global do conjunto de dados originais. Ao contrário de técnicas anteriores que frequentemente sacrificam a disposição geral em prol do ajuste de vizinhanças imediatas, o UMAP assegura que as proporções de distância sejam mantidas na projeção visual. Como resultado geométrico direto desse processamento topológico, elementos de dados com propriedades numéricas semelhantes convergem naturalmente para regiões isoladas do gráfico, formando densos agrupamentos visuais conhecidos na estatística descritiva como *clusters*. Essa capacidade inerente de revelar a separabilidade natural de bases complexas consolida o método como um recurso indispensável na análise exploratória avançada (Bollon *et al.*, 2022).

Apesar de sua complexidade matemática interna, a aplicação prática do UMAP exige a calibração de hiperparâmetros fundamentais que governam o resultado da projeção geométrica. De acordo com Bollon *et al.* (2022), o principal deles é o número de vizinhos mais próximos (*nearest neighbors* ou NN), que dita como o algoritmo constrói o grafo inicial, balanceando a atenção entre a estrutura local e global dos dados. Outro parâmetro crucial é a distância mínima (*minimum distance* ou MD), que controla o quão próximos os pontos podem ficar no espaço de baixa dimensão. Por fim, deve-se definir a métrica de saída, que determina a topologia do espaço latente, como a Euclidiana ou a Esférica. Nesse cenário, a sintonia exata desses valores é vital para aplicações oncológicas. Estudos voltados à estratificação de tumores de mama evidenciam, por exemplo, que a adoção de uma distância mínima nula maximiza a coesão biológica da separação espacial. Além disso, para assegurar a reprodutibilidade

científica e contornar a natureza estocástica inerente à otimização do algoritmo, faz-se necessária a adoção de estratégias de estabilização em sua execução (Bollon *et al.*, 2022). As características destes parâmetros estão sumarizadas no Quadro 1.

QUADRO 1 – PRINCIPAIS HIPERPARÂMETROS DO ALGORITMO UMAP

Hiperparâmetro	**Descrição**
Número de Vizinhos (NN)	Controla a construção do grafo inicial, ditando o equilíbrio entre a preservação da estrutura local e global dos dados.
Distância Mínima (MD)	Define o quão próximos os pontos podem ficar no espaço reduzido, afetando diretamente a compactação visual dos *clusters*.
Métrica de Saída	Determina o espaço geométrico (como Euclidiano ou Esférico) no qual as distâncias finais serão projetadas.

FONTE: Adaptado de Bollon *et al.*, 2022

No ambiente de desenvolvimento, a implementação desta técnica é frequentemente realizada por meio da biblioteca *umap-learn* em Python. O Código 1 ilustra a instanciação do algoritmo com a definição de seus respectivos hiperparâmetros para a posterior redução de dimensionalidade de um conjunto de dados clínicos. Os valores do exemplo são ilustrativos.

CÓDIGO 1 – IMPLEMENTAÇÃO DA REDUÇÃO DIMENSIONAL UTILIZANDO O ALGORITMO UMAP EM PYTHON.

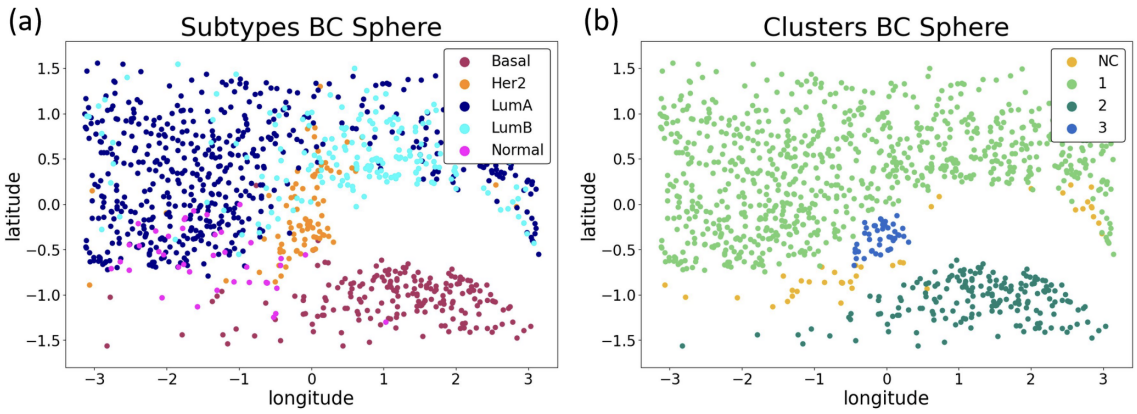
```
1  import umap
2
3  # Configuracao e instanciacao do redutor topologico
4  redutor = umap.UMAP(
5      n_neighbors=65,
6      min_dist=0.0,
7      metric='euclidean',
8      random_state=42
9  )
10
11 # Aplicacao da reducao dimensional na base de dados
12 dados_reduzidos = redutor.fit_transform(dados_pacientes)
```

FONTE: O autor

A eficácia dessa convergência topológica pode ser observada na Figura 7. A imagem ilustra a projeção geométrica gerada pelo UMAP a partir de uma base de dados de pacientes com câncer de mama. É possível notar nitidamente como a

redução de dimensionalidade preserva a estrutura biológica original: os diferentes subtipos tumorais agrupam-se em *clusters* densos e isolados no novo espaço reduzido. Essa representação comprova a capacidade visual do algoritmo em evidenciar a separabilidade natural e as relações de similaridade em bases oncológicas de alta dimensionalidade (Bollon *et al.*, 2022).

FIGURA 7 – PROJEÇÃO UMAP E FORMAÇÃO DE CLUSTERS EM DADOS DE CÂNCER DE MAMA



FONTE: Adaptado de Bollon *et al.*, 2022

3 TRABALHOS RELACIONADOS

Este capítulo apresenta uma análise detalhada da literatura científica que fundamenta o estado da arte no uso de aprendizado de máquina para o diagnóstico oncológico. A seleção abrange desde os estudos seminais que deram origem às bases de dados modernas até pesquisas recentes focadas em inteligência artificial explicável, estabelecendo o contexto necessário para a identificação da lacuna de pesquisa preenchida por este projeto.

3.1 EXTRAÇÃO DE CARACTERÍSTICAS NUCLEARES PARA O DIAGNÓSTICO DE TUMORES MAMÁRIOS (STREET *ET AL.*, 1993)

O trabalho conduzido por Street *et al.* (1993) é considerado a pedra angular para o desenvolvimento de sistemas de diagnóstico assistido por computador aplicados ao câncer de mama. O objetivo primordial da pesquisa foi desenvolver um sistema que pudesse processar imagens digitais de aspirados por agulha fina para fornecer um diagnóstico maligno ou benigno de forma automatizada e precisa.

A metodologia baseou-se na criação de um sistema de análise de imagens que permitia ao usuário delimitar grosseiramente as bordas dos núcleos celulares. A partir dessa interação inicial, o software calculava automaticamente dez características geométricas distintas para cada núcleo, incluindo o raio, o perímetro, a textura e a simetria. Esse processo gerou a base de dados conhecida como *Wisconsin Diagnostic Breast Cancer* (WDBC), que é utilizada como referência na literatura acadêmica até os dias atuais.

Os resultados obtidos na época demonstraram uma acurácia de classificação de noventa e sete por cento utilizando um classificador baseado em programação linear. O trabalho provou que as medidas nucleares, quando extraídas de forma sistemática, continham informações estatísticas suficientes para diferenciar tumores sem a necessidade de intervenções invasivas imediatas.

Para este projeto de graduação, este estudo é fundamental pois define a origem e o significado biológico de cada uma das variáveis que serão processadas pelos modelos de SHAP e UMAP. Compreender a gênese dos dados permite uma interpretação mais rica das explicações fornecidas pela inteligência artificial explicável.

3.2 APLICAÇÕES DE MACHINE LEARNING NA PREDIÇÃO E PROGNÓSTICO DO CÂNCER (CRUZ E WISHART, 2006)

A revisão sistemática elaborada por Cruz e Wishart (2006) ofereceu um panorama crítico sobre como as técnicas de aprendizado de máquina estavam migrando de laboratórios de pesquisa para aplicações práticas no prognóstico oncológico. O foco do estudo foi avaliar a viabilidade de substituir métodos estatísticos convencionais por modelos preditivos mais robustos.

Os autores analisaram diversas arquiteturas, como as Máquinas de Vetores de Suporte (SVM) e Redes Neurais Artificiais, destacando que a complexidade biológica do câncer exigia ferramentas capazes de lidar com relacionamentos não lineares. A pesquisa ressaltou que, embora o câncer de mama fosse o mais estudado, a metodologia poderia ser estendida para outros tipos de neoplasias, como as de próstata e pulmão.

Uma das conclusões mais relevantes deste trabalho foi a identificação de que a acurácia isolada não era o único fator de sucesso. Os pesquisadores apontaram que a qualidade dos dados de entrada e a seleção cuidadosa de variáveis eram determinantes para a utilidade clínica do modelo.

Este estudo corrobora a necessidade de superar as limitações da estatística básica na oncologia. No entanto, a busca por capturar as nuances da malignidade celular não deve resultar em modelos de complexidade interpretativa inacessível. A abordagem deste trabalho enfatiza que, no contexto médico, modelos preditivos que priorizam a simplicidade e a explicabilidade trazem vantagens substanciais, permitindo que a equipe de saúde compreenda e confie nos critérios lógicos que fundamentam o diagnóstico.

3.3 DIAGNÓSTICO DE CÂNCER DE PULMÃO E CÓLON VIA DEEP LEARNING (MASUD *ET AL.*, 2021)

A pesquisa de Masud *et al.* (2021) explorou o uso de Redes Neurais Profundas para o diagnóstico de câncer em tecidos pulmonares e colorretais. O diferencial do trabalho foi o uso de uma estrutura de classificação baseada em imagens de histopatologia para identificar padrões malignos de forma automática.

O modelo desenvolvido utilizou técnicas de aprendizado profundo para extrair características de alto nível que muitas vezes são imperceptíveis ao olho humano. Os autores conseguiram alcançar métricas de desempenho superiores a noventa e seis por cento de acurácia, demonstrando o poder das arquiteturas modernas de inteligência artificial na oncologia.

Contudo, os pesquisadores notaram que modelos de rede neural profunda, apesar de precisos, operam como sistemas de difícil interpretação. O estudo concluiu que a integração de sistemas computacionais na medicina requer um equilíbrio entre a capacidade de processamento e a facilidade de uso pelo corpo clínico.

Este trabalho é citado para contrastar com a abordagem tabular deste TCC. Ele exemplifica o estado da arte em processamento de imagens, servindo de base para discutir por que a explicabilidade se torna ainda mais necessária quando lidamos com modelos de alta complexidade como os de *Deep Learning*.

3.4 PREDIÇÃO DE CÂNCER DE PULMÃO COM SELEÇÃO DE CORRELAÇÃO (ABDULLAH *ET AL.*, 2021)

Focando na eficiência computacional, Abdullah *et al.* (2021) investigaram como a seleção inteligente de variáveis pode melhorar a precisão do diagnóstico de câncer de pulmão. O objetivo era identificar quais características clínicas e genéticas eram mais correlacionadas com a presença da doença.

A metodologia utilizou a ferramenta WEKA para testar diversos classificadores, com destaque para as Máquinas de Vetores de Suporte (SVM). Os autores aplicaram um método de seleção baseado em correlação para remover variáveis irrelevantes ou redundantes, buscando um modelo mais enxuto e rápido.

Os resultados mostraram que modelos com menos variáveis, porém mais significativas, apresentavam desempenho equivalente ou superior a modelos que utilizavam todos os dados disponíveis. Isso demonstrou que o excesso de informação pode, por vezes, prejudicar o aprendizado da máquina.

Este estudo dialoga com o presente projeto na questão dos atributos redundantes. Ao mostrar que a remoção de variáveis correlacionadas não prejudica o desempenho, o trabalho de Abdullah, Abdulazeez e Sallow ampara o tratamento da colinearidade adotado aqui, como a regularização da Regressão Logística e o agrupa-

mento de raio, perímetro e área em um único fator nas explicações.

3.5 ABORDAGENS DE MACHINE LEARNING NA PREDIÇÃO DO CÂNCER DE MAMA (RABIEI *ET AL.*, 2022)

O estudo de Rabiei *et al.* (2022) avaliou diferentes algoritmos de aprendizado de máquina sobre dados hospitalares reais, obtidos de forma retrospectiva no Motamed Cancer Institute, em Teerã. É importante delimitar o objeto: diferentemente dos demais trabalhos analisados neste capítulo, a pesquisa não classifica a malignidade de um tumor já identificado a partir de sua morfologia, mas estima o risco de desenvolvimento da doença a partir de fatores demográficos, laboratoriais e mamográficos, como idade, índice de massa corporal, tempo de amamentação, histórico familiar e densidade mamária. Dos 5.178 registros iniciais, 1.290 permaneceram após o pré-processamento, cada um descrito por 24 atributos.

Os pesquisadores testaram três modelos: *Random Forest*, *Gradient Boosting Trees* e *Multi-Layer Perceptron*. Para corrigir o desbalanceamento entre casos positivos e negativos, aplicaram a técnica de sobreamostragem sintética SMOTE sobre o conjunto de treinamento. A otimização dos hiperparâmetros foi conduzida por um algoritmo genético com validação cruzada de três dobras, enquanto a avaliação final do desempenho recorreu a uma divisão única entre treino e teste, na proporção de 75% e 25%.

As conclusões apontaram o *Random Forest* como o modelo de melhor desempenho global, com acurácia de 80%, sensibilidade de 95% e especificidade de 83%. Cabe registrar, contudo, que as áreas sob a curva ROC relatadas situam-se entre 0,53 e 0,59 para os três modelos, valores próximos ao acaso, sendo o *Gradient Boosting Trees* o de maior AUC. O trabalho enfatizou que o ajuste de hiperparâmetros e o pré-processamento rigoroso são chaves para a obtenção de modelos confiáveis em ambientes médicos.

Para este TCC, a pesquisa serve como referência metodológica para a fase de treinamento e valida a inclusão de comitês de árvores no conjunto de classificadores testados. Serve igualmente como advertência quanto à comparação direta de métricas entre estudos: o contraste entre as AUC próximas ao acaso obtidas naquele trabalho e os valores superiores a 0,99 alcançados sobre a base Wisconsin não decorre da supe-

rioridade dos algoritmos empregados aqui, mas da natureza distinta dos problemas. Predizer o risco de adoecer a partir de fatores de estilo de vida é tarefa substancialmente mais difícil do que classificar a malignidade de um tumor a partir de medidas morfológicas extraídas de seus próprios núcleos celulares.

3.6 SEGMENTAÇÃO E CONTAGEM DE CÉLULAS EM IMAGENS (SILVA JÚNIOR, 2023)

Desenvolvido no contexto acadêmico de Curitiba, o trabalho de Silva Júnior (2023) propôs um *pipeline* de processamento digital de imagens para a segmentação e a contagem de núcleos celulares em lâminas de câncer de mama. O objetivo era automatizar uma tarefa exaustiva do patologista: a quantificação de células positivas em exames de imuno-histoquímica, cujo resultado é expresso em uma escala de quatro classes de intensidade, negativa, fraca, moderada e forte, utilizada na composição do escore de proporção e intensidade.

A abordagem dispensou algoritmos de aprendizado de máquina, apoiando-se integralmente em técnicas clássicas de visão computacional: separação de canais de cor, limiarização, operações de morfologia matemática, detecção de pontos côncavos para a separação de núcleos sobrepostos, transformada de *Watershed* e momentos de Hu para a caracterização geométrica das formas segmentadas. O autor detalhou cada etapa do fluxo de trabalho, desde a captura da imagem até a extração final dos dados quantitativos, enfatizando os desafios técnicos de lidar com células sobrepostas ou imagens de baixa qualidade.

Um aspecto deste trabalho merece registro por seu valor metodológico. O autor declara explicitamente que os resultados não puderam ser validados de forma quantitativa: a aferição da qualidade da segmentação exigiria as contagens reais de células em cada amostra, que dependeriam da disponibilidade de um patologista, o que não foi possível obter dentro do prazo do estudo. A avaliação apresentada é, portanto, qualitativa e visual, e o próprio autor remete a validação a trabalhos futuros, reconhecendo que sua ausência compromete a robustez das conclusões.

A relevância deste estudo para o presente projeto é dupla. Em primeiro lugar, ele esclarece a infraestrutura necessária para gerar os dados de entrada: enquanto este TCC opera sobre atributos morfológicos já tabulados, o trabalho de Silva Júnior mostra

como tais medidas são extraídas do mundo físico. Em segundo lugar, a limitação assumida pelo autor ilustra de maneira concreta o problema que a Seção 4.7 deste trabalho procura enfrentar: sem um protocolo capaz de quantificar o desempenho e a sua variabilidade, mesmo um *pipeline* tecnicamente bem construído permanece sem sustentação empírica.

3.7 PREDIÇÃO BASEADA EM APRENDIZADO DE MÁQUINA (CHEN *ET AL.*, 2023)

A pesquisa de Chen *et al.* (2023) revisitou o desafio da classificação do câncer de mama focando na robustez das métricas de avaliação. O objetivo era determinar quais algoritmos eram mais seguros para a adoção clínica, priorizando a redução de falsos negativos.

O estudo utilizou a base de dados de Wisconsin, submetida à padronização *Z-score* e a uma seleção de atributos por correlação de Pearson que reduziu as trinta variáveis originais às quinze mais associadas à variável alvo. Quatro algoritmos foram comparados: XGBoost, *Random Forest*, Regressão Logística e K-Nearest Neighbors. A avaliação empregou acurácia, precisão, revocação e F1-score, elegendo explicitamente a revocação como índice primário, sob o argumento de que deixar de detectar um caso maligno acarreta consequências clínicas mais graves do que emitir um alarme falso. Os autores destacaram que a inteligência artificial não deve ser vista como um substituto para o médico, mas como uma ferramenta de segunda opinião capaz de filtrar casos suspeitos com alta velocidade.

Quanto ao protocolo experimental, o desempenho foi medido sobre divisões estratificadas únicas entre treino e teste, nas proporções de 8:2 e 7:3, recorrendo-se à validação cruzada apenas para a escolha do número de vizinhos do KNN. Os resultados confirmaram a eficácia dos modelos de *Boosting* para este tipo de dado tabular: na divisão 8:2, o XGBoost alcançou acurácia de 0,974, precisão de 0,960, revocação de 1,000 e F1-score de 0,980. A pesquisa concluiu que a integração desses modelos em sistemas de apoio à decisão poderia acelerar significativamente o início do tratamento de pacientes oncológicos.

Este trabalho é relevante por ser uma das publicações mais recentes sobre a mesma base de dados utilizada neste projeto, estabelecendo o patamar de desempenho que este TCC deve buscar atingir antes de aplicar as camadas de explicabilidade. Cabe

observar, porém, que a avaliação restringe-se a métricas dependentes de um limiar fixo, sem recorrer a curvas ROC ou Precisão-Revocação, e apoia-se em partições únicas dos dados, sem estimativa da variabilidade do desempenho entre diferentes divisões.

3.8 ESTUDO COMPARATIVO COM SELEÇÃO LASSO E SHAP (SHAON *ET AL.*, 2024)

Considerado o trabalho mais próximo da proposta deste TCC, Shaon *et al.* (2024) realizaram uma comparação de modelos preditivos utilizando técnicas modernas de seleção de atributos e explicabilidade. O objetivo era não apenas prever o câncer, mas entender quais variáveis eram determinantes para o modelo.

A metodologia comparou cinco modelos tradicionais, Regressão Logística, Árvore de Decisão, *Extremely Randomized Trees*, AdaBoost e Análise Discriminante Linear, e dois meta-modelos construídos por votação, um por voto majoritário e outro por voto suave sobre as probabilidades. Todos foram avaliados sob validação cruzada de dez dobras. O ponto central do estudo está na comparação entre duas estratégias de seleção de atributos: o LASSO e o SHAP. É necessário precisar o papel desempenhado pelo SHAP nesse desenho experimental: ele foi empregado como método de seleção de atributos, isto é, para identificar as vinte variáveis mais frequentemente relevantes ao longo dos sete modelos e, em seguida, retreiná-los apenas sobre esse subconjunto. Não houve produção de explicações individuais por paciente. Os autores alcançaram acurácia de 99,82% com o *Extremely Randomized Trees* e com ambos os meta-modelos, demonstrando que a seleção orientada por valores de Shapley melhora o desempenho da maioria dos algoritmos testados.

O estudo concluiu que a seleção de atributos baseada em SHAP produz modelos simultaneamente mais precisos e mais interpretáveis, por concentrar a decisão em um número menor de biomarcadores comprovadamente relevantes. No entanto, o trabalho limitou-se à análise técnica dos dados: os próprios autores registram, nas considerações finais, que ainda seria necessário disponibilizar aplicações práticas para que os modelos chegassem ao usuário final. A avaliação também se apoia exclusivamente em métricas dependentes de limiar, acurácia, precisão, revocação, F1-score, coeficiente de correlação de Matthews e *kappa* de Cohen, sem recorrer a curvas ROC ou Precisão-Revocação.

Este artigo representa o "estado da arte" atual e serve como o principal ponto de comparação. Os diferenciais deste TCC em relação ao trabalho de Shaon et al. são a utilização do SHAP como instrumento de explicação individual de cada diagnóstico emitido, e não apenas como filtro global de atributos; a inclusão do UMAP para visualização topológica; e o desenvolvimento de um software completo com interface gráfica, indo além da análise estatística pura.

3.9 SÍNTESE E LACUNA DE PESQUISA

A análise dos trabalhos relacionados permite concluir que, embora existam pesquisas robustas focadas na acurácia preditiva e estudos recentes explorando a técnica SHAP, ainda há uma carência de soluções que integrem esses elementos em uma ferramenta de software coesa e utilizável pelo profissional de saúde.

Muitos dos modelos propostos na literatura permanecem restritos a ambientes de programação ou relatórios estáticos. O Quadro 2 sintetiza a comparação entre as obras citadas e a proposta deste projeto. A contribuição acadêmica deste trabalho reside na integração de quatro elementos que, isoladamente, já foram explorados na literatura, mas que não foram reunidos em uma única solução: o treinamento e a comparação sistemática de algoritmos clássicos de aprendizado de máquina supervisionado sobre a base Wisconsin, a aplicação do SHAP para explicabilidade local e global das decisões, a utilização do UMAP para visualização topológica da separabilidade dos dados, e o desenvolvimento de uma interface funcional capaz de processar dados em lote e gerar relatórios estruturados com as fundamentações visuais dos diagnósticos.

A comparação por escopo não esgota a análise. Como os trabalhos diferem sobretudo no rigor com que sustentam empiricamente seus resultados, o Quadro 3 os confronta segundo quatro critérios técnicos. Metade avalia o desempenho sobre uma partição única; nenhum reporta a área sob a curva Precisão-Revocação, mais apropriada a classes desbalanceadas conforme a Seção 2.3.3; nenhum testa a significância das diferenças entre modelos; e nenhum avalia a calibração das probabilidades. Apenas Shaon *et al.* recorrem ao SHAP, ainda assim como filtro global de atributos.

QUADRO 2 – COMPARAÇÃO ENTRE TRABALHOS RELACIONADOS E O PRESENTE PROJETO.

Trabalho	**ML**	**Base Pública**	**Tabular**	**Câncer de mama**	**Interface**	**XAI**
Street *et al.* (1993)	Sim	—	Não	Sim	Sim	Não
Cruz & Wishart (2006)	Sim	Sim	Sim	Sim	Não	Não
Masud *et al.* (2021)	Sim	Sim	Não	Não	Não	Não
Abdullah *et al.* (2021)	Sim	Sim	Sim	Não	Não	Não
Rabiei *et al.* (2022)	Sim	Não	Sim	Sim	Não	Não
Silva Júnior (2023)	Não	Sim	Não	Sim	Não	Não
Chen *et al.* (2023)	Sim	Sim	Sim	Sim	Não	Não
Shaon *et al.* (2024)	Sim	Sim	Sim	Sim	Não	Sim
Este Projeto	**Sim**	**Sim**	**Sim**	**Sim**	**Sim**	**Sim**

FONTE: O autor

QUADRO 3 – COMPARAÇÃO TÉCNICA ENTRE OS TRABALHOS RELACIONADOS E O PRESENTE PROJETO.

Trabalho	**Melhor algoritmo**	**Métricas reportadas**	**Validação**	**Explicabilidade**
Street *et al.* (1993)	MSM-T	Acurácia (97,0%)	Cruzada 10-*fold*	Nenhuma
Cruz & Wishart (2006)	Revisão	—	Critica a falta de validação	Nenhuma
Masud *et al.* (2021)	CNN	Acurácia (96,33%), F1, MCC	Única 70/30	Nenhuma
Abdullah *et al.* (2021)	SVM	Acurácia (95,56%), F1, área ROC	Cruzada 10-*fold*	Nenhuma
Rabiei *et al.* (2022)	*Random Forest*	Acurácia (80%), AUC (0,53)	Única 75/25	Nenhuma
Silva Júnior (2023)	Proc. de imagens	Nenhuma	Nenhuma	Nenhuma
Chen *et al.* (2023)	XGBoost	Acurácia (97,4%), revocação, F1	Únicas 8:2 e 7:3	Nenhuma
Shaon *et al.* (2024)	ERT e votação	Acurácia (99,82%), F1, MCC	Cruzada 10-*fold*	SHAP global (seleção)
Este Projeto	**Sem diferença entre RL, SVM, RF e KNN**	**Acurácia, F1, ROC-AUC, PR-AUC, Brier, ECE**	**Cruzada 10×5, 5×2cv, Friedman**	**SHAP local e global, UMAP, calibração, OOD**

FONTE: O autor

4 METODOLOGIA

Este capítulo descreve o processo técnico de desenvolvimento da solução proposta, abrangendo desde a preparação dos dados até a serialização dos artefatos que alimentam o software. A construção é dividida em dois componentes principais, detalhados nas seções seguintes: o módulo científico, responsável pelo treinamento e avaliação dos modelos, e o módulo de software, responsável pela interface de uso pelo profissional de saúde.

4.1 CLASSIFICAÇÃO DA PESQUISA

A correta caracterização do tipo de pesquisa é um requisito metodológico fundamental, pois delimita o escopo do trabalho e orienta as decisões relacionadas à coleta de dados, à escolha dos instrumentos de análise e à forma de apresentação dos resultados. Neste contexto, o presente trabalho pode ser classificado segundo quatro dimensões complementares.

Quanto à sua natureza, a pesquisa é classificada como aplicada, pois seu objetivo central não é a geração de conhecimento teórico abstrato, mas sim o desenvolvimento de uma solução computacional concreta voltada a um problema real da área da saúde: a opacidade dos modelos preditivos utilizados no diagnóstico oncológico (Gil, 2002).

Quanto à abordagem, a pesquisa é quantitativa, uma vez que todo o processo de modelagem, avaliação e comparação entre os algoritmos fundamenta-se no tratamento numérico de dados morfológicos celulares e na mensuração objetiva do desempenho dos modelos por meio de métricas estatísticas formalmente definidas (Faceli *et al.*, 2021).

Quanto ao objetivo, o trabalho possui caráter simultaneamente preditivo e exploratório. O componente preditivo manifesta-se no treinamento de classificadores supervisionados capazes de estimar a probabilidade de malignidade de um tumor a partir de seus atributos morfológicos. O componente exploratório está presente na investigação visual da estrutura dos dados por meio de técnicas de redução de dimensionalidade, permitindo identificar padrões, agrupamentos e relações de similaridade que não são diretamente observáveis no espaço original de trinta dimensões (Cruz e

Wishart, 2006).

Quanto ao procedimento, a pesquisa é classificada como experimental e computacional. O desenvolvimento ocorre integralmente em ambiente de programação controlado, com experimentos reprodutíveis garantidos pela fixação de sementes de aleatoriedade, divisão padronizada dos dados e registro sistemático das métricas de cada modelo avaliado (Faceli *et al.*, 2021).

4.2 VISÃO GERAL DA ARQUITETURA DA SOLUÇÃO

A arquitetura da solução proposta foi concebida sob uma perspectiva modular, visando segregar de forma clara a etapa de experimentação e modelagem estatística do ambiente de produção e interação com o usuário. Essa estratégia de projeto garante o desacoplamento do sistema, otimiza a manutenibilidade do código e simplifica a distribuição da ferramenta, dividindo o ecossistema em dois componentes fundamentais: o módulo científico e o módulo de software.

O módulo científico é centralizado no *notebook* Wisconsin.ipynb. Este componente engloba todo o *pipeline* experimental do projeto, compreendendo as rotinas de análise exploratória dos dados (EDA), preparação dos atributos preditivos, tratamento de inconsistências, codificação de variáveis e padronização *Z-score* das características morfológicas. Além disso, é neste ambiente que ocorre o treinamento e a avaliação dos algoritmos de aprendizado de máquina supervisionado nos conjuntos de treino e teste, bem como a configuração dos modelos de Inteligência Artificial Explicável acoplados via bibliotecas shap e umap-learn.

Por outro lado, o módulo de software compreende a aplicação de interface gráfica desktop estruturada dentro do diretório app, tendo o script main.py como ponto de entrada principal do sistema. Construído sobre a biblioteca CustomTkinter, este componente gerencia a experiência do usuário final, operando as telas de consulta, dashboards de métricas e a lógica de processamento em lote. Para mitigar erros humanos e otimizar a rotina de trabalho em ambientes clínicos, a aplicação foi projetada para receber diretamente arquivos de planilhas formatadas, eliminando a necessidade de inserção manual dos trinta atributos preditivos por parte do operador.

A comunicação entre esses dois ambientes independentes ocorre por meio de artefatos gerados no módulo científico. O principal é o arquivo serializado wisconsin.pkl,

gravado com a biblioteca cloudpickle, que reúne os cinco classificadores treinados, as versões recalibradas pelo escalonamento de Platt dos quatro que produzem probabilidade informativa, o padronizador *Z-score*, a lista ordenada dos atributos, as partições de treino e teste, os explicadores de cada modelo e a amostra de referência e as importâncias globais do SHAP. Os explicadores são serializados por referência à sua definição em app/core/explainers.py, de modo que o *notebook* e a aplicação executam o mesmo código. O segundo artefato, limiares.json, é gerado pelo script scripts/calibrar_limiares.py a partir do próprio wisconsin.pkl e guarda o limiar de operação e a faixa de recusa de cada modelo, descritos na Subseção 4.7.4; o terceiro, umap_train_2d.npy, guarda o *embedding* UMAP do treino usado pelo mapa populacional. Dessa forma, o módulo de software realiza inferências de modo puramente local, sem a necessidade de retreinar os algoritmos ou expor os dados a servidores externos, garantindo desempenho computacional e privacidade à infraestrutura de saúde.

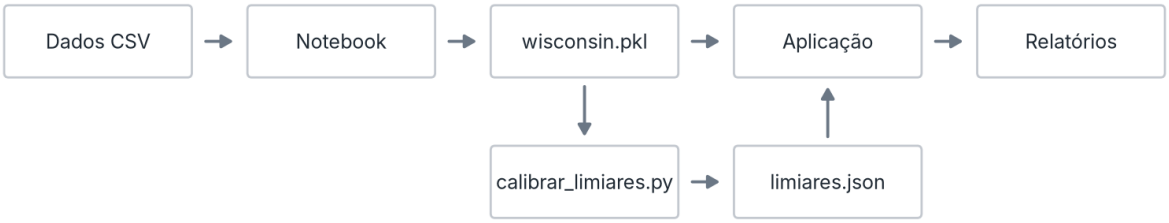
A escolha por uma arquitetura desacoplada em dois módulos distintos também reflete uma decisão de manutenibilidade a longo prazo. Caso seja necessário retreinar os modelos com uma base de dados atualizada ou substituir um algoritmo, basta reexecutar o módulo científico, que regrava o wisconsin.pkl, e em seguida o script calibrar_limiares.py, que recalcula os limiares sobre os novos modelos, sem qualquer alteração no código do módulo de software; para a versão distribuída, o executável é então regenerado, conforme a Subseção 4.8.6. Da mesma forma, melhorias na interface gráfica ou na lógica de geração de relatórios podem ser realizadas de forma independente, sem risco de comprometer a integridade dos modelos preditivos já validados. O fluxo completo de processamento e a respectiva transição dos dados entre as camadas lógica e operacional da arquitetura integrada encontram-se detalhados na Figura 8.

4.3 BASE DE DADOS E AMBIENTE DE DESENVOLVIMENTO

A base utilizada neste projeto é a *Breast Cancer Wisconsin (Diagnostic)*, disponibilizada publicamente no repositório UCI Machine Learning Repository (WOLBERG *et al.*, 1995), e referenciada ao longo deste trabalho como base Wisconsin.

Antes do início do *pipeline* de modelagem, duas colunas foram removidas da base por não agregarem valor preditivo ao sistema. A coluna id consiste em um

FIGURA 8 – DIAGRAMA DE BLOCOS DO FLUXO DE DADOS E COMUNICAÇÃO DA ARQUITETURA



FONTE: O Autor

identificador administrativo sem qualquer significado morfológico ou biológico e, caso mantida, introduziria ruído espúrio no processo de aprendizado. A coluna Unnamed: 32, por sua vez, é um artefato gerado automaticamente durante a exportação do arquivo no formato CSV, não correspondendo a nenhum atributo real da base original. Após essas remoções, o conjunto de dados utilizado para modelagem passa a conter 569 amostras e 31 colunas: a variável alvo e os trinta atributos preditivos.

O ambiente de desenvolvimento utiliza Python 3.12.3, a mesma versão com que o executável da aplicação é gerado. Manter uma única versão entre o módulo científico (Wisconsin.ipynb), o módulo de software (app/main.py) e o executável garante que os objetos persistidos no arquivo wisconsin.pkl sejam lidos no mesmo ambiente em que foram gravados.

Todo o desenvolvimento foi realizado em um ambiente virtual isolado. O arquivo requirements.txt lista as dependências com versões mínimas, o que basta para reproduzir os experimentos; as versões exatas do ambiente que gerou o wisconsin.pkl ficam fixadas em requirements-executavel.txt, usado na geração do executável, pois uma versão diferente do scikit-learn pode não conseguir abrir os objetos serializados.

O Quadro 4 apresenta as principais bibliotecas empregadas nos dois módulos, com suas respectivas funções no projeto.

4.4 PRÉ-PROCESSAMENTO DOS DADOS

O pré-processamento dos dados constitui uma etapa fundamental para garantir a qualidade e a confiabilidade dos modelos preditivos desenvolvidos. Antes de qualquer algoritmo de aprendizado ser instanciado, os dados brutos da base Wisconsin passam

QUADRO 4 – BIBLIOTECAS UTILIZADAS NO PROJETO.

Biblioteca	**Função no Projeto**
Módulo científico e aplicação	
numpy	Operações vetoriais sobre os atributos, as probabilidades e os valores de Shapley.
pandas	Carregamento do arquivo CSV, remoção das colunas id e Unnamed: 32, codificação da variável alvo e manipulação dos subconjuntos de dados.
scikit-learn	Treinamento dos cinco classificadores, pré-processamento (StandardScaler, train_test_split), PCA, validação cruzada, calibração de Platt, covariância de Ledoit-Wolf e métricas de avaliação.
shap	Cálculo dos valores de Shapley para explicabilidade global e local dos cinco classificadores.
matplotlib	Visualizações estáticas do *notebook* e gráficos embutidos nas janelas de explicabilidade.
cloudpickle	Serialização do wisconsin.pkl, inclusive dos explicadores.
Somente no módulo científico	
umap-learn	Redução de dimensionalidade não linear para visualização da separabilidade entre tumores benignos e malignos.
seaborn	*Countplot* da distribuição de classes e *heatmap* das matrizes de confusão.
scipy	Teste de Friedman entre os cinco modelos.
mlxtend	Teste pareado 5×2cv de Dietterich.
scikit-posthocs	Pós-hoc de Nemenyi após o teste de Friedman.
Somente na aplicação	
customtkinter	Interface gráfica *desktop*.
reportlab	Relatórios em PDF do lote e de cada paciente.
bokeh	Versões interativas do mapa populacional e da margem do SVM, abertas no navegador.

FONTE: O autor

por uma sequência de transformações que os tornam adequados para o treinamento supervisionado. As subseções a seguir detalham cada etapa desse *pipeline*, executado na ordem em que aparece no módulo científico.

4.4.1 Codificação da variável alvo

A variável alvo da base Wisconsin, denominada diagnosis, armazena os rótulos das amostras em formato categórico: o caractere B para tumores benignos e M para tumores malignos. Como os algoritmos de aprendizado de máquina supervisionado operam exclusivamente sobre valores numéricos, essa coluna é convertida para uma representação binária antes do treinamento. O mapeamento adotado atribui o valor 0 à classe benigna e o valor 1 à classe maligna, convenção amplamente consolidada na literatura para problemas de classificação binária em oncologia (Street *et al.*, 1993). Aproveitando a mesma etapa, duas colunas são removidas da base por não agregarem valor preditivo ao sistema, conforme descrito na Seção 4.3. O Código 2 apresenta as operações de limpeza e codificação realizadas sobre o DataFrame bruto.

CÓDIGO 2 – LIMPEZA E CODIFICAÇÃO DA VARIÁVEL ALVO.

```
# Remocao de colunas sem valor preditivo
wisconsin_base = wisconsin_base.drop(
    columns=['id', 'Unnamed: 32'], errors='ignore'
)

# Codificacao do rotulo: 'B' (Benigno) -> 0 | 'M' (Maligno) -> 1
wisconsin_base['diagnosis'] = wisconsin_base['diagnosis'].map(
    {'B': 0, 'M': 1}
)

# Separacao entre atributos (X) e variavel alvo (y)
X = wisconsin_base.drop(columns=['diagnosis'])
y = wisconsin_base['diagnosis']
```

FONTE: O autor

4.4.2 Divisão treino e teste

Após a codificação da variável alvo, a base é particionada em dois subconjuntos mutuamente exclusivos: treino e teste. O conjunto de treino, composto por 75% das amostras (426 registros), é utilizado para o ajuste dos parâmetros internos de cada classificador. O conjunto de teste, com os 25% restantes (143 registros), permanece completamente isolado durante todo o desenvolvimento e é acionado apenas na etapa final de avaliação, simulando o comportamento do modelo diante de dados clínicos inéditos.

Um aspecto metodológico crítico desta divisão é o uso do parâmetro stratify=y, conforme demonstrado no Código 3. Esse parâmetro instrui a função a realizar uma amostragem estratificada, garantindo que a proporção original entre as classes, sendo 357 tumores benignos (62,7%) e 212 malignos (37,3%), seja preservada em ambos os subconjuntos. Sem essa estratificação, uma partição aleatória desfavorável poderia concentrar a maioria dos casos malignos em um único subconjunto, introduzindo viés no treinamento e comprometendo a validade estatística da avaliação final. A semente RANDOM_STATE = 42 é fixada para garantir a reprodutibilidade dos resultados.

CÓDIGO 3 – DIVISÃO ESTRATIFICADA DA BASE EM CONJUNTOS DE TREINO E TESTE.

```
# Split estratificado (75% treino | 25% teste)
# stratify=y: mantem a proporcao original de classes em ambos os conjuntos
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=RANDOM_STATE, stratify=y
)
```

FONTE: O autor

4.4.3 Padronização Z-score

Com os subconjuntos definidos, aplica-se a padronização *Z-score* sobre os atributos numéricos por meio do StandardScaler da biblioteca scikit-learn. Essa transformação recalcula cada valor subtraindo a média da coluna e dividindo pelo desvio padrão, de forma que todos os atributos passem a operar em uma escala comum com média zero e variância unitária. Essa etapa é indispensável para algoritmos sensíveis à magnitude das variáveis, como a Regressão Logística, o SVM e o KNN, nos quais diferenças de escala entre atributos, como a área, medida em pixels quadrados da imagem e na casa das centenas a milhares, e a simetria, índice adimensional entre 0 e 1, distorceriam o cálculo das distâncias.

A decisão mais importante desta etapa, ilustrada no Código 4, é que o StandardScaler é ajustado exclusivamente sobre o conjunto de treino. O mesmo objeto já calibrado é então aplicado tanto ao conjunto de teste quanto à base completa. Esse procedimento evita o *data leakage*: se o escalonador fosse ajustado sobre todos os dados antes da divisão, informações estatísticas do conjunto de teste contaminariam o processo de treinamento, produzindo uma estimativa artificialmente otimista do

desempenho real do modelo (Faceli *et al.*, 2021).

CÓDIGO 4 – AJUSTE E APLICAÇÃO DO PADRONIZADOR Z-SCORE.

```
# Ajuste exclusivamente sobre o treino para evitar data leakage
scaler         = StandardScaler().fit(X_train)
X_train_scaled = scaler.transform(X_train)
X_test_scaled  = scaler.transform(X_test)
X_scaled_all   = scaler.transform(X)   # base completa - visualizacoes e
    SHAP
```

FONTE: O autor

A Árvore de Decisão é a única exceção: utiliza a mesma partição da Subseção 4.4.2, mas sobre os valores brutos, pois suas regras comparam cada atributo com um limiar de valor absoluto, não com distâncias ou gradientes, e são, portanto, invariantes à escala.

4.5 ANÁLISE EXPLORATÓRIA DOS DADOS

A análise exploratória dos dados (EDA) constitui uma etapa preliminar indispensável ao desenvolvimento de qualquer modelo preditivo. Antes de submeter os dados ao treinamento dos classificadores, é necessário compreender a estrutura, a distribuição e a qualidade das informações disponíveis. Essa inspeção permite identificar eventuais inconsistências, avaliar o balanceamento entre as classes e observar o comportamento estatístico dos atributos morfológicos, subsidiando decisões metodológicas nas etapas subsequentes do *pipeline*.

4.5.1 Estatísticas descritivas

A primeira etapa da EDA consistiu na inspeção estrutural do *DataFrame* por meio dos métodos info() e describe() da biblioteca pandas. O método info() confirmou que a base, após a remoção das colunas não preditivas, contém 569 amostras e 31 colunas, a variável alvo e os trinta atributos morfológicos numéricos, sem a presença de valores ausentes em nenhuma das colunas, dispensando etapas de inserção de dados.

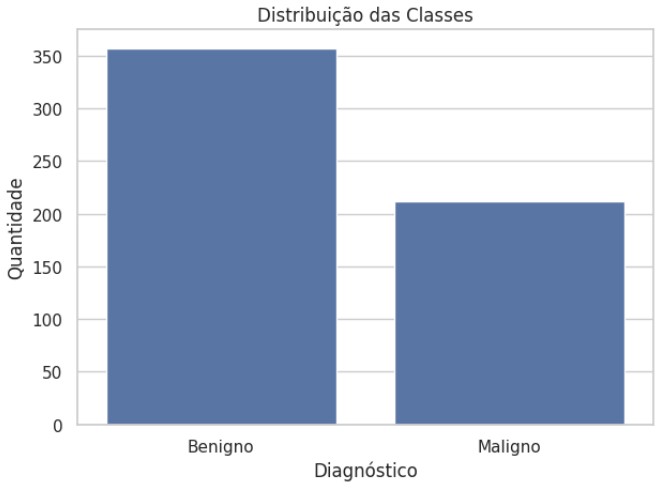
O método describe() forneceu as estatísticas descritivas de cada atributo, incluindo média, desvio padrão, valores mínimo e máximo e os quartis Q1, Q2 e Q3. A análise dessas estatísticas revelou amplitudes consideravelmente distintas entre os atri-

butos: variáveis como area_worst operam em escalas na casa dos milhares, enquanto atributos como symmetry_mean assumem valores entre 0 e 1. Essa disparidade de magnitude reforça a necessidade da padronização *Z-score* aplicada na Seção 4.4, especialmente para os algoritmos sensíveis à escala, como a Regressão Logística, o SVM e o KNN.

4.5.2 Distribuição das classes

A distribuição da variável alvo foi verificada por meio de um gráfico de barras (*countplot*), conforme apresentado no Gráfico 1. A contagem confirmou um leve desbalanceamento entre as classes: 357 amostras pertencem à classe benigna (62,7%) e 212 à classe maligna (37,3%). Embora essa proporção não caracterize um desbalanceamento severo, ela é suficiente para que a acurácia isolada se torne uma métrica enganosa, na qual um classificador trivial que sempre predissesse a classe benigna atingiria 62,7% de acurácia sem aprender nenhum padrão real. Por essa razão, a avaliação dos modelos prioriza métricas como Sensibilidade, F1-score e PR-AUC, que mensuram o desempenho sobre a classe minoritária de forma mais fiel.

GRÁFICO 1 – DISTRIBUIÇÃO DAS CLASSES NA BASE WISCONSIN

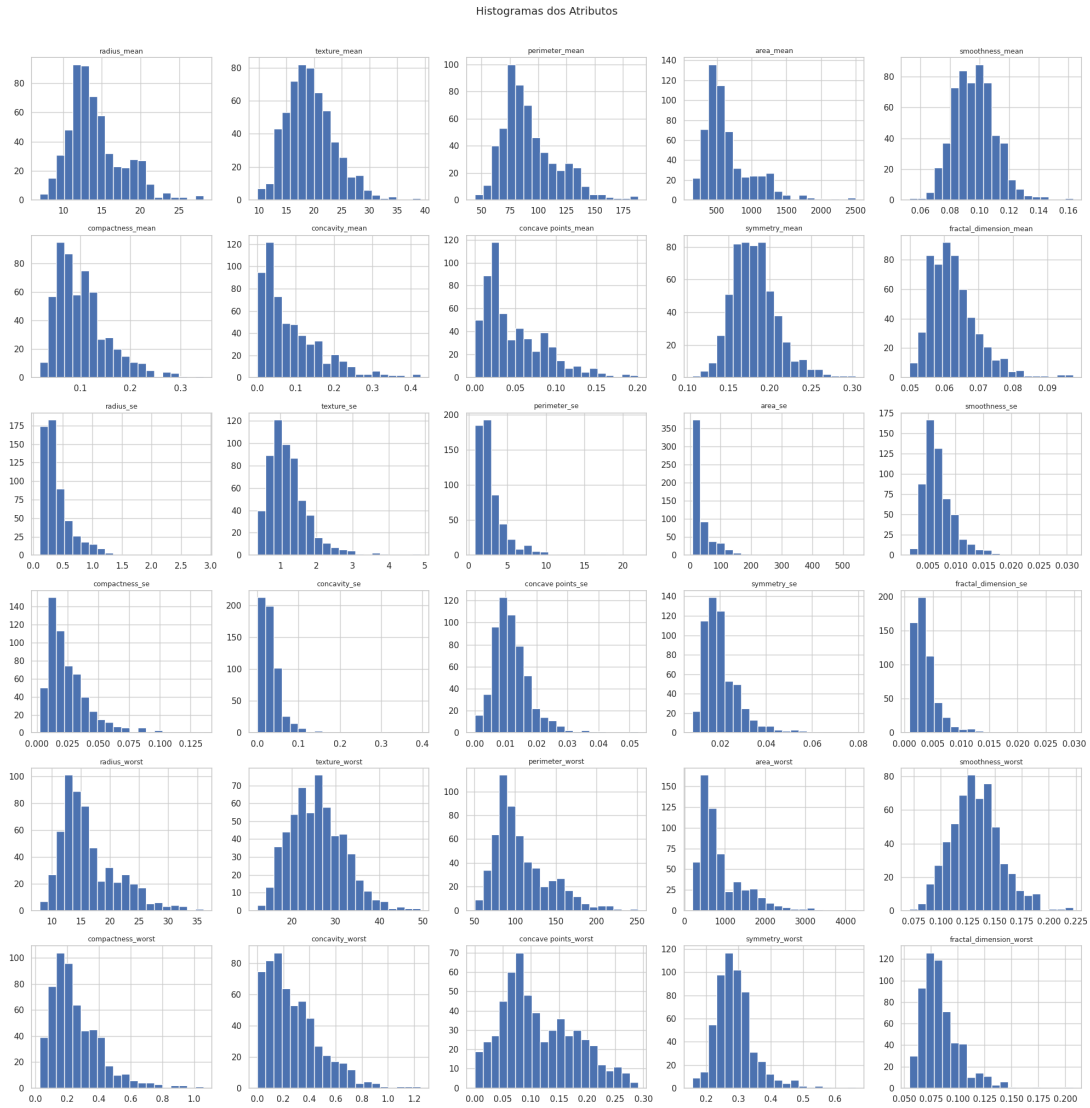


FONTE: O Autor

4.5.3 Histogramas dos atributos

Os trinta atributos morfológicos foram inspecionados por meio de uma grade de histogramas com 6 linhas e 5 colunas, utilizando 20 intervalos (*bins*) por variável, conforme exibido na Figura 9.

FIGURA 9 – HISTOGRAMAS DOS TRINTA ATRIBUTOS MORFOLÓGICOS DA BASE WISCONSIN



FONTE: O Autor

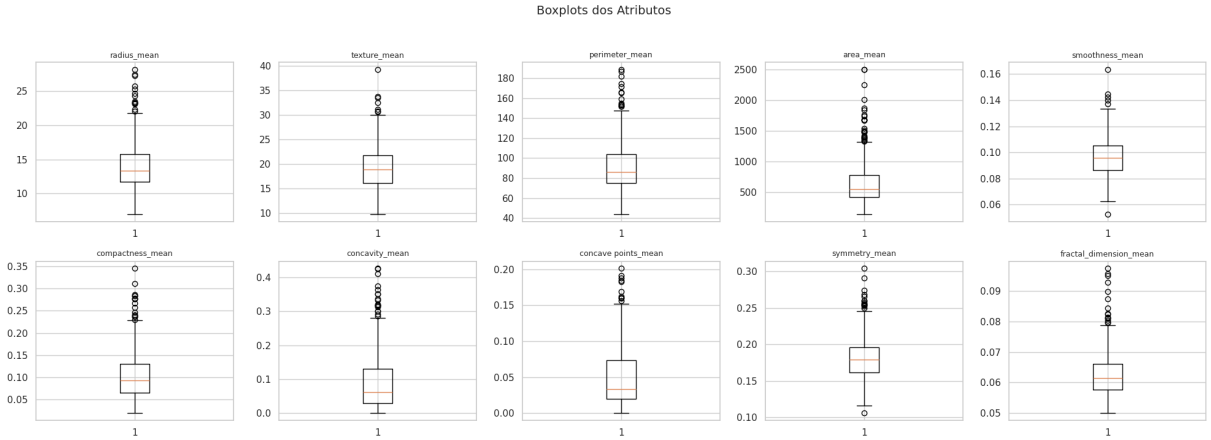
A visualização evidenciou que a maioria dos atributos apresenta distribuição assimétrica à direita, com concentração de valores em magnitudes menores e caudas alongadas em direção aos valores máximos, padrão especialmente pronunciado nos atributos do grupo _se, que medem o erro padrão das características morfológicas. Esse comportamento é esperado em medidas morfológicas celulares, nas quais a maioria das amostras benignas concentra valores mais baixos, enquanto os tumores malignos tendem a ocupar as regiões de maior magnitude. Em alguns atributos, como radius_mean e area_mean, é possível observar indícios de distribuição bimodal, sugerindo que os dois grupos de classes contribuem com picos distintos para o histograma global, um indicativo qualitativo da separabilidade entre as classes que será explorada

formalmente nas projeções UMAP e PCA.

4.5.4 Boxplots dos atributos

Complementando a análise dos histogramas, *boxplots* foram gerados para os atributos do grupo mean, que reúne as médias das dez características morfológicas extraídas dos núcleos celulares, conforme apresentado na Figura 10. Os demais grupos de atributos, erro padrão (_se) e valor máximo (_worst), apresentaram padrões análogos e foram omitidos da figura por questões de espaço.

FIGURA 10 – BOXPLOTS DOS ATRIBUTOS DO GRUPO MEAN DA BASE WISCONSIN



FONTE: O Autor

Os *boxplots* permitiram identificar a presença de valores extremos (*outliers*) em praticamente todos os atributos, com maior concentração nos grupos de variáveis relacionadas à área, ao perímetro e às concavidades dos núcleos celulares. Do ponto de vista clínico, esses valores extremos não necessariamente representam erros de medição, podendo corresponder a amostras com morfologia celular atipicamente agressiva. Por essa razão, optou-se por não realizar remoção sistemática de *outliers*, preservando a integridade biológica dos dados e delegando aos algoritmos de aprendizado a tarefa de aprender a lidar com essa variabilidade natural (Faceli *et al.*, 2021).

4.6 TREINAMENTO E AVALIAÇÃO DOS MODELOS

Para garantir a comparabilidade entre os algoritmos avaliados, três funções auxiliares foram implementadas no módulo científico e aplicadas de forma padronizada

a todos os classificadores. A função compute_stats recebe os rótulos reais, as predições e as probabilidades estimadas, e retorna um dicionário com seis métricas: Acurácia, Sensibilidade, Especificidade, F1-score, ROC-AUC e PR-AUC, calculadas a partir dos elementos da matriz de confusão. A função plot_confusion gera o *heatmap* anotado da matriz de confusão via Seaborn, com os rótulos das classes Benigno e Maligno. A função plot_roc_pr plota as curvas ROC e Precisão-Revocação lado a lado em uma única figura. A adoção dessas funções padronizadas elimina inconsistências na avaliação e garante que todos os classificadores sejam submetidos exatamente ao mesmo protocolo de mensuração de desempenho. Vale destacar que a escolha por calcular simultaneamente tanto a curva ROC quanto a curva Precisão-Revocação decorre da recomendação de Davis e Goadrich (2006), segundo a qual a curva ROC isolada pode superestimar o desempenho em bases com desbalanceamento de classes, tornando a análise conjunta das duas curvas indispensável para uma avaliação clínica fidedigna.

A seleção dos cinco algoritmos avaliados foi orientada por dois critérios complementares. O primeiro critério é a representatividade das principais famílias de classificadores do aprendizado supervisionado: a Árvore de Decisão representa os modelos baseados em regras hierárquicas; o KNN representa os modelos baseados em distância e memória; a Regressão Logística representa os modelos probabilísticos lineares; o Random Forest representa os métodos de comitê baseados em árvores; e o SVM representa os modelos baseados em margem geométrica. O segundo critério é a adequação ao contexto oncológico: todos os algoritmos selecionados possuem documentação consolidada em aplicações de diagnóstico assistido por computador na literatura médica, conforme evidenciado pelos trabalhos revisados no Capítulo 3 (Cruz e Wishart, 2006).

4.6.1 Árvore de Decisão

A Árvore de Decisão foi incluída no estudo com a função específica de modelo *baseline*, estabelecendo uma referência de desempenho mínimo que os demais classificadores devem superar para justificar sua maior complexidade computacional. Sua escolha para essa função se justifica pela total interpretabilidade intrínseca: as regras de divisão geradas pelo algoritmo podem ser visualizadas e auditadas diretamente,

sem necessidade de técnicas de explicabilidade externas (Faceli *et al.*, 2021).

A configuração adotada utilizou o critério de entropia como função de impureza, conforme o Código 5. Essa escolha corresponde diretamente ao ganho de informação descrito na fundamentação teórica, privilegiando divisões que reduzam ao máximo a incerteza sobre a classe em cada nó da árvore. Nenhum parâmetro de poda foi definido, como profundidade máxima ou número mínimo de amostras por folha: a árvore cresce até que todas as folhas sejam puras, chegando a profundidade 7 e 18 folhas e acertando os 426 pacientes do treino.

CÓDIGO 5 – CONFIGURAÇÃO E TREINAMENTO DA ÁRVORE DE DECISÃO.

```
# Mesma particao estratificada dos demais modelos, sem Z-score
x_wisconsin_train, y_wisconsin_train = X_train.values, y_train.values

wisconsin_decision_tree = DecisionTreeClassifier(
    criterion='entropy',
    random_state=RANDOM_STATE
)
wisconsin_decision_tree.fit(x_wisconsin_train, y_wisconsin_train)
```

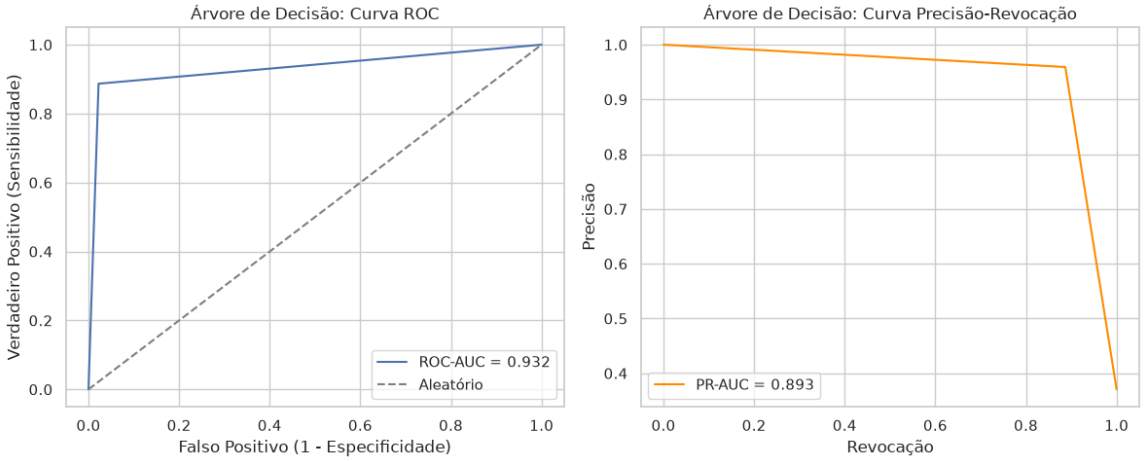
FONTE: O autor

Do ponto de vista clínico, a Árvore de Decisão oferece uma vantagem singular em relação aos demais classificadores: suas regras de decisão podem ser traduzidas diretamente em linguagem condicional legível. Essa característica torna o modelo naturalmente auditável por profissionais de saúde sem formação em computação, ainda que sua acurácia seja estruturalmente limitada pela ausência de mecanismos de ensemble para redução da variância.

A ausência de poda determina a forma das curvas do Gráfico 2. Como toda folha é pura, a árvore atribui a cada paciente probabilidade 0 ou 1, e não um escore graduado; as curvas, que variam o limiar sobre esse escore, reduzem-se a um único ponto de operação ligado aos extremos por segmentos de reta. Na curva ROC, esse ponto corresponde à Sensibilidade de 0,887 com taxa de falsos positivos de 0,022, e a ROC-AUC de 0,932 equivale à simples média entre Sensibilidade e Especificidade, sem medir a capacidade de ordenar pacientes por risco que essa métrica expressa nos demais modelos. Na curva Precisão-Revocação, a precisão vale 0,959 nesse ponto e cai para 0,371, a proporção de malignos no teste, quando a revocação é levada a 1, o que resulta em PR-AUC de 0,893. No conjunto de teste, a árvore deixa de

detectar 6 dos 53 tumores malignos e classifica 2 dos 90 benignos como malignos, erro concentrado no lado clinicamente mais grave, o do falso negativo (Davis e Goadrich, 2006).

GRÁFICO 2 – CURVAS ROC E PRECISÃO-REVOCAÇÃO DA ÁRVORE DE DECISÃO



FONTE: O Autor

4.6.2 K-Nearest Neighbors

O KNN foi selecionado por representar uma abordagem radicalmente diferente dos demais algoritmos: em vez de construir um modelo matemático durante o treinamento, ele memoriza toda a base histórica e realiza a classificação de novos pacientes com base na similaridade geométrica com os casos já conhecidos. Essa lógica de vizinhança é intuitivamente alinhada ao raciocínio clínico de comparar um novo caso com pacientes anteriores de perfil morfológico semelhante.

O algoritmo foi instanciado com 4 vizinhos, ponderação por distância e métrica de Manhattan, conforme o Código 6. A ponderação por distância atribui a cada vizinho um peso inversamente proporcional à sua distância ao paciente consultado, de modo que casos morfologicamente mais próximos exercem maior influência sobre a decisão do que os situados na periferia da vizinhança, comportamento mais aderente ao raciocínio clínico do que o voto uniforme, no qual um vizinho distante pesa tanto quanto o mais similar. A adoção da distância de Manhattan, formalizada na Equação 10, decorre de sua menor sensibilidade a valores extremos isolados: por somar os deslocamentos absolutos atributo a atributo, em vez de elevá-los ao quadrado como a distância euclidiana, ela evita que uma única medida discrepante domine o cálculo da similaridade. A combinação foi escolhida por validação cruzada estratificada de 5 dobras no treino,

na qual superou a configuração com 20 vizinhos e voto uniforme. O valor par $k = 4$ contraria a recomendação de k ímpar apresentada na fundamentação teórica, mas não produz empates na prática: com o voto ponderado pela distância, um empate exigiria que os pesos somados das duas classes coincidissem exatamente, o que não ocorre com distâncias contínuas. Por ser fundamentado no cálculo de distâncias entre atributos, o KNN é altamente sensível à escala das variáveis: atributos com maior magnitude dominariam a métrica em detrimento de características igualmente relevantes, mas medidas em escalas menores. Por essa razão, seu treinamento e inferência utilizam obrigatoriamente os conjuntos padronizados X_train_scaled e X_test_scaled (Bishop, 2006).

CÓDIGO 6 – CONFIGURAÇÃO, TREINAMENTO E INFERÊNCIA DO KNN.

```
wisconsin_knn = KNeighborsClassifier(
    n_neighbors=4,
    weights='distance',
    metric='manhattan'
)
wisconsin_knn.fit(X_train_scaled, y_train)

y_pred_knn = wisconsin_knn.predict(X_test_scaled)
y_prob_knn = wisconsin_knn.predict_proba(X_test_scaled)[:, 1]
```

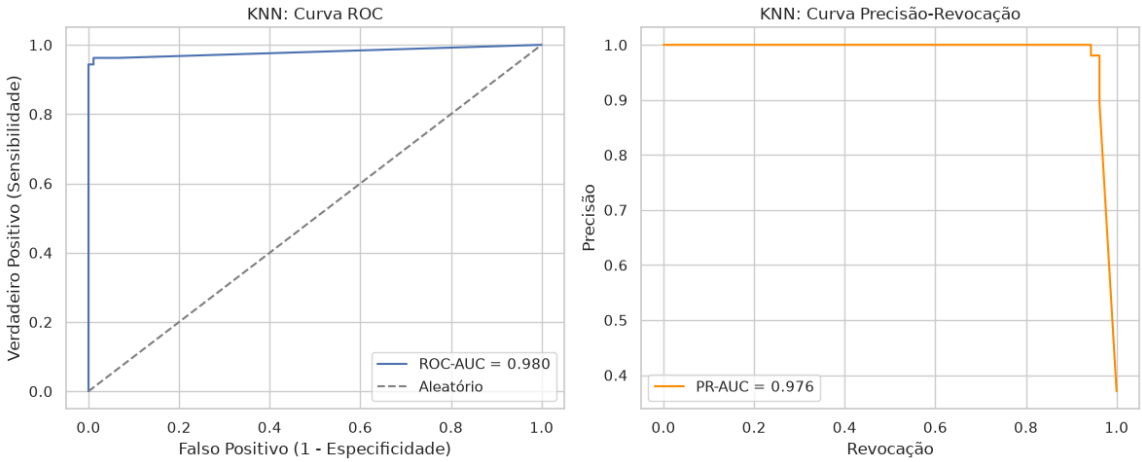
FONTE: O autor

Uma limitação inerente ao KNN relevante para este contexto é o custo computacional da fase de inferência: como não existe uma fase de treinamento formal, toda a computação ocorre no momento da predição, exigindo o cálculo da distância entre o novo paciente e todos os 426 registros do conjunto de treino. Embora esse custo seja desprezível para a base Wisconsin, ele cresce linearmente com o volume de dados, o que tornaria o modelo inadequado para sistemas de triagem em larga escala sem otimizações adicionais de indexação espacial (Faceli *et al.*, 2021).

As curvas do Gráfico 3 revelam um desempenho notavelmente superior ao *baseline*. A curva ROC, com AUC de 0,980, apresenta uma subida acentuada próxima ao eixo da sensibilidade, indicando que o modelo consegue separar as duas classes com alta discriminação já nos primeiros limiares de decisão. A curva Precisão-Revocação, com PR-AUC de 0,976, mantém precisão próxima a 1,0 ao longo da maior parte da faixa de revocação, com queda mais pronunciada apenas nos valores extremos. Cabe observar que a adoção de uma vizinhança reduzida (k = 4) confere ao modelo alta

Especificidade, nenhum tumor benigno foi classificado como maligno, mas também torna suas estimativas de probabilidade mais discretas, uma vez que apenas quatro votos ponderados compõem cada predição. Esse é o motivo pelo qual suas áreas sob as curvas, embora elevadas, ficam abaixo das obtidas pelos modelos que produzem probabilidades contínuas. Esse comportamento sugere que a estrutura geométrica da base Wisconsin, na qual os perfis morfológicos de tumores benignos e malignos formam regiões densas e bem separadas no espaço de atributos, favorece intrinsecamente os algoritmos baseados em distância (Faceli *et al.*, 2021).

GRÁFICO 3 – CURVAS ROC E PRECISÃO-REVOCAÇÃO DO KNN



FONTE: O Autor

4.6.3 Regressão Logística

A Regressão Logística foi incluída por ser o modelo probabilístico linear de maior tradição no diagnóstico médico assistido por computador. Sua equação sigmoide produz diretamente a probabilidade de malignidade em um intervalo entre 0 e 1, e os coeficientes associados a cada atributo permitem uma leitura direta do peso de cada característica morfológica na decisão final. Essa transparência intrínseca a torna um ponto de referência importante para avaliar se a explicabilidade *post-hoc* fornecida pelo SHAP sobre modelos mais complexos é consistente com o que um modelo interpretável nativo já indicaria.

O modelo foi configurado com o *solver liblinear*, adequado para bases de porte médio como a Wisconsin, com limite de 2000 iterações para garantir convergência completa e correção automática do desbalanceamento de classes, conforme o Código 7. O parâmetro class_weight = balanced instrui o modelo a penalizar proporcionalmente

os erros sobre a classe maligna, compensando a diferença de frequência entre as classes sem necessidade de técnicas de reamostragem. A regularização foi ajustada para C = 0,1 com penalidade L2. Como o parâmetro C é o inverso da intensidade de regularização, esse valor corresponde a uma penalização relativamente forte sobre a magnitude dos coeficientes. Tal escolha se justifica pela alta colinearidade entre os atributos da base, uma vez que raio, perímetro e área descrevem a mesma geometria nuclear sob três formulações distintas. Sem essa restrição, o modelo tenderia a distribuir pesos elevados e instáveis entre variáveis redundantes, prejudicando tanto a generalização quanto a leitura clínica dos coeficientes.

CÓDIGO 7 – CONFIGURAÇÃO E TREINAMENTO DA REGRESSÃO LOGÍSTICA.

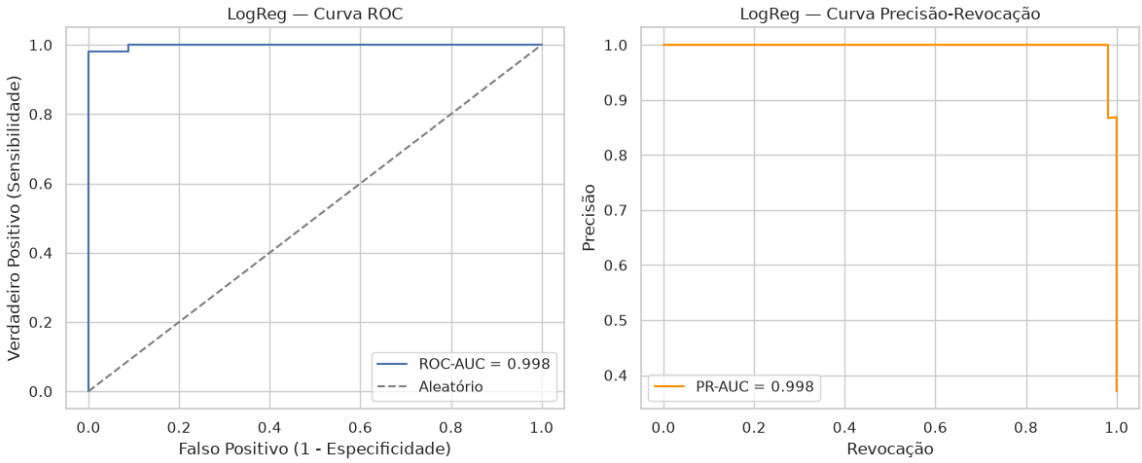
```
logreg = LogisticRegression(
    C=0.1,
    penalty='l2',
    class_weight='balanced',
    solver='liblinear',
    max_iter=2000,
    random_state=RANDOM_STATE
)
logreg.fit(X_train_scaled, y_train)
proba_lr = logreg.predict_proba(X_test_scaled)[:, 1]
pred_lr  = (proba_lr >= 0.5).astype(int)
```

FONTE: O autor

A interpretação dos coeficientes da Regressão Logística também complementa a análise de explicabilidade conduzida pelo SHAP na Seção 2.5. Enquanto o SHAP quantifica a contribuição de cada atributo para uma predição específica, os coeficientes logísticos fornecem uma perspectiva global e estática dos pesos aprendidos pelo modelo linear sobre toda a base de treinamento. A concordância entre as duas perspectivas, contudo, é apenas parcial: dos seis atributos de maior coeficiente absoluto na Regressão Logística, quatro estão entre os seis de maior importância SHAP no Random Forest (perimeter_worst, area_worst, radius_worst e concave points_mean), enquanto texture_worst e radius_se aparecem apenas no modelo linear. O núcleo comum, ligado ao tamanho do núcleo celular e às suas concavidades, é o que se sustenta independentemente do algoritmo; a ordem dos demais atributos depende do modelo e, entre variáveis colineares, da forma como cada um distribui o peso entre elas.

As curvas do Gráfico 4 demonstram que, apesar de sua estrutura linear, a Regressão Logística atinge desempenho comparável aos modelos mais complexos nesta base de dados. A curva ROC com AUC de 0,998 e a curva Precisão-Revocação com PR-AUC de 0,998 confirmam que os atributos morfológicos da base Wisconsin possuem uma relação suficientemente linear com a variável alvo para que um modelo probabilístico simples os explore com eficiência. A subida praticamente vertical da curva ROC mostra que o modelo já recupera cerca de 98% dos casos malignos sem incorrer em nenhum falso positivo, enquanto a curva PR mantém precisão igual a 1,0 em quase toda a faixa de revocação, cedendo apenas no extremo final. Essa queda concentrada nos últimos limiares indica que o custo em alarmes falsos só se manifesta quando se exige a recuperação da totalidade dos casos malignos, comportamento esperado em classificadores lineares diante de dados com alguma sobreposição de classes (Bishop, 2006).

GRÁFICO 4 – CURVAS ROC E PRECISÃO-REVOCAÇÃO DA REGRESSÃO LOGÍSTICA



FONTE: O Autor

4.6.4 Random Forest

O Random Forest reúne três características relevantes para o contexto oncológico. Primeiro, sua arquitetura de comitê de árvores produz estimativas estáveis, menos suscetíveis ao sobreajuste que uma árvore individual. Segundo, o mecanismo de votação entre centenas de árvores diversas torna o modelo resistente a ruídos e valores extremos presentes nos dados morfológicos. Terceiro, é compatível com o Tree-

Explainer da biblioteca SHAP, que calcula os valores exatos de Shapley aproveitando a estrutura interna das árvores, sem aproximações.

O modelo foi configurado com 500 estimadores, paralelismo total e correção de desbalanceamento, conforme o Código 8. O número de 500 árvores garante estimativas de importância e probabilidade estáveis, pois conjuntos menores tendem a apresentar maior variância nas predições. O parâmetro n_jobs = -1 instrui o scikit-learn a utilizar todos os núcleos de processamento disponíveis durante o treinamento, reduzindo o tempo de execução sem afetar os resultados.

CÓDIGO 8 – CONFIGURAÇÃO E TREINAMENTO DO RANDOM FOREST.

```
rf = RandomForestClassifier(
    n_estimators=500,
    max_depth=10,
    min_samples_split=4,
    min_samples_leaf=2,
    max_features='sqrt',
    criterion='entropy',
    class_weight='balanced_subsample',
    random_state=RANDOM_STATE,
    n_jobs=-1
)
rf.fit(X_train_scaled, y_train)
proba_rf = rf.predict_proba(X_test_scaled)[:, 1]
pred_rf  = (proba_rf >= 0.5).astype(int)
```

FONTE: O autor

À configuração inicial foi acrescentado um conjunto de restrições de complexidade destinadas a conter o sobreajuste, dado que a base dispõe de apenas 426 registros de treino para 30 atributos. A profundidade máxima foi limitada a 10 níveis e exigiu-se um mínimo de 4 amostras para dividir um nó e de 2 amostras em cada folha, impedindo que as árvores individuais isolassem pacientes únicos em folhas puras, comportamento que memoriza ruído em vez de aprender padrões generalizáveis. O parâmetro max_features = sqrt restringe cada divisão a um subconjunto aleatório de cinco atributos, mecanismo que descorrelaciona as árvores entre si e constitui a própria fonte da diversidade que sustenta o ganho do comitê sobre a árvore isolada. O critério de entropia foi adotado por coerência com a Árvore de Decisão *baseline*, permitindo que a comparação entre os dois modelos isole o efeito do *ensemble*. Por fim, o class_weight = balanced_subsample recalcula os pesos das classes a cada amostra *bootstrap*, em vez de fixá-los uma única vez sobre a base completa como faz a

variante balanced, o que é mais adequado à natureza reamostrada do Random Forest e compensa a menor frequência da classe maligna dentro de cada árvore.

Outro benefício técnico do Random Forest relevante para este projeto é a geração nativa de estimativas de importância de variáveis por meio da diminuição média de impureza (MDI). Essa métrica calcula, para cada atributo, a redução média de entropia que ele proporciona em todas as árvores da floresta, oferecendo uma primeira indicação de quais características morfológicas são mais discriminativas entre tumores benignos e malignos. Essa informação é posteriormente enriquecida e refinada pela análise SHAP, que adiciona a dimensão de direção e magnitude por paciente individual, indo além da importância global fornecida pelo MDI (Lundberg e Lee, 2017).

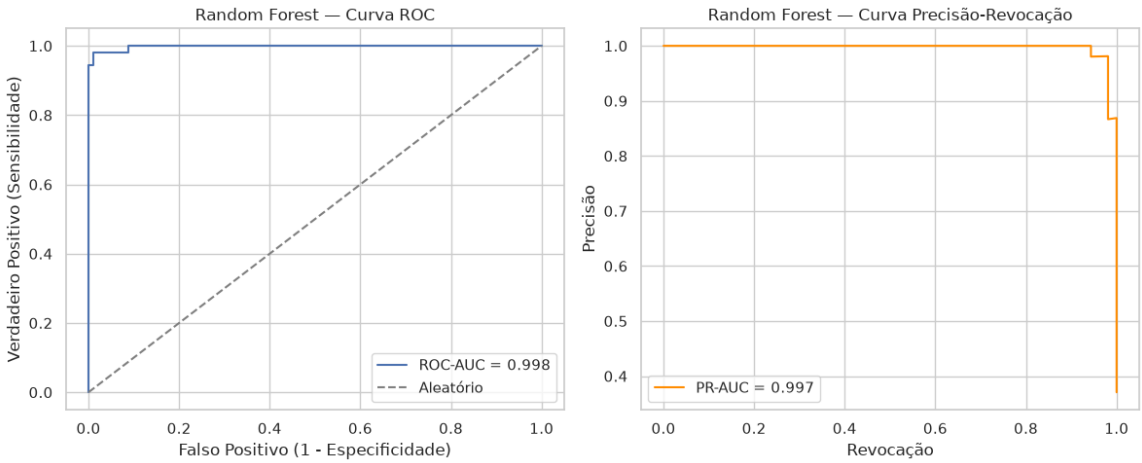
As curvas do Gráfico 5 confirmam o alto desempenho discriminativo do Random Forest, com ROC-AUC de 0,998 e PR-AUC de 0,997. A curva ROC apresenta subida quase vertical junto ao eixo esquerdo, indicando que o modelo atinge sensibilidade próxima a 1,0 com taxa de falsos positivos próxima a zero nos primeiros limiares de decisão. A curva Precisão-Revocação mantém precisão máxima ao longo de toda a faixa intermediária de revocação, com queda gradual apenas nos limiares mais permissivos. Esse comportamento é atribuível ao mecanismo de votação entre 500 árvores diversas, que dilui os erros individuais e produz um escore capaz de ordenar os pacientes por risco. Ordenar bem, porém, não equivale a estar calibrado: como mostra a Subseção 4.7.3, a probabilidade bruta do Random Forest tem escore de Brier de 0,0269, pior que o da Regressão Logística e o do SVM. No corte padrão de 50%, o modelo deixa de detectar 4 dos 53 tumores malignos do teste, a menor Sensibilidade entre os quatro modelos avançados.

4.6.5 Support Vector Machine

O SVM foi selecionado por sua capacidade de lidar com fronteiras de decisão altamente não lineares, característica relevante para dados morfológicos oncológicos onde as classes não são linearmente separáveis no espaço original de trinta dimensões. O kernel RBF mapeia os atributos para um espaço de dimensão superior onde as classes passam a ser separáveis por um hiperplano, contornando essa limitação sem aumentar explicitamente a dimensionalidade dos dados (Bishop, 2006).

Uma característica relevante do SVM no contexto deste projeto é que, ao con-

GRÁFICO 5 – CURVAS ROC E PRECISÃO-REVOCAÇÃO DO RANDOM FOREST



FONTE: O Autor

trário dos modelos baseados em árvores, ele não fornece nativamente uma medida de importância de variáveis. As decisões são determinadas pela posição dos vetores de suporte no espaço transformado pelo kernel, e não por uma redução de impureza acumulada ao longo de divisões sucessivas. A importância global exibida pelo software para este modelo é, por isso, obtida por permutação, medindo-se a queda de desempenho provocada pelo embaralhamento individual de cada atributo; a explicação por paciente, por sua vez, é construída sobre os próprios vetores de suporte mais similares a ele, ponderados pela contribuição de cada um na função de decisão.

O modelo foi configurado com kernel RBF, habilitação de probabilidades e correção de desbalanceamento, conforme o Código 9. O parâmetro probability = True habilita o método predict_proba, que estima a probabilidade de cada classe por um ajuste de Platt interno e é usado pelas funções auxiliares para traçar as curvas ROC e Precisão-Revocação; as curvas também poderiam ser obtidas diretamente da função de decisão, como na validação cruzada da Seção 4.7.

As curvas do Gráfico 6 revelam o SVM entre os modelos de melhor desempenho do conjunto, com PR-AUC de 0,996 e ROC-AUC de 0,997. A curva ROC apresenta a subida mais vertical de todo o conjunto: a taxa de verdadeiros positivos alcança 0,981 com a taxa de falsos positivos ainda igual a zero, ou seja, o modelo identifica corretamente 52 dos 53 tumores malignos do conjunto de teste sem classificar erroneamente um único caso benigno. A sensibilidade chega a 1,0 quando a taxa de falsos positivos atinge 0,167. A curva Precisão-Revocação é a mais estável visualmente, mantendo precisão igual a 1,0 por toda a faixa de revocação até 0,981, com queda brusca apenas

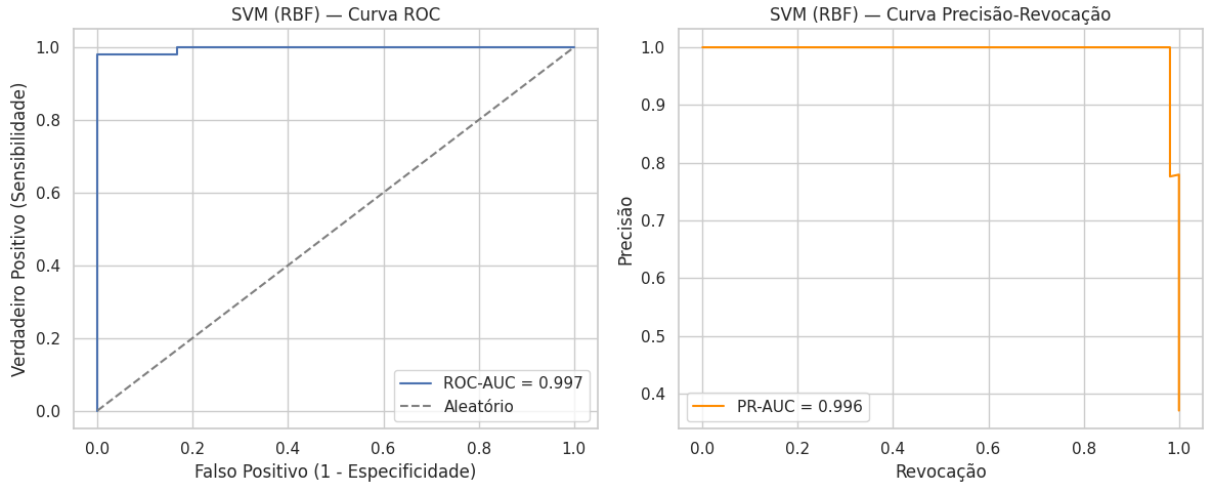
CÓDIGO 9 – CONFIGURAÇÃO E TREINAMENTO DO SVM.

```
svm = SVC(
    kernel='rbf',
    probability=True,
    class_weight='balanced',
    random_state=RANDOM_STATE
)
svm.fit(X_train_scaled, y_train)
proba_svm = svm.predict_proba(X_test_scaled)[:, 1]
pred_svm  = (proba_svm >= 0.5).astype(int)
```

FONTE: O autor

no limiar final. Esse comportamento reflete a natureza da margem máxima do SVM: ao maximizar a distância entre as classes no espaço transformado pelo kernel RBF, o modelo cria uma fronteira de decisão particularmente robusta para os casos mais próximos da região de separação (Bishop, 2006).

GRÁFICO 6 – CURVAS ROC E PRECISÃO-REVOCAÇÃO DO SVM



FONTE: O Autor

4.6.6 Comparação entre os modelos

A Tabela 1 consolida as métricas de desempenho obtidas pelos cinco classificadores no conjunto de teste, permitindo a comparação direta entre as abordagens avaliadas. Os resultados consolidados confirmam a superioridade dos demais classificadores sobre o *baseline* da Árvore de Decisão em todas as métricas avaliadas. A Árvore de Decisão, com ROC-AUC de 0,932 e PR-AUC de 0,893, estabelece o patamar mínimo de referência. Os quatro classificadores restantes atingem ROC-AUC

igual ou superior a 0,980 e PR-AUC igual ou superior a 0,976, indicando capacidade discriminativa consideravelmente superior para este conjunto de dados.

TABELA 1 – COMPARAÇÃO DE DESEMPENHO ENTRE OS CLASSIFICADORES

Modelo	**Acurácia**	**Sensibilidade**	**Especificidade**	**F1-score**	**ROC-AUC**	**PR-AUC**
Árvore de Decisão	0,944	0,887	0,978	0,922	0,932	0,893
KNN	0,979	0,943	1,000	0,971	0,980	0,976
Regressão Logística	0,993	0,981	1,000	0,990	0,998	0,998
Random Forest	0,972	0,925	1,000	0,961	0,998	0,997
SVM	0,993	0,981	1,000	0,990	0,997	0,996

Fonte: O Autor

O desempenho máximo do conjunto foi obtido em empate pela Regressão Logística e pelo SVM, ambos com Acurácia de 0,993, Sensibilidade de 0,981, Especificidade de 1,000 e F1-score de 0,990, resultado que corresponde, no conjunto de teste de 143 pacientes, a um único tumor maligno não detectado e a nenhum falso positivo. O desempate ocorre apenas nas áreas sob as curvas, nas quais a Regressão Logística lidera com ROC-AUC de 0,998 e PR-AUC de 0,998, seguida de perto pelo Random Forest (0,998 e 0,997) e pelo SVM (0,997 e 0,996). Todos os quatro modelos avançados alcançaram Especificidade de 1,000, significando que nenhum tumor benigno foi classificado erroneamente como maligno.

O achado mais relevante desta comparação é que o melhor desempenho não coube a um modelo de fronteira não linear, mas ao classificador linear mais simples do conjunto. A Regressão Logística iguala ou supera o SVM e o Random Forest em todas as seis métricas, apesar de sua estrutura consideravelmente mais enxuta e de produzir coeficientes diretamente interpretáveis, sem necessidade de explicabilidade *post-hoc*. Esse resultado reforça a observação de que os atributos morfológicos da base Wisconsin possuem uma componente de separabilidade linear suficientemente forte para ser plenamente explorada por modelos simples (Bishop, 2006), e tem consequência prática direta: nesta base, adotar um modelo de caixa preta não se justifica por ganho de desempenho, uma vez que esse ganho não foi observado.

Cabe ressalvar, contudo, que as diferenças relatadas neste parágrafo foram

apuradas sobre uma única partição de teste, no corte padrão de 50%, e, portanto, não bastam para estabelecer superioridade estatística de um modelo sobre outro. A Seção 4.7 retoma essa comparação sob validação cruzada repetida e testes de significância, verificando quais dessas diferenças resistem à variação amostral, e descreve o ponto de operação com que o software efetivamente decide.

4.7 RIGOR ESTATÍSTICO: VALIDAÇÃO CRUZADA, SIGNIFICÂNCIA, CALIBRAÇÃO E PONTO DE OPERAÇÃO

Os resultados apresentados na Seção 4.6 foram obtidos sobre uma única partição de treino e teste. Essa é a forma mais comum de reportar desempenho na literatura aplicada, mas ela é insuficiente para sustentar afirmações comparativas: uma diferença de um ou dois acertos entre dois modelos pode decorrer inteiramente da amostra que a partição selecionou, e não de qualquer superioridade real do algoritmo. Esta seção submete os cinco classificadores a três análises complementares que endereçam justamente essa fragilidade, estabilidade do desempenho, significância estatística das diferenças e confiabilidade das probabilidades produzidas, e encerra com o ponto de operação que converte essas probabilidades na decisão exibida pelo software.

4.7.1 Validação cruzada estratificada repetida

Para estimar o desempenho de forma independente de uma partição específica, adotou-se validação cruzada estratificada de 10 dobras repetida 5 vezes, totalizando 50 ajustes por modelo. A estratificação preserva em cada dobra a proporção original entre tumores benignos e malignos, e a repetição com diferentes embaralhamentos reduz a influência de uma divisão particularmente favorável ou desfavorável.

Um cuidado metodológico decisivo foi adotado neste procedimento: a padronização Z-score é reajustada dentro de cada dobra, utilizando exclusivamente as estatísticas do subconjunto de treino daquela iteração. Padronizar a base inteira antes de particioná-la, como é frequente em implementações descuidadas, faria com que a média e o desvio-padrão dos dados de teste influenciassem a transformação aplicada ao treino, configurando vazamento de informação e produzindo estimativas otimistas. A Tabela 2 apresenta a média e o desvio-padrão de cada métrica ao longo das 50 dobras.

A comparação entre a Tabela 2 e a Tabela 1 revela que os valores obtidos na

TABELA 2 – DESEMPENHO SOB VALIDAÇÃO CRUZADA (MÉDIA $\pm$ DESVIO-PADRÃO EM 50 DOBRAS)

Modelo	**Acurácia**	**Sensibilidade**	**Especificidade**	**F1-score**	**ROC-AUC**	**PR-AUC**
Árvore de Decisão	0,929 $\pm$ 0,039	0,907 $\pm$ 0,071	0,942 $\pm$ 0,037	0,905 $\pm$ 0,052	0,925 $\pm$ 0,043	0,857 $\pm$ 0,072
KNN	0,967 $\pm$ 0,024	0,928 $\pm$ 0,053	0,990 $\pm$ 0,024	0,954 $\pm$ 0,034	0,980 $\pm$ 0,018	0,975 $\pm$ 0,022
Regressão Logística	0,973 $\pm$ 0,023	0,959 $\pm$ 0,044	0,982 $\pm$ 0,024	0,964 $\pm$ 0,032	0,994 $\pm$ 0,011	0,993 $\pm$ 0,011
Random Forest	0,960 $\pm$ 0,025	0,935 $\pm$ 0,051	0,975 $\pm$ 0,028	0,946 $\pm$ 0,035	0,990 $\pm$ 0,013	0,988 $\pm$ 0,014
SVM	0,971 $\pm$ 0,022	0,961 $\pm$ 0,045	0,977 $\pm$ 0,027	0,961 $\pm$ 0,029	0,995 $\pm$ 0,009	0,994 $\pm$ 0,010

FONTE: O autor

partição única eram sistematicamente otimistas. A Regressão Logística, que registrara Acurácia de 0,993 no conjunto de teste, apresenta média de 0,973 sob validação cruzada; o SVM cai de 0,993 para 0,971. Essa diferença não indica erro no procedimento anterior, mas sim que aquela partição específica era favorável, o que confirma a necessidade da análise ora conduzida.

Os desvios-padrão qualificam a leitura das médias. A Árvore de Decisão não apenas obtém o pior desempenho médio como também a maior dispersão, com desvio-padrão de 0,071 na Sensibilidade e de 0,072 no PR-AUC: seu comportamento depende fortemente de quais pacientes compõem o treino, característica esperada de um modelo sem mecanismo de redução de variância. No extremo oposto, o SVM apresenta a menor dispersão em ROC-AUC (0,009) e PR-AUC (0,010), configurando-se como o classificador mais estável do conjunto. A Regressão Logística mantém a melhor Acurácia média (0,973) e o melhor F1-score médio (0,964), ao passo que o SVM lidera em Sensibilidade média (0,961) e nas duas áreas sob as curvas, uma inversão parcial em relação ao ordenamento observado na partição única, e mais uma evidência de que aquele ordenamento não era estável.

4.7.2 Testes de significância estatística

Estabelecida a estabilidade do desempenho, resta determinar quais das diferenças observadas entre os modelos são estatisticamente reais e quais são indistinguíveis do ruído amostral. Adotou-se o nível de significância $\alpha = 0{,}05$ e dois testes complemen-

tares.

O primeiro é o teste pareado 5×2cv proposto por Dietterich (1998), recomendado especificamente para a comparação de dois classificadores sobre um único conjunto de dados. Sua vantagem sobre o teste t convencional está na correção da dependência entre as dobras: como os conjuntos de treino de uma validação cruzada se sobrepõem, as estimativas de erro não são independentes, e ignorar esse fato eleva a taxa de falsos positivos do teste. Tomou-se como referência a Regressão Logística, modelo de melhor Acurácia média na subseção anterior, comparada individualmente a cada rival. Os resultados constam da Tabela 3.

TABELA 3 – TESTE PAREADO 5×2CV DA REGRESSÃO LOGÍSTICA CONTRA CADA RIVAL

Modelo comparado	t	p	**Conclusão**
Árvore de Decisão	$+2{,}346$	0,0659	Sem diferença significativa
KNN	$+1{,}127$	0,3110	Sem diferença significativa
Random Forest	$+2{,}181$	0,0810	Sem diferença significativa
SVM	$+0{,}506$	0,6341	Sem diferença significativa

FONTE: O autor

Nenhuma das comparações atingiu significância estatística. Ainda que os valores de t sejam sistematicamente positivos, indicando vantagem consistente da Regressão Logística, os valores de p permanecem acima de 0,05 em todos os casos, inclusive contra a Árvore de Decisão ($p = 0{,}0659$). Esse resultado ilustra o conhecido conservadorismo do teste 5×2cv, que dispõe de apenas dez estimativas de diferença e, portanto, de baixo poder estatístico (Dietterich, 1998).

O segundo teste oferece um panorama global. O teste de Friedman, seguido do pós-hoc de Nemenyi, é o procedimento recomendado por Demšar (2006) para comparar múltiplos classificadores simultaneamente, evitando a inflação do erro tipo I decorrente de comparações pareadas repetidas. Nesse teste, os blocos são as 50 dobras da validação cruzada 10×5 sobre o conjunto de treino, e cada dobra fornece a acurácia dos cinco modelos. Como as dobras compartilham parte dos dados de treino, suas estimativas não são independentes, o que tende a tornar os valores de p otimistas; por isso, o Friedman e o Nemenyi são lidos como panorama. O Friedman

rejeitou a hipótese nula de equivalência entre os cinco modelos com $\chi^2 = 65{,}766$ e $p = 1{,}775 \times 10^{-13}$, confirmando que ao menos dois deles diferem. O pós-hoc de Nemenyi identifica quais pares, conforme a Tabela 4.

TABELA 4 – VALORES DE p DO PÓS-HOC DE NEMENYI ENTRE OS CINCO MODELOS

Modelo	**AD**	**KNN**	**RL**	**RF**	**SVM**
Árvore de Decisão (AD)	—	0,0000	0,0000	0,0004	0,0000
KNN	0,0000	—	0,6535	0,8500	0,9239
Regressão Logística (RL)	0,0000	0,6535	—	0,1231	0,9834
Random Forest (RF)	0,0004	0,8500	0,1231	—	0,3538
SVM	0,0000	0,9239	0,9834	0,3538	—

FONTE: O autor

A leitura da Tabela 4 é inequívoca e constitui o principal achado desta seção. A Árvore de Decisão difere significativamente de todos os demais classificadores, com valores de p entre 0,0000 e 0,0004, sua inferioridade como *baseline* é estatisticamente sustentada. Entre os quatro modelos avançados, porém, nenhum par apresenta diferença significativa: o menor valor de p registrado é 0,1231, entre Regressão Logística e Random Forest, e o maior chega a 0,9834, entre Regressão Logística e SVM.

A consequência metodológica é relevante e merece ser explicitada. As diferenças de desempenho observadas entre KNN, Regressão Logística, Random Forest e SVM na Tabela 1 não são estatisticamente distinguíveis do ruído amostral. Afirmar que um desses modelos é superior aos outros nesta base não encontra respaldo estatístico.

4.7.3 Análise de calibração das probabilidades

Um classificador pode apresentar alta acurácia e, ainda assim, produzir probabilidades mal calibradas. Em um sistema de apoio ao diagnóstico, essa distinção deixa de ser um detalhe técnico e passa a ser uma questão de confiabilidade clínica: como o software exibe ao profissional de saúde uma estimativa numérica de certeza, essa estimativa precisa corresponder à frequência real do desfecho, sob pena de induzir decisões equivocadas (Guo *et al.*, 2017).

A qualidade da calibração foi avaliada por dois instrumentos quantitativos. O escore de Brier, proposto por Brier (1950), corresponde ao erro quadrático médio entre a probabilidade prevista e o desfecho observado, penalizando simultaneamente erros de discriminação e de calibração. O ECE (*Expected Calibration Error*) particiona as predições em faixas de probabilidade e mede a discrepância média entre a confiança declarada e a acurácia efetivamente observada em cada faixa (Guo *et al.*, 2017). Em ambas as métricas, valores menores indicam melhor calibração. A Árvore de Decisão foi excluída desta análise: suas folhas puras produzem probabilidades degeneradas, iguais a 0 ou 1, sobre as quais a análise de calibração é pouco informativa. Os resultados constam da Tabela 5.

TABELA 5 – MÉTRICAS DE CALIBRAÇÃO DAS PROBABILIDADES NO CONJUNTO DE TESTE (MENOR É MELHOR)

Modelo	**Escore de Brier**	**ECE**
KNN	0,0292	0,0429
Regressão Logística	0,0202	0,0609
Random Forest	0,0269	0,0420
SVM	**0,0156**	**0,0306**

FONTE: O autor

O SVM apresenta a melhor calibração do conjunto em ambas as métricas, com escore de Brier de 0,0156 e ECE de 0,0306. A Regressão Logística exibe um resultado aparentemente contraditório que merece explicação: obtém o segundo melhor escore de Brier (0,0202), mas o pior ECE (0,0609). A razão está na natureza distinta das duas medidas, o escore de Brier agrega discriminação e calibração em um único número, ao passo que o ECE isola o desalinhamento entre confiança declarada e acurácia observada. Um modelo que separa muito bem as classes, mas que sistematicamente subestima ou superestima sua própria confiança, obtém bom Brier e ECE ruim, exatamente o padrão observado. Para os fins deste trabalho, no qual o valor de certeza é exibido ao usuário, o ECE é a métrica mais pertinente.

Diante desse quadro, aplicou-se recalibração às probabilidades por dois métodos consolidados: o escalonamento de Platt, que ajusta uma sigmoide sobre os escores do modelo (Platt, 1999), e a regressão isotônica, método não paramétrico que ajusta uma

função monotônica por partes (Niculescu-Mizil e Caruana, 2005). A Tabela 6 apresenta o efeito de cada método sobre o SVM e o Random Forest, cujos escores de origem são, respectivamente, uma distância à margem e uma fração de votos entre árvores.

TABELA 6 – ESCORE DE BRIER ANTES E DEPOIS DA RECALIBRAÇÃO

Modelo	**Original**	**Platt (sigmoide)**	**Isotônica**
SVM	0,0156	0,0213	**0,0141**
Random Forest	0,0269	0,0246	**0,0221**

FONTE: O autor

A regressão isotônica produziu o melhor escore de Brier para ambos os modelos, reduzindo o valor do SVM de 0,0156 para 0,0141 e o do Random Forest de 0,0269 para 0,0221. O escalonamento de Platt melhorou o Random Forest, mas degradou o SVM, elevando seu Brier de 0,0156 para 0,0213.

Optou-se, ainda assim, pelo escalonamento de Platt na implementação do software. A justificativa é a robustez em amostras pequenas: a regressão isotônica dispõe de muito mais graus de liberdade e, em conjuntos do porte da base Wisconsin, tende a sobreajustar-se ao conjunto de calibração, produzindo ganhos que não se sustentam em dados novos, limitação documentada por Niculescu-Mizil e Caruana (2005), que recomendam o método sigmoidal para amostras reduzidas. São essas probabilidades recalibradas por Platt que alimentam a coluna de certeza exibida na interface do sistema. Na versão serializada para o software, a calibração cobre os quatro modelos de probabilidade informativa, com um único estimador ajustado sobre todo o treino e o calibrador ajustado sobre as previsões *out-of-fold* de 5 dobras desse mesmo treino; no SVM, o calibrador atua sobre a função de decisão. Nessa configuração, o escore de Brier no teste passa de 0,0292 para 0,0243 no KNN, de 0,0202 para 0,0156 na Regressão Logística e de 0,0269 para 0,0232 no Random Forest, e permanece em 0,0156 no SVM. A diferença em relação à Tabela 6, em que o escalonamento de Platt elevou o Brier do SVM para 0,0213, decorre da forma de ajuste: naquela comparação, o scikit-learn treina cinco pares de modelo e calibrador, um por dobra, e faz a média de suas probabilidades; na versão do software, um único SVM, ajustado sobre todo o treino, é calibrado uma única vez.

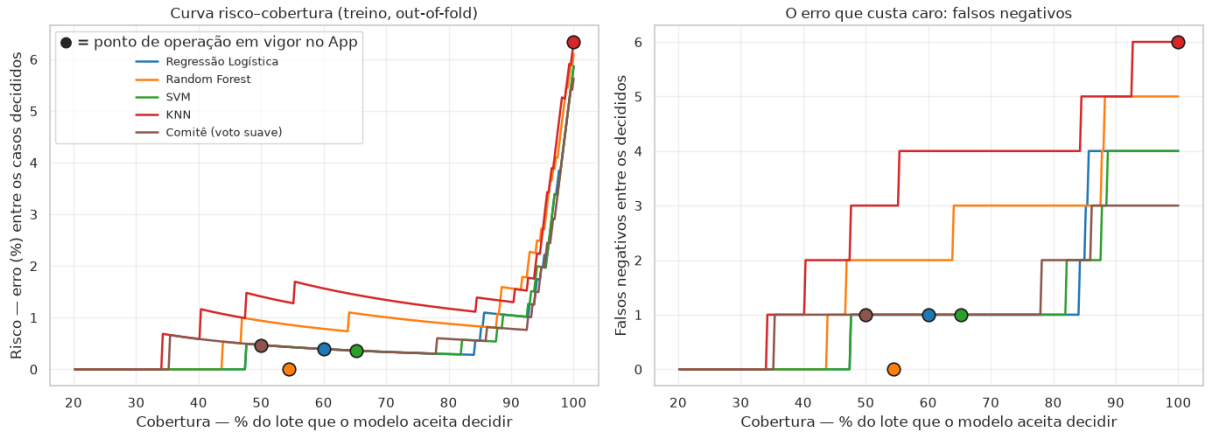
4.7.4 Ponto de operação e curva risco-cobertura

Uma probabilidade calibrada ainda não é uma decisão. O método predict() do scikit-learn corta em 50%, valor que trata falso positivo e falso negativo como igualmente custosos, o que não vale em rastreio oncológico: o primeiro custa um exame adicional; o segundo, um tumor não tratado. O software decide, por isso, com dois parâmetros por modelo, ambos escolhidos pelo script calibrar_limiares.py sobre probabilidades *out-of-fold* do treino: cada paciente recebe a probabilidade de um modelo que não o viu, em 5 dobras estratificadas com o escalonamento de Platt refeito dentro de cada dobra. O conjunto de teste não participa da escolha. O limiar de operação é o menor corte cuja especificidade *out-of-fold* atinge 92%. A faixa de recusa vai da menor certeza atribuída a um paciente maligno à maior atribuída a um benigno: fora dela, nenhum caso do treino seria decidido errado, e os casos dentro dela são devolvidos para revisão humana. A faixa só é adotada se o modelo continuar decidindo ao menos 45% do treino. O comitê de voto suave entra nessa análise como a média simples das probabilidades calibradas de Regressão Logística, Random Forest, SVM e KNN; a Árvore de Decisão fica de fora por não ter probabilidade calibrada.

Recusar casos sempre melhora as métricas entre os decididos, bastando adiar os difíceis, de modo que esse número isolado nada informa. A curva risco–cobertura do Gráfico 7 mostra o custo: para cada fração do lote que o modelo aceita decidir, adiando primeiro os casos cuja decisão tem maior probabilidade estimada de estar errada, o erro entre os decididos e o número de falsos negativos. A Tabela 7 resume o ponto em vigor no software.

A curva mostra que o erro se concentra nos últimos casos. Decidindo 80% do treino, o erro entre os decididos fica entre 0,29% e 1,17%, conforme o modelo; decidindo todos, sobe para 5,63% a 6,34%, e o do comitê passa de 0,78% a 90% de cobertura para 5,63% a 100%. Os modelos não erram de forma espalhada, mas num pequeno grupo de casos difíceis, situação em que abster-se compensa. Com a faixa, os quatro modelos que a possuem decidem entre 50% e 65% do treino, contra três a cinco falsos negativos se decidissem todos os casos; assim, entre 35% e 50% dos pacientes do treino voltam para revisão humana. A faixa foi construída para não produzir erro no treino: com os limites exatos, os quatro modelos não cometem nenhum erro entre os casos decididos. Os limites gravados em `limiares.json`, porém, têm quatro casas

GRÁFICO 7 – CURVA RISCO-COBERTURA NO TREINO (*OUT-OF-FOLD*), COM O PONTO DE OPERAÇÃO DE CADA MODELO



FONTE: O Autor

TABELA 7 – PONTO DE OPERAÇÃO: LIMIAR, FAIXA DE RECUSA, COBERTURA E ERRO

			Treino (*out-of-fold*)		Teste	
Modelo	**Limiar**	**Faixa de recusa**	**Erro sem recusa**	**Com a faixa: cobertura / erro**	**Erro sem recusa**	**Com a faixa: cobertura / erro**
Regressão Logística	0,151	0,003–0,670	5,87% (4)	60,1% / 0,39% (1)	4,90% (1)	69,9% / 0% (0)
Random Forest	0,120	0,013–0,922	6,10% (5)	54,5% / 0,00% (0)	2,10% (1)	67,8% / 0% (0)
SVM	0,155	0,004–0,730	5,87% (4)	65,3% / 0,36% (1)	3,50% (1)	74,1% / 0% (0)
KNN	0,170	—	6,34% (6)	100% / 6,34% (6)	3,50% (2)	100% / 3,50% (2)
Comitê	0,146	0,011–0,682	5,63% (3)	50,0% / 0,47% (1)	2,10% (1)	67,1% / 0% (0)

Nota: entre parênteses, o número de falsos negativos.

FONTE: O autor

decimais, e o arredondamento do limite inferior para cima faz um paciente maligno, com certeza logo abaixo desse limite, ser decidido como benigno. Esse é o falso negativo que aparece na Tabela 7, em três dos quatro modelos com faixa (Regressão Logística, SVM e comitê). O KNN não recebe faixa, pois suas probabilidades calibradas, com $k = 4$, assumem poucos valores distintos, e a faixa que zeraria seus erros o faria decidir menos de 45% do treino; por isso, opera com cobertura total e o maior erro do conjunto. Como a faixa foi ajustada com tolerância zero sobre as mesmas probabilidades *out-of-fold*, seu bom desempenho no treino é esperado por construção. A evidência está no teste, que não participou da escolha: ali, os quatro modelos com faixa decidem entre 67% e 74% do lote sem nenhum erro, e devolvem entre 26% e 33% dos pacientes à

revisão humana, cerca de um terço do lote de teste.

Esses resultados situam o comitê na solução. Como a Subseção 4.7.2 não encontrou diferença significativa entre os quatro modelos avançados, nenhum deles se justifica isoladamente, e o software não elege um modelo único: o operador escolhe entre os cinco classificadores, o comitê e um modo de comparação simultânea. O comitê é a opção que menos erra sem recusa no treino *out-of-fold*, com 5,63% e três falsos negativos, e, com a faixa, decide 67,1% do teste sem falso negativo nem falso positivo. A média dilui o engano isolado de um membro, ao custo de executar os quatro modelos a cada lote e de oferecer uma explicação que também é média, como discutido na Subseção 4.8.4.

4.8 O SOFTWARE DESENVOLVIDO

O módulo de software apresentado na Seção 4.2 encontra-se implementado e operacional. Esta seção documenta sua organização interna, o fluxo de trabalho oferecido ao profissional de saúde e, sobretudo, os recursos de explicabilidade que convertem a saída numérica dos classificadores em justificativa auditável. As instruções de instalação e de uso estão nos Apêndices A e B.

4.8.1 Organização do código

A aplicação separa lógica de apresentação: app/core concentra as regras de negócio, sem dependência da interface; app/views reúne as telas em CustomTkinter; e app/utils, os utilitários de apoio, como a geração de PDF e os mapas interativos. Isso permite verificar a lógica isoladamente, e o projeto conta hoje com 231 testes automatizados em pytest. O Quadro 5 descreve cada módulo de app/core. Fora dele, app/autoteste.py percorre sem interface o fluxo completo de uso, recurso empregado na validação do executável (Subseção 4.8.6), e scripts/calibrar_limiares.py gera o arquivo limiares.json (Subseção 4.7.4).

Os testes dividem-se em dois grupos. Os isolados treinam modelos na hora, sobre a base pública distribuída com o scikit-learn, e verificam se a decisão exibida na interface corresponde à decisão real do classificador, tipo de inconsistência encontrado e corrigido no SVM e no KNN durante o desenvolvimento; os do memorial de cálculo conferem os números citados na aba Sobre com os que o código usa. Os de integração

QUADRO 5 – MÓDULOS DE LÓGICA DA APLICAÇÃO (app/core).

Módulo	**Responsabilidade**
inference.py	Carrega o arquivo wisconsin.pkl e disponibiliza modelos, escalonador, explicadores e artefatos SHAP à aplicação.
caminhos.py	Define onde a aplicação lê seus recursos e grava os dados do usuário, pelo código-fonte ou no executável.
validacao.py	Valida a planilha recebida antes de qualquer cálculo e recusa lotes malformados.
batch_processor.py	Higieniza a planilha e aplica o escalonador *Z-score* ajustado no conjunto de treino.
decision.py	Política de decisão: limiar de operação, faixa de recusa, banda de limítrofe e zona de decisão de cada paciente.
predictor.py	Motor de inferência: produz o diagnóstico e as colunas de confiabilidade de cada paciente.
ood_detector.py	Sinaliza perfis atípicos pela distância de Mahalanobis ao conjunto de treino.
explainers.py	Explicadores exatos da Árvore de Decisão, Regressão Logística, KNN, Random Forest e SVM.
fatores.py	Fatores que mais pesaram: valores de Shapley exatos por fator, sobre a certeza calibrada.
shap_explainer.py	Valores de Shapley coluna a coluna de cada modelo, calculados sob demanda.
committee.py	Explica o comitê de voto suave pela concordância entre seus membros.
metrics.py	Métricas da auditoria acadêmica, com cobertura e intervalo de confiança de Wilson, e leitura crítica por modelo.
calculos.py	Memorial de cálculo da aba Sobre, fonte única dos números que a interface cita.
biomarkers.py	Glossário dos trinta biomarcadores, exibido na aba Sobre e nas dicas da tabela de resultados.
history_manager.py	Persistência das sessões de diagnóstico no histórico.

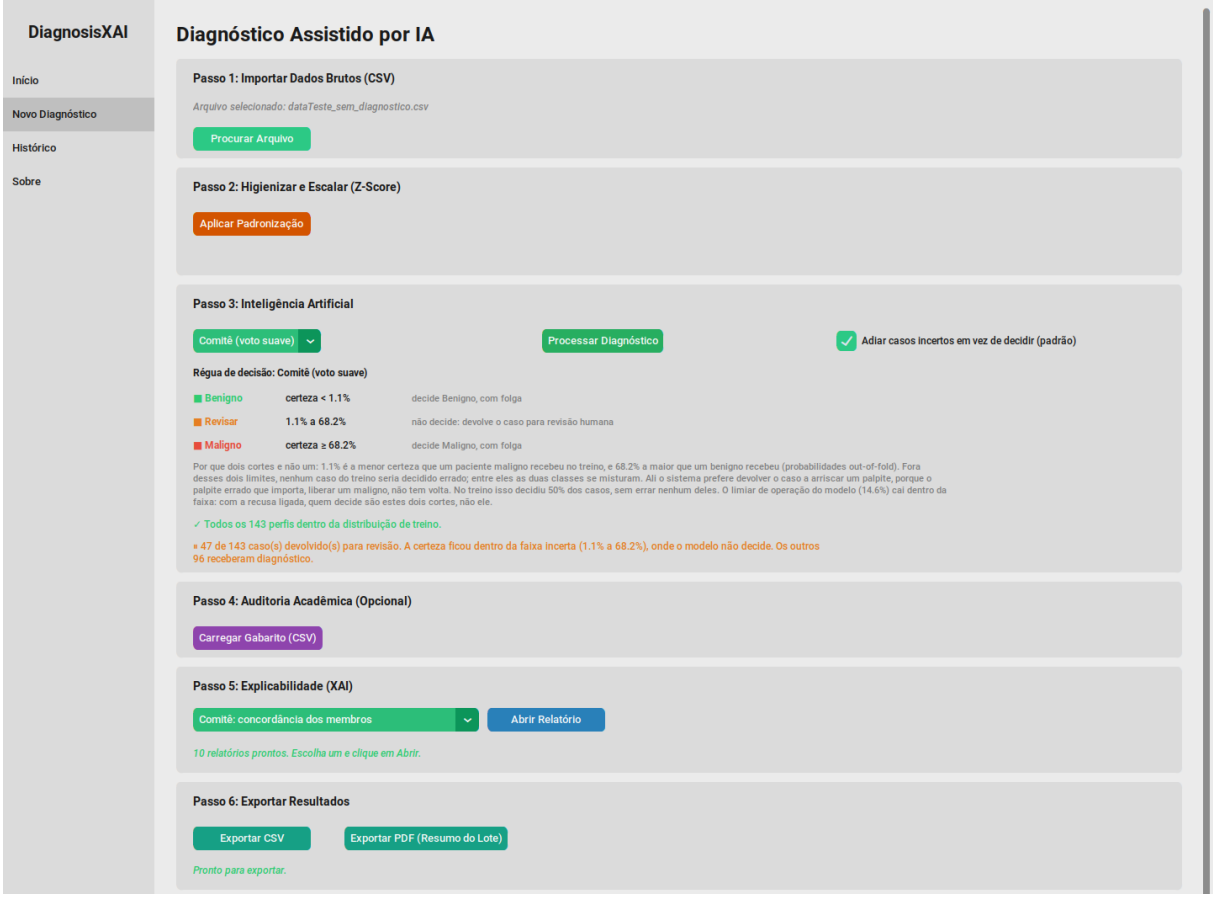
FONTE: O autor

exercitam o próprio wisconsin.pkl versionado no repositório, conferem que o bloco de fatores fecha na certeza exibida e acusam qualquer alteração no formato do artefato.

4.8.2 Fluxo de trabalho

A tela de diagnóstico organiza a operação em seis passos sequenciais, cada um liberado somente após a conclusão do anterior, conforme a Figura 11. O encadeamento é deliberado: impede que o operador submeta à inferência dados que ainda não foram padronizados, erro que produziria diagnósticos silenciosamente incorretos.

FIGURA 11 – TELA DE DIAGNÓSTICO COM OS SEIS PASSOS DO FLUXO DE TRABALHO



FONTE: O Autor

Primeiro, o profissional importa uma planilha em formato CSV contendo os trinta atributos morfológicos e aplica a padronização *Z-score*, executada com o escalonador ajustado no treino e recuperado do arquivo wisconsin.pkl. Antes de padronizar, o sistema valida a planilha e recusa o lote inteiro quando ela está malformada, com mensagem que indica a coluna e a linha do problema. Em seguida, seleciona o

classificador, qualquer um dos cinco modelos avaliados na Seção 4.6, o comitê de voto suave ou o modo de comparação simultânea, e processa o lote; a mesma tela exibe a régua de decisão do modelo escolhido, descrita a seguir. Os passos seguintes são de leitura e verificação: auditoria acadêmica contra um gabarito, abertura dos relatórios de explicabilidade e exportação dos resultados. Os critérios de recusa da planilha e a operação de cada passo estão no Apêndice B.

4.8.3 Sinais de confiabilidade

Entregar apenas o rótulo Benigno ou Maligno seria repetir o problema da caixa preta em outra forma. Ao lado do diagnóstico, a tabela de resultados traz, portanto, três colunas que qualificam cada previsão, Certeza_Maligno(%), Zona_de_Decisão e Perfil, exibidas na Figura 12; no comitê, a tabela mostra também a certeza calibrada de cada membro.

FIGURA 12 – COLUNAS DE CONFIABILIDADE NA TABELA DE RESULTADOS

Colunas: Diagnóstico_IA: o que o sistema entrega para o paciente · Certeza_Maligno(%): a evidência, lida nesta régua: Benigno: certeza < 1.1% · Revisar: 1.1% a 68.2% · Maligno: certeza ≥ 68.2% · Zona_de_Decisão: em qual dessas faixas a certeza caiu · Perfil: se o paciente se parece com os casos de treino ("Atípico" quer dizer que o modelo está extrapolando)

ractal_dimension_v	Diagnóstico_IA	Certeza_Maligno(%	Zona_de_Decisão	Certeza_REG(%)	Certeza_RAN(%)	Certeza_SVM(%)	Certeza_KNN(%)	Perfil
1.0327	Maligno	94.77	Definida	99.99	98.99	81.0	99.09	Típico
0.2535	Revisar	1.23	Revisar	0.89	1.42	0.26	2.33	Típico
-1.3743	Maligno	99.31	Definida	99.89	98.38	99.89	99.09	Típico
1.3744	Revisar	6.27	Revisar	0.0	1.21	21.52	2.33	Típico
0.3213	Revisar	7.79	Revisar	11.52	13.06	4.25	2.33	Típico
-0.6433	Benigno	1.06	Definida	0.67	1.19	0.05	2.33	Típico
-0.8831	Benigno	0.97	Definida	0.06	1.35	0.13	2.33	Típico
-0.6747	Benigno	1.01	Definida	0.32	1.19	0.17	2.33	Típico
-0.7632	Revisar	1.37	Revisar	1.55	1.36	0.24	2.33	Típico
-0.1117	Revisar	4.8	Revisar	7.09	6.94	2.83	2.33	Típico
1.7497	Maligno	94.65	Definida	94.12	96.23	89.18	99.09	Típico
-1.0741	Maligno	96.37	Definida	96.37	95.55	99.14	94.43	Típico
-0.1173	Revisar	1.37	Revisar	1.61	1.36	0.18	2.33	Típico
-0.6159	Benigno	0.88	Definida	0.02	1.14	0.02	2.33	Típico
-0.8629	Revisar	65.94	Revisar	75.94	14.47	78.57	94.77	Típico

FONTE: O Autor

A coluna de certeza apresenta a probabilidade de malignidade recalibrada pelo escalonamento de Platt, conforme a Subseção 4.7.3, e o diagnóstico sai dessa mesma probabilidade, comparada aos cortes da Subseção 4.7.4, e não a 50%. Os cortes são lidos do arquivo limiares.json e exibidos na tela de diagnóstico como uma régua de três faixas contíguas, acompanhada do critério que as gerou e do desempenho medido. No comitê, a régua indica Benigno abaixo de 1,1% de certeza, Revisar de 1,1% a 68,2% e Maligno a partir de 68,2%. A régua acompanha o lote nos PDFs exportados, para que cada diagnóstico possa ser conferido fora da aplicação.

A recusa vem ligada por padrão: os casos da faixa do meio recebem o rótulo

Revisar, que não é uma classe intermediária, e sim a ausência intencional de resposta onde decidir equivaleria a adivinhar. O operador pode desligá-la; o modelo passa então a decidir todos os casos pelo limiar de operação, de 14,6% no comitê, e a coluna Zona_de_Decisão marca como Limítrofe o paciente cuja certeza fique a menos de dez pontos percentuais do limiar. Com a recusa ligada, a coluna indica Revisar para os casos devolvidos e Definida para os demais. O KNN e a Árvore de Decisão não oferecem a recusa e decidem todos os casos: o primeiro não tem faixa calibrada, e a segunda não tem probabilidade calibrada.

A coluna Perfil sinaliza pacientes atípicos pela distância de Mahalanobis ao centro do treino, medida sobre os trinta atributos padronizados com covariância regularizada por Ledoit-Wolf e cortada no percentil 99. Perfil atípico indica extrapolação para uma região pouco observada no aprendizado, não malignidade.

4.8.4 Relatórios de explicabilidade

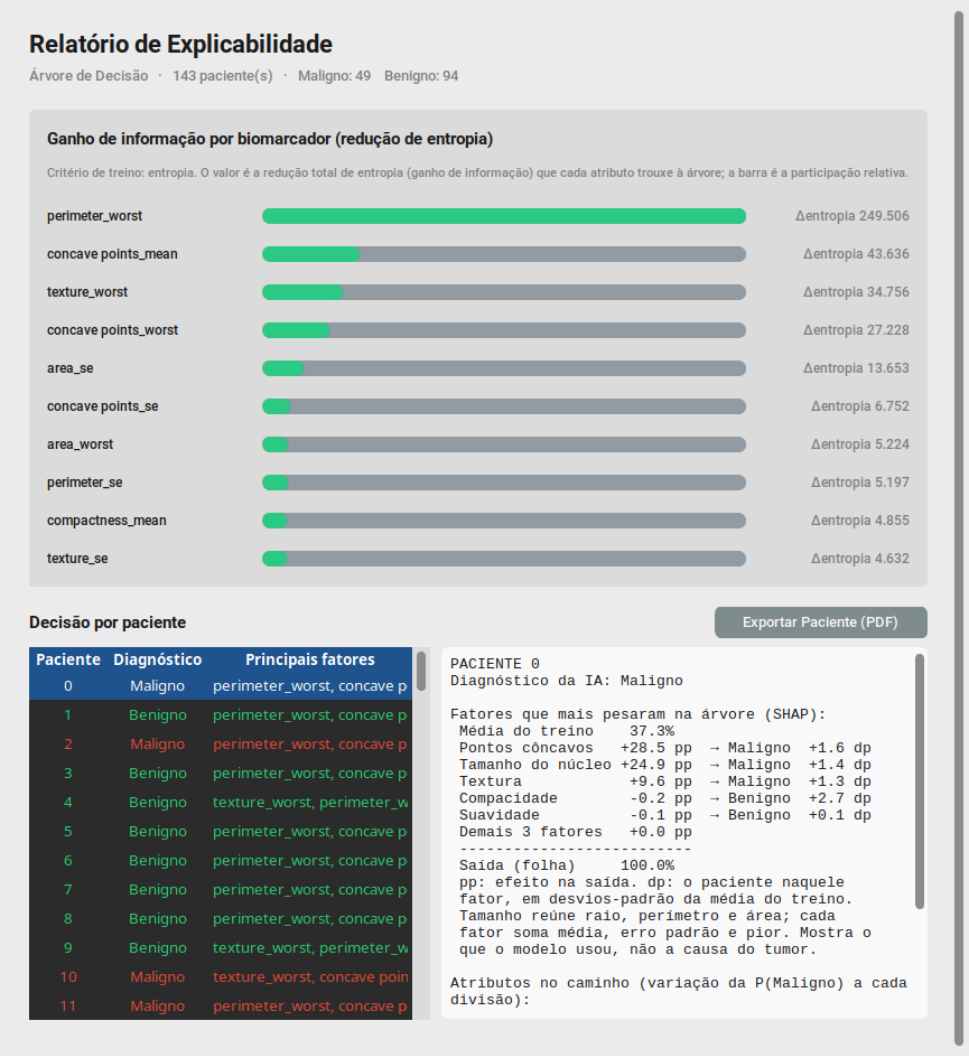
A aplicação abre uma janela de explicabilidade específica para o modelo executado. A opção por explicadores distintos, em vez de uma única visualização comum, decorre de uma constatação simples: cada algoritmo decide por um mecanismo próprio, e apresentar todos sob a mesma representação obscureceria justamente aquilo que os torna auditáveis.

Antes do raciocínio próprio de cada algoritmo, porém, o detalhe de todo paciente abre pelo mesmo bloco, Fatores que mais pesaram, presente na janela de cada modelo e na do comitê. O bloco decompõe a certeza exibida na tabela pelos valores de Shapley da Seção 2.5, com três adaptações. Primeiro, as trinta colunas são agrupadas em oito fatores, as dez medições de base da Wisconsin com raio, perímetro e área fundidos no tamanho do núcleo, pois essas três têm correlação entre 0,98 e 0,998 no treino; cada fator leva junto sua média, seu erro padrão e seu pior valor. Segundo, com oito fatores há apenas $2^8 = 256$ coalizões, e o valor de Shapley de cada fator é calculado por enumeração completa, sem a amostragem do KernelExplainer. Terceiro, a função explicada é a própria certeza calibrada (na Árvore de Decisão, que não a possui, a saída da folha), e o ponto de partida é a certeza média do modelo sobre todo o treino, próxima da prevalência de malignos (37,3%), de modo que a cascata fecha exatamente no número da tabela. O bloco lista os seis fatores de maior efeito e soma os demais em

uma linha. Como toda explicação SHAP, descreve o que o modelo usou para chegar à certeza, não a causa biológica do tumor.

A Árvore de Decisão é o caso mais direto, pois sua estrutura já é a própria explicação. A janela correspondente, na Figura 13, ordena os biomarcadores pelo ganho de informação, a redução de entropia que cada um promove, e reconstrói, para o paciente selecionado, o caminho de regras percorrido da raiz até a folha.

FIGURA 13 – RELATÓRIO DA ÁRVORE DE DECISÃO: GANHO DE INFORMAÇÃO E DETALHE DO PACIENTE

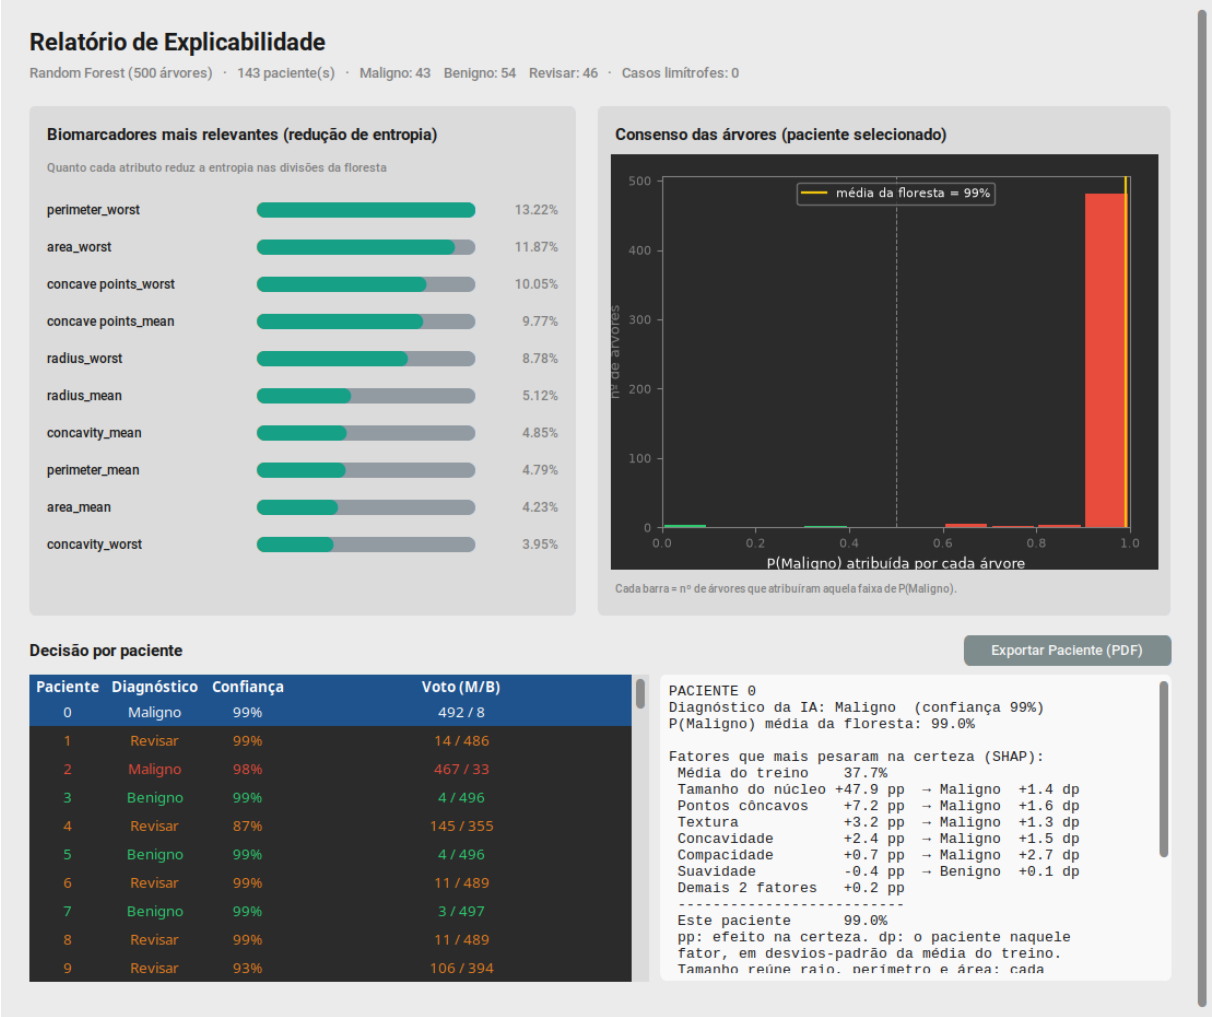


FONTE: O Autor

O Random Forest exige outra abordagem, uma vez que sua decisão emerge da agregação de quinhentas árvores. A janela da Figura 14 apresenta a importância global pela redução média de entropia (MDI) e, para o paciente selecionado, a distribuição das probabilidades atribuídas individualmente por cada árvore, acompanhada da contagem de votos. A representação distingue duas situações que a média isolada confunde: o

consenso amplo da floresta e a divisão interna entre árvores discordantes.

FIGURA 14 – RELATÓRIO DO RANDOM FOREST: CONSENSO ENTRE AS ÁRVORES DA FLORESTA



FONTE: O Autor

No SVM, o elemento a tornar visível é a margem definida pela Equação 8. A janela da Figura 15 combina duas vistas. No mapa populacional, cada paciente de treino é colorido pelo seu escore de decisão z, o valor real da função de decisão do modelo, e os vetores de suporte recebem um anel que distingue os situados dentro da margem ($|z| < 1$) dos demais. No painel da margem, o eixo horizontal é o próprio z, de modo que a faixa entre $z = -1$ e $z = +1$ que o SVM maximiza e a fronteira em $z = 0$ aparecem sem aproximação; para o paciente selecionado, a janela mostra ainda o balanço de forças entre os vetores de suporte das duas classes que compõem seu escore. A margem não é traçada sobre o mapa porque o UMAP não tem inversa exata (a biblioteca oferece apenas uma aproximação): não há como avaliar a função

de decisão em um ponto arbitrário do plano, apenas interpolar o escore dos pacientes vizinhos. Medida por validação *leave-one-out* sobre o treino, essa interpolação acerta o lado da fronteira em cerca de 96% dos casos, mas desenharia metade dos pacientes com $|z| < 1$ fora da margem, errando justamente nos casos limítrofes. A Regressão Logística e o KNN dispõem de janelas equivalentes: a primeira exibe a curva sigmoide com o escore linear do paciente e a função matemática da decisão; o segundo, o mapa de vizinhança com os quatro vizinhos que efetivamente votaram.

FIGURA 15 – RELATÓRIO DO SVM: MAPA COLORIDO PELO ESCORE DE DECISÃO E PAINEL DA MARGEM



FONTE: O Autor

A janela SHAP, na Figura 16, mantém o detalhe coluna a coluna para os cinco classificadores: a importância global dos trinta atributos e o gráfico em cascata do

paciente selecionado. Ela decompõe a probabilidade do modelo antes da calibração, que não é a certeza da tabela, e por isso exibe os dois números lado a lado, cada um com seu nome. Na Árvore de Decisão e no Random Forest, os valores vêm do TreeExplainer e são exatos; na Regressão Logística, no SVM e no KNN, vêm do KernelExplainer e são aproximados. A explicação comparável entre modelos, que fecha na certeza exibida, é o bloco de fatores descrito acima.

FIGURA 16 – RELATÓRIO SHAP: IMPORTÂNCIA GLOBAL E CONTRIBUIÇÃO POR PACIENTE

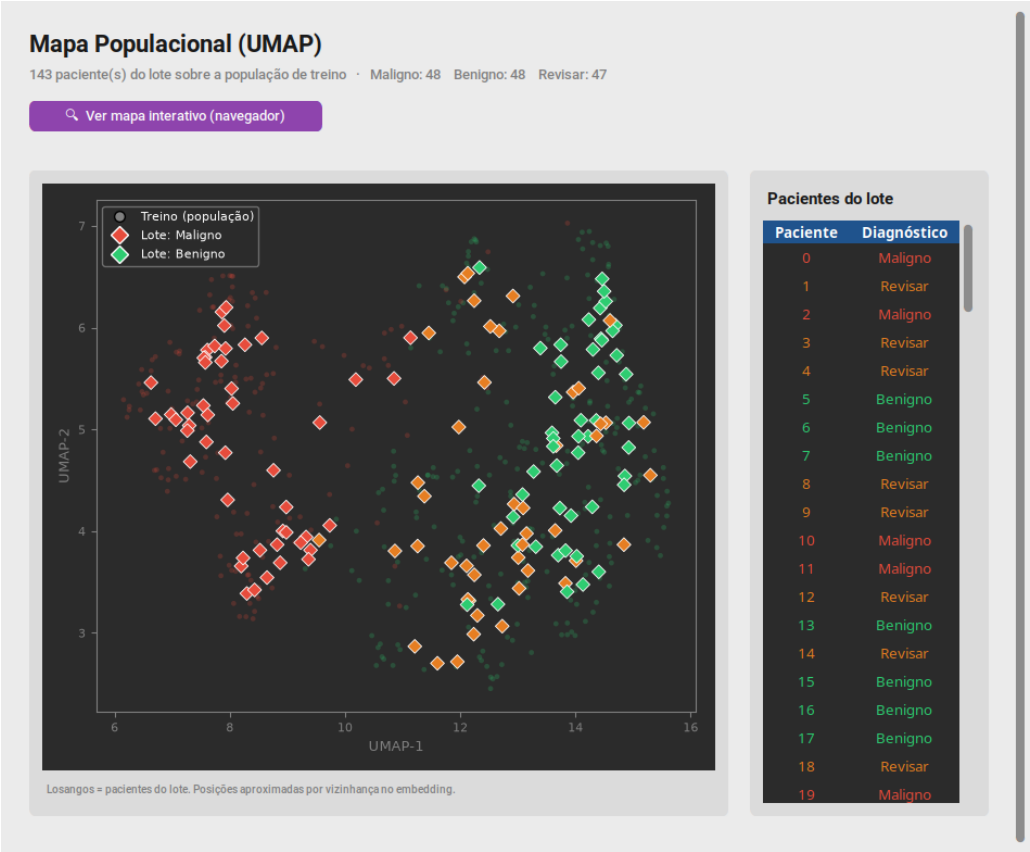


FONTE: O Autor

O mapa populacional, apresentado na Figura 17, projeta os pacientes do lote sobre o *embedding* UMAP ajustado no conjunto de treino, discutido na Seção 2.6. Como o UMAP não é reajustado a cada lote, cada paciente novo é posicionado pela média das posições de seus vizinhos de treino mais próximos no espaço dos trinta atributos, ponderada pela distância. O mapa situa o caso em relação à população

conhecida, mas nenhum ponto cai fora da nuvem do treino; a atipicidade é medida pela coluna Perfil, no espaço completo dos atributos.

FIGURA 17 – MAPA POPULACIONAL: PROJEÇÃO UMAP DO LOTE SOBRE O CONJUNTO DE TREINO

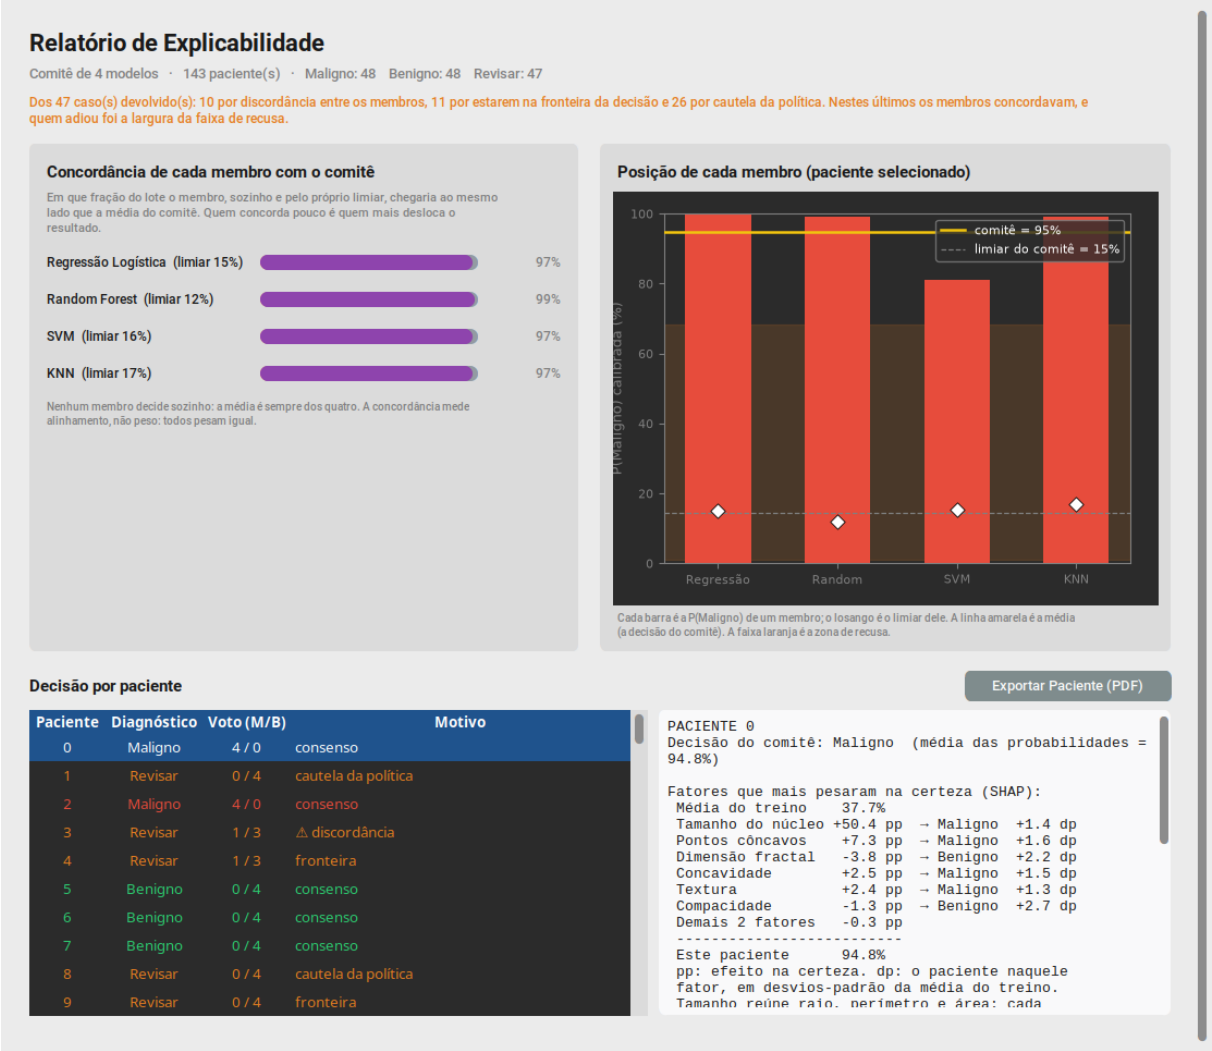


FONTE: O Autor

O comitê de voto suave, que agrega Regressão Logística, Random Forest, SVM e KNN, não tem mecanismo interno a expor, pois não possui coeficientes, regras ou vetores de suporte. O que pesou em sua decisão vem do bloco de fatores: como sua certeza é a média das certezas dos membros e o valor de Shapley é linear, seus fatores são exatamente a média dos fatores dos membros. Sua janela, na Figura 18, responde a outra pergunta, a de como os quatro chegaram, ou não, a um acordo. Ela mostra em que fração do lote cada membro, sozinho e pelo próprio limiar, chegaria ao mesmo lado que a média e, para cada paciente, a posição de cada membro e a origem de um caso devolvido à revisão: divergência entre os modelos, proximidade da fronteira ou conservadorismo da própria política de decisão. Cada uma dessas situações pede conduta diferente do profissional. Quando os membros discordam, a média dos fatores esconde a divergência, e o relatório de cada membro permanece

disponível para consulta.

FIGURA 18 – RELATÓRIO DO COMITÊ: CONCORDÂNCIA DOS MEMBROS E FATORES QUE MAIS PESARAM



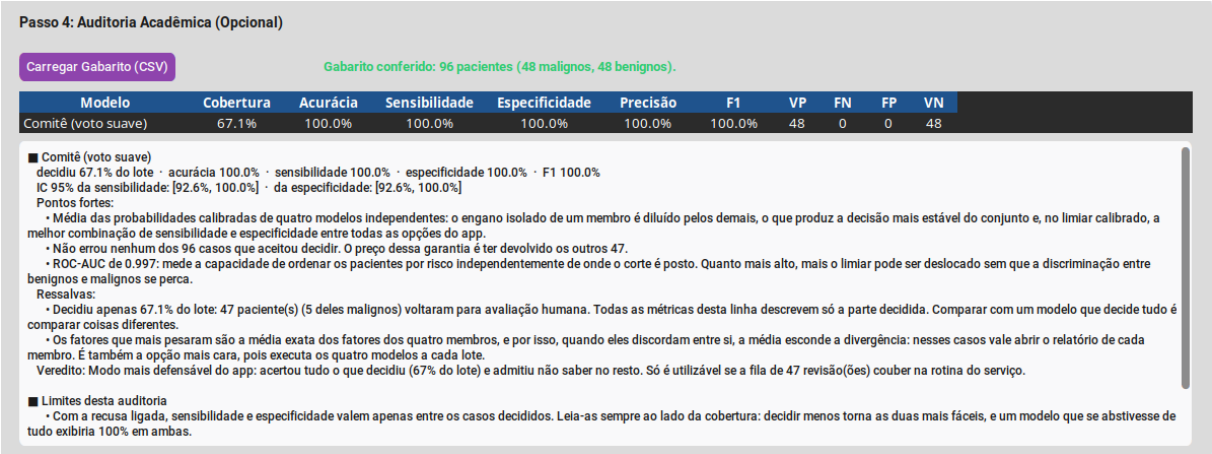
FONTE: O Autor

4.8.5 Auditoria, exportação e consulta

A auditoria, opcional e voltada ao uso acadêmico, recebe um gabarito com os diagnósticos reais do mesmo lote e avalia o desempenho sobre ele. A Figura 19 exibe a tabela resultante para o comitê. A primeira coluna é a cobertura, a fração do lote que o modelo decidiu: com a recusa ligada, as demais métricas descrevem apenas os casos decididos, e comparar a acurácia de um modelo que decidiu dois terços do lote com a de outro que decidiu todo ele é comparar coisas diferentes. Seguem acurácia, sensibilidade, especificidade, precisão e F1, e a matriz de confusão de onde todas

derivam. Uma leitura crítica em texto traz o intervalo de confiança de Wilson de 95% da sensibilidade e da especificidade, interpreta os números em termos dos custos clínicos assimétricos entre falso negativo e falso positivo e repete por extenso a ressalva de cobertura. No lote de teste, o comitê decide 96 dos 143 pacientes, sem nenhum erro, e devolve os outros 47, dos quais 5 são malignos.

FIGURA 19 – AUDITORIA ACADÊMICA: DESEMPENHO DO COMITÊ CONTRA O GABARITO



FONTE: O Autor

A aplicação exporta os resultados em CSV, preservando as colunas de confiabilidade, ou em PDF, no formato de relatório do lote acompanhado da régua de decisão, e cada janela de modelo exporta o laudo individual de um paciente, com o bloco de fatores e a justificativa do modelo. As sessões ficam registradas na aba Histórico, e a aba Sobre reúne o memorial de cálculo e o glossário dos trinta biomarcadores, descritos no Apêndice B.

4.8.6 Distribuição

A aplicação é distribuída como executável para Windows e Linux, que dispensa a instalação do Python. O empacotamento usa o PyInstaller no modo de pasta, compactada em um arquivo .zip, com as versões exatas de requirements-executavel.txt. Como o PyInstaller só gera executável para o sistema em que roda, um fluxo do GitHub Actions compila as duas versões em máquinas Windows e Linux a cada etiqueta de versão (v*) e as publica em um *Release* do repositório. Antes de compactar, o script de geração executa o programa pronto com a opção `--autoteste`, que percorre sem

interface as catorze etapas do uso real, do carregamento do wisconsin.pkl e da régua ao diagnóstico com todos os modelos, à auditoria, às explicações, aos fatores, ao SHAP, ao mapa interativo, aos PDFs e ao histórico, e interrompe a geração se alguma falhar. A verificação é necessária porque o PyInstaller inclui apenas o que enxerga nas importações, e o que fica de fora só se manifesta com o programa em execução. No executável, o histórico e os PDFs são gravados na pasta DiagnosisXAI do diretório pessoal do usuário, pois a pasta do programa pode ser somente leitura.

4.8.7 Limitações do software

A aplicação opera apenas sobre os trinta atributos da base Wisconsin, já extraídos das imagens: não faz segmentação de núcleos nem processamento de imagem, etapa que permanece a cargo do laboratório. Os modelos são estáticos e herdam as limitações da base de origem, 569 amostras de uma população específica. A recusa tem custo explícito: no conjunto de teste, cerca de um terço do lote volta para revisão humana, e o KNN, sem faixa calibrada, decide todos os casos. Os fatores que mais pesaram descrevem o que o modelo usou para chegar à certeza, não a causa biológica do tumor, e os valores SHAP coluna a coluna da Regressão Logística, do SVM e do KNN são aproximações do KernelExplainer. A validação até aqui é técnica: os testes verificam a coerência entre o diagnóstico exibido e a decisão efetiva dos modelos, mas o sistema ainda não passou por avaliação de usabilidade com profissionais de saúde.

5 CONCLUSÃO

Este trabalho partiu de um obstáculo à adoção clínica do aprendizado de máquina no diagnóstico do câncer de mama: modelos de alto desempenho que não revelam o raciocínio por trás de suas decisões. Perguntou-se como integrar técnicas de explicabilidade e de redução de dimensionalidade a um modelo preditivo, de modo a obter diagnósticos acurados e interpretáveis por profissionais de saúde. O objetivo foi desenvolver um software que classificasse tumores benignos ou malignos a partir da base Wisconsin e acompanhasse cada diagnóstico de uma justificativa transparente.

Os experimentos mostraram, em primeiro lugar, que nesta base o desempenho não depende de um modelo complexo. A Regressão Logística, intrinsecamente interpretável, igualou ou superou o SVM e o Random Forest no conjunto de teste. A validação cruzada repetida revelou que essa partição única era otimista. Os testes de significância não encontraram diferença entre os quatro modelos avançados, com acurácia média entre 0,960 e 0,973, e apontaram apenas a inferioridade da Árvore de Decisão. Trocar um modelo transparente por uma caixa preta não se justificou por ganho de desempenho, e por isso o software oferece os cinco classificadores e um comitê de voto suave, sem eleger um único modelo.

Em segundo lugar, acertar não basta: a certeza exibida precisa corresponder à frequência real do desfecho. As probabilidades foram recalibradas pelo escalonamento de Platt, e a decisão deixou de usar o corte de 50%, passando a depender de um limiar de operação e de uma faixa de recusa definidos sem o conjunto de teste. Nesse conjunto, os quatro modelos com faixa, entre eles o comitê, decidiram entre 67% e 74% dos pacientes sem nenhum erro. O preço é explícito: cerca de um terço do lote volta para revisão humana.

Em terceiro lugar, quanto à explicabilidade, os coeficientes da Regressão Logística e os valores SHAP do Random Forest concordaram apenas em parte. O núcleo comum, atributos ligados ao tamanho e às concavidades do núcleo celular, coincide com alterações morfológicas associadas à malignidade. No software, cada modelo é explicado pelo próprio mecanismo de decisão, e todos compartilham um bloco de fatores que decompõe a certeza exibida em valores de Shapley exatos, de modo que a explicação fecha no mesmo número que o profissional lê na tabela. O UMAP serve

para situar cada paciente na população de treino, mas não explica a decisão nem revela casos atípicos; esses são sinalizados pela distância de Mahalanobis no espaço completo dos atributos.

A resposta à pergunta de pesquisa é que a integração não se resume a acoplar uma técnica de explicabilidade a um classificador. Diagnósticos acurados e interpretáveis exigiram combinar certeza calibrada, regra de decisão capaz de se abster, explicações coerentes com essa certeza e recursos que situam o paciente na população conhecida e sinalizam quando ele se afasta dela. O objetivo geral foi atingido: o software está implementado, é distribuído como executável para Windows e Linux, processa lotes recebidos em planilha e exporta os resultados em CSV e os relatórios em PDF, com a fundamentação de cada diagnóstico. A interpretabilidade, porém, foi tratada no plano técnico e ainda precisa ser confirmada pelos profissionais a quem a ferramenta se destina.

Ao longo do desenvolvimento, três obstáculos exigiram ajustes que alteraram o resultado inicial. O primeiro foi a divergência entre a decisão exibida ao profissional e a decisão efetiva do classificador, identificada no SVM e no KNN. A correção foi incorporada ao código, e um conjunto de testes automatizados passou a verificar que o diagnóstico exibido corresponde à decisão de cada modelo. O segundo foi a calibração: a regressão isotônica produziu o menor escore de Brier no teste, mas foi descartada em favor do escalonamento de Platt, mais robusto em amostras pequenas. Como a calibração padrão, que faz a média de cinco SVMs calibrados, piorava o Brier, o software passou a calibrar um único SVM sobre previsões *out-of-fold*. O KNN, cujas probabilidades assumem poucos valores distintos, ficou sem faixa de recusa. O terceiro foi o empacotamento. O PyInstaller inclui apenas o que identifica nas importações, e as falhas de módulos ausentes só apareciam com o programa em execução; a solução foi um modo de autoteste que percorre o fluxo completo antes de gerar o executável. Como o arquivo de modelos exige a mesma versão do scikit-learn para ser lido, as versões foram fixadas em um arquivo próprio. Como o PyInstaller só gera executáveis para o sistema em que roda, a compilação para Windows e Linux foi automatizada com GitHub Actions. Por fim, a pasta do programa pode ser somente leitura, e por isso o histórico e os relatórios são gravados no diretório do usuário.

O trabalho contribui em duas frentes. A metodológica: ao complementar a

validação cruzada com testes de significância e análise de calibração, procedimentos que nenhum dos trabalhos relacionados empregou, mostrou que uma partição única pode produzir estimativas otimistas e não basta para sustentar a superioridade de um algoritmo. A prática: reúne, em uma ferramenta utilizável, elementos que a literatura explorava isoladamente (comparação sistemática de classificadores, SHAP local e global, UMAP, calibração e sinalização de perfis atípicos), e mostra como um sistema de apoio ao diagnóstico pode ser transparente quanto à própria incerteza, devolvendo os casos duvidosos ao especialista e avisando quando o paciente foge do perfil de treino. Por operar localmente, preserva a privacidade dos pacientes, e sua arquitetura pode servir de referência a empresas que desenvolvem software para a saúde. Para a sociedade, aponta um caminho em que a inteligência artificial chega à prática clínica como apoio auditável ao profissional, e não como seu substituto.

Essas conclusões têm limites. A base Wisconsin reúne 569 amostras de uma população específica, e os modelos, estáticos, não foram avaliados em dados de outras instituições. Os atributos são trinta medidas morfológicas já extraídas das imagens, algumas fortemente correlacionadas, a maioria sem unidade física e sem informações clínicas do paciente; a aplicação não processa imagens e depende da extração feita pelo laboratório. As explicações descrevem o que o modelo usou para chegar à certeza, não a causa biológica do tumor, e os valores SHAP coluna a coluna da Regressão Logística, do SVM e do KNN são aproximações. Por fim, a validação foi apenas técnica, sem avaliação de usabilidade com profissionais de saúde.

Os próximos passos são validar os modelos em bases externas, recalculando limiares e faixas de recusa, o que a arquitetura já permite sem alterar a aplicação; avaliar a ferramenta com patologistas e oncologistas, verificando se as explicações apoiam a decisão e se a parcela de casos devolvidos é aceitável na rotina clínica; incorporar a segmentação dos núcleos, para que o sistema receba diretamente as imagens da punção; e investigar se variáveis clínicas complementares permitem decidir parte dos casos hoje devolvidos à revisão.

Em síntese, na base estudada, acurácia e transparência não precisaram ser trocadas uma pela outra. O desafio mostrou-se menos o de escolher o algoritmo de melhor desempenho do que o de deixar explícito, para cada paciente, quão segura é a resposta, o que a sustenta e quando o sistema deve se abster.

REFERÊNCIAS

ABDULLAH, D. M.; ABDULAZEEZ, A. M.; SALLOW, A. B. Lung cancer prediction and classification based on correlation selection method using machine learning techniques. **Qubahan Academic Journal**, v. 1, n. 2, p. 141–150, 2021.

ADADI, A.; BERRADA, M. Peeking inside the black-box: a survey on explainable artificial intelligence (xai). **IEEE access**, IEEE, v. 6, p. 52138–52160, 2018.

AI Online Course. **Kernel SVM for Dummies (with Python Code) | Machine Learning**. 2025. Disponível em: https://www.aionlinecourse.com/tutorial/machine-learning/kernel-svm. Acesso em: 07 nov. 2026.

BISHOP, C. M. **Pattern Recognition and Machine Learning**. [S.l.]: Springer, 2006.

BOLLON, J. *et al.* Investigating how reproducibility and geometrical representation in umap dimensionality reduction impact the stratification of breast cancer tumors. **Applied Sciences**, MDPI, v. 12, n. 9, p. 4247, 2022.

BRIER, G. W. Verification of forecasts expressed in terms of probability. **Monthly Weather Review**, American Meteorological Society, v. 78, n. 1, p. 1–3, 1950.

CHEN, H. *et al.* Classification prediction of breast cancer based on machine learning. **Computational Intelligence and Neuroscience**, v. 2023, p. 1–9, 2023.

CRUZ, J. A.; WISHART, D. S. Applications of machine learning in cancer prediction and prognosis. **Cancer Informatics**, v. 2, p. 59–77, 2006.

DAVIS, J.; GOADRICH, M. The relationship between precision-recall and roc curves. In: **Proceedings of the 23rd International Conference on Machine Learning**. [S.l.]: ACM, 2006. p. 233–240.

DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. **Journal of Machine Learning Research**, v. 7, p. 1–30, 2006.

DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. **Neural Computation**, MIT Press, v. 10, n. 7, p. 1895–1923, 1998.

DUTTA, M. An interpretable machine learning-based breast cancer classification using xgboost. **Bulletin of Electrical Engineering and Informatics**, Institute of Advanced Engineering and Science, v. 13, n. 6, p. 4306–4315, 2024.

FACELI, K. *et al.* **Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina**. 2nd. ed. [S.l.]: LTC, 2021.

GIL, A. C. **Como Elaborar Projetos de Pesquisa**. 4. ed. São Paulo: Atlas, 2002.

GUO, C. *et al.* On calibration of modern neural networks. In: **Proceedings of the 34th International Conference on Machine Learning**. [S.l.]: PMLR, 2017. p. 1321–1330.

HOLZINGER, A. *et al.* Causability and explainability of artificial intelligence in medicine. **Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery**, Wiley Online Library, v. 9, n. 4, p. e1312, 2019.

IBM. **O que é random forest?** 2026. Disponível em: https://www.ibm.com/br-pt/think/topics/random-forest. Acesso em: 07 nov. 2026.

INCA. **Bioinformática e biologia computacional**. Instituto Nacional de Câncer, 2022a. Disponível em: https://www.gov.br/inca/pt-br/assuntos/pesquisa/pesquisa-basica-e-experimental/bioinformatica-e-biologia-computacional/bioinformatica-e-biologia-computacional-1. Acesso em: 19 mar. 2026.

INCA. **Como surge o câncer?** Instituto Nacional de Câncer, 2022b. Disponível em: https://www.gov.br/inca/pt-br/assuntos/cancer/como-surge-o-cancer. Acesso em: 07 abr. 2026.

INCA. **O que é câncer?** Instituto Nacional de Câncer, 2022c. Disponível em: https://www.gov.br/inca/pt-br/assuntos/cancer/o-que-e-cancer. Acesso em: 07 abr. 2026.

INCA. **INCA estima 781 mil novos casos de câncer por ano no Brasil entre 2026 e 2028**. Instituto Nacional de Câncer, 2026. Disponível em: https://www.gov.br/inca/pt-br/assuntos/noticias/2026/inca-estima-781-mil-novos-casos-de-cancer-por-ano-no-brasil-entre-2026-e-2028. Acesso em: 19 mar. 2026.

JAMES, G. *et al.* **An Introduction to Statistical Learning: with Applications in Python**. 1. ed. New York: Springer, 2023.

KAVLAKOGLU, E. **O que é a Máquina de Vetores de Suporte?** 2026a. Disponível em: https://www.ibm.com/br-pt/think/topics/support-vector-machine. Acesso em: 31 mai. 2026.

KAVLAKOGLU, E. **O que é o algoritmo dos k vizinhos mais próximos?** 2026b. Disponível em: https://www.ibm.com/br-pt/think/topics/knn. Acesso em: 31 mai. 2026.

KAVLAKOGLU, E. **O que é uma Decision Tree?** 2026c. Disponível em: https://www.ibm.com/br-pt/think/topics/decision-trees. Acesso em: 31 mai. 2026.

LEE, F. **O que é regressão logística?** 2026. Disponível em: https://www.ibm.com/br-pt/think/topics/logistic-regression. Acesso em: 31 mai. 2026.

LUNDBERG, S. M. **SHAP: SHapley Additive exPlanations Documentation**. 2026. Disponível em: https://shap.readthedocs.io/en/latest/. Acesso em: 21 abr. 2026.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: GUYON, I. *et al.* (Ed.). **Advances in Neural Information Processing Systems 30**. [S.l.]: Curran Associates, Inc., 2017. p. 4765–4774.

MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. **Introduction to Information Retrieval**. New York: Cambridge University Press, 2008.

MASUD, M. *et al.* A machine learning approach to diagnosing lung and colon cancer using a deep learning-based classification framework. **Sensors**, v. 21, n. 3, p. 1–20, 2021.

MCINNES, L. *et al.* **UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction Documentation**. 2018. Disponível em: https://umap-learn.readthedocs.io/en/latest/. Acesso em: 21 abr. 2026.

MITCHELL, T. M. **Machine Learning**. [S.l.]: McGraw-Hill, 1997.

NCI. **What is Cancer?** NATIONAL CANCER INSTITUTE, 2021. Disponível em: https://www.cancer.gov/about-cancer/understanding/what-is-cancer. Acesso em: 08 abr. 2026.

NICULESCU-MIZIL, A.; CARUANA, R. Predicting good probabilities with supervised learning. In: **Proceedings of the 22nd International Conference on Machine Learning**. [S.l.]: ACM, 2005. p. 625–632.

PAHO. **Câncer**. Organização Pan-Americana da Saúde, 2026. Disponível em: https://www.paho.org/pt/topicos/cancer. Acesso em: 18 mar. 2026.

PLATT, J. C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: SMOLA, A. J. *et al.* (Ed.). **Advances in Large Margin Classifiers**. Cambridge: MIT Press, 1999. p. 61–74.

RABIEI, R. *et al.* Prediction of breast cancer using machine learning approaches. **Journal of Biomedical Physics and Engineering**, v. 12, n. 3, p. 297–308, 2022.

RICHARDSON, D. **O que é IA/ML e por que é importante para seus negócios?** Red Hat, 2022. Disponível em: https://www.redhat.com/pt-br/blog/what-aiml-and-why-does-it-matter-your-business. Acesso em: 11 abr. 2026.

RUDIN, C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. **Nature Machine Intelligence**, Nature Publishing Group, v. 1, n. 5, p. 206–215, 2019.

RUSSELL, S.; NORVIG, P. **Artificial Intelligence: A Modern Approach**. 3rd. ed. [S.l.]: Prentice Hall, 2010.

SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the roc plot when evaluating binary classifiers on imbalanced datasets. **PLoS ONE**, Public Library of Science, v. 10, n. 3, p. e0118432, 2015.

SHAON, M. S. H. *et al.* A comparative study of machine learning models with lasso and shap feature selection for breast cancer prediction. **Healthcare Analytics**, v. 6, p. 100353, 2024.

SILVA JÚNIOR, O. J. d. **Segmentação e contagem de células em imagens de câncer de mama: um estudo detalhado do desenvolvimento do pipeline**. Monografia (Trabalho de Conclusão de Curso) — Universidade Federal do Paraná, Curitiba, 2023.

STREET, W. N.; WOLBERG, W. H.; MANGASARIAN, O. L. Nuclear feature extraction for breast tumor diagnosis. SPIE, p. 861–870, 1993.

WOLBERG, W. H.; STREET, W. N.; MANGASARIAN, O. L. **Breast Cancer Wisconsin (Diagnostic)**. 1995. UCI Machine Learning Repository. Disponível em: https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic. Acesso em: 07 nov. 2026.

APÊNDICE A – MANUAL DE INSTALAÇÃO DO DIAGNOSISXAI

Este apêndice descreve como instalar e executar o DiagnosisXAI, software desenvolvido neste trabalho. Há duas formas de uso: o executável, indicado a quem deseja apenas operar o sistema, e o código-fonte, necessário para reproduzir os experimentos ou retreinar os modelos. O código-fonte e os executáveis estão disponíveis no repositório https://github.com/Gabas/DiagnosisXAI.

A.1 REQUISITOS

Para utilizar o sistema, são necessários:

a) computador com Windows ou Linux de 64 bits, para o executável, ou com Windows, Linux ou macOS, para o código-fonte;

b) tela com resolução de 1920 $\times$ 1080 pixels ou próxima dela; em telas menores, cada janela é limitada a 90% da área disponível;

c) navegador web, para as versões interativas do mapa populacional e da margem do SVM;

d) o Python 3.12 e o Git, somente para a execução pelo código-fonte.

A.2 INSTALAÇÃO DO EXECUTÁVEL

O executável dispensa a instalação do Python e de qualquer biblioteca. Para instalá-lo:

a) acesse a página de versões (*Releases*) do repositório, https://github.com/Gabas/DiagnosisXAI/releases, e baixe o arquivo DiagnosisXAI-windows-x64.zip ou DiagnosisXAI-linux-x64.zip da versão mais recente, conforme o sistema operacional;

b) extraia o conteúdo do arquivo .zip em uma pasta de sua escolha, mantendo todos os arquivos juntos, pois o programa depende da pasta inteira, e não apenas do executável;

c) no Windows, abra o arquivo DiagnosisXAI.exe; caso o sistema exiba o aviso “O Windows protegeu o computador”, emitido porque o programa não tem

assinatura digital, selecione Mais informações e, em seguida, Executar assim mesmo;

d) no Linux, abra um terminal na pasta extraída e execute `./DiagnosisXAI`; se necessário, conceda antes a permissão de execução com `chmod +x DiagnosisXAI`;

e) opcionalmente, para conferir a instalação, execute o programa com a opção `--autoteste`, que percorre sem interface as catorze etapas do uso real e grava o resultado no arquivo autoteste.txt, em uma pasta temporária.

A primeira abertura leva alguns segundos. A pasta exemplos, que acompanha o executável, traz o conjunto de teste da base Wisconsin em dois arquivos: dataTeste_sem_diagnostico.csv, para o primeiro passo, e dataTeste_com_diagnostico.csv, gabarito para a auditoria do quarto passo.

O executável grava o histórico de sessões e os relatórios em PDF na pasta DiagnosisXAI do diretório pessoal do usuário (C:\Users\<usuário>\DiagnosisXAI, no Windows, e ~/DiagnosisXAI, no Linux), pois a pasta do programa pode ser somente leitura. Para desinstalar o sistema, basta apagar a pasta extraída e, se desejado, essa pasta de dados.

A.3 EXECUÇÃO A PARTIR DO CÓDIGO-FONTE

A execução pelo código-fonte é indicada para reproduzir os experimentos do Capítulo 4. No macOS e no Linux, a biblioteca gráfica Tkinter, usada pela interface, é distribuída separadamente do Python e deve ser instalada junto com ele, por exemplo pelo pacote python3-tk, no Ubuntu, ou python-tk@3.12, no Homebrew; no Windows, o instalador oficial do Python já a inclui. Os passos são:

a) clone o repositório com o comando `git clone`, seguido do endereço https://github.com/Gabas/DiagnosisXAI.git, e entre na pasta DiagnosisXAI;

b) crie um ambiente virtual com `python3 -m venv .venv` e ative-o com `source .venv/bin/activate`, no Linux e no macOS, ou `.venv\Scripts\activate`, no Windows;

c) instale as dependências com `pip install -r requirements.txt`; para reproduzir exatamente o ambiente que gerou o arquivo wisconsin.pkl,

use o arquivo requirements-executavel.txt, que fixa as versões exatas;

d) entre na pasta app e inicie a aplicação com `python main.py`.

Os modelos treinados já acompanham o repositório, no arquivo data/wisconsin.pkl. Para retreiná-los, abra o *notebook* notebooks/Wisconsin.ipynb no Jupyter e execute todas as células, o que regrava o wisconsin.pkl; em seguida, execute `python scripts/calibrar_limiares.py` a partir da raiz do repositório, para recalcular os limiares e as faixas de recusa gravados em data/limiares.json. Os testes automatizados são executados com o comando `pytest`, também a partir da raiz.

APÊNDICE B – MANUAL DE USO DO DIAGNOSISXAI

Este apêndice orienta a operação do DiagnosisXAI. As telas mencionadas estão ilustradas na Seção 4.8.

B.1 ORGANIZAÇÃO DA INTERFACE

A barra lateral dá acesso a quatro abas:

a) a aba Início exibe o estado do sistema, como os modelos carregados;

b) a aba Novo Diagnóstico conduz o processamento de um lote em seis passos;

c) a aba Histórico lista as sessões anteriores e permite reabrir seus relatórios de explicabilidade sem reprocessar o lote;

d) a aba Sobre reúne o memorial de cálculo, que percorre, na ordem dos passos, a origem de cada número exibido, da padronização à matemática de cada explicador, e o glossário dos trinta biomarcadores, com o registro de que a maioria deles não tem unidade física; as descrições do glossário aparecem também como dicas nos cabeçalhos da tabela de resultados.

O tema claro ou escuro da interface pode ser trocado no seletor Tema, no rodapé da barra lateral.

B.2 PREPARAÇÃO DA PLANILHA DE ENTRADA

O sistema recebe os pacientes em um arquivo CSV, uma linha por paciente, com as trinta colunas morfológicas da base Wisconsin, nomeadas como na base original (radius_mean, texture_mean, . . . , fractal_dimension_worst). Os valores devem ser os brutos, medidos pelo laboratório, e não padronizados, pois a padronização é feita pelo próprio sistema. A planilha não deve conter as colunas id nem diagnosis. O lote é recusado, com mensagem que indica a coluna e a linha do problema, quando falta alguma coluna, há células vazias, texto no lugar de número, valores negativos ou nenhuma linha de dados.

Para a auditoria do quarto passo, usa-se um segundo arquivo, o gabarito, com as mesmas colunas acrescidas da coluna diagnosis, preenchida com 1 para maligno e 0 para benigno, como no arquivo dataTeste_com_diagnostico.csv.

B.3 PROCESSAMENTO DE UM LOTE

Na aba Novo Diagnóstico, cada passo é liberado somente após a conclusão do anterior, conforme a Figura 11:

a) no Passo 1, Importar Dados Brutos (CSV), selecione a planilha; os valores aparecem na tabela;

b) no Passo 2, Higienizar e Escalar (Z-Score), clique em Aplicar Padronização; o sistema valida a planilha e aplica a padronização ajustada no conjunto de treino;

c) no Passo 3, Inteligência Artificial, escolha na lista um dos cinco classificadores, o Comitê (voto suave) ou Todos (Comparação), que é a opção inicial; confira a régua de decisão exibida e clique em Processar Diagnóstico; a opção Adiar casos incertos em vez de decidir vem ligada e só está disponível para a Regressão Logística, o Random Forest, o SVM e o comitê;

d) no Passo 4, Auditoria Acadêmica, que é opcional, carregue o gabarito para obter a cobertura, as métricas de desempenho, a matriz de confusão e uma leitura crítica dos resultados; no modo Todos (Comparação), a auditoria avalia lado a lado os cinco classificadores individuais, e, para auditar o comitê, é preciso selecioná-lo no Passo 3;

e) no Passo 5, Explicabilidade (XAI), abra a janela de explicação do modelo executado e selecione um paciente para ver os fatores que mais pesaram e o raciocínio próprio do modelo; nessa janela, o botão Exportar Paciente (PDF) gera o laudo individual do paciente;

f) no Passo 6, Exportar Resultados, salve a tabela completa em CSV ou o relatório do lote em PDF, acompanhado da régua de decisão.

B.4 LEITURA DOS RESULTADOS

A tabela de resultados traz, para cada paciente, as seguintes colunas:

a) a coluna Diagnóstico_IA indica Maligno, Benigno ou Revisar; Revisar não é uma classe intermediária, e sim a indicação de que o sistema se absteve e de que o caso deve ser avaliado pelo especialista;

b) a coluna Certeza_Maligno(%) mostra a probabilidade calibrada de malignidade, que não deve ser comparada a 50%, pois o diagnóstico decorre dos cortes da régua exibida no terceiro passo;

c) a coluna Zona_de_Decisão indica Definida, Revisar ou, quando a recusa está desligada, Limítrofe, para os casos a menos de dez pontos percentuais do limiar de operação;

d) a coluna Perfil indica Típico ou Atípico; Atípico significa que o paciente se afasta da população de treino, situação em que a predição merece cautela, e não que o tumor seja maligno.

No modo Todos (Comparação), essas colunas são substituídas por uma coluna por modelo, com o diagnóstico que cada um daria ao mesmo paciente.

B.5 CUIDADOS DE USO

O DiagnosisXAI é um software acadêmico de apoio, não é um dispositivo médico e não substitui o diagnóstico do profissional de saúde. O sistema não processa imagens: opera apenas sobre os trinta atributos já extraídos pelo laboratório, obtidos pelo mesmo procedimento da base Wisconsin. Os casos devolvidos para revisão e os pacientes de perfil atípico devem ser examinados com atenção redobrada.