

UNIVERSIDADE TUIUTI DO PARANÁ

GABRIEL AST DOS SANTOS

**DESENVOLVIMENTO DE UM SOFTWARE COM INTELIGÊNCIA
ARTIFICIAL EXPLICÁVEL (XAI) PARA APOIO AO DIAGNÓSTICO
PREDITIVO DE CÂNCER DE MAMA UTILIZANDO SHAP E UMAP**

**CURITIBA
2026**

GABRIEL AST DOS SANTOS

**DESENVOLVIMENTO DE UM SOFTWARE COM INTELIGÊNCIA
ARTIFICIAL EXPLICÁVEL (XAI) PARA APOIO AO DIAGNÓSTICO
PREDITIVO DE CÂNCER DE MAMA UTILIZANDO SHAP E UMAP**

Trabalho de Conclusão de Curso apresentado ao curso de Bacharelado em Ciência da Computação da Faculdade de Ciências Exatas e de Tecnologia da Universidade Tuiuti do Paraná, como requisito à obtenção ao grau de Bacharel.

Orientador: Prof. Rodrigo Ramos Alves

**CURITIBA
2026**

LISTA DE FIGURAS

FIGURA 1 – Contraste morfológico entre células normais e neoplásicas.	7
FIGURA 2 – Hierarquia e relação de inclusão entre IA, ML e DL.	9
FIGURA 3 – Exemplo de citação de fontes.	20
FIGURA 4 – Exemplo de figura.	25
FIGURA 5 – Exemplo de subfiguras simples.	27
FIGURA 6 – Exemplo de subfiguras com legendas individuais.	27

LISTA DE SIGLAS E ACRÔNIMOS

AUC	<i>Area Under the Curve</i> (Área Sob a Curva)
DNA	Ácido desoxirribonucleico
DL	<i>Deep Learning</i>
IA	Inteligência Artificial
INCA	Instituto Nacional de Câncer
KNN	<i>K-Nearest Neighbors</i> (K-Vizinhos Mais Próximos)
ML	<i>Machine Learning</i>
PAAF	Punção Aspirativa por Agulha Fina
PAHO	<i>Pan American Health Organization</i>
RBF	<i>Radial Basis Function</i> (Função de Base Radial)
ROC	<i>Receiver Operating Characteristic</i> (Curva de Característica de Operação do Receptor)
SHAP	<i>SHapley Additive exPlanations</i>
SVM	<i>Support Vector Machine</i> (Máquina de Vetores de Suporte)
UMAP	<i>Uniform Manifold Approximation and Projection</i>
XAI	<i>eXplainable AI</i> (Inteligência Artificial Explicável)

1 INTRODUÇÃO

De acordo com a Organização Pan-Americana da Saúde (PAHO, 2026), as patologias oncológicas impõem uma enorme carga de adoecimento nas Américas, sendo superadas unicamente pelas doenças cardiovasculares. A instituição aponta que, durante o ano de 2022, a região contabilizou mais de 4,2 milhões de novos casos, com a expectativa de que esse índice sofra um acréscimo de 60% até 2045, chegando à marca de 6,7 milhões. Como uma das causas primárias de mortalidade no continente, a doença resultou em 1,4 milhão de perdas fatais em 2022, afetando pessoas com 69 anos ou menos em 45% das ocorrências. Contudo, o órgão ressalta que muitos desses quadros possuem elevadas taxas de cura quando há o rastreio precoce somado ao tratamento clínico assertivo.

No cenário nacional, as projeções apontam para um panorama de alerta, com a estimativa de 781 mil novos casos de câncer por ano no Brasil ao longo do triênio de 2026 a 2028. Dentro dessa estatística, o câncer de mama consolida-se de forma alarmante como a neoplasia mais incidente entre o público feminino, representando 30% de todos os novos diagnósticos nas mulheres. Esses números expressivos refletem não apenas o envelhecimento populacional, mas também evidenciam as profundas desigualdades regionais e os desafios persistentes que as pacientes enfrentam no acesso à prevenção, ao rastreamento, ao diagnóstico precoce e ao tratamento oportuno no sistema de saúde (INCA, 2026).

O uso de tecnologias computacionais para enfrentar essa carga de adoecimento está em plena expansão, impulsionado pela chamada revolução do *Big Data* na saúde. Instituições de referência, como o próprio Instituto Nacional de Câncer (INCA, 2022a), destacam que a bioinformática e a biologia computacional são cruciais para analisar dados em larga escala e identificar assinaturas do câncer. Ao processar grandes volumes de dados morfológicos e genéticos, abrem-se caminhos para uma medicina cada vez mais direcionada e personalizada. Nesse contexto, o uso de algoritmos de *Machine Learning* para o reconhecimento de padrões e classificação de tumores já se consolida como uma linha de pesquisa fundamental para a oncologia moderna, capaz de extrair marcadores de interesse clínico de forma automatizada.

Apesar do notável desempenho preditivo, a adoção clínica dessas tecnologias esbarra no chamado "problema da caixa preta". Algoritmos avançados fornecem previsões altamente acuradas, mas não revelam o raciocínio matemático interno que levou àquela conclusão. Na prática médica, entregar um diagnóstico de malignidade automatizado sem uma fundamentação biológica rastreável é insuficiente e eticamente questionável. O profissional de saúde necessita compreender quais fatores morfológicos e celulares pesaram na decisão para validar a previsão, confiar no modelo e transmitir o diagnóstico com segurança ao paciente.

É nesse cenário que a Inteligência Artificial Explicável (XAI - *eXplainable AI*) se faz estritamente necessária. A aplicação de técnicas de interpretabilidade, como o *SHapley Additive exPlanations* (SHAP), permite "abrir" essa caixa preta ao quantificar o impacto exato e a contribuição de cada variável clínica no risco de malignidade. Em paralelo, a utilização de algoritmos de redução de dimensionalidade, como o *Uniform Manifold Approximation and Projection for Dimension Reduction* (UMAP), facilita a análise visual da separabilidade natural dos dados, identificando agrupamentos (*clusters*) e anomalias de forma gráfica. Dessa forma, o sistema computacional deixa de ser apenas um classificador opaco e passa a atuar como uma ferramenta de apoio transparente, unindo a precisão analítica à explicabilidade exigida pelo campo oncológico.

Diante disso, surge o seguinte problema de pesquisa: integrar técnicas de explicabilidade e redução de dimensionalidade em um modelo preditivo de câncer de mama, de modo a fornecer diagnósticos que sejam, simultaneamente, acurados e interpretáveis por profissionais de saúde.

O objetivo deste trabalho é desenvolver um software integrado a um modelo preditivo para a classificação de tumores mamários (benignos ou malignos), utilizando algoritmos de Machine Learning e a base de dados pública Breast Cancer Wisconsin. O intuito principal é mitigar a opacidade característica dos modelos de "caixa preta", fornecendo aos profissionais de saúde diagnósticos preditivos que unam alta precisão analítica a justificativas clínicas transparentes.

Para alcançar esse propósito, o projeto engloba o treinamento e a seleção de classificadores, bem como a aplicação do UMAP para a análise visual da separabilidade natural dos dados, facilitando a identificação de agrupamentos (*clusters*) e anomalias (*outliers*) biológicas. Em paralelo, o sistema integrará a biblioteca SHAP para garantir a explicabilidade das decisões, quantificando o impacto de cada variável celular no risco de malignidade apontado pelo modelo. Por fim, visando a viabilidade de uso no cotidiano médico, o trabalho contempla a criação de uma interface capaz de receber dados em lote via upload de planilhas, automatizando a geração de relatórios de saída estruturados (como PDF, Excel ou CSV) com os resumos dos diagnósticos e suas respectivas fundamentações visuais.

2 FUNDAMENTAÇÃO

Este capítulo destina-se à fundamentação teórica que sustenta a pesquisa, conectando conceitos fundamentais ao problema proposto. O objetivo é estabelecer uma base sólida, com base na literatura científica consolidada, que conduza e valide o estudo. Nas seções a seguir, serão explorados os aspectos clínicos da doença, a evolução tecnológica na análise de dados em saúde e as abordagens computacionais escolhidas para o desenvolvimento do modelo preditivo.

2.1 O CÂNCER DE MAMA E A ANÁLISE MORFOLÓGICA


O termo câncer abrange um complexo conjunto de mais de cem doenças malignas que têm como denominador comum o crescimento desordenado e incontrolável das células. A base biológica dessa patologia reside na perda estrutural e funcional dos mecanismos de regulação celular. Esse processo de formação tumoral, cientificamente denominado carcinogênese ou oncogênese, é engatilhado quando o ácido desoxirribonucleico (DNA), a "memória química" que guarda as instruções das atividades celulares, sofre alterações críticas. Em condições normais, genes reguladores específicos chamados proto-oncogenes permanecem inativos; contudo, sob a ação de fatores cancerígenos cumulativos, eles sofrem mutações e são ativados, convertendo-se em oncogenes. Essa ativação desencadeia um processo lento e progressivo composto por três estágios: a *iniciação*, onde a célula sofre a alteração genética primária de forma silenciosa; a *promoção*, fase em que agentes externos ou internos transformam gradual e lentamente essa célula iniciada em uma estrutura maligna; e, por fim, a *progressão*, caracterizada pela multiplicação descontrolada e irreversível das células alteradas, culminando na consolidação clínica do tumor e em seu potencial de invasão (INCA, 2022b).

O tipo mais comum desta doença é classificado como carcinoma, uma nomeação atribuída aos tumores malignos que se originam nas células epiteliais, que são os tecidos responsáveis por revestir as superfícies internas e externas do corpo humano. Dependendo do tipo específico de célula epitelial afetada, o carcinoma recebe denominações distintas. No contexto anatômico do câncer de mama, a manifestação predominante é o adenocarcinoma, um subtipo que se desenvolve especificamente nas células epiteliais dos tecidos glandulares, cuja função biológica é produzir fluidos e muco (NCI, 2021).

No entanto, o desenvolvimento desse adenocarcinoma não ocorre de maneira instantânea, estruturando-se por meio de uma progressão morfológica gradual e microscopicamente rastreável. Inicialmente, o tecido mamário pode apresentar uma hiperplasia, caracterizada por um acúmulo de células que se multiplicam em um ritmo

acelerado, mas que ainda preservam rigorosamente sua aparência e arquitetura originais. Se a anomalia celular progredir para o estágio de displasia, além do acúmulo excessivo, as células perdem sua organização e começam a apresentar deformidades morfológicas evidentes. O ápice dessa fase pré-invasiva é denominado carcinoma *in situ* (frequentemente referido na literatura clínica como estágio 0). Neste limiar, as células já exibem características visualmente malignas em seus núcleos, mas ainda se encontram confinadas, pois não romperam as barreiras do tecido glandular original para invadir as áreas vizinhas (NCI, 2021). A diferença fundamental entre a biologia de um tecido saudável e o desenvolvimento anômalo gerado por essa cascata de mutações pode ser observada na Figura 1.

FIGURA 1 – Contraste morfológico entre células normais e neoplásicas.



FONTE: INCA, 2022c, Disponível em: <https://www.gov.br/inca/pt-br/assuntos/cancer/o-que-e-cancer>

Na ciência da computação aplicada à saúde, o dado mais valioso desta anomalia não é apenas a mutação genética em si, mas sim a profunda alteração morfológica que ela desencadeia. A pressão para sustentar uma replicação em massa e desordenada leva à deformação severa do núcleo de uma célula maligna. Como resultado, quando analisadas ao microscópio, estas células apresentam variações perceptíveis e quantificáveis na área, no raio, na textura e na concavidade, em comparação com uma célula saudável. São justamente essas assimetrias físicas que se tornam o insumo fundamental para alimentar e treinar algoritmos de aprendizagem de máquina. Estes algoritmos apoiam o diagnóstico preditivo.

Um dos marcos pioneiros na convergência entre a oncologia clínica e a ciência da computação, voltado especificamente para a quantificação dessas assimetrias celulares, é a base de dados *Breast Cancer Wisconsin (Diagnostic)*. No início dos anos 90, pesquisadores da Universidade de Wisconsin criaram esta base para reduzir a subjetividade e o cansaço que os humanos sentem quando analisam coisas ao microscópio (STREET *et al.*, 1993). O mais importante neste trabalho foi a decisão de não criar um armazém de imagens de doença com muitos pixels, que precisariam de muita capacidade de processamento, mas sim uma base de dados organizada e que não precisasse de muita capacidade de computação.

Para alcançar esse resultado, os pesquisadores utilizaram amostras coletadas via Punção Aspirativa por Agulha Fina (PAAF) e aplicaram algoritmos de processamento de imagem, conhecidos como contornos ativos (*snakes*), para delinear digitalmente as fronteiras dos núcleos celulares. A partir deste tratamento computacional, foram extraídas matematicamente dez características morfológicas essenciais de cada célula, incluindo o raio, a textura, o perímetro, a área e a suavidade. Ao calcular a média, o erro padrão e o valor máximo para cada uma dessas dez medidas, o sistema gerou as 30 variáveis numéricas que compõem o conjunto de dados. Esta otimização consolidou a base de Wisconsin como um recurso de referência na literatura, permitindo que os algoritmos preditivos processem informações oncológicas complexas de forma rápida e eficiente.

2.2 INTELIGÊNCIA ARTIFICIAL E MACHINE LEARNING: DEFINIÇÕES E HIERARQUIA

A Inteligência Artificial (IA) é uma área da ciência da computação que começou no verão de 1956, na conferência de Dartmouth, onde o termo foi criado. Desde então, a área evoluiu e ramificou-se em diversas vertentes de pesquisa. Segundo Russell e Norvig (2010), as definições históricas e contemporâneas de IA podem ser organizadas em quatro categorias principais, divididas entre abordagens que buscam simular o comportamento ou o pensamento humano, e abordagens focadas puramente no conceito de racionalidade. No contexto computacional moderno, a abordagem mais adotada e cientificamente rigorosa é a dos "agentes racionais", que são sistemas que operam de forma autônoma e agem para alcançar o melhor resultado possível diante de um problema, dado o conhecimento e as percepções que possuem do ambiente.


Para que um sistema alcance essa racionalidade em ambientes complexos, a programação de regras lógicas estáticas (*if-then*) torna-se inviável. É para solucionar esta limitação que surge o *Machine Learning* (ML), o principal subcampo da Inteligência Artificial. Em vez de serem explicitamente programados para executar uma tarefa passo a passo, os algoritmos de ML utilizam métodos estatísticos para extrair padrões diretamente dos dados. A definição formal mais consolidada na literatura é proposta por Mitchell (1997), que estabelece que um programa de computador aprende a partir da experiência E , em relação a uma classe de tarefas T e uma medida de desempenho P , se o seu desempenho em T , quantificado por P , melhora com a experiência E .

Para compreender essa definição de forma mais prática, pode-se estabelecer um paralelo com o aprendizado humano em jogos. A tarefa T representa o objetivo, como identificar tumores; a experiência E consiste nos dados históricos e exemplos fornecidos ao sistema (como a base de dados Wisconsin), e o desempenho P atua como a métrica de sucesso, indicando quantos diagnósticos a máquina acertou. O

algoritmo é considerado capaz de "aprender" quando, ao ser exposto a mais dados (maior E), ele aumenta sua taxa de acertos (maior P) ao realizar o diagnóstico (tarefa T).

A hierarquia da inteligência computacional estende-se ainda a camadas mais especializadas, como o *Deep Learning* (DL), ou Aprendizado Profundo. Essa vertente é um subconjunto do ML que utiliza arquiteturas de redes neurais artificiais com múltiplas camadas para processar volumes massivos de dados de altíssima complexidade dimensional. Essa relação hierárquica e de pertencimento entre os campos pode ser visualizada por meio de um diagrama de conjuntos, conforme ilustrado na Figura 2.

FIGURA 2 – Hierarquia e relação de inclusão entre IA, ML e DL.



FONTE: Richardson, 2022, Disponível em: <https://www.redhat.com/pt-br/blog/what-aiml-and-why-does-it-matter-your-business>

Essa estrutura demonstra que todo Aprendizado Profundo é uma forma de Aprendizado de Máquina, e todo Aprendizado de Máquina é uma aplicação de Inteligência Artificial. Para o escopo do diagnóstico preditivo oncológico proposto neste estudo, a construção do agente racional será fundamentada especificamente nas técnicas clássicas de *Machine Learning*, cujos paradigmas e mecânicas de avaliação serão detalhados a seguir.

2.3 MACHINE LEARNING: CONCEITOS E PARADIGMAS

O desenvolvimento de um modelo de IA não segue uma receita universal, a abordagem escolhida depende fundamentalmente da natureza dos dados disponíveis e do objetivo do problema. Na literatura clássica de *Machine Learning*, os algoritmos são categorizados em três grandes paradigmas de aprendizado: Não Supervisionado, Aprendizado por Reforço e Aprendizado Supervisionado. Como o escopo deste trabalho visa prever um diagnóstico clínico a partir de dados históricos previamente validados por

médicos patologistas, o referencial teórico e metodológico desta pesquisa concentra-se exclusivamente no paradigma do Aprendizado Supervisionado.

2.3.1 O Paradigma do Aprendizado Supervisionado e a Classificação Binária

O Aprendizado Supervisionado, que a literatura classifica como uma tarefa preditiva de aprendizagem indutiva, caracteriza-se sobretudo pela presença de um "gabarito" nos dados de treinamento. Neste paradigma, o algoritmo é alimentado com um conjunto de dados históricos contendo tanto as variáveis independentes de entrada, conhecidas como *features* ou atributos, quanto as suas respectivas variáveis dependentes de saída, os rótulos ou *labels*. O objetivo deste método é fazer com que o modelo descubra e mapeie a relação matemática entre as entradas e a saída. Dessa forma, ao aprender as regras ocultas que conectam as características observadas ao resultado final, o sistema torna-se capaz de generalizar esse conhecimento para realizar previsões automáticas quando exposto a novos dados não rotulados no futuro (FACELI *et al.*, 2011).

Em termos didáticos, o processo assemelha-se a um professor ensinando um aluno por meio de exemplos. O algoritmo analisa casos em que tanto o problema quanto a resposta correta são fornecidos simultaneamente. Após essa fase de treinamento, o modelo deve ser capaz de generalizar o conhecimento adquirido para prever a resposta correta quando apresentado a novos dados inéditos, que não possuem o rótulo.

Dentro do Aprendizado Supervisionado, Bishop (2006) divide os problemas de acordo com o tipo de resultado que se deseja alcançar. Quando o objetivo do modelo é organizar as informações recebidas em grupos bem definidos, a tarefa é chamada de problema de classificação. Por outro lado, se o sistema tenta prever um valor numérico contínuo, como estimar a expectativa de vida de um paciente ou calcular o rendimento de um processo químico, a tarefa recebe o nome de problema de regressão.

No contexto da oncologia e da base de dados *Breast Cancer Wisconsin*, a tarefa computacional se enquadra como um problema de Classificação Binária. Isso significa que a variável de saída que o modelo deve prever possui apenas dois estados: o tumor é Benigno ou Maligno (STREET *et al.*, 1993). Todo o esforço de treinamento e otimização dos algoritmos neste trabalho visa buscar a melhor fronteira de decisão matemática capaz de separar essas duas classes, minimizando ao máximo os erros de categorização, dada a criticidade de um falso diagnóstico médico.

2.3.2 O Dilema da Generalização e o Ciclo de Vida do Modelo

A construção de um classificador médico eficiente vai muito além do simples processamento numérico de dados históricos. O objetivo central de um modelo de aprendizado de máquina não é apenas memorizar os exemplos exatos que foram apre-

sentados durante o treinamento, mas sim desenvolver a capacidade de generalização. Ou seja, o sistema precisa aprender a regra geral para conseguir prever com precisão o diagnóstico de novos pacientes que nunca processou antes. Nesse processo de aprendizado, o algoritmo pode cometer dois erros estatísticos extremos: o *underfitting* e o *overfitting*.

O *underfitting* ocorre quando o modelo matemático é estruturalmente simples demais e não consegue capturar nem mesmo os padrões morfológicos básicos dos tumores. Nesse cenário, o algoritmo falha em extrair o conhecimento necessário e erra classificações fundamentais. No extremo oposto temos o *overfitting*, que é um risco estatístico muito mais comum e perigoso na área da saúde. Nesse caso, o modelo se torna tão complexo que passa a "decorar" não apenas as características reais do câncer, mas também as falhas, as exceções e os pequenos ruídos específicos daquela base de dados de treinamento. Consequentemente, o modelo atinge uma precisão artificialmente alta durante seu desenvolvimento, mas fracassa ao avaliar novos pacientes, pois apenas memorizou os dados antigos em vez de assimilar a lógica subjacente à doença (FACELI *et al.*, 2011).

Na estatística, essa linha tênue entre memorizar e generalizar é explicada pelo dilema viés e variância (*bias-variance tradeoff*). O viés representa a limitação estrutural do modelo em enxergar a complexidade dos dados reais, o que causa o *underfitting*. Já a variância mede o quanto o modelo altera sua fronteira de decisão de forma exagerada diante de pequenas mudanças nos dados, o que resulta no *overfitting*. Para garantir que o classificador encontre o equilíbrio estatístico perfeito e seja seguro para uso clínico, é obrigatório adotar um ciclo de vida rigoroso no qual a base de dados original nunca é entregue inteira de uma só vez ao algoritmo. Ela precisa ser metodologicamente dividida em subconjuntos separados (BISHOP, 2006).

Essa metodologia de divisão geralmente particiona os dados em três grupos: Treinamento, Validação e Teste. O conjunto de treinamento é o ambiente computacional primário, onde o algoritmo ajusta seus pesos e constrói suas regras de classificação. O conjunto de validação atua como um ambiente de aferição intermediária, permitindo que o desenvolvedor calibre os detalhes matemáticos do modelo e perceba rapidamente se o *overfitting* está ocorrendo. Por fim, o conjunto de teste representa o cenário do mundo real. Ele permanece totalmente isolado e oculto do computador durante todo o processo de desenvolvimento, sendo acionado apenas uma única vez na etapa final. O desempenho alcançado neste conjunto de teste isolado é o indicador soberano que comprova a verdadeira eficácia do sistema em acertar diagnósticos na prática médica.

2.3.3 Métricas de Avaliação de Desempenho

Após submeter o conjunto de teste ao algoritmo, é fundamental quantificar o seu desempenho clínico. Na classificação binária, a base para qualquer avaliação é a construção de uma Matriz de Confusão. Essa ferramenta organiza os resultados das previsões em quatro categorias possíveis. Os Verdadeiros Positivos representam os tumores malignos corretamente identificados, enquanto os Verdadeiros Negativos são os tumores benignos confirmados. Por outro lado, os erros são divididos em Falsos Positivos, que ocorrem quando um tumor benigno gera um alarme falso de malignidade, e Falsos Negativos, que acontecem quando o sistema ignora um tumor maligno e o classifica como inofensivo. Em um cenário oncológico, o falso negativo representa a falha mais crítica do modelo, pois resulta em um paciente doente que é liberado sem receber o tratamento adequado.

A métrica mais intuitiva extraída dessa matriz é a acurácia, que representa a taxa geral de acertos do modelo. Contudo, confiar exclusivamente na acurácia é um erro metodológico perigoso na área da saúde devido ao problema matemático das classes desbalanceadas. Considere uma situação onde a base de dados possui noventa e nove pacientes saudáveis para cada paciente com câncer. Se um algoritmo quebrado simplesmente classificar todas as pessoas do mundo como saudáveis, ele obterá uma acurácia de noventa e nove por cento. Apesar de parecer um sucesso estatístico absoluto, o modelo seria clinicamente inútil e letal para a pequena parcela de pacientes doentes (FACELI *et al.*, 2011).

Para contornar essa ilusão estatística, o desempenho deve ser avaliado por métricas específicas que observam os erros separadamente. A sensibilidade, também conhecida na literatura internacional como *recall*, mede a capacidade do algoritmo de rastrear e encontrar todos os pacientes que realmente estão doentes. Em paralelo, a precisão avalia a confiabilidade técnica do alerta, ou seja, de todos os tumores que o sistema afirmou serem malignos, qual proporção realmente era. Como frequentemente existe uma balança entre essas duas métricas, onde o aumento de uma pode diminuir a outra, utiliza-se a métrica *F1-score*. Esse indicador calcula a média harmônica entre a precisão e a sensibilidade, fornecendo um único número que atesta o equilíbrio e a segurança geral do classificador.

A avaliação final do modelo é consolidada visualmente pela Curva de Característica de Operação do Receptor, amplamente referenciada pela sigla em inglês ROC. Essa curva ilustra graficamente a relação entre a taxa de acertos em pacientes doentes e a taxa de alarmes falsos em pacientes saudáveis. Para resumir essa visualização em uma nota clara, calcula-se a área sob a curva, denominada métrica AUC. O valor da AUC varia de zero a um, sendo que um resultado igual a um indica um classificador estatisticamente perfeito, capaz de separar totalmente os tumores benignos dos malignos.

Por oferecer essa visão ampla do comportamento do modelo independentemente do equilíbrio dos dados, a AUC é considerada a métrica de ouro para comparar diferentes algoritmos oncológicos (FACELI *et al.*, 2011).

2.3.4 Principais Algoritmos Classificadores

Com a base de dados metodologicamente preparada e as métricas de avaliação estabelecidas, o desenvolvimento do sistema avança para o seu núcleo computacional: a escolha do algoritmo de classificação. O campo do aprendizado supervisionado dispõe de um vasto leque de modelos matemáticos, variando desde equações probabilísticas mais tradicionais até arquiteturas estruturalmente complexas. Embora todos esses algoritmos compartilhem o mesmo propósito central de traçar uma fronteira capaz de separar as células benignas das malignas, cada um deles interpreta os dados e resolve esse problema geométrico utilizando lógicas completamente distintas.

O modelo de base mais clássico na modelagem estatística em saúde é a Regressão Logística. Apesar do nome referenciar problemas contínuos, trata-se de um classificador probabilístico. Ele atua calculando uma combinação linear das características da célula, como o seu raio e a sua textura, e aplica esse resultado numérico em uma função matemática chamada sigmoide. Essa função comprime qualquer valor para um intervalo estrito entre zero e um, fornecendo diretamente a probabilidade de o tumor ser maligno. Se essa probabilidade exceder um limiar de corte, o sistema consolida o diagnóstico positivo. A sua adoção contínua na prática clínica decorre da transparência da equação, permitindo que o médico entenda o peso exato de cada variável na decisão final (BISHOP, 2006).

Quando a dispersão entre as características de células benignas e malignas apresenta uma distribuição complexa que não pode ser separada por uma linha reta simples, a computação recorre às Máquinas de Vetores de Suporte, frequentemente referenciadas pela sigla SVM. O objetivo primário deste algoritmo é encontrar uma fronteira de decisão geométrica, denominada hiperplano, que consiga separar as duas classes de tumores garantindo a maior margem de segurança possível entre elas. Os vetores de suporte, que dão nome ao modelo, são justamente os dados dos pacientes que estão posicionados de forma mais arriscada, ou seja, mais próximos a essa fronteira crítica. Eles atuam como os pilares estruturais que sustentam e definem o formato da decisão final do algoritmo (BISHOP, 2006).

Entretanto, nos problemas oncológicos reais, é muito comum que os dados das células estejam sobrepostos, configurando um cenário não linear. Para solucionar essa limitação e viabilizar a classificação, o SVM utiliza uma operação matemática sofisticada conhecida como truque de *kernel*. Conforme detalhado por AI Online Course (2023), o *kernel* atua como uma função de mapeamento que eleva os dados originais

de um espaço de baixa dimensão para um espaço de dimensão superior. Nessa nova perspectiva matemática ampliada, as células malignas e benignas que antes pareciam misturadas passam a se afastar, tornando-se linearmente separáveis por um hiperplano. Existem diversas funções capazes de realizar essa transformação geométrica, sendo o *kernel* Polinomial e o *kernel* Gaussiano RBF os mais utilizados na prática para garantir que o algoritmo se adapte perfeitamente à complexidade biológica do câncer.

Outra abordagem geométrica muito intuitiva para a classificação é o algoritmo KNN (*K-Nearest Neighbors*). Diferente dos modelos que processam os dados para construir uma equação fixa durante o treinamento, o KNN adota um método de aprendizado baseado em instâncias. Na prática, ele memoriza todo o conjunto de dados históricos de tumores. Quando os dados de um novo paciente são inseridos no sistema, o algoritmo calcula a distância matemática espacial, como a distância Euclidiana, entre as características dessa nova célula e todas as células antigas já armazenadas. O sistema então identifica os "K" vizinhos mais próximos, ou seja, os exames históricos que possuem as medidas anatômicas mais idênticas ao caso atual. O diagnóstico preditivo é determinado por uma votação simples nessa vizinhança. Se a maioria dos tumores vizinhos for maligna, o novo caso será classificado como maligno. A sua aplicação em sistemas médicos destaca-se pela facilidade de interpretação espacial por parte do profissional de saúde, embora o esforço computacional para calcular essas distâncias aumente consideravelmente em bases de dados muito volumosas (FACELI *et al.*, 2011).

Explorando uma abordagem fundamentada em regras lógicas sucessivas, surgem os algoritmos baseados em Árvores de Decisão. Uma árvore individual funciona como um fluxograma hierárquico, testando condições passo a passo para classificar a célula oncológica. A matemática que define qual pergunta deve ser feita primeiro baseia-se frequentemente no critério de entropia, um conceito oriundo da teoria da informação que mede o grau de desordem ou impureza de um grupo de dados. Em cada etapa do fluxograma, o algoritmo calcula qual característica celular, como o raio ou a simetria, é capaz de dividir os pacientes de modo a reduzir ao máximo essa entropia. O objetivo é criar ramificações onde os tumores fiquem cada vez mais organizados e separados em suas classes puras. Contudo, quando crescem sem limites estritos, árvores de decisão isoladas tornam-se extremamente suscetíveis ao *overfitting* (FACELI *et al.*, 2011).

Para sanar essa vulnerabilidade da árvore única, a estatística computacional recorre à técnica *Random Forest*, ou Floresta Aleatória. Este modelo opera sob o paradigma de comitês de máquinas, criando grandes quantidades de árvores de decisão simultâneas de forma paralela. Para garantir que as árvores não tomem decisões idênticas, o algoritmo força uma diversidade matemática ao treinar cada uma delas com um subconjunto aleatório de pacientes e características. Ao submeter

os dados de um novo exame ao modelo, o diagnóstico final não é imposto por uma única regra, mas determinado por uma votação majoritária entre todas as árvores que compõem a floresta. Essa dinâmica de sabedoria coletiva dilui os erros de árvores individuais e gera um sistema preditivo altamente estável e protegido contra anomalias (FACELI *et al.*, 2011).

Ainda dentro do paradigma de comitês de máquinas, destaca-se o *Extreme Gradient Boosting*, amplamente conhecido no mercado como *XGBoost*. Ao contrário da floresta aleatória que constrói todas as suas árvores de forma simultânea e independente, este algoritmo adota uma arquitetura sequencial focada no aprendizado com os próprios erros. A primeira árvore tenta classificar os tumores e inevitavelmente comete equívocos. A segunda árvore é construída com o propósito exclusivo de corrigir os erros da primeira, a terceira foca nos erros da segunda, e assim sucessivamente. Essa otimização contínua baseada na descida do gradiente cria um modelo preditivo de altíssima performance (FACELI *et al.*, 2011).

No ápice da complexidade arquitetônica encontram-se as Redes Neurais Artificiais, algoritmos inspirados no funcionamento biológico do cérebro humano. Elas são compostas por múltiplas camadas de neurônios matemáticos interconectados, capazes de extrair relacionamentos profundos ocultos nos dados oncológicos (BISHOP, 2006). Entretanto, essa evolução tecnológica impõe um grave dilema clínico. À medida que a ciência avança da transparente Regressão Logística para as poderosas redes neurais e algoritmos sequenciais como o *XGBoost*, o modelo ganha acurácia estatística, mas perde drasticamente a sua interpretabilidade, transformando-se em uma caixa preta inescrutável. Na prática médica, entregar uma predição isolada não é eticamente aceitável, pois o oncologista necessita compreender as justificativas celulares do sistema. É exatamente para romper essa barreira analítica e resgatar a transparência das decisões que a Inteligência Artificial Explicável se torna indispensável.

2.4 O PROBLEMA DA "CAIXA PRETA" E INTELIGÊNCIA ARTIFICIAL EXPLICÁVEL (XAI)

Definir o que é XAI e diferenciar modelos explicáveis (intrínsecos) de técnicas de pós-hoc. Discutir a importância da interpretabilidade na medicina, especialmente em oncologia, onde decisões clínicas críticas dependem da confiança no modelo. Explicar o dilema da "caixa preta": modelos complexos (como redes neurais profundas) oferecem alta acurácia, mas não fornecem explicações sobre o processo de decisão, o que é problemático para a adoção clínica.

2.5 SHAP (SHAPLEY ADDITIVE EXPLANATIONS)

Explicar a origem do SHAP na teoria dos jogos cooperativos, onde o valor de Shapley é usado para atribuir a contribuição de cada jogador (variável) para o resultado final. No contexto de Machine Learning, o SHAP quantifica a importância de cada característica na predição do modelo, permitindo uma interpretação local (para uma instância específica) e global (para o modelo como um todo). Discutir as vantagens do SHAP em relação a outras técnicas de explicabilidade, como LIME, e sua aplicabilidade em modelos complexos.

2.6 REDUÇÃO DE DIMENSIONALIDADE E UMAP

Explicar o conceito de redução de dimensionalidade como uma técnica para simplificar dados de alta dimensão, preservando suas características essenciais. O UMAP é um algoritmo de redução de dimensionalidade que se destaca por sua capacidade de preservar a estrutura global e local dos dados, facilitando a visualização e a identificação de padrões, como agrupamentos (clusters) e anomalias (outliers). Discutir a importância do UMAP na análise exploratória de dados, especialmente em contextos onde a separabilidade natural dos dados é crucial para a interpretação dos resultados.

3 ORGANIZAÇÃO DO TRABALHO

Este capítulo apresenta as principais seções de um trabalho acadêmico, discute a hierarquia de seções e fornece exemplos de como implementar a sua organização. A organização de um trabalho acadêmico é um ponto fundamental para garantir a clareza e a estrutura lógica do texto (SEVERINO, 2007).

Normalmente, um trabalho acadêmico possui a seguinte divisão de capítulos:

- a) Introdução: estabelece o contexto do trabalho e apresenta o problema de pesquisa;
- b) Fundamentação teórica: explora os conceitos e teorias que embasam a pesquisa, proporcionando uma base teórica para a compreensão do tema;
- c) Revisão da Literatura: analisa e discute estudos anteriores relacionados ao tema, identificando lacunas que a pesquisa busca preencher;
- d) Metodologia: descreve os métodos e técnicas utilizados para conduzir a pesquisa, permitindo a reprodução do estudo por outros pesquisadores;
- e) Resultados Experimentais: apresenta e analisa os dados obtidos durante a pesquisa, evidenciando os achados e sua relevância para o tema investigado;
- f) Conclusão: resume os principais resultados, discute suas implicações, e sugere direções para futuras pesquisas ou aplicações práticas.

A organização adequada de um trabalho acadêmico não apenas melhora a legibilidade, mas também facilita a navegação pelo documento. O uso correto dos comandos de seção, subseção e subsubseção ajuda a estruturar o conteúdo de forma lógica e coesa, orientando o leitor através dos diferentes tópicos abordados. Além disso, a numeração automática das seções e subseções torna o trabalho mais profissional e alinhado às normas acadêmicas (GIL, 2008).

4 CITAÇÃO

Este capítulo apresenta os principais tipos de citação empregados em trabalhos acadêmicos, detalhando suas características e a importância de sua correta aplicação para fundamentar teoricamente a pesquisa. Citações diretas e indiretas são essenciais para a construção de uma argumentação sólida, e o uso de ferramentas como o BibTeX facilita a organização e padronização das referências bibliográficas. Ao final, são discutidas as melhores práticas para citação de livros, artigos, capítulos de livros, teses, dissertações e fontes online, com vistas à preservação da integridade acadêmica.

4.1 TIPOS DE CITAÇÕES

As citações são classificadas em dois tipos principais: (1) diretas e (2) indiretas, sendo ambas complementares no desenvolvimento da argumentação e fundamentação teórica de um trabalho.

4.1.1 Citação Direta

A citação direta consiste na reprodução literal das palavras de um autor. Segundo Gil (GIL, 2008), ela é utilizada quando se deseja destacar uma formulação precisa ou quando o uso exato das palavras é fundamental para a compreensão do argumento. No entanto, seu uso deve ser comedido e sempre referenciado adequadamente.

As citações diretas curtas podem ser inseridas com aspas e acompanhadas da devida referência, como demonstrado: “O conhecimento científico é sistemático e controlado” (GIL, 2008). Quando a citação excede três linhas, deve ser formatada em bloco, sem aspas, como no exemplo a seguir:

O conhecimento científico é um conhecimento crítico, que tenta resolver os problemas que surgem em sua busca pela compreensão dos fenômenos, submetendo suas hipóteses e teorias a rigorosos testes de falseabilidade (GIL, 2008).

Por se tratar de uma reprodução exata, a citação direta deve preservar a ortografia, a pontuação e o uso de maiúsculas do texto original. Qualquer alteração ou omissão no texto original deve ser indicada com colchetes. Mesmo os erros presentes no texto original não devem ser corrigidos (UNIVERSIDADE TUIUTI DO PARANÁ, 2024). Para isso, algumas convenções são seguidas, como:

- a) [...]: indica a omissão de parte do texto original;
- b) [sic]: sinaliza um erro ou incoerência no texto original, significando "assim mesmo";

- c) [grifo meu], [grifo nosso], [sem grifo no original]: utilizados quando o autor que cita adiciona ênfase (negrito, sublinhado, etc.) que não estava no texto original;
- d) [grifo do autor]: indica que o grifo já fazia parte do texto original citado;
- e) Alterações ou comentários feitos na citação direta devem ser incluídos entre colchetes: [].

Citações em idiomas estrangeiros devem ser traduzidas, acompanhadas da devida referência. Quando a tradução for feita pelo próprio autor do trabalho, deve-se incluir a nota “tradução do autor(a)” e a versão original pode ser inserida como nota de rodapé. No entanto, em textos de caráter literário, é comum manter o idioma original, especialmente quando a tradução poderia comprometer o estilo ou a análise literária (LEITE, 2003; UNIVERSIDADE TUIUTI DO PARANÁ, 2024).

4.1.2 Citação Indireta

A citação indireta ocorre quando as ideias de outro autor são parafraseadas ou resumidas. Essa prática permite ao autor integrar diferentes perspectivas em seu próprio raciocínio. Segundo Creswell (2014), a citação indireta é uma ferramenta importante para articular múltiplas fontes e construir uma análise mais crítica. As citações indiretas podem ser feitas de duas maneiras: (1) explícitas ou (2) implícitas.

No caso da citação explícita, o nome do autor é mencionado no texto usando o comando `\citeonline`, como no exemplo a seguir. De acordo com Creswell (2014), a pesquisa qualitativa depende de um processo interpretativo contínuo.


Já na citação indireta implícita, as ideias de um ou mais autores são sintetizadas e as citações são incluídas ao final da frase ou parágrafo usando o comando `\cite`. as referências são inseridas ao final do parágrafo ou frase, sem menção direta ao autor no texto, como a seguir. A pesquisa qualitativa envolve um processo de reflexão constante e interpretação dos dados (CRESWELL, 2014).

4.1.3 Citação de Fonte

Ao utilizar figuras ou tabelas de outras fontes, ou até mesmo do próprio autor, é fundamental dar o devido crédito à fonte original. Isso garante o reconhecimento adequado do trabalho original e evita problemas de plágio. A citação da fonte de figuras e tabelas pode ser feita de maneira semelhante à citação de textos, usando o comando `\fonte`. A Figura 3 ilustra como as fontes devem ser citadas (UNIVERSIDADE TUIUTI DO PARANÁ, 2024).

O Código 1 exemplifica como que os diferentes tipos de fontes devem ser incluídos no código para adequação às normas técnicas.

FIGURA 3 – Exemplo de citação de fontes.



FONTE: Universidade Tuiuti do Paraná, 2024, p. 23

CÓDIGO 1 – Diferentes tipos de citação em fontes.

```

1 % Citação de autor
2 \fonte{\citeauthoronline{autor}, \citeyear{autor}, p. 99}
3
4 % Citação de autor-entidade
5 \fonte{\citeauthoronline{entidade}, \citeyear{entidade}, p. 105}
6
7 % Citação de site
8 \fonte{\citeauthoronline{site}, \citeyear{site}, Disponível em: \url{...}}
9
10 % Citação de autoria própria
11 \fonteautor % ou \fonteautora
12 \fonteautores % ou \fonteautoras
13 \fonteautoria

```

FONTE: O autor

4.2 DIFERENTES TIPOS DE REFERÊNCIAS

Além de conhecer os tipos de citação, é importante dominar os diversos formatos de referências utilizados em diferentes tipos de publicações. O uso do BibTeX permite automatizar a formatação dessas referências, garantindo padronização. A seguir, são apresentados os formatos para as principais fontes acadêmicas.

4.2.1 Livros

Referências de livros são amplamente utilizadas na fundamentação teórica, pois oferecem uma visão geral e detalhada sobre os conceitos e teorias fundamentais de uma área de estudo. Elas são essenciais para embasar o desenvolvimento dos argumentos do autor. A referência de livro pode ser inserida no arquivo BibTeX conforme apresentado no Código 2.

CÓDIGO 2 – Estrutura BibTeX para citação de um livro.

```

1  @book{autor,
2      author    = {Sobrenome, Nome},
3      title     = {Título do Livro},
4      edition   = {Edição},
5      publisher = {Editora},
6      year      = {Ano},
7      pages     = {Número de Páginas}
8      address   = {Local de Publicacao}
9  }
```

FONTE: O autor

4.2.2 Artigos de Periódicos

Artigos científicos publicados em periódicos são uma fonte de informação atualizada e focada em tópicos específicos. Em um trabalho acadêmico, esses artigos são essenciais para manter a pesquisa em sintonia com as discussões mais recentes na área, e, por isso, sua correta citação é de extrema importância. A entrada BibTeX para artigos de periódicos é descrita no Código 3.

CÓDIGO 3 – Estrutura BibTeX para citação de um artigo de periódico.

```

1  @article{autor,
2      author    = {Sobrenome, Nome},
3      title     = {Título do Artigo},
4      journal   = {Nome do Periódico},
5      volume    = {Volume},
6      number    = {Número},
7      pages     = {Páginas},
8      year      = {Ano}
9  }
```

FONTE: O autor

4.2.3 Capítulos de Livros

Muitas vezes, é necessário citar apenas um capítulo de um livro organizado por diversos autores. Isso ocorre quando o capítulo em questão é escrito por um autor diferente do editor do livro, ou quando se deseja dar destaque a uma seção específica da obra. Isto pode ser feito utilizando a estrutura apresentada no Código 4.

4.2.4 Tese de Doutorado

Teses de doutorado são referências relevantes em muitas áreas, especialmente porque contêm contribuições originais de pesquisa. Elas são uma fonte importante de

CÓDIGO 4 – Estrutura BibTeX para citação de um capítulo de livro.

```

1 @incollection{autor,
2   author    = {Sobrenome, Nome},
3   title     = {Título do Capítulo},
4   booktitle = {Título do Livro},
5   publisher = {Editora},
6   year      = {Ano},
7   address   = {Local de Publicação},
8   pages     = {Páginas do Capítulo}
9 }

```

FONTE: O autor

conhecimento atualizado e inédito. A estrutura de citação para uma tese de doutorado em BibTeX pode ser vista no Código 5.

CÓDIGO 5 – Estrutura BibTeX para citação de uma tese de doutorado.

```

1 @phdthesis{autor,
2   author = {Sobrenome, Nome},
3   title  = {Título da Tese},
4   school = {Nome da Universidade},
5   year   = {Ano},
6   address = {Local da Universidade}
7 }

```

FONTE: O autor

4.2.5 Dissertação de Mestrado

As dissertações de mestrado, assim como as teses de doutorado, são fundamentais para a pesquisa científica, por apresentarem investigações originais ou revisões aprofundadas de temas específicos. A estrutura para citar uma dissertação de mestrado é semelhante à de teses, como mostrado no Código 6.

CÓDIGO 6 – Estrutura BibTeX para citação de uma dissertação de mestrado.

```

1 @mastersthesis{autor,
2   author = {Sobrenome, Nome},
3   title  = {Título da Dissertação},
4   school = {Nome da Universidade},
5   year   = {Ano},
6   address = {Local da Universidade},
7   type   = {Dissertação de Mestrado}
8 }

```

FONTE: O autor

4.2.6 Monografia de Graduação

Monografias de graduação são trabalhos acadêmicos exigidos para a conclusão de cursos de graduação e podem ser relevantes como base de estudos introdutórios ou revisões bibliográficas. Para citá-las, o formato é apresentado no Código 7 e é similar à de dissertações.

CÓDIGO 7 – Estrutura BibTeX para citação de uma monografia de graduação.

```

1  @mastersthesis{autor,
2      author   = {Sobrenome, Nome},
3      title    = {Título da Monografia},
4      school   = {Nome da Universidade},
5      year     = {Ano},
6      address  = {Local da Universidade},
7      type     = {Monografia de Graduação}
8  }
```

FONTE: O autor

4.2.7 Conferências

Artigos apresentados em conferências acadêmicas também podem ser relevantes para a fundamentação teórica, principalmente em áreas de pesquisa emergentes. Esses artigos são revisados por pares e muitas vezes discutem temas inovadores. O Código 8 apresenta o formato de citação BibTeX de um artigo de conferência.

CÓDIGO 8 – Estrutura BibTeX para citação de um artigo de conferência.

```

1  @inproceedings{autor,
2      author   = {Sobrenome, Nome},
3      title    = {Título do Artigo},
4      booktitle = {Anais da Conferência},
5      year     = {Ano},
6      address  = {Local da Conferência},
7      pages    = {Páginas},
8      volume   = {Volume},
9      number   = {Número}
10 }
```

FONTE: O autor

4.2.8 Sites

Sites também podem ser utilizados como fontes em pesquisas acadêmicas, desde que sejam confiáveis e possuam relevância no contexto da pesquisa. O uso de fontes *online* é comum em pesquisas que abordam temas emergentes ou questões

práticas. A citação de sites deve incluir a data de acesso, como mostrado no Código 9, uma vez que conteúdos online podem ser modificados.

CÓDIGO 9 – Estrutura BibTeX para citação de um site.

```

1  @online{pagina,
2      author      = {Autor},
3      organization = {Organização},
4      title       = {Título},
5      year        = {Ano},
6      url         = {URL da página},
7      urlaccessdate = {05 out. 2024}
8  }
```

FONTE: O autor

A citação de verbetes da Wikipédia devem ser realizados conforme apresentado no Código cod:bibtex-wiki. A citação será referenciada como apresentado em Machine... (2024).

CÓDIGO 10 – Estrutura BibTeX para citação de um artigo na Wikipédia.

```

1  @inbook{wikipedia,
2      title      = {Machine Learning},
3      publisher   = {Wikimedia},
4      booktitle   = {Wikip\`edia: a enciclop\`edia livre},
5      year        = {2024},
6      url         = {https://en.wikipedia.org/wiki/Machine_learning},
7      urlaccessdate = {05 out. 2024}
8  }
```

FONTE: O autor

4.3 CONSIDERAÇÕES FINAIS

A fundamentação teórica é a espinha dorsal de qualquer trabalho acadêmico, uma vez que é por meio dela que o autor constrói o suporte necessário para desenvolver suas ideias e hipóteses. O uso correto das citações e a inclusão de fontes confiáveis e pertinentes são fundamentais para assegurar a qualidade e a credibilidade da pesquisa.

5 ILUSTRAÇÕES E GRÁFICOS

Este capítulo aborda o uso adequado de figuras e subfiguras em trabalhos acadêmicos, além de orientações sobre a inserção e formatação de gráficos. O uso de elementos visuais, como figuras e gráficos, é essencial para a clareza da apresentação de dados e conceitos. Em pesquisas que demandam a comunicação visual de resultados, esses elementos complementam a argumentação textual e auxiliam na compreensão do conteúdo (TUFTE, 1990).

5.1 FIGURAS

A inserção de figuras é feita utilizando o ambiente `figure`, que, em conjunto com o comando `\fig`, permite a incorporação de imagens no documento. Cada figura deve ser acompanhada de uma legenda explicativa e, preferencialmente, ser referenciada no corpo do texto para que o leitor possa localizá-la facilmente (KNUTH, 1984). O Código 11 apresenta o exemplo de inserção de uma figura.

CÓDIGO 11 – Código para inclusão de uma figura no texto.

```
1 \begin{figure}[htb]
2   \legenda[fig:figura]{Legenda da figura}
3   \fig{width=0.7\textwidth}{imagens/exemplo.png}
4   \fonteautor
5 \end{figure}
```

FONTE: O autor

A Figura 4 mostra um exemplo de figura usando os comandos do Código 11.

FIGURA 4 – Exemplo de figura.



THE BEST THESIS DEFENSE IS A GOOD THESIS OFFENSE.

FONTE: XKCD, 2024b, Disponível em: <https://xkcd.com/1403/>

No Código 11, a imagem é centralizada e redimensionada para 70% da largura do texto. A legenda da figura é definida pelo comando `\legenda`, e o rótulo é definido pelo parâmetro opcional (definido pelos colchetes). O rótulo permite que a figura seja referenciada no texto, como em “veja a Figura 4”.

O parâmetro “[htb]” indica as preferências de posicionamento da figura: “h” para o local exato do código, “t” para o topo da página, e “b” para a parte inferior (GOOSSENS *et al.*, 1997).

5.2 SUBFIGURAS

As subfiguras são recomendadas em situações onde é necessário inserir múltiplas imagens agrupadas. Elas permitem organizar várias imagens em uma única figura, cada uma com sua legenda individual. Os comandos `\sfig` e `\lfig` podem ser utilizados para facilitar esse processo. O exemplo de código para inserção de subfiguras é apresentado no Código 12.

CÓDIGO 12 – Código para inclusão de três subfiguras no texto.

```

1  \begin{figure}[htb]
2    \legenda[fig:subfigura]{Exemplo de varias subfiguras}
3    % Linha 1: Figuras simples com label
4    \sfig[sfig:fig1]{scale=0.3}{imagens/fig1}\hfil
5    \sfig[sfig:fig2]{scale=0.3}{imagens/fig2}
6    % Linha em branco move as próximas subfiguras para a linha seguinte
7
8    % Linha 2: Figuras simples sem label
9    \sfig{scale=0.3}{imagens/fig1}\hfil
10   \sfig{scale=0.3}{imagens/fig2}
11
12   % Linha 3: Figuras com legenda e com label
13   \lfig[lfig:fig1]{scale=0.3}{imagens/fig1}{legenda 1}\hfil
14   \lfig[lfig:fig2]{scale=0.3}{imagens/fig2}{legenda 2}
15
16   % Linha 3: Figuras com legenda e sem label
17   \lfig{scale=0.3}{imagens/fig1}{legenda 1}\hfil
18   \lfig{scale=0.3}{imagens/fig2}{legenda 2}
19   \fonteautor
20 \end{figure}

```

FONTE: O autor

No Código 12, três subfiguras são organizadas em uma linha, com espaçamento entre elas proporcionado pelo comando `\hfill`. As subfiguras podem ser referenciadas individualmente, como “veja a Subfigura 5a”, ou em conjunto, como na “veja a Figura 5”. Esse recurso é útil quando se deseja comparar diferentes imagens de maneira simultânea (GOOSSENS *et al.*, 1997).

A Figura 5 apresenta um exemplo composição de subfiguras usando o comando `\sfig`. Neste exemplo, todas as subfiguras foram organizadas em apenas uma linha.

FIGURA 5 – Exemplo de subfiguras simples.



FONTE: Nintendo, 2024, Disponível em: <https://www.nintendo.com>

O comando `\lfig` deve ser utilizado quando for necessária a inclusão de legendas explicativas para cada uma das subfiguras. Este comando recebe um terceiro parâmetro que é a legenda referente a subfigura. A Figura 6 mostra um exemplo usando este comando. Ambos os comandos podem ser combinados em uma mesma composição dentro do ambiente `figure`.

FIGURA 6 – Exemplo de subfiguras com legendas individuais.



FONTE: Nintendo, 2024, Disponível em: <https://www.nintendo.com>

5.3 GRÁFICOS

A inserção de gráficos segue os mesmos princípios da inserção de figuras. O ambiente `grafico` é utilizado para acomodar gráficos gerados a partir de softwares de plotagem de dados ou imagens externas (MITTELBACH *et al.*, 2004). O Código 13 apresenta um exemplo de inserção de gráfico e o Gráfico 1 mostra o resultado do código.

CÓDIGO 13 – Código para inclusão de um gráfico no texto.


```

1 \begin{grafico}[htb]
2   \legenda[fig:grafico]{Legenda do grafico}
3   \fig{width=0.7\textwidth}{imagens/exemplo.png}
4   \fonteautor
5 \end{grafico}

```

FONTE: O autor

GRÁFICO 1 – Exemplo de gráfico.



FONTE: XKCD, 2024a, Disponível em: <https://xkcd.com/1945/>

Gráficos são recursos visuais valiosos para a representação de dados quantitativos e a comunicação clara de tendências ou padrões observados durante a pesquisa. Assim como nas figuras, é importante que os gráficos sejam acompanhados de legendas claras e referenciados no corpo do texto (TUFTE, 1990).

5.4 CONSIDERAÇÕES FINAIS

O uso adequado de figuras, subfiguras e gráficos em trabalhos acadêmicos é fundamental para uma comunicação visual eficiente. Esses elementos não apenas ilustram os conceitos discutidos, mas também ajudam a sintetizar e evidenciar os resultados da pesquisa. Quando bem utilizados, eles aumentam a clareza e a coesão do trabalho, facilitando a compreensão pelo leitor (TUFTE, 1990; KNUTH, 1984).

6 TABELAS E QUADROS

Este capítulo aborda as técnicas de criação de tabelas e quadros, com a distinção de seus usos e estruturas. A apresentação organizada de dados é fundamental em trabalhos acadêmicos, e tanto as tabelas quanto os quadros desempenham um papel essencial na comunicação clara e precisa das informações. Contudo, eles diferem na natureza e no tipo de dado que apresentam.

6.1 DIFERENÇA ENTRE TABELAS E QUADROS

Embora os termos “tabela” e “quadro” sejam muitas vezes usados de forma intercambiável, há distinções claras entre esses elementos no contexto acadêmico. Tabelas são utilizadas principalmente para exibir dados quantitativos de forma estruturada, facilitando comparações entre diferentes valores ou categorias. Por outro lado, quadros organizam informações qualitativas, como definições ou classificações de conceitos, sendo mais descritivos e menos focados em dados numéricos (Associação Brasileira de Normas Técnicas, 2018).

Assim, enquanto as tabelas proporcionam uma apresentação visual de dados comparativos ou numéricos, os quadros são apropriados para descrever ou categorizar informações qualitativas, o que evidencia a diferença fundamental entre ambos (CHAGAS *et al.*, 2016).

6.2 TABELAS

As tabelas são criadas utilizando-se os ambientes `table` e `tabular`. O primeiro define o posicionamento e a legenda, enquanto o segundo organiza o conteúdo em linhas e colunas. O Código 14 apresenta uma tabela com quatro colunas, com diferentes tipos de alinhamento: fixo com 3cm (p), à esquerda (l), centralizado (c) e à direita (d). A Tabela 1 apresenta o resultado da tabela descrita no código.

TABELA 1 – Exemplo de uma tabela.

Nome	Idade	Prova	Trabalhos
Joao	24	8,5	4,8
Maria	20	9,0	7,1
Pedro	22	4,8	9,9

FONTE: O autor

CÓDIGO 14 – Código para criação de uma tabela.

```

1 \begin{table}[htb]
2   \centering
3   \legenda[tab:tabela]{Exemplo de uma tabela}
4   \begin{tabular}{p{3cm}lcr}
5     \toprule
6     \textbf{Nome} & \textbf{Idade} & \textbf{Prova} & & \\
7     \midrule
8     \midrule
9     Joao      & 24 & 8,5 & 4,8 & \\
10    Maria     & 20 & 9,0 & 7,1 & \\
11    Pedro     & 22 & 4,8 & 9,9 & \\
12    \bottomrule
13  \end{tabular}
14  \fonteautor
15 \end{table}

```

FONTE: O autor

6.3 QUADROS

Quadros, por sua vez, são mais adequados para a organização de informações qualitativas, sendo amplamente utilizados para categorizações ou descrições. Embora utilizem a mesma estrutura básica de uma tabela, sua função é distinta. O Código 15 mostra um exemplo de quadro no qual são categorizados tipos de pesquisa, e o Quadro 1 mostra o resultado deste código.

CÓDIGO 15 – Código para criação de um quadro.

```

1 \begin{quadro}[htb]
2   \centering
3   \legenda[tab:quadro]{Exemplo de Quadro com tipos de pesquisa}
4   \begin{tabular}{|l|p{9cm}|}
5     \hline
6     \textbf{Tipo de Pesquisa} & \textbf{Descrição} \\
7     \hline\hline
8     Pesquisa Exploratória & Investigação inicial sobre um fenômeno, \\
9     sem hipóteses definidas & \\
10    Pesquisa Descritiva & Caracterização detalhada de um fenômeno, \\
11    com hipóteses exploradas & \\
12    Pesquisa Explicativa & Busca identificar as causas de um \\
13    fenômeno & \\
14  \end{tabular}
15  % Fix para ajustar a distancia da fonte (apenas para quadros)
16  \vspace{0.2cm}
17  \fonteautor
18 \end{quadro}

```

FONTE: O autor

QUADRO 1 – Exemplo de Quadro com tipos de pesquisa.

Tipo de Pesquisa	Descrição
Pesquisa Exploratória	Investigação inicial sobre um fenômeno, sem hipóteses definidas
Pesquisa Descritiva	Caracterização detalhada de um fenômeno, com hipóteses exploradas
Pesquisa Explicativa	Busca identificar as causas de um fenômeno

FONTE: O autor

O posicionamento de tabelas e quadros é controlado por meio de argumentos opcionais nos ambientes `table` e `quadro`. As opções mais comuns incluem:

- a) `h` (*here*): posiciona o objeto o mais próximo possível do ponto onde foi inserido no código;
- b) `t` (*top*): coloca o objeto no topo da página;
- c) `b` (*bottom*): coloca o objeto na parte inferior da página;
- d) `p` (*page of floats*): insere o objeto em uma página dedicada apenas a elementos flutuantes, como tabelas e figuras.

Por exemplo, o argumento `[htb]`, utilizado nos Códigos 14 e 15, permite posicionar a tabela “aqui” (*here*), mas com a flexibilidade de movê-la para o topo (*top*) ou parte inferior (*bottom*) da página, se necessário.

6.4 CONSIDERAÇÕES FINAIS

A correta utilização de tabelas e quadros é essencial para a apresentação organizada de dados e informações em trabalhos acadêmicos. Tabelas são mais apropriadas para dados quantitativos, enquanto quadros são utilizados para informações qualitativas e descritivas. A aplicação adequada desses elementos contribui significativamente para a clareza e profissionalismo do trabalho, facilitando a leitura e interpretação dos dados apresentados (KNUTH, 1984).

7 CÓDIGOS E ALGORITMOS

Este capítulo apresenta o uso de algoritmos e trechos de código, abordando desde a inclusão básica até a personalização de estilos e numeração. A formatação clara e precisa de algoritmos e códigos é fundamental em áreas como ciência da computação, matemática e engenharias, onde a transparência dos métodos e a reprodutibilidade são essenciais para a validade dos resultados apresentados (KNUTH, 1984).

7.1 INCLUSÃO DE CÓDIGOS

Para incluir códigos de programação, o pacote mais comum é o `listings`. Esse pacote suporta várias linguagens de programação e permite a personalização do estilo de exibição, incluindo o realce de sintaxe, a numeração de linhas e a adição de comentários. O ambiente `codigo` formata a posição do código e localização da legenda e da fonte.

O Código 16 apresenta um exemplo de código para inclusão de códigos-fonte e o Código 17 mostra o código renderizado. Este código implementa uma função recursiva em Python para calcular o fatorial de um número. A sintaxe da linguagem Python é destacada automaticamente e o código é numerado.

CÓDIGO 16 – Código para inclusão de códigos-fonte.

```

1 \begin{codigo}[htb]
2   \legenda[cod:codigo]{Código para inclusão de códigos-fonte}
3   \begin{lstlisting}[language=Python]
4     def fatorial(n):
5         if n == 0:
6             return 1
7         else:
8             return n * fatorial(n - 1)
9   \end{lstlisting}
10  \fonteautor
11 \end{codigo}

```

FONTE: O autor

CÓDIGO 17 – Função recursiva para calcular o fatorial de um número.

```

1 def fatorial(n):
2     if n == 0:
3         return 1
4     else:
5         return n * fatorial(n - 1)

```

FONTE: O autor

7.2 INCLUSÃO DE ALGORITMOS

A formatação de algoritmos é realizada de maneira análoga à inclusão de códigos, porém, utiliza o ambiente `algoritmo`. O Algoritmo 1 mostra um exemplo de algoritmo para o cálculo do fatorial de maneira recursiva.

ALGORITMO 1 – Algoritmo para o calcular o fatorial de um número.

```
1  ENTRADA: Número inteiro não negativo  $n$ 
2  SAÍDA Valor de  $n!$ 
3
4  SE  $n = 0$ 
5      RETORNA 1
6  SENÃO
7      RETORNA  $n \times \text{fatorial}(n - 1)$ 
8  FIM-SE
```

FONTE: O autor

7.3 CONSIDERAÇÕES FINAIS

O uso de algoritmos e códigos é um recurso poderoso para a formatação de trabalhos acadêmicos e científicos, especialmente em áreas técnicas. A personalização oferecida pelo LaTeX permite a adaptação dos estilos de exibição conforme as necessidades específicas do autor ou da instituição.

8 EQUAÇÕES E FÓRMULAS

Este capítulo apresenta como criar e formatar equações, usar comandos específicos, a numeração e referência de equações, além de explorar exemplos de equações e sistemas de equações. As equações e fórmulas matemáticas desempenham um papel essencial em diversos campos do conhecimento, especialmente nas áreas de ciências exatas, engenharias e tecnologia. Em trabalhos acadêmicos, é fundamental que a apresentação dessas expressões seja clara e bem estruturada, facilitando a comunicação precisa de conceitos matemáticos.

8.1 EQUAÇÕES SIMPLES

Para a inserção de equações matemáticas, utiliza-se o ambiente `equation`. Por padrão, as equações são centralizadas e numeradas automaticamente, permitindo a referência posterior no corpo do texto. O Código 18 exemplifica a inclusão de uma equação.

CÓDIGO 18 – Código para inclusão de equações.

```
1 \begin{equation}
2   E = mc^2
3   \label{eq:einstein}
4 \end{equation}
```

FONTE: O autor

A Equação (8.1) exibe a equação de Einstein. A referência a essa equação no texto pode ser realizada com o comando `\ref`, como apresentado na frase “conforme mostrado na Equação 8.1”.

$$E = mc^2 \tag{8.1}$$

8.2 SISTEMAS DE EQUAÇÕES

Para formatar sistemas de equações, utiliza-se o ambiente `\cases`, que insere chaves ao lado do sistema, facilitando a organização de condições ou equações inter-relacionadas. O Código 19 exemplifica a inclusão de um equações alinhadas.

A Equação (8.2) mostra um exemplo de sistemas de equações. Neste exemplo, a função $f(x)$ é definida de acordo com duas condições diferentes, dependendo do valor de x . O uso do ambiente “cases” formata o sistema de forma clara e visualmente organizada.

CÓDIGO 19 – Código para inclusão de equações.

```

1 \begin{equation}
2   f(x) =
3   \begin{cases}
4     x^2 & \text{se } x \geq 0 \\
5     -x^2 & \text{se } x < 0
6   \end{cases}
7   \label{eq:sistemas}
8 \end{equation}

```

FONTE: O autor

$$f(x) = \begin{cases} x^2 & \text{se } x \geq 0 \\ -x^2 & \text{se } x < 0 \end{cases} \quad (8.2)$$

8.3 SÍMBOLOS E NOTAÇÕES AVANÇADAS

O $\text{\LaTeX}$ oferece uma vasta gama de símbolos e notações matemáticas, permitindo a criação de expressões complexas de forma elegante. Entre os exemplos mais comuns, incluem-se:

- a) Frações: $\text{\textbackslash frac}\{a\}\{b\}$ para $\frac{a}{b}$
- b) Somatórios: $\text{\textbackslash sum_}\{i=1\}^{\{n\}} i^2$ para $\sum_{i=1}^n i^2$
- c) Integrais: $\text{\textbackslash int_}0^1 x^2 \, dx$ para $\int_0^1 x^2 dx$
- d) Vetores: $\text{\textbackslash vec}\{v\}$ para $\vec{v}$

Através desses comandos, é possível construir fórmulas matemáticas de alta complexidade de maneira eficiente e esteticamente agradável.

8.4 CONSIDERAÇÕES FINAIS

O $\text{\LaTeX}$ é uma ferramenta robusta para a formatação de equações e fórmulas matemáticas, oferecendo recursos avançados que garantem precisão e consistência na apresentação de conceitos matemáticos. Com ambientes específicos para equações, sistemas de equações e expressões *inline*, o autor possui grande flexibilidade para a elaboração de textos acadêmicos de alta qualidade, facilitando a leitura e a compreensão dos leitores.

9 ALÍNEAS

Este capítulo apresenta o modo de uso de alíneas. Em documentos acadêmicos, o uso correto de alíneas é fundamental para garantir a clareza na apresentação de informações que não possuem um título próprio. A norma técnica da Associação Brasileira de Normas Técnicas (ABNT) orienta a estruturação adequada das alíneas de forma a facilitar a compreensão e a organização textual. O uso das alíneas segue diretrizes específicas que devem ser rigorosamente aplicadas, conforme descrito a seguir (ABNT, 2012).

As alíneas são empregadas quando é necessário enumerar vários assuntos em uma seção sem título. Um exemplo de alíneas pode ser observado na classificação dos paradigmas de programação. Os principais paradigmas de programação são:

- a) Programação imperativa;
- b) Programação funcional;
- c) Programação orientada a objetos;
- d) Programação lógica:
 - baseada no uso de lógica formal para expressar programas;
 - foca em resolver problemas declarando relações e permitindo que o computador derive soluções;
 - exemplos comuns incluem linguagens como Prolog.

Neste exemplo, observa-se o uso correto de alíneas para organizar a informação de maneira hierárquica e clara. O uso de subalíneas foi aplicado para detalhar a “Programação lógica”. Este tipo de estruturação facilita a compreensão e o destaque de elementos dentro de uma lista de assuntos.

10 CRONOGRAMA

O cronograma é uma ferramenta essencial no planejamento de um Trabalho de Conclusão de Curso (TCC). Ele representa a programação das atividades necessárias para a conclusão do projeto, facilitando a organização e o gerenciamento do tempo. Um cronograma bem elaborado é fundamental para garantir que todas as etapas do TCC sejam realizadas dentro do prazo, evitando sobrecargas de trabalho.

O cronograma deve incluir as principais etapas do TCC, como a definição do tema, revisão bibliográfica, desenvolvimento da metodologia, coleta e análise de dados, redação do trabalho e entrega final. O Quadro 2 apresenta um exemplo de cronograma.

QUADRO 2 – Cronograma detalhado das atividades do TCC.

Atividade	Ago	Set	Out	Nov	Dez
Definição do Tema					
Revisão Bibliográfica					
Desenvolvimento da Metodologia					
Coleta de Dados					
Análise dos Dados					
Redação do TCC					
Revisão Final e Entrega					

FONTE: O autor

11 CONCLUSÃO

A conclusão é uma das partes mais relevantes de um Trabalho de Conclusão de Curso (TCC), pois é nela que o autor sintetiza os principais achados da pesquisa e apresenta suas reflexões finais. O objetivo principal da conclusão é proporcionar uma visão clara e objetiva sobre os resultados obtidos, além de contextualizá-los dentro da problemática abordada no trabalho. Para isso, uma conclusão eficaz deve seguir algumas diretrizes, garantindo que todos os pontos cruciais sejam abordados.

Primeiramente, a conclusão deve retomar os objetivos do trabalho. Ao revisar as perguntas de pesquisa e os objetivos estabelecidos na introdução, o autor consegue avaliar se foram alcançados ou não. Este processo de revisão não apenas reforça a relevância do tema, mas também permite que o leitor entenda como as informações apresentadas ao longo do texto se conectam com o que foi inicialmente proposto. Segundo Gil (2008), a conclusão deve “revisitar os objetivos traçados, avaliando o quanto se conseguiu avançar na pesquisa” (GIL, 2008).

Em segundo lugar, é fundamental que a conclusão contenha uma síntese dos principais resultados e achados da pesquisa. Essa síntese deve ser objetiva e direta, evitando a inclusão de novos dados ou informações não discutidas previamente no corpo do texto. A análise crítica dos resultados obtidos pode ser feita de maneira a apontar as implicações e contribuições que o trabalho traz para o campo de estudo em questão. Como afirma Lakatos e Marconi, “a conclusão é o momento de apresentar as implicações do estudo realizado, bem como suas contribuições para a área de conhecimento” (LAKATOS; MARCONI, 2003).

Por fim, a conclusão pode incluir sugestões para futuras pesquisas. Este aspecto é importante porque pode abrir novas possibilidades de investigação, além de indicar áreas que precisam de mais atenção ou aprofundamento. A inclusão de sugestões é uma forma de reconhecer que o conhecimento é um processo contínuo e que existem lacunas a serem preenchidas. Como destaca Lakatos e Marconi (2003), “sugerir novos caminhos de pesquisa é uma maneira de contribuir para o desenvolvimento da área e para a construção do conhecimento” (LAKATOS; MARCONI, 2003).

Em suma, a conclusão deve retomar os objetivos, sintetizar os resultados e sugerir novas pesquisas. Essa estrutura não apenas ajuda o leitor a entender o trabalho de forma mais clara, mas também enfatiza a contribuição do autor para a área estudada.

REFERÊNCIAS

- ABNT. **Norma Brasileira NBR 6024: Informação e Documentação - Numeração Progressiva das Seções de um Documento Escrito**. Rio de Janeiro: Associação Brasileira de Normas Técnicas, 2012.
- AI Online Course. **Kernel SVM for Dummies (with Python Code) | Machine Learning**. 2023. Disponível em: <https://www.aionlinecourse.com/tutorial/machine-learning/kernel-svm>. Acesso em: 21 abr. 2026.
- Associação Brasileira de Normas Técnicas. **NBR 14724: Informação e Documentação: Trabalhos Acadêmicos: Apresentação**. Rio de Janeiro: ABNT, 2018.
- BISHOP, C. M. **Pattern Recognition and Machine Learning**. [S.l.]: Springer, 2006.
- CHAGAS, C. A.; OLIVEIRA, F. M.; ALMEIDA, J. R. A. **Manual de Redação Científica: Normas e Orientações**. Recife: Editora Universitária, 2016.
- CRESWELL, J. W. **Research design: qualitative, quantitative, and mixed methods approaches**. Thousand Oaks, CA: SAGE Publications, 2014.
- FACELI, K. *et al.* **Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina**. 2nd. ed. [S.l.]: LTC, 2011.
- GIL, A. C. **Como elaborar projetos de pesquisa**. São Paulo: Atlas, 2008.
- GOOSSENS, M.; MITTELBAACH, F.; SAMARIN, A. **The LaTeX Companion**. [S.l.]: Addison-Wesley, 1997.
- INCA. **Bioinformática e biologia computacional**. Instituto Nacional de Câncer, 2022. Disponível em: <https://www.gov.br/inca/pt-br/assuntos/pesquisa/pesquisa-basica-e-experimental/bioinformatica-e-biologia-computacional/bioinformatica-e-biologia-computacional-1>. Acesso em: 19 mar. 2026.
- INCA. **Como surge o câncer?** Instituto Nacional de Câncer, 2022. Disponível em: <https://www.gov.br/inca/pt-br/assuntos/cancer/como-surge-o-cancer>. Acesso em: 07 abr. 2026.
- INCA. **O que é câncer?** Instituto Nacional de Câncer, 2022. Disponível em: <https://www.gov.br/inca/pt-br/assuntos/cancer/o-que-e-cancer>. Acesso em: 07 abr. 2026.
- INCA. **Câncer de Mama**. Instituto Nacional de Câncer, 2026. Disponível em: <https://www.gov.br/inca/pt-br/assuntos/noticias/2026/inca-estima-781-mil-novos-casos-de-cancer-por-ano-no-brasil-entre-2026-e-2028>. Acesso em: 19 mar. 2026.
- KNUTH, D. E. **The TeXbook**. [S.l.]: Addison-Wesley, 1984. A.
- LAKATOS, E. M.; MARCONI, M. A. **Fundamentos de metodologia científica**. São Paulo: Editora Atlas, 2003.

LEITE, J. **Normas Técnicas: Elaboração e Apresentação de Trabalhos Acadêmico-Científico**. 1. ed. São Paulo: Editora Acadêmica, 2003. 332 p.

MACHINE Learning. In: WIKIPÉDIA: a enciclopédia livre. Wikimedia, 2024. Disponível em: https://en.wikipedia.org/wiki/Machine_learning. Acesso em: 05 out. 2024.

MITCHELL, T. M. **Machine Learning**. [S.l.]: McGraw-Hill, 1997.

MITTELBAACH, F.; GOOSSENS, M.; BRAAMS, J. **The LaTeX Companion**. [S.l.]: Addison-Wesley Professional, 2004.

NCI. **What is Cancer?** NATIONAL CANCER INSTITUTE, 2021. Disponível em: <https://www.cancer.gov/about-cancer/understanding/what-is-cancer>. Acesso em: 08 abr. 2026.

NINTENDO. **Personagens**. 2024. Disponível em: <https://www.nintendo.com/pt-pt/Jogos/Portal-Nintendo/Portal-Super-Mario/Personagens-2493286.html>. Acesso em: 05 out. 2024.

PAHO. **Câncer**. Organização Pan-Americana da Saúde, 2026. Disponível em: <https://www.paho.org/pt/topicos/cancer>. Acesso em: 18 mar. 2026.

RICHARDSON, D. **O que é IA/ML e por que é importante para seus negócios?** Red Hat, 2022. Disponível em: <https://www.redhat.com/pt-br/blog/what-aiml-and-why-does-it-matter-your-business>. Acesso em: 11 abr. 2026.

RUSSELL, S.; NORVIG, P. **Artificial Intelligence: A Modern Approach**. 3rd. ed. [S.l.]: Prentice Hall, 2010.

SEVERINO, A. J. **Metodologia da pesquisa: projeto e execução**. São Paulo: Editora Cortez, 2007.

STREET, W. N.; WOLBERG, W. H.; MANGASARIAN, O. L. Nuclear feature extraction for breast tumor diagnosis. SPIE, p. 861–870, 1993.

TUFTE, E. R. **Envisioning Information**. [S.l.]: Graphics Press, 1990.

UNIVERSIDADE TUIUTI DO PARANÁ. **Normas para Apresentação de Trabalhos Acadêmicos**. 3. ed. Curitiba: Editora da Universidade Tuiuti do Paraná, 2024.

XKCD. **Scientific Paper Graph Quality**. 2024. Disponível em: <https://xkcd.com/1945/>. Acesso em: 05 out. 2024.

XKCD. **Thesis Defense**. 2024. Disponível em: <https://xkcd.com/605/>. Acesso em: 05 out. 2024.

APÊNDICE A – EXEMPLO DE APÊNDICE

Os apêndices e anexos são elementos complementares em um Trabalho de Conclusão de Curso (TCC) que têm como objetivo fornecer informações adicionais relevantes ao entendimento da pesquisa. Embora sejam frequentemente utilizados de forma intercambiável, eles possuem finalidades distintas e devem ser utilizados em contextos específicos. A correta utilização de apêndices e anexos contribui para a clareza e a organização do trabalho acadêmico.

Os apêndices são utilizados para incluir informações que são de autoria do próprio autor do TCC. Isso pode incluir questionários, roteiros de entrevistas, tabelas com dados adicionais e qualquer outro material que seja essencial para a compreensão do trabalho, mas que não é possível inserir diretamente no corpo do texto. Segundo Severino (2007), “os apêndices servem para apresentar materiais elaborados pelo autor que complementam a sua pesquisa” (SEVERINO, 2007). Dessa forma, o uso de apêndices é fundamental quando se deseja apresentar materiais que, embora relevantes, não se encaixam na narrativa principal do trabalho.

ANEXO A – EXEMPLO DE ANEXO

Os anexos são documentos que não são de autoria do autor do TCC, mas que são pertinentes à pesquisa. Eles podem incluir gráficos, documentos oficiais, normativas e textos que foram utilizados como referência ou que fornecem suporte à pesquisa. Segundo a Associação Brasileira de Normas Técnicas (ABNT), “os anexos são documentos que, embora não sejam parte integrante do texto, são relevantes para a compreensão do tema tratado” (ABNT, 2012). O uso de anexos é indicado quando se deseja fornecer ao leitor informações complementares que não foram geradas pelo autor, mas que ajudam a esclarecer ou contextualizar a pesquisa.

Ambos, apêndices e anexos, devem ser listados em uma página específica após a conclusão do trabalho, de forma a facilitar a consulta por parte do leitor. A correta distinção entre apêndices e anexos, bem como o seu uso apropriado, é essencial para a organização e a credibilidade do TCC. Ao fornecer informações adicionais de maneira clara e sistemática, o autor contribui para uma melhor compreensão do seu trabalho, enriquecendo a experiência do leitor.